



报告日期 2026 年 07 月 09 日

分析师：郑兆磊

S0190520080006

zhengzhaolei@xyzq.com.cn

分析师：罗婧

S0190525070003

luojing1@xyzq.com.cn

相关研究

【兴证金工】转债强赎：事件分析与因子构建-2026.07.01

【兴证金工】ESG 观察——月度聚焦：基金名称监管框架落地，可持续投资迈向实质应用阶段-2026.07.01

【兴证金工】博道基金刘玮明：“稳健派”与“弹性派”的量化固收+产品矩阵-2026.06.29

风险平价的演进与应用扩展：风险刻画、结构重构与动态决策

投资要点：

- 西学东渐，是指从明朝末年到近代，西方学术思想向中国传播的历史过程。在今天，西学东渐仍有其重要意义。由于 AI 的发展，单篇文献翻译的价值和难度已经大幅降低。为此，我们转化呈现形式，通过文献综述的方式为大家呈现海外资产定价与量化投资领域的最新研究成果，进而最大化地提供研究增量。本篇聚焦的主题是风险平价。
- 风险平价作为一种经典的资产配置方法，旨在通过均衡组合中各资产的风险贡献来实现真正的风险分散。风险平价以均衡不同资产或风险来源对组合总风险的贡献为基本原则。相较依赖预期收益估计的均值-方差模型，它通过弱化收益预测、强调风险分散，成为全球资产配置和机构风险预算的重要方法。不过，传统风险平价通常建立在静态波动率、样本协方差、完整资产池和单期配置之上，难以充分处理尾部损失、参数误差、高维相关结构、交易约束以及市场状态变化。面对日益复杂的金融市场，传统的风险平价理论框架及其应用实践正面临多维度的挑战。
- 风险平价正在由单一资产配置规则演变为包含风险识别、参数预测、结构筛选、组合优化和交易执行的综合决策体系。海外最新研究可以归纳为不同的脉络：
 - 第一，从波动率平价走向尾部风险、前瞻预测和鲁棒参数估计，解决“均衡什么风险、如何可靠度量风险”的问题；
 - 第二，从全资产等风险走向稀疏组合、层次结构和因子风险源配置，解决“风险预算应分配给哪些对象、如何落地实施”的问题；
 - 第三，从静态单期配置走向多期控制、端到端学习和收益信号融合，解决“风险预算如何随市场变化并转化为最终投资决策”的问题。
- 总体来看，风险平价研究呈现以下特征：研究目标从追求形式上的风险贡献相等，转向追求样本外有效的风险分散；风险预算对象从资产向风险来源迁移，行业风险、相关网络、风格因子和管理人 α 比单只资产更能解释组合为何承受风险；风险平价由静态配置规则演变为动态决策过程，前瞻波动率、多期 MPC、机器学习方向信号和端到端训练使参数估计、权重形成和交易执行逐渐一体化，评价重点也从样本内风险贡献误差转向样本外收益、回撤、换手和成本后绩效；风险平价越来越多地与其他策略结合，趋势、动量、机器学习择时和指数跟踪并不属于传统风险平价本身，却能够围绕风险预算骨架提供收益来源、状态控制和产品化应用。

风险提示：文献结论外推至 A 股存在市场制度与数据口径差异；报告结论基于历史数据，在市场环境转变时存在失效风险。

目录

一、 引言	4
二、 风险度量、风险预测与参数稳健化.....	4
(一) 条件期望分位数下的风险平价	5
(二) 基于机器学习的 CVaR 风险平价模型	7
(三) 基于混合神经网络方法的波动率预测，用于风险平价投资策略	11
(四) 基于因子协方差矩阵的资产配置.....	13
(五) 基于稳健风险平价模型的资产配置策略研究.....	15
三、 组合结构优化与现实可实施性	17
(一) 基数约束下的风险平价投资组合	18
(二) 外围资产筛选与层次风险平价	21
(三) 行业风险贡献驱动指数跟踪	24
(四) 风格因子与管理人 α 一体化风险平价	25
四、 动态配置、决策学习与收益信号融合	28
(一) 全球资产配置中的风险平价、动量和趋势跟踪	29
(二) 模型预测控制下的多期风险平价	31
(三) 动态风险偏好、最小交易手数和交易成本	34
(四) 按最终组合质量训练风险模型的端到端学习.....	37
五、 总结	40
参考文献.....	40

图目录

图 1、 各个投资组合的权重（左）与相对风险贡献（右）的对比	6
图 2、 总体设计框架图	9
图 3、 各种机器学习算法的 ROC 曲线	10
图 4、 实现波动率与 GRU-GARCH 预测波动率对比	12
图 5、 周度再平衡组合	13
图 6、 不同估计方法下协方差预测准确度对比.....	15
图 7、 回测期内六种投资组合策略的累计净值表现	17
图 8、 各项 HRP 与基准的净值对比.....	23
图 9、 2021 年 8 月网络拓扑快照	24
图 10、 风险平价组合超参数调优结果	33
图 11、 MPO 与 MPO_RP 在疫情期间的资产表现与仓位变化	34
图 12、 运行回测流程图	36
图 13、 无最低交易费用的多期交易	36
图 14、 E2E 框架	39

表目录

表 1、 ExpRP 模型的实证结果——以 $\alpha=0.7/0.9, n=5/10, T=100$ 为例	7
表 2、 在有无机器学习的情况下的各类策略表现	10
表 3、 不同训练方法下的各类策略表现	10
表 4、 各策略训练与预测集上的表现	13
表 5、 无交易成本下基准与策略表现对比	15

表 6、	六种模型表现对比	17
表 7、	模型在不同约束参数下求解的平均表现.....	20
表 8、	策略回测表现.....	21
表 9、	不同 k 值下策略表现对比	23
表 10、	策略表现.....	25
表 11、	集成风险平价策略表现对比.....	28
表 12、	基础资产、趋势组合和风险平价策略表现.....	30
表 13、	大类资产内的波动率调整动量与趋势跟踪策略表现	31
表 14、	跨资产类别的波动率调整动量与趋势跟踪复合策略的表现	31
表 15、	两种算法平均单次迭代表现.....	33
表 16、	E2E 策略回测表现.....	39
表 17、	不同基数约束下 E2E 模型回测表现	39

一、引言

风险平价的基本思想不是平均分配资本，而是平均分配风险。对于风险度量 $\rho(w)$ ，资产 i 的风险贡献通常可写为 $RC_i = w_i \cdot \frac{\partial \rho(w)}{\partial w_i}$ ；等风险贡献组合要求各资产的 RC_i 相等。传统模型最常使用组合波动率或方差，因为它们易于通过 Euler 定理分解，也不需要直接估计预期收益。与均值—方差模型相比，这种方法减少了收益均值误差对权重的放大，并能够避免高波动资产在资本等权组合中支配整体风险。

但风险平价的简洁性也来自一组较强假设。首先，标准差同时惩罚上行和下行波动，无法充分表达极端损失；其次，样本协方差在高维环境中容易失真，风险贡献的“精确均衡”可能只是对估计误差的精确拟合；再次，传统模型默认持有全部资产，容易产生大量小仓位和较高管理成本；最后，单期静态配置不能充分考虑交易成本、未来权重路径和市场状态变化。基于此，海外研究逐步向风险度量、组合结构和动态决策三个层面延伸。

从研究演进看，早期文献更多把风险平价作为跨资产风险标准化工具，并考察其与趋势、动量等策略结合后的表现；随后，研究开始修改风险度量和求解结构，将 expectile、CVaR、基数约束和多期控制纳入模型；近期文献则进一步吸收机器学习、因子降维、网络分析和鲁棒优化。由此，风险平价的研究重点已从“如何求一组等风险权重”转向“如何在风险不可准确观测、资产数量庞大且市场持续变化的条件下维持有效的风险分散”。

二、风险度量、风险预测与参数稳健化

传统波动率风险平价的首要问题是无法区分有利波动和不利波动。Bellini 等（2021）从这一缺口出发，将 expectile 引入风险平价。Expectile 通过非对称平方损失提高对不利尾部的权重，同时具有一致性和可诱导性，可以进行风险贡献分解。Sheng 等（2025）进一步以 CVaR 作为风险预算对象，CVaR 衡量损失超过 VaR 阈值后的平均损失，能够反映极端损失的严重程度。

Di Persio 等（2023）把研究焦点从风险度量本身转向波动率预测，用 GARCH 捕捉波动聚集，再用 GRU、LSTM 和混合循环神经网络提取非线性时间依赖，并将预测波动率用于前瞻逆波动率配置。Conlon、Cotter 和 Kynigakis（2025）使用 PCA、PLS、稀疏降维、自编码器和去噪自编码器提取潜在风险因子，再构造静态或动态因子协方差矩阵，长期美国股票样本显示，多数因子模型能够改善协方差预测，并形成波动更低、Sharpe 更高、权重更平滑和换手更低的组合。

风险预测和因子降维仍然产生一个协方差点估计，而真实参数可能偏离该估计。Li 和 Ye（2026）因此提出自适应鲁棒风险平价：假设真实协方差位于估计协

方差附近的 **Frobenius** 范数不确定集合内，组合不再只对一个估计矩阵实现等风险，而是最小化最坏协方差情形下的风险贡献差异。模型同时使用 **Ledoit-Wolf** 收缩、主成分因子结构、**GARCH** 波动率预测和 **K-means** 市场状态识别，并根据高低波动状态动态调整不确定集合半径。

（一）条件期望分位数下的风险平价

Bellini 等(2021)将平价模型中的风险度量拓展至期望分位数(**Expectiles**)。 **Expectiles** 是方差在非对称权重下的广义形式，具有 **Euler** 齐次性满足可加性条件，且通过参数 τ 可灵活调节对下行风险的敏感度。本文的创新点在于：第一，在理论层面严格刻画了 **Expectile** 的可微性与可加性条件，并提出针对不可微情形的“广义欧拉分配”机制以实现风险的精确拆解；第二，针对期望分位数风险平价组合，创新性地提出了三大类、共六种不同的计算求解框架，并给出了传统均值-**Expectile** 优化问题的高效线性规划形式

核心模型框架

在模型构建部分，作者首先基于非对称分段二次损失函数的最小化来严格定义期望分位数。对于给定的随机损失变量 X 以及非对称参数 $\alpha \in (1/2, 1)$ ，其期望分位数 $e_\alpha(X)$ 被定义为以下优化问题的解：

$$e_\alpha(X) = \arg \min_{\eta \in \mathbb{R}} \mathbb{E}[\alpha(X - \eta)_+^2 + (1 - \alpha)(X - \eta)_-^2]$$

其中 $(b)_+ = \max(b, 0)$ 且 $(b)_- = -\min(b, 0)$ 。由该最小化问题的一阶条件，可以推导出刻画 $e_\alpha(X)$ 的核心等式：

$$\alpha \mathbb{E}[(X - e_\alpha(X))_+] = (1 - \alpha) \mathbb{E}[(X - e_\alpha(X))_-]$$

定义投资组合的权重向量为 $\mathbf{x} = (x_1, \dots, x_n)$ ，各资产的随机损失向量为 $\mathbf{L}_k$ ，则投资组合的总损失为 $L(\mathbf{x}) = \sum_{k=1}^n x_k L_k$ ，组合的总体风险即为 $\zeta_\alpha(\mathbf{x}) = e_\alpha(L(\mathbf{x}))$ 。由于 $\zeta_\alpha(\mathbf{x})$ 满足一次齐次性，基于欧拉齐次函数定理，组合总风险可被完全分解为各资产的边际风险之和。在满足 Gateaux 可微性的前提下，资产 k 的边际风险贡献度 (**Marginal Risk Contribution**) 在文中被解析推导为：

$$\frac{\partial \zeta_\alpha(\mathbf{x})}{\partial x_k} = \frac{\alpha \mathbb{E}[L_k \mathbb{I}_{\{L(\mathbf{x}) > \zeta_\alpha(\mathbf{x})\}}] + (1 - \alpha) \mathbb{E}[L_k \mathbb{I}_{\{L(\mathbf{x}) \leq \zeta_\alpha(\mathbf{x})\}}]}{\alpha \mathbb{P}(L(\mathbf{x}) > \zeta_\alpha(\mathbf{x})) + (1 - \alpha) \mathbb{P}(L(\mathbf{x}) \leq \zeta_\alpha(\mathbf{x}))}$$

因此，资产 k 的绝对总风险贡献度定义为 $\text{TRC}_k^{\text{Exp}}(\mathbf{x}) = x_k \frac{\partial \zeta_\alpha(\mathbf{x})}{\partial x_k}$ 。针对真实历史回测中离散样本容易导致不可微的数学挑战，作者引入了基于次微分集 $Q(L(\mathbf{x}))$ 的广义欧拉分配，证明了对于任意次梯度 $\varphi \in Q(L(\mathbf{x}))$ ，广义风险贡献度 $x_k \mathbb{E}[\varphi L_k]$ 同样能实现风险的加和分解。在此基础上，期望分位数风险平价 (**ExpRP**) 组合被严格定义为满足各资产风险贡献绝对相等的权重向量，即对于任意 i ，均满足 $\text{TRC}_i^{\text{Exp}}(\mathbf{x}) = \lambda$ ，其中 $\lambda \in \mathbb{R}$ 为常数。


为了有效求解，作者提出了不同求解模型：第一类是方程组求解法，即直接联立求解TRC相等的非线性方程组，为了应对权重非负约束，作者通过引入辅助变量 $q_i^2 = x_i$ 将问题转化为无约束方程组；第二类是Log对数惩罚法，作者证明了ExpRP等价于在约束资产多元化的前提下最小化组合风险；第三类是最小二乘法，通过直接最小化各资产风险贡献占比相对 $1/n$ 偏离程度的平方和来逼近风险平价，这一相对偏差最小化模型虽然是非凸的，但在实践中只要目标函数收敛至零即证明找到了全局最优的ExpRP解。

实验设计、数据与实证结果

数据集涵盖5只道琼斯工业平均指数成分股，时间跨度从1990年2月至2016年4月的周度除权收益率数据。作者在该数据集上对比了等权组合（EW）、全局最小期望分位数组合（GME）、天真期望分位数平价组合（NExpRP，权重与单资产Expectile成反比）以及本文提出的严格ExpRP组合。

回测结果表明，尽管等权组合在资金上实现了绝对均分，但其风险分布呈现高度极化；而GME组合同样被极个别低波动资产主导了风险。相较之下，ExpRP精确地实现了各资产风险贡献的绝对平价，展现了真正意义上的风险分散能力。

图1、各个投资组合的权重（左）与相对风险贡献（右）的对比



数据来源：Risk parity with expectiles，兴业证券经济与金融研究院整理

在鲁棒性测试中，作者设定了一个包含3个具有特定预期收益和波动率的多元正态分布仿真市场，并动态调整资产间的相关系数。结果显示，当市场相关性结构发生剧烈变化时，ExpRP组合的权重依然维持高度稳定。

进一步，作者使用 NASDAQ100 中 82 只股票、2004 年 11 月至 2016 年 4 月的 596 个周度观测，在不同资产数 N 、情景数 T 和 α 下比较六种算法的目标误差、平均/最大风险贡献偏差和运行时间，从结果来看，方程组方法通常快，但部分极端 α 和问题规模下风险贡献误差较大；对数和最小二乘优化在某些设置下更准确，但大规模计算时间显著上升。

表1、ExpRP 模型的实证结果——以 $\alpha=0.7/0.9, n=5/10, T=100$ 为例

$\alpha = 0.7; n = 5; T = 100; \text{MinExp} = 0.45 \cdot 10^{-2}$					$\alpha = 0.9; n = 5; T = 100; \text{MinExp} = 2.00 \cdot 10^{-2}$			
	F(x)	MeanAbsDev	MaxAbsDev	time (secs.)	F(x)	MeanAbsDev	MaxAbsDev	time (secs.)
fsolve_few	$3.06 \cdot 10^{-37}$	$2.22 \cdot 10^{-17}$	$2.78 \cdot 10^{-17}$	0.0	$1.90 \cdot 10^{-6}$	$1.00 \cdot 10^{-2}$	$2.50 \cdot 10^{-2}$	0.0
fsolve_many	$3.06 \cdot 10^{-37}$	$2.22 \cdot 10^{-17}$	$2.78 \cdot 10^{-17}$	0.0	$1.90 \cdot 10^{-6}$	$1.00 \cdot 10^{-2}$	$2.50 \cdot 10^{-2}$	0.0
log_constr	$4.32 \cdot 10^{-14}$	$6.23 \cdot 10^{-6}$	$1.46 \cdot 10^{-5}$	64.6	$3.42 \cdot 10^{-7}$	$4.66 \cdot 10^{-3}$	$8.93 \cdot 10^{-3}$	1.9
log_obj	$2.57 \cdot 10^{-20}$	$5.34 \cdot 10^{-9}$	$1.29 \cdot 10^{-8}$	2.3	$1.90 \cdot 10^{-6}$	$1.00 \cdot 10^{-2}$	$2.50 \cdot 10^{-2}$	1.4
ls_abs	$1.11 \cdot 10^{-19}$	$1.14 \cdot 10^{-8}$	$2.45 \cdot 10^{-8}$	1.6	$1.90 \cdot 10^{-6}$	$1.00 \cdot 10^{-2}$	$2.50 \cdot 10^{-2}$	1.3
ls_rel	$5.82 \cdot 10^{-18}$	$8.48 \cdot 10^{-8}$	$1.56 \cdot 10^{-7}$	2.0	$3.34 \cdot 10^{-7}$	$4.73 \cdot 10^{-3}$	$8.38 \cdot 10^{-3}$	1.8
$\alpha = 0.7; n = 10; T = 100; \text{MinExp} = 0.26 \cdot 10^{-2}$					$\alpha = 0.9; n = 10; T = 100; \text{MinExp} = 1.67 \cdot 10^{-2}$			
fsolve_few	$2.19 \cdot 10^{-7}$	$7.23 \cdot 10^{-3}$	$3.61 \cdot 10^{-2}$	6.2	$1.20 \cdot 10^{-5}$	$1.41 \cdot 10^{-2}$	$3.96 \cdot 10^{-2}$	0.0
fsolve_many	$2.72 \cdot 10^{-8}$	$3.56 \cdot 10^{-3}$	$9.17 \cdot 10^{-3}$	0.1	$1.16 \cdot 10^{-5}$	$1.39 \cdot 10^{-2}$	$3.87 \cdot 10^{-2}$	0.1
log_constr	$9.51 \cdot 10^{-8}$	$5.96 \cdot 10^{-3}$	$1.62 \cdot 10^{-2}$	6.1	$7.48 \cdot 10^{-7}$	$4.02 \cdot 10^{-3}$	$8.33 \cdot 10^{-3}$	3.6
log_obj	$2.08 \cdot 10^{-8}$	$2.40 \cdot 10^{-3}$	$1.09 \cdot 10^{-2}$	3.8	$3.79 \cdot 10^{-7}$	$2.69 \cdot 10^{-3}$	$7.30 \cdot 10^{-3}$	2.1
ls_abs	$2.08 \cdot 10^{-8}$	$2.40 \cdot 10^{-3}$	$1.09 \cdot 10^{-2}$	2.4	$3.79 \cdot 10^{-7}$	$2.69 \cdot 10^{-3}$	$7.30 \cdot 10^{-3}$	1.7
ls_rel	$2.13 \cdot 10^{-6}$	$2.02 \cdot 10^{-2}$	$1.01 \cdot 10^{-1}$	15.0	$4.57 \cdot 10^{-7}$	$2.82 \cdot 10^{-3}$	$7.31 \cdot 10^{-3}$	2.3

数据来源：Risk parity with expectiles，兴业证券经济与金融研究院整理

综合来看，论文完成了 expectile 风险度量、风险贡献定义和算法的理论闭环，证明 ExpRP 在数学上成立且可计算，且对相关性扰动鲁棒。但于此同时，论文没有进行系统滚动样本外收益检验，因此结论限于理论性质、稳定性示例和计算效率，未来需在真实回测中验证其经济价值。

（二）基于机器学习的 CVaR 风险平价模型

Sheng 等 (2025) 将条件在险价值 (CVaR) 引入风险平价。CVaR 衡量的是超过 VaR 阈值的尾部平均损失，相比 VaR 满足子可加性，能更准确地捕捉极端下行风险。

核心模型框架

在模型构建部分，首先假设金融市场中 n 个资产的收益率序列服从多元正态分布。设定 μ 为资产预期收益率向量， Ω 为资产收益率的协方差矩阵， $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 为投资组合的资金权重向量，其中 x_i 代表分配给第 i 个资产的资金比例。根据多元正态分布的可加性，投资组合的总收益 r_p 同样服从正态分布，即 $r_p \sim N(\mathbf{x}^T \mu, \mathbf{x}^T \Omega \mathbf{x})$ 。基于此，在给定的置信水平 α 下，投资组合的在险价值 (Value-at-Risk, VaR) 可以表示为：

$$\text{VaR}_\alpha = \mathbf{x}^T \mu + \sqrt{\mathbf{x}^T \Omega \mathbf{x}} \phi^{-1}(\alpha)$$

其中， $\phi^{-1}(\alpha)$ 代表标准正态分布的累计概率密度函数的逆函数 (分位数)。然而，VaR 只能测量特定置信度下的最小损失边界，无法衡量超过该边界后的平均损失。因此，作者引入了条件风险价值 CVaR。在正态分布假设下，其矩阵解析形式推导为：

$$CVaR_{\alpha} = \mathbf{x}^T \boldsymbol{\mu} + \sqrt{\mathbf{x}^T \boldsymbol{\Omega} \mathbf{x}} \frac{\phi(\phi^{-1}(\alpha))}{1 - \alpha}$$

其中， $\phi(\cdot)$ 是标准正态分布的概率密度函数。通过将 CVaR 确立为总风险指标，作者进一步对其针对单个资产权重 x_i 求偏导，得到了第 i 个资产的边际风险贡献度：

$$MRC_i(\mathbf{x}) = \frac{\partial(CVaR)}{\partial x_i} = r_i + \frac{(\boldsymbol{\Omega} \mathbf{x})_i}{\sqrt{\mathbf{x}^T \boldsymbol{\Omega} \mathbf{x}}} \frac{\phi(\phi^{-1}(\alpha))}{1 - \alpha}$$

在此公式中， $(\boldsymbol{\Omega} \mathbf{x})_i$ 代表协方差矩阵与权重向量乘积的第 i 个元素。由此，第 i 个资产对组合的总风险贡献等于其资金权重乘以边际风险贡献，即：

$$TRC_i(\mathbf{x}) = x_i \frac{\partial(CVaR)}{\partial x_i} = x_i r_i + x_i \frac{(\boldsymbol{\Omega} \mathbf{x})_i}{\sqrt{\mathbf{x}^T \boldsymbol{\Omega} \mathbf{x}}} \frac{\phi(\phi^{-1}(\alpha))}{1 - \alpha}$$

并且所有资产的总风险贡献之和恰好等于投资组合的总 CVaR 值。为了实现尾部风险平价，模型要求所有资产的 TRC 必须彼此绝对相等，即对于任意的 i 和 j ，均满足 $TRC_i(\mathbf{x}) = TRC_j(\mathbf{x}) = \lambda$ ，其中 $\lambda = CVaR/n$ 为常数目标风险预算。由于这一风险平价方程组属于高度非凸的复杂系统，不存在显式解析解，作者构建了如下的最小二乘优化目标函数进行数值逼近求解：

$$\text{Minimize } \sum_{i=1}^n (x_i r_i + x_i \frac{(\boldsymbol{\Omega} \mathbf{x})_i}{\sqrt{\mathbf{x}^T \boldsymbol{\Omega} \mathbf{x}}} \frac{\phi(\phi^{-1}(\alpha))}{1 - \alpha} - \lambda)^2$$

约束条件为全额投资限制 $\sum_{i=1}^n x_i = 1$ 以及做多约束 $0 \leq x_i \leq 1$ 。算法通过不断迭代（设定收敛阈值及最大迭代次数），直至各资产的风险贡献平方差无限逼近于零，从而解出初始的 CVaR-RP 静态权重。

为了克服参数估计的滞后性，作者紧接着引入了基于机器学习的价格趋势预测机制对上述初始权重进行二次修正。为了防止模型陷入局部最优或发生过拟合，采用两阶段训练算法：

- 1) 第一阶段，算法在验证集上并行训练并比对了四大传统机器学习算法（逻辑回归 LR、支持向量机 SVM、随机森林 RF、梯度提升树 GBDT）以及四大深度学习算法（卷积神经网络 CNN、循环神经网络 RNN、长短期记忆网络 LSTM、Transformer）。系统通过 ROC 曲线和准确率等核心指标，为投资组合中的每一个特定资产分别选拔出预测胜率最高的专属最优算法。
- 2) 第二阶段，这些被选拔出的最优模型将在完整的样本内数据上重新进行微调与全量训练，随后用于预测样本外每月的资产涨跌趋势。预测为下跌的资产的权重将在当期被直接强制置为 0，而被置为 0 的这部分多余资金，

将按照剩余看涨资产的原定风险平价权重的比例进行同比例缩放和重新分配。


通过这种基于机器学习预测的权重修剪与重分配逻辑，模型实现了对尾部风险防范与上行趋势捕获的动态平衡。

实验设计、数据与实证结果

实验标的涵盖了核心股票指数（沪深 300 指数、恒生指数、纳斯达克指数）、债券指数（中证金融债指数）、大宗商品指数（化工和农产品），时间跨度从 2005 年 1 月至 2023 年 1 月，采用月度重新平衡频率。

在样本切分上，2005 年 1 月至 2019 年 12 月作为样本内数据集（进一步切分为训练集与验证集），2020 年 1 月至 2023 年 1 月作为样本外测试集。在预处理阶段，作者运用 GARCH(1,1)模型去捕捉资产序列的异方差性与波动率聚集特征，并推算未来的协方差矩阵，且设定 CVaR 的置信度水平 α 为 95%。


图2、总体设计框架图



数据来源：CVaR-based risk parity model with machine learning，兴业证券经济与金融研究院整理

下图展示了各类机器学习算法在各资产上的 ROC 曲线及 AUC 值对比图。从预测模型的结果来看，不存在一种能够通吃所有资产的单一算法。例如，LSTM 由于具有卓越的时序记忆能力，在预测沪深 300 和金融债上表现最优；而在捕捉恒生指数的局部非线性特征时，CNN 的准确率最高；Transformer 则在农产品指数的预测上拔得头筹。

图3、各种机器学习算法的 ROC 曲线



数据来源：CVaR-based risk parity model with machine learning，兴业证券经济与金融研究院整理

在核心的样本外实证回测环节，作者对比了六大策略矩阵：基础等权策略（EW）、传统波动率风险平价策略（RP）、基础条件风险价值平价策略（CVaR-RP），以及这三者结合机器学习择时优化后的升级版（Re_EW、Re_RP、Re_CVaR-RP）。

实证结果方面，机器学习调整显著提高了三类策略的收益。Re_EW 的收益和 Sharpe 最高，Re_CVaR-RP 则在机器学习增强策略中取得最低最大回撤和最高 Calmar，体现出更好的收益—尾部风险平衡。

表2、在有无机器学习的情况下的各类策略表现

	Re_EW	Re_RP	Re_CVaR-RP	EW	RP	CVaR-RP
Annualized return	23.59 %	14.44 %	17.43 %	4.29 %	4.34 %	6.30 %
Annualized volatility	34.41 %	27.71 %	29.49 %	40.95 %	9.04 %	11.23 %
Sharpe ratio	68.57 %	52.12 %	59.10 %	10.48 %	48.02 %	56.07 %
Maximum drawdown	5.63 %	4.75 %	3.77 %	18.67 %	1.77 %	1.92 %
Calmar ratio	4.19	3.04	4.63	0.23	2.46	3.27

数据来源：CVaR-based risk parity model with machine learning，兴业证券经济与金融研究院整理

表3、不同训练方法下的各类策略表现

	Two-stage training approach			Traditional training approach		
	Re_EW	Re_RP	Re_CVaR-RP	Re_EW	Re_RP	Re_CVaR-RP
Annualized return	23.59 %	14.44 %	17.43 %	17.16 %	13.64 %	16.95 %
Annualized volatility	34.41 %	27.71 %	29.49 %	37.20 %	28.41 %	30.76 %
Sharpe ratio	68.57 %	52.12 %	59.10 %	46.12 %	47.99 %	55.09 %
Maximum drawdown	5.63 %	4.75 %	3.77 %	8.43 %	7.00 %	5.71 %
Calmar ratio	4.19	3.04	4.63	2.04	1.95	2.97

数据来源：CVaR-based risk parity model with machine learning，兴业证券经济与金融研究院整理

综上所述，本文计算的 CVaR 使风险预算直接针对尾部损失；机器学习方向信号提高适应性和收益捕获。同时，作者也客观地指出了本框架目前存在的部分局限性：当前模型在多维度运算中存在性能瓶颈，当投资池内资产数量急剧膨胀时，协方差矩阵极易产生多重共线性并陷入病态，这将导致底层优化权重变得极度敏感和不稳定。

（三）基于混合神经网络方法的波动率预测，用于风险平价投资策略

Di Persio (2023) 等提出了一种用于动态预测金融时间序列波动率的混合神经网络架构，并将该预测模块集成到风险平价投资组合优化策略之中。作者没有依赖纯深度学习模型进行缺乏经济学直觉的直接预测，而是将 GARCH 模型的预测值作为先验特征，再将其配合原始量价数据一并输入到 LSTM 网络中进行高阶的非线性残差映射，不仅提高了样本外波动率预测的绝对准确度，且通过将更为精准的预期波动率注入传统的风险平价优化器，提升了多资产配置在极端不确定性市场环境下的抗尾部风险能力。

核心模型框架

论文引入了 GARCH(1,1) 作为理论波动率的基础提取器。对于任意给定资产的收益率时间序列 r_t ，假设其满足均值方程 $r_t = \mu + \epsilon_t$ ，其中 $\epsilon_t = \sigma_t z_t$ 为残差扰动， z_t 为服从标准正态或 t 分布的独立同分布白噪声。GARCH(1,1) 核心的条件方差演化方程定义如下：

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

方程中， $\omega > 0$ 代表长期方差基准水平，ARCH 系数 α 衡量了前一期外部市场瞬时冲击幅度的强度，而 GARCH 系数 β 则反映了前期波动率水平对当前波动率的长期记忆平滑与衰减特征。

针对 GARCH 无法拟合严重非对称冲击以及金融市场非线性高阶动态的理论盲区，作者设计了混合 LSTM 深度时序网络结构。LSTM 细胞单元的核心在于通过设置不同的门控机制来精细化管理时间序列信息的长期遗忘与短期更新。输入门 i_t 、遗忘门 f_t 和输出门 o_t 的动态控制方程可概括为：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

上式中， W 与 b 分别代表对应深度网络层级内的权重矩阵和偏置向量， σ 为控制信息流通阈值的 Sigmoid 激活函数。系统长程细胞记忆状态的流转则由旧的细胞记忆与候选新状态特征的非线性组合共同决定：

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

最终通过输出门控提纯后的前向隐藏层状态为 $h_t = o_t * \tanh(C_t)$ 。


在文章构建的 Hybrid GARCH-LSTM 算法构架中，输入特征矩阵 x_t 不仅仅是原始的收益率序列或交易量指标，而是高维融合了基于上述 GARCH(1,1) 方程滚动推导出的理论条件波动率 $\hat{\sigma}_t^{\text{GARCH}}$ 。算法设定长度为 100 天的固定回溯观测窗口数据 $[x_{t-99}, \dots, x_t]$ ，深度网络进行梯度反向传播训练后，输出对 $t+1$ 时刻的精确波动率预测值 $\hat{\sigma}_{t+1}$ 。

实验设计、数据与实证结果

本文的数据为 S&P500、STOXXEurope600、恒生和日经 225 四个股票指数的日收盘价。训练期为 2000 年 1 月至 2020 年 6 月，内部验证比例 10%；测试和风险平价模拟覆盖 2020 年 10 月至 2022 年 12 月。模型按 MSE、RMSE、MAE、MAPE 比较日、周、月预测，并将不同预测频率用于相应再平衡组合。

原文将预测波动率输入逆波动率权重，并与等权股票指数篮子比较；其配置忽略资产间相关性且未计交易成本。下图展示了底层资产观测到的真实已实现波动率与通过 GRU GARCH 前瞻性预测出的波动率在整个回溯区间内的时间序列双重拟合曲线，初步验证了混合模型在金融危机初期捕捉波动率非线性暴涨峰值时的及时性。

图4、实现波动率与 GRU-GARCH 预测波动率对比



数据来源：Volatility forecasting with hybrid neural networks methods for Risk Parity investment strategies，兴业证券经济与金融研究院整理

在时序预测精度上，混合的 GARCH-LSTM 模型在均方根误差与均方误差上表现较好。单独 GARCH 的训练误差明显高于混合模型；以 S&P500 为例，GRU-GARCH 的训练 MSE 约 0.000288，低于 LSTM-GARCH 的约 0.000763，日度测试中 GRU-GARCH 和集成模型也较好。

表4、各策略训练与预测集上的表现


Table 2 Training Errors for 2000–2020 simulation, for S&P500.				
Models	MSE	RMSE	MAE	MAPE [%]
GARCH	0.00908571	0.0953190	0.09150850	345.56987
LSTM-GARCH	0.00076309	0.0953190	0.01614862	10.246528
GRU-GARCH	0.0002882	0.095319	0.0915085	6.329703
LSTM-GRU-GARCH	0.00033954	0.0953190	0.01105917	6.7951889

Table 3 Errors on daily forecast, for S&P500.				
Model	MSE	RMSE	MAE	MAPE
LSTM-GARCH	0.023628595	0.153715	0.0177804	12.043454
GRU-GARCH	0.013872029	0.120729	0.0013675	5.7662236
LSTM-GRU-GARCH	0.014445018	0.120187	0.0059371	6.6963885
ENSEMBLE	0.01384343	0.11765	0.009488	5.922075

数据来源：Volatility forecasting with hybrid neural networks methods for Risk Parity investment strategies，兴业证券经济与金融研究院整理

进一步观察绩效数据，基于 GRU-GARCH 预测的简化 RP 组合在 Sharpe 与回撤上优于基于 GARCH 的 RP，预测精度提升可以转化为组合表现提升。

图5、周度再平衡组合



数据来源：Volatility forecasting with hybrid neural networks methods for Risk Parity investment strategies，兴业证券经济与金融研究院整理

综上所述，本文证实了混合神经网络(尤其 GRU-GARCH)优于传统 GARCH 的波动率预测，且在简化 RP 策略中有实际经济价值，GRU 的门控机制适合捕捉波动率的非线性时序模式，Ensemble 提供边际改进。

(四) 基于因子协方差矩阵的资产配置

Conlon 等(2025)系统性地将多类机器学习降维算法——包括线性无监督的主成分分析 (PCA)、有监督的偏最小二乘法 (PLS)、引入变量筛选机制的稀疏性惩罚方法 (SPCA、SPLS)，以及捕捉非线性特征的浅层神经网络 (自编码器 AEN、降噪自编码器 DAE)——应用于提取资产的潜在因子 (Latent Factors)，从而重构出降维、去噪后的资产协方差矩阵。同时，文章评估了静态协方差与允许因子载荷、残差波动随时间动态演化的复合影响。

核心模型框架

在模型构建部分，文章首先假设高维资产收益率由一组维度远低于资产数（ $K \ll N$ ）的潜在因子驱动。对于包含 N 个资产的系统，资产 i 在 t 时刻的收益率 $r_{i,t}$ 的基础因子模型数学表达为：

$$r_{i,t} = \alpha_i + \beta_i F_t + u_{i,t}$$

其中， $F_t = (f_{t,1}, \dots, f_{t,K})$ 是 t 时刻包含 K 个潜在因子的 $1 \times K$ 向量； β_i 是资产 i 对因子的敏感度（因子载荷）； α_i 为截距项； $u_{i,t}$ 是特定于该资产且与因子正交的特质残差项。

潜在因子矩阵通过权重映射构建，即 $F_t = R_t W$ ，其中 R_t 是原始资产的 $T \times N$ 收益率矩阵， W 是通过上述六种机器学习算法（如PCA或自编码器）对原始数据流学习后得到的 $N \times K$ 降维权重矩阵。在此基础上，静态精确因子模型（Static Factor Covariance, SFC）假设残差之间相互独立（残差协方差矩阵 Σ_u 为对角阵），则 N 个资产的联合协方差矩阵 Σ_r 被分解并重构为：

$$\Sigma_r = B' \Sigma_f B + \Sigma_u$$

公式中， B 是 $K \times N$ 的因子载荷矩阵， Σ_f 是提取出的潜在因子的协方差矩阵。通过这一分解，待估参数从 $O(N^2)$ 数量级断崖式降维至 $O(NK)$ ，大幅消灭了噪音拟合。

接下来，核心的投资组合优化目标被设定为最小化总方差，约束条件为全额投资限制以及严格禁止做空的非负限制。

为了进一步捕捉真实市场波动率聚集等时变特征，作者还拓展了三种动态协方差系统：1）动态贝塔协方差，允许因子载荷随时间变化；2）动态因子协方差，引入动态条件相关模型来预估时变因子协方差；3）动态残差协方差，使用单变量GARCH模型处理特质风险的时变方差。

实验设计、数据与实证结果

数据集选取自CRSP数据库中每月市值最大的100只股票（后续稳健性检验拓展至30~500只），时间跨度达62年（1960年1月至2022年12月），采用月度总收益率数据。

对比基准涵盖了等权组合、市值加权组合，以及基于四种传统协方差矩阵的最小方差组合：样本协方差、线性收缩、非线性收缩以及Wishart随机协方差。

在纯粹的协方差预测准确性实验中，以前推12个月的日度已实现协方差作为真实目标。结果表明，在均方误差和平均绝对误差指标下，基于无监督机器学习技术（PCA、SPCA、自编码器AEN和DAE）的因子模型协方差矩阵，在统计学上战胜了所有传统基准估计器。非对称损失函数揭示了因子模型的预测优势很大程度上源于其削弱了对真实协方差的“向上夸大预测（Over-predictions）”。

图6、不同估计方法下协方差预测准确度对比

Panel A Mean squared error and mean absolute error									
	MSE	MAE							
Sample	51.666	18.777							
LINS	51.972	19.139							
NLS	48.217	18.306							
Wishart	54.911	19.143							
	SFC		DFC		DBC		DEC		
	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	
PCA	14.900**	6.540***	16.752***	6.989***	19.561***	6.397***	17.381***	6.384***	
PLS	18.471**	8.071**	20.665***	8.353***	26.225**	7.941***	20.301***	7.926**	
SPCA	14.639**	6.463**	15.977***	6.806***	23.382***	6.309***	16.802***	6.308**	
SPLS	18.394**	8.022**	20.645***	8.317***	26.060**	7.883***	21.000***	7.878**	
AEN	14.729**	6.467**	17.828***	7.201**	19.708***	6.184**	21.469	6.316**	
DAE	14.730**	6.492*	17.550***	7.181**	19.337***	6.240**	24.374***	6.336**	
Panel B Quasi-likelihood function and asymmetric loss function									
	QLK	ASYM							
Sample	21.810	3.488							
LINS	23.599	3.558							
NLS	24.965	3.247							
Wishart	23.328	3.818							
	SFC		DFC		DBC		DEC		
	QLK	ASYM	QLK	ASYM	QLK	ASYM	QLK	ASYM	
PCA	29.000	0.444**	29.004	0.628***	29.178**	1.433**	24.086	0.907***	
PLS	28.677*	0.663**	28.675*	0.984***	28.862***	2.685	23.868	0.942***	
SPCA	29.022	0.422**	29.023	0.556***	29.187*	4.406	24.136	0.850***	
SPLS	28.697*	0.660**	28.696*	0.977***	28.879***	2.698	23.887	1.140***	
AEN	29.004	0.434**	29.013	0.715**	29.190	1.667	24.053	98.997	
DAE	28.984*	0.430**	28.992*	0.687***	29.174**	1.512*	24.046	6.638	

数据来源：Asset allocation with factor-based covariance matrices，兴业证券经济与金融研究院整理

下表展示了无交易成本下各大基准与各类机器学习因子策略的样本外组合标准差与夏普比率核心表现。因子协方差总体改善预测和组合表现，相对样本、线性收缩与 Wishart 优势更明确；NLS 在降低标准差方面仍是较难超越的基准。因子组合的权重通常更分散、更稳定。

表5、无交易成本下基准与策略表现对比

	SD	SR							
EW	4.275	0.196							
VW	4.137	0.188							
Sample	3.501	0.212							
LINS	3.510	0.218							
NLS	3.450	0.219							
Wishart	3.736	0.210							
	SFC		DFC		DBC		DEC		
	SD	SR	SD	SR	SD	SR	SD	SR	
PCA	3.413	0.241	3.412	0.241	3.347	0.245	3.323	0.243	
PLS	3.422	0.229	3.429	0.228	3.348	0.233	3.320	0.241	
SPCA	3.424	0.241	3.427	0.240	3.346	0.246	3.340	0.243	
SPLS	3.425	0.230	3.431	0.228	3.352	0.233	3.306	0.241	
AEN	3.404	0.243	3.401	0.243	3.343	0.249	3.329	0.244	
DAE	3.408	0.241	3.405	0.241	3.362	0.245	3.317	0.244	

数据来源：Asset allocation with factor-based covariance matrices，兴业证券经济与金融研究院整理

（五）基于稳健风险平价模型的资产配置策略研究

Li 和 Ye (2026) 提出了稳健风险平价 (RRP) 模型，直接应对传统 RP 对参数不确定性的脆弱性。论文的三层创新包括：(1) 自适应扰动半径——根据市场波动率动态调整稳健优化的不确定集大小；(2) 因子结构协方差——通过 PCA 提取主成分降低估计维度；(3) 二阶锥规划 (SOCP) 转化——使模型可用商业求解器高效求解。

核心模型框架

传统模型的优化目标是使得所有资产的风险贡献尽量相等，即最小化风险贡献差值的平方和，在鲁棒优化框架下，论文不再假设协方差矩阵 Σ 是已知常量，而是认为真实的协方差矩阵存在于一个以样本估计值 Σ_0 为中心、以 ρ_t 为半径的椭圆型不确定性集合 U 中：

$$U = \{\Sigma | \Sigma = \Sigma_0 + \Delta, \|\Delta\|_F \leq \rho_t\}$$

其中， Δ 为扰动矩阵， $\|\cdot\|_F$ 表示矩阵的 **Frobenius** 范数。为了捕捉时变特征，作者定义了动态扰动半径 ρ_t 。该半径由静态基准和动态调整因子两部分构成：

$$\rho_t = \rho_{\text{base}} \left(1 + \gamma_t \frac{|\sigma_{t+1|t} - \sigma_{\text{hist}}|}{\sigma_{\text{hist}}} \right)$$

式中， $\rho_{\text{base}} = t_{\alpha/2, v} \frac{\|\Sigma_0\|_F}{\sqrt{T}}$ 代表基于给定置信区间计算出的静态基准扰动。动态调整因子中， $\sigma_{t+1|t}$ 为利用 **GARCH(1,1)-t** 模型预测出的下一期波动率， σ_{hist} 为历史平均波动率。敏感度参数 γ_t 是通过 **K-means** 聚类算法对市场状态进行划分确定的，当市场处于高波动状态时 γ_t 取 1.0，常态下则取 0.5。为了进一步克服高维矩阵估计的维度灾难，论文在获取初始协方差矩阵时采用了 **Ledoit-Wolf** 压缩估计法与主成分因子模型。

结合上述机制，鲁棒风险平价模型旨在最恶劣的协方差扰动情境下，最小化风险贡献的离散程度，即：

$$\min_w \max_{\Sigma \in U} \sum_{i=1}^n \sum_{j=1}^n (\text{TRC}_i(\Sigma, w) - \text{TRC}_j(\Sigma, w))^2$$

由于该公式中包含针对矩阵范数绝对值的内部最大化求解，直接计算呈现高度的非凸性。作者运用矩阵范数不等式和柯西-施瓦茨不等式 (**Cauchy-Schwarz inequality**)，引入辅助变量 t_{ij} (代表资产 i 与 j 之间风险贡献偏差的上界) 和 z_{ij} (替代 L_2 范数的辅助变量)，将问题转化为如下标准的二阶锥规划 (**SOCP**) 问题：

$$\min_{w, \{t_{ij}\}_{i < j}, \{z_{ij}\}_{i < j}} \sum_{i < j} t_{ij}^2$$

实验设计、数据与实证结果

在数据集选取方面，时间跨度被设定为 2012 年 1 月至 2024 年的大周期，资产池包含 10 个具有低相关性的代表性指数资产，跨越三大核心类别：股票资产 (涵盖医药生物、金融地产、信息技术、公共事业四大板块的申万一级行业指数)、债券资产 (中国国债指数与企业债指数)、以及大宗商品期货资产 (中证能源、农产品、工业金属及油脂期货综合指数)。

论文选取了五类主流的资产配置模型作为对照组，分别是：等权重模型 (**EW**)、全局最小方差模型 (**GMV**)、全局最大收益模型 (**MaxRet**)、传统风险平价模型

(TRP), 以及增强型风险平价模型 (ERP, 使用了改进的协方差矩阵但不包含动态鲁棒极小极大优化模块)。回测的基本参数设定为：采用 252 个交易日的滚动窗口 (Lookback period) 来估算参数，并以 21 个交易日为周期进行定期的组合重平衡。

回测期间内，鲁棒风险平价 (RRP) 模型实现了 6.49% 的年化收益率，远超传统风险平价的 2.26% 与等权重的 3.24%。与此同时，RRP 模型的年化波动率被控制在 7.66%，最大回撤仅 14.35%。

图7、回测期内六种投资组合策略的累计净值表现



数据来源：Research on asset allocation strategies based on robust risk parity model，兴业证券经济与金融研究院整理

表6、六种模型表现对比

	RRP	ERP	TRP	EW	GMV	MaxRet
Annual Return (%)	6.49	2.97	2.26	3.24	2.34	-3.33
Annual Volatility (%)	7.66	7.69	7.54	10.65	7.16	29.36
Sharpe Ratio (%)	61.41	15.40	6.26	13.64	7.77	-17.45
Max Drawdown (%)	14.35	14.99	15.17	29.07	12.81	76.06
Calmar Ratio (%)	32.78	7.90	3.11	4.99	4.34	-6.73
Sharpe <i>p</i> -value vs RRP	0.0000	0.2842	0.2051	0.2949	0.2029	0.1211

Note: RRP = robust risk parity; ERP = enhanced risk parity; TRP = traditional risk parity; EW = equal weight; GMV = global minimum variance; MaxRet = maximum return.

数据来源：Research on asset allocation strategies based on robust risk parity model，兴业证券经济与金融研究院整理

三、组合结构优化与现实可实施性

传统风险平价往往使用全部资产，但大量微小仓位会增加交易、托管和管理成本。Anis 和 Kwon (2022) 直接在风险平价中加入基数约束，要求组合只持有固定数量的资产。论文给出非凸和凸二次约束整数规划，并通过更紧变量界和有效约束提高通用求解器效率。这项研究证明“控制资产数量”不必破坏风险均衡原则。风险平价由全资产配置转变为可根据运营能力选择持仓规模的组合方法。

不过，基数约束解决的是持仓数量，并未回答应选择哪些资产。Cho 和 Song (2023) 进一步利用相关网络解决资产筛选问题，将层次风险平价与最小生成树的外围资产选择结合。一类模型使用完整相关矩阵，另一类先剔除最大特征值代表的全市场共同运动，再构建相关网络。位于网络外围的资产与市场中心联系较弱，理论上能够提供更独立的风险来源。滚动回测显示，经过筛选的 HRP 在许多持仓规模下优于全资产 HRP 和市场指数，说明全资产并不必然实现最佳分散。完整相关矩阵适合资产数量较少、强调危机后修复的组合；剔除共同运动后的相关矩阵在资产数较多和危机环境中更有防御性。

即使组合选择了较少且相关性较低的资产，证券层面的分散仍可能掩盖行业或因因子集中。Anis、Costa 和 Kwon (2023) 的 RABIT 因此把风险预算思想用于指数跟踪。RABIT 要求跟踪组合的行业百分比风险贡献接近基准，并以传统跟踪误差作为辅助目标。实验显示 RABIT 能以较小的传统目标代价显著改善行业风险画像匹配，样本外表现也通常更接近基准。

Lee 和 Sohn (2023) 把风险来源的重构推进到基金组合。全球股票 FoF 即使持有许多外部管理人，也可能因共同暴露于成长、价值、小盘或动量因子而高度集中。该文先用因子回归分离风格风险，再对残差收益进行 PCA，提取代表管理人选股风险的主成分，最后同时对风格因子和 alpha 来源实施风险平价。

(一) 基数约束下的风险平价投资组合

Anis 和 Kwon (2022) 将基数约束（即限制投资组合中最终实际持有资产的最大数量）引入风险平价模型，并提出了可以直接利用现成商用求解器求解至全局最优解的数学规划公式。作者构建了两种全新的混合整数二次约束二次规划模型——一种为非凸公式，另一种为等价的凸公式。通过在模型内部引入更紧致的变量边界（Tighter variable bounds）和有效不等式约束（Valid constraints），免除了以往处理该类问题时对特定启发式算法或近似计算手段的依赖，从底层数学结构上保证了求解的准确性。

核心模型框架

在数学模型构建部分，作者详细阐述了如何将经典的风险平价非线性方程组转化为可精确求解的混合整数二次约束二次规划（MIQCQP）形式。为了引入基数约束机制，模型引入了二元整数变量 $z_i \in \{0,1\}$ ，当资产 i 被选中并纳入投资组合时 $z_i = 1$ ，否则为 0。基数约束被严格定义为在全集资产中恰好选择 K 个资产：

$$\sum_{i=1}^N z_i = K$$

作者引入了一个连续辅助变量 θ 来代表这个统一的风险贡献基准数值。在第一种非凸 MIQCQP 模型中，通过引入充分大的常数 μ ，风险平价的强制相等条件被巧妙地转化为如下基于二元变量控制的不等式约束：

$$-\mu(1 - z_i) \leq x_i(\sum x)_i - \theta \leq \mu(1 - z_i)$$

此外，资产权重必须满足资金的全额分配约束 $\sum_{i=1}^N x_i = 1$ ，以及基于二元选择变量的严格上下界约束 $l_i z_i \leq x_i \leq u_i z_i$ 。然而，由于上述含有非凸二次等式特征的约束在求解时会导致分支定界树呈指数级爆炸，为了实现工程上的极速求解，作者的核心理论推导在于进一步提出了一种极为高效的凸 MIQCQP 重构方案。该凸模型深度利用了运筹学优化机制：在全局最小化投资组合整体方差的目标牵引下，特定的不等式约束会在最优解处自动取紧。利用这一凸优化性质，模型将严格的等式放宽为凸二次不等式，并重新构造目标函数以确保求解空间的严格凸性。通过这种数学上的有效降维和凸化重构，混合整数模型得以直接输入至现成的标准数学优化引擎中，从而在极短的时间内锁定满足基数限制的全局最优资产组合。

实验设计、数据与实证结果

为了严密验证上述两种 MIQCQP 公式的实际效能、运算效率以及在真实市场中的经济学价值，作者调用了来自真实金融市场（如通过 Wharton Research Data Services 获取的 Compustat 数据库）的长期历史数据进行了广泛的计算回测与实验论证。在实验标的设定上，资产池涵盖了具备代表性的真实股票资产簇，并针对不同的基数约束参数 K （即强制要求模型在数百只备选资产中精准挑选出 K 只股票）进行了多组穷举式测算。比较基准不仅包括了不含基数约束的理论全量资产风险平价模型，还对标了等权配置策略（即简单的 $1/N$ 分散）等传统范式。

核心实证结果首先聚焦于算法级别的计算学表现。实验数据清晰地表明，凸 MIQCQP 公式在计算速度和解的绝对精度上展现出了压倒性的统治力。下表 11 展示非凸 MIQCQP 模型与凸 MIQCQP 模型在不同基数约束参数 K 下求解至全局最优解的平均计算时间与处理节点数对比。

表7、模型在不同约束参数下求解的平均表现

(a) TSX60				
Strategy	K	Solved (%)	Rel. Optimality Gap	Solution Times (s)
CCMV	5	100	0.00 ± 0.00	0.48 ± 0.74
	15	100	5.86e-07 ± 2.62e-07	0.14 ± 0.08
	30	100	2.03e-07 ± 8.45e-07	4.32e-02 ± 8.23e-02
cvxRP ₀	5	30	2.08e-03 ± 1.86e-03	17.80 ± 15.98
	15	70	2.08e-03 ± 3.73e-03	303.63 ± 408.99
	30	50	2.97e-02 ± 4.43e-02	487.72 ± 428.72
cvxRP _{lb}	5	60	1.67e-03 ± 2.13e-03	34.68 ± 38.01
	15	65	1.67e-03 ± 3.11e-03	338.05 ± 424.11
	30	35	1.92e-02 ± 2.62e-02	601.19 ± 418.88
ncvxRP _{0,l}	5	30	0.68 ± 0.46	672.96 ± 364.51
	15	0	0.996 ± 1.59e-02	900.00 ± 0.00
	30	0	1.00 ± 2.13e-15	900.00 ± 0.00
ncvxRP _{lb,l}	5	35	4.79e-02 ± 4.85e-02	646.23 ± 372.12
	15	0	0.354 ± 9.45e-02	900.00 ± 0.00
	30	0	0.91 ± 0.19	900.00 ± 0.00
ncvxRP _{0,t}	5	80	7.47e-04 ± 1.55e-03	189.90 ± 124.39
	15	10	0.266 ± 0.167	883.31 ± 53.37
	30	0	0.91 ± 0.23	900.00 ± 0.00
ncvxRP _{lb,t}	5	65	1.19e-02 ± 2.17e-02	499.81 ± 332.88
	15	5	0.187 ± 0.108	855.95 ± 197.96
	30	0	0.623 ± 0.26	900.00 ± 0.00
(b) S&P500				
Strategy	K	Solved (%)	Rel. Optimality Gap	Solution Times (s)
CCMV	25	100	1.05e-05 ± 2.39e-05	0.61 ± 1.42
	50	100	3.46e-06 ± 7.44e-06	4.18 ± 6.83
	100	100	9.64e-06 ± 2.18e-06	18.55 ± 38.80
	200	100	4.03e-06 ± 1.27e-05	24.07 ± 64.29
	250	100	2.26e-06 ± 4.91e-06	2.58 ± 0.20
cvxRP ₀	25	100	0.00 ± 0.00	12.72 ± 4.33
	50	100	0.00 ± 0.00	11.30 ± 3.41
	100	100	0.00 ± 0.00	11.26 ± 3.39
	200	100	0.00 ± 0.00	11.62 ± 4.24
	250	100	0.00 ± 0.00	11.89 ± 4.50
cvxRP _{lb}	25	100	0.00 ± 0.00	12.61 ± 4.33
	50	100	0.00 ± 0.00	11.21 ± 3.42
	100	100	0.00 ± 0.00	11.31 ± 3.47
	200	100	0.00 ± 0.00	11.65 ± 4.45
	250	100	0.00 ± 0.00	12.05 ± 4.63

数据来源：Cardinality-constrained risk parity portfolios，兴业证券经济与金融研究院整理

与非凸公式动辄陷入庞大算力消耗的困境相比，凸公式极大地缩减了求解器的收敛时间，彻底证明了所提紧凑变量边界和有效约束的正确性，使得在大规模资产池中执行带有离散整数约束的风险平价成为工程上的可能。

CCd-RP 在指定持仓数下实现接近相等的风险贡献。样本外，凸 CCd-RP 在各持仓规模下的风险调整后表现优于 CCMV；论文同时报告换手率，但未计入交易成本。其结果证明稀疏风险平价具有可实施性

表8、策略回测表现

(a) TSX60						
Strategy	K	Ann. Ret.	Ann. Vol.	SR	maxDD	Turnover
0.60MV		0.601.160	0.600.112	0.6010.349	0.600.149	0.605.948
0.60EW		0.601.095	0.600.126	0.608.486	0.600.273	0.602.056
0.60RP		0.601.065	0.600.105	0.6010.394	0.600.214	0.602.181
CCMV	5	1.129	0.118	9.555	0.165	6.746
	15	1.024	0.191	5.370	0.149	5.843
	30	1.004	0.210	4.787	0.149	5.658
cvxRP	5	1.111	0.107	10.337	0.136	8.972
	15	1.003	0.168	5.967	0.127	9.200
	30	1.021	0.172	5.945	0.154	5.956
ncvxRP	5	1.117	0.116	9.602	0.152	16.689
	15	1.026	0.176	5.828	0.138	16.611
	30	0.963	0.205	4.704	0.216	16.239
(b) S&P500						
Strategy	K	Ann. Ret.	Ann. Vol.	SR	maxDD	Turnover
0.60MV		0.600.981	0.600.218	0.604.499	0.600.404	0.6021.761
0.60EW		0.601.055	0.600.136	0.607.734	0.600.220	0.601.990
0.60RP		0.601.056	0.600.130	0.608.096	0.600.193	0.604.692
CCMV	25	0.9797	0.2181	4.4923	0.404	21.8841
	50	1.0011	0.2204	4.5420	0.404	21.7563
	100	0.9993	0.2203	4.5372	0.405	21.7748
	200	1.0013	0.2203	4.5446	0.403	21.7696
	250	0.9985	0.2200	4.5381	0.404	21.8289
cvxRP	25	1.03959	0.1924	5.4050	0.427	16.7055
	50	0.9388	0.1896	4.9335	0.383	14.7942
	100	1.0472	0.1715	6.1302	0.360	7.6772
	200	1.0246	0.1544	6.6335	0.329	7.1709
	250	0.9917	0.1655	5.9941	0.300	6.8952

数据来源：Cardinality-constrained risk parity portfolios，兴业证券经济与金融研究院整理

（二）外围资产筛选与层次风险平价

Cho 和 Song (2023) 提出了两项核心创新：(1) 全局运动剔除相关性矩阵 (GMSC) —— 基于随机矩阵理论，从经验相关性矩阵中剔除最大特征值对应的 "全局运动" 分量 (代表整个市场对外部信息的集体反应)，聚焦于资产异质风险之间的内部交互；(2) 基于最小生成树 (MST) 外围节点的证券选择 —— 采用混合外围性度量 (综合度中心性、介数中心性、特征向量中心性等五个指标)，选择外围性最高的 κ 只资产，再在所选资产上应用 HRP。

核心模型框架

在模型构建部分，作者详细阐述了从对数收益率的标准化、相关性矩阵去噪，到网络拓扑中心度计算及层次风险分配的完整数学与算法逻辑。首先，为了消除不同资产波动率量级的差异，模型对资产的对数收益率进行了标准化处理。

作者引入了基于 Marchenko-Pastur 分布的随机矩阵理论。任何经验相关性矩阵的特征值均可被分解为三部分：代表系统性市场风险的极大特征值、包含真实资产互动的有意义特征值，以及纯粹的随机白噪音。数学上，经验相关性矩阵可表达为：

$$\rho = \lambda_1 u_1 u_1^T + \sum_{i=2}^{N_g} \lambda_i u_i u_i^T + \sum_{i=N_g+1}^N \lambda_i u_i u_i^T$$

公式中， λ_i 是按降序排列的特征值， u_i 是对应的特征向量， N_g 表示超过 Marchenko-Pastur 理论分布上界的有意义特征值的数量。第一部分 $\lambda_1 u_1 u_1^T$ 被严

谨地定义为全局运动，它代表了全市场对宏观外部信息的集体同向反应（例如大盘指数的系统性涨跌）。为了深度挖掘资产间的特质性关系，作者构建了全局运动剔除相关性（GMSC）矩阵 $\hat{\rho}$ ：

$$\hat{\rho} = \rho - \lambda_1 u_1 u_1^T$$

在获得 FC 或 GMSC 矩阵后，模型通过非线性映射将其转化为度量空间中的距离矩阵。资产间距离 D_{ij} 定义为 $D_{ij} = \sqrt{2(1 - r_{ij})}$ ，其中 r_{ij} 为前述的相关性系数。基于此距离矩阵，模型利用 Kruskal 算法生成最小生成树（MST），同时运用单连接的层次凝聚聚类对资产进行重排与准对角化。为了在庞大的资产池中进行降维优选，作者构建了综合外围度量指标 P 。该指标融合了资产在加权与非加权 MST 中的度中心性、介数中心性、特征向量中心性、偏心率及接近中心性。指标 P 被划分为 X 和 Y 两个加权秩和维度，经济学含义在于： P 值越大的资产，处于金融网络拓扑结构的越边缘地带，其收益表现越不容易受到网络中心高关联度资产崩溃时的风险传染。

最终，模型选取外围度最高的 κ 个资产，并执行递归二分法（Recursive Bisection）。在层次树的每个分叉节点上，模型根据子集群的方差分布，按照方差倒数的比例动态分配资金权重，直到每个底层资产都被赋予独立的平价权重。


实验设计、数据与实证结果

为了验证这一融合网络拓扑与层次风险平价框架的实战效能，数据集选定为标普 500 指数（S&P500）成分股的日度收盘价数据，时间跨度从 2000 年 7 月延伸至 2021 年 8 月（共 5320 个观测日）。相关性矩阵与网络拓扑的滚动估计窗口设定为 120 个交易日，并按月度频率执行调仓重平衡。

回测的比较基准设定为标普 500 指数本身，以及基于全量资产构建的传统 FC-HRP 策略，并严格扣除了单边 10bps 的交易成本。

全样本期（2001-2021）的累计收益与风险平价结果显示，无论采用全相关性（FC-HRP）还是剔除全局运动的相关性（GMSC-HRP），带有外围资产选择机制的组合在绝大多数参数设定下均碾压了标普 500 指数。

图8、各项 HRP 与基准的净值对比



数据来源：Hierarchical risk parity using security selection based on peripheral assets of correlation-based minimum spanning trees，兴业证券经济与金融研究院整理

具体而言，FC-HRP 在 $\kappa=20$ 时年化复合收益较高；在 $\kappa=10$ 时 Sharpe 和 Calmar 更高。然而，全相关性矩阵的劣势在于其波动率防御力不足。此时，GMSC-HRP 展现出了降波属性：在 $\kappa=50$ 或 100 的中大型配置下，GMSC 最大回撤显著降低，录得了所有组合中最高的索提诺比率。下表展示了不同 κ 值下 FC-HRP 和 GMSC-HRP 在全样本回测期间的年化收益、标准差、最大回撤、夏普比率及换手率等详尽指标。


表9、不同 κ 值下策略表现对比

		$\kappa=5$	$\kappa=10$	$\kappa=20$	$\kappa=30$	$\kappa=50$	$\kappa=100$	$\kappa=200$	$\kappa=300$	All	S&P500
C/R	FC-HRP	0.1282 ^a	0.2319 ^a	0.1956 ^a	0.1560	0.1693	0.1900	0.1411	0.1329	0.1290	0.1224
	GMSC-HRP	0.1056	0.0751	0.1318	0.1618 ^a	0.2368 ^a	0.2008 ^a	0.1638 ^a	0.1546 ^a	0.1317 ^a	
S/D	FC-HRP	0.2868	0.2435	0.2235	0.2148 ^a	0.2030 ^a	0.1921 ^a	0.1856 ^a	0.1790 ^a	0.1716	0.1961
	GMSC-HRP	0.2752 ^a	0.2434 ^a	0.2231 ^a	0.2194	0.2117	0.2036	0.1932	0.1859	0.1705 ^a	
D/D	FC-HRP	0.2112	0.1794	0.1685	0.1608 ^a	0.1510	0.1412 ^a	0.1364 ^a	0.1315 ^a	0.1260	0.1423
	GMSC-HRP	0.1992 ^a	0.1759 ^a	0.1614 ^a	0.1589	0.1534 ^a	0.1475	0.1404	0.1352	0.1251 ^a	
MDD	FC-HRP	-0.8105	-0.7058 ^a	-0.6589	-0.6726 ^a	-0.6172	-0.5976 ^a	-0.6156	-0.6074 ^a	-0.6197	-0.6103
	GMSC-HRP	-0.7779 ^a	-0.7173	-0.6393 ^a	-0.6865	-0.6018 ^a	-0.6239	-0.6048 ^a	-0.6080	-0.6127 ^a	
SH/R	FC-HRP	0.4471 ^a	0.9522 ^a	0.8752 ^a	0.7260	0.8340	0.9891 ^a	0.7602	0.7422	0.7517	0.6241
	GMSC-HRP	0.3838	0.3083	0.5907	0.7374 ^a	1.1182 ^a	0.9863	0.8479 ^a	0.8312 ^a	0.7723 ^a	
SO/R	FC-HRP	0.6073 ^a	1.2929 ^a	1.1607 ^a	0.9697	1.1213	1.3451	1.0338	1.0102	1.0242	0.8597
	GMSC-HRP	0.5301	0.4267	0.8164	1.0184 ^a	1.5438 ^a	1.3615 ^a	1.1667 ^a	1.1429 ^a	1.0528 ^a	
CA/R	FC-HRP	0.1582 ^a	0.3286 ^a	0.2969 ^a	0.2319	0.2743	0.3179	0.2291	0.2188	0.2082	0.2005
	GMSC-HRP	0.1358	0.1046	0.2061	0.2357 ^a	0.3934 ^a	0.3218 ^a	0.2709 ^a	0.2542 ^a	0.2150 ^a	
P/Y	FC-HRP	14 ^a	16 ^a	16 ^a	15	14	16	15	16	16	16
	GMSC-HRP	13	13	14	15	16 ^a	16	15	16	16	
M/TO	FC-HRP	1.8092 ^a	1.7497 ^a	1.7043 ^a	1.6375 ^a	1.5294 ^a	1.2997 ^a	0.9484 ^a	0.7155	0.3091	
	GMSC-HRP	1.9233	1.8684	1.8032	1.7548	1.6346	1.3762	0.9763	0.7084 ^a	0.2987 ^a	
SD/TO	FC-HRP	0.2962	0.2729	0.2412	0.2333	0.2306	0.2163	0.1901	0.1541	0.0908 ^a	
	GMSC-HRP	0.1726 ^a	0.1783 ^a	0.1603 ^a	0.1550 ^a	0.1979 ^a	0.1974 ^a	0.1769 ^a	0.1420 ^a	0.0930	

数据来源：Hierarchical risk parity using security selection based on peripheral assets of correlation-based minimum spanning trees，兴业证券经济与金融研究院整理

FC-HRP 在小资产池和危机后恢复阶段更具进攻性；GMSC-HRP 在较大资产池和危机阶段具有更好的风险控制。同一持仓规模下 FC 的平均换手通常略低于 GMSC，但稀疏筛选会显著提高相对全资产组合的换手。

图9、2021 年 8 月网络拓扑快照



数据来源：Hierarchical risk parity using security selection based on peripheral assets of correlation-based minimum spanning trees，兴业证券经济与金融研究院整理

(三) 行业风险贡献驱动指数跟踪

Anis 等（2023）将风险平价思想从组合构建扩展到指数跟踪领域，提出了 RABIT（Risk-Allocation-Based Index Tracking）框架。RABIT 将指数跟踪问题重新表述为风险分配问题——不再追求跟踪误差最小化，而是使跟踪组合中各资产的风险贡献与基准指数中各资产的风险贡献成比例。

核心模型框架

RABIT 框架的核心在于将投资组合的风险结构化分解。传统方法通常最小化方差误差或收益误差，而 RABIT 则通过分解资产协方差矩阵来获取风险贡献。作者定义了稀疏矩阵 $A_i \in \mathbb{R}^{n \times n}$ 以分解协方差矩阵：

$$A_i = \frac{1}{2} (e_i e_i^T \Sigma + \Sigma e_i e_i^T)$$

其中 e_i 是单位矩阵的第 i 列。基于此，投资组合的总方差 σ_P^2 可以表示为各资产风险贡献 $R_i(x)$ 之和：

$$\sigma_P^2 = x^T \Sigma x = \sum_{i=1}^n x^T A_i x = \sum_{i=1}^n R_i(x)$$

其中，单个资产的风险贡献定义为 $R_i(x) = x_i (\Sigma x)_i$ 。

在 RABIT 框架下，假设资产被划分为 P 个互不重叠的组 g_p （如行业板块）。基准指数中第 p 组的百分比风险贡献定义为：

$$\widehat{\rho}_p = \frac{1}{\widehat{\sigma}^2(x)} \sum_{i \in g_p} \widehat{R}(x)_i$$

RABIT 的目标是寻找一个组合，使其各组的风险贡献尽可能接近基准。为了提高计算效率，作者引入自由变量 θ 替代共享方差，构建了如下优化目标函数：

$$\min_{\mathbf{x}, \mathbf{y} \in \mathcal{X}_K, \boldsymbol{\theta} \in \mathbb{R}} F(\mathbf{x}, \boldsymbol{\theta}) = \frac{1}{2} \sum_{p=1}^P \left(\sum_{i \in \mathcal{C}_p} R(\mathbf{x})_i - \widehat{\rho}_p \boldsymbol{\theta} \right)^2$$

其中约束集包含了预算约束、基数约束以及长仓约束。为了保证解的唯一性，作者在目标函数中加入了一个带权重 λ 的辅助正则化项，通常选择传统的跟踪误差函数。该模型最终被转化为一个目标函数为凸、但约束包含非凸项的形式。此外，论文通过引理证明了在给定可行权重 $\mathbf{x}$ 的情况下，存在唯一的 $\boldsymbol{\theta}^*$ 最小化该目标函数，从而为全局最优性提供了理论凭证。

实验设计、数据与实证结果

为了全面验证 RABIT 框架的有效性，作者设计了三组不同规模的实验。首先是基于合成数据的模拟实验，资产规模 $n = 20$ ，划分为 $P = 5$ 个组，旨在验证模型能否在基数约束下准确捕捉风险特征。其次是基于标普 500 的大规模样本内实验，测试启发式算法的扩展性与参数稳定性，资产按 GICS 标准分为 6 个组。最后是基于标普/多伦多证交所 60 指数的样本外实证研究。

在合成实验中，作者对比了 RABIT 框架与名义模型 (REG)。结果显示，在全样本情况下，RABIT 能将风险特征偏差降至极低水平 (如 1.93×10^{-9})，而名义模型的偏差高达 0.82。

在引入基数约束后，名义模型的风险特征背离更加显著，而 RABIT 仍能保持高度一致。在样本外回测中，RABIT 框架在所有基数规模下均能提供比名义模型更接近基准的风险调整后收益。此外，RABIT 组合在换手率方面表现更优，有助于降低实际操作中的交易成本。

表10、策略表现

	K = 15						K = 30					
	MinVar		RTE		TE		MinVar		RTE		TE	
	EE	REG	EE	REG	EE	REG	EE	REG	EE	REG	EE	REG
annRet	0.0709	0.0761	0.0203	0.0106	0.0068	0.0077	0.0653	0.0776	0.0056	0.0061	0.0042	0.0023
annVol	0.0261	0.0283	0.0026	0.0045	0.0020	0.0001	0.0241	0.0287	0.0019	0.0039	0.0024	0.0021
SR	1.0490	1.1460	0.0349	0.0513	0.0133	0.0382	0.9575	1.1670	0.0177	0.1151	0.0352	0.0362
maxDD	0.0378	0.0523	0.0204	0.0122	0.0232	0.0198	0.0278	0.0507	0.0018	0.0046	0.0130	0.0089
retDiff	0.1484	0.1979	0.0831	0.0843	0.0645	0.0623	0.1433	0.1942	0.0675	0.0718	0.0403	0.0408

数据来源：Risk-allocation-based index tracking，兴业证券经济与金融研究院整理

(四) 风格因子与管理人 alpha 一体化风险平价

Lee 和 Sohn (2023) 研究全球股票 FoF 的风险配置问题。传统 FoF 通过配置多个外部管理人分散单一基金风险，但基金数量增加并不意味着真正实现风险分散：不同管理人可能同时暴露于成长、价值、小盘或动量等共同风格因子，导致组合在特定市场环境下出现隐蔽的风险集中。

另一方面，如果组合只对风格因子实施风险平价，又会忽略基金经理选股产生的特有 Alpha 来源。为此，作者提出 Alpha-factor integrated risk parity，将基

金收益分解为可观测的风格因子收益和不能被风格因子解释的选股收益，并同时
对两类风险来源进行配置。其核心思想是，FoF 的风险预算对象不应只是单只基
金，而应进一步下沉至基金共同承担的风格风险和管理人特有的 Alpha 风险。

核心模型框架

作者首先使用多因子回归分解基金收益：

$$R_{i,t} = \alpha_i + \sum_{j=1}^m \beta_{i,j} F_{j,t} + \varepsilon_{i,t}$$

其中， $F_{j,t}$ 包括市场、价值、盈利、保守投资、动量和小盘等风格因子； $\beta_{i,j}$ 表
示基金 i 对风格因子的暴露；残差 $\varepsilon_{i,t}$ 表示不能被共同风格因子解释的收益。由
于不同基金残差之间仍可能相关，作者进一步对残差收益矩阵实施主成分分析，
将其转换为若干相互正交的 principal alpha portfolios。它们并不等同于基金经理
实际实现的 Alpha，而是从风格调整后残差中提取出的主要共同变动来源，用于
刻画 FoF 面临的管理人选股风险。

模型将组合风险划分为风格因子风险和 principal alpha 风险：

$$\sigma_F = \sqrt{S^T \Sigma_F S} \quad \sigma_P = \sqrt{P^T \Lambda P}$$

其中， Σ_F 为风格因子协方差矩阵， Λ 为主成分对应的特征值矩阵。两类风险
来源的风险贡献分别为：

$$RC_{F(i)} = S_i \frac{(\Sigma_F S)_i}{\sigma_F} \quad RC_P(i) = P_i \frac{(\Lambda P)_i}{\sigma_P}$$

一体化风险平价模型同时最小化两个风险分区内部的风险贡献差异：

$$\min_w [\sum_i \sum_j (RC_F(i) - RC_F(j))^2 + \sum_i \sum_j (RC_P(i) - RC_P(j))^2]$$

模型要求组合权重之和为 1，并限制单只基金的仓位。作者还要求各风险来
源的边际风险贡献为正，并使风格因子分区和 principal alpha 分区承担相同的目
标风险，从而避免组合只在其中一个风险分区实现表面上的风险均衡。

由于联合目标具有非凸、多目标特征，传统顺序二次规划（SQP）容易陷入
局部最优。作者因此采用 Basin-Hopping 两阶段优化：先用 SQP 获得局部解，再
对该解进行扰动并在新邻域内重新优化。Basin-Hopping 的作用是扩大最优解搜
索范围，而不是降低换手率或直接控制交易成本。

实验设计、数据与实证结果

为研究使用 eVestment 全球股票机构基金数据库。截至 2022 年 6 月，数据
库包含 2721 个策略，其中 1688 个仍处于活跃状态、1033 个为已终止策略。作
者保留历史上曾经运行但目前已经停止的策略，以降低只使用存续基金造成的存
续偏差。

原始数据覆盖 2001 年至 2022 年第二季度，组合模拟期为 2006 年 1 月至 2022 年第二季度。基金收益采用月度数据，但组合按年度重新构建，而不是月度调仓。每次构建组合时，作者使用过去五年的基金表现估计风格因子暴露和 principal alpha 结构，并从风格调整后 Alpha 高于当年基金池平均水平的基金中建立投资范围。

研究比较了三种策略：Alpha-factor integrated risk parity、只均衡风格因子的 style factor risk parity，以及只均衡 principal alpha 风险的 principal alpha risk parity。目标风险预算从 1% 提高至 6%，评价指标为累计收益、累计和年化超额收益、跟踪误差（TE）及信息比率（IR）；作者还检验了市场状态、基金池变化、估计窗口、优化参数和卖空约束。

实证结果显示，一体化风险平价在大多数风险预算范围内比两种单侧风险平价表现得更稳定。在 1% 的低风险预算下，一体化组合的年化超额收益为 1.46%，信息比率为 0.53，均高于风格因子风险平价的 0.76% 和 0.28，以及 principal alpha 风险平价的 1.03% 和 0.40。随着风险预算上升，一体化组合的超额收益和信息比率继续改善，在 3% 的风险预算下，年化超额收益达到 3.20%，信息比率达到 0.72。当风险预算提高至 4% 时，一体化组合的年化超额收益为 3.32%，信息比率为 0.60；同期风格因子风险平价的年化超额收益转为 -0.31%，信息比率为 -0.05。这表明，只对风格因子进行风险平价可能在特定风格失效时期产生较大业绩压力。

Principal alpha 风险平价在高风险预算下可能取得更高收益。例如，在 6% 的风险预算下，其年化超额收益为 3.51%，高于一体化组合的 1.94%。但原文认为，这种表现较多集中在 2009 年、2017 年和 2020 年等特定市场环境，并受到成长型管理人表现的影响，因而稳定性较弱。

相比之下，一体化组合的年度超额收益标准差在不同风险预算下相对稳定。它未必在每个年份或最高风险预算下取得最高收益，但可以降低对单一风格或单一 Alpha 来源的依赖。因此，其优势主要表现为超额收益来源更加分散、不同市场环境下的表现更加平稳，而不是简单追求最高累计收益。

市场状态分析也支持这一判断。在高波动和市场下跌阶段，一体化组合仍能维持正的相对超额收益；而单纯风格因子策略在 COVID-19 等风格偏离显著的时期表现较弱。作者还发现，一体化策略的风险预算并非越高越好：当风险预算超过一定水平后，跟踪误差继续扩大，但信息比率开始下降，说明组合存在较为合适的中等风险“甜蜜点”。

表11、集成风险平价策略表现对比

	Risk budget	Return	BM	Excess	Annualized excess	Tracking error	IR
Alpha-Factor Integrated Risk Parity	1%	250.1%	179.8%	70.3%	1.46%	2.72%	0.53
Style Factor Risk Parity		214.9%	179.8%	35.1%	0.76%	2.71%	0.28
Principal Alpha Risk Parity		227.8%	179.8%	48.0%	1.03%	2.55%	0.40
Alpha-Factor Integrated Risk Parity	2%	294.9%	179.8%	115.1%	2.25%	3.28%	0.69
Style Factor Risk Parity		230.5%	179.8%	50.6%	1.08%	3.91%	0.28
Principal Alpha Risk Parity		269.8%	179.8%	90.0%	1.81%	3.65%	0.50
Alpha-Factor Integrated Risk Parity	3%	356.1%	179.8%	176.2%	3.20%	4.43%	0.72
Style Factor Risk Parity		188.2%	179.8%	8.4%	0.19%	5.11%	0.04
Principal Alpha Risk Parity		294.5%	179.8%	114.6%	2.24%	4.80%	0.47
Alpha-Factor Integrated Risk Parity	4%	364.8%	179.8%	185.0%	3.32%	5.54%	0.60
Style Factor Risk Parity		166.7%	179.8%	-13.1%	-0.31%	6.38%	-0.05
Principal Alpha Risk Parity		326.8%	179.8%	146.9%	2.76%	6.41%	0.43
Alpha-Factor Integrated Risk Parity	5%	323.8%	179.8%	143.9%	2.71%	6.48%	0.42
Style Factor Risk Parity		229.7%	179.8%	49.9%	1.06%	6.50%	0.16
Principal Alpha Risk Parity		319.3%	179.8%	139.4%	2.64%	8.02%	0.33
Alpha-Factor Integrated Risk Parity	6%	277.2%	179.8%	97.3%	1.94%	7.85%	0.25
Style Factor Risk Parity		143.3%	179.8%	-36.5%	-0.90%	6.81%	-0.13
Principal Alpha Risk Parity		378.2%	179.8%	198.4%	3.51%	9.50%	0.37

数据来源：Alpha-factor integrated risk parity portfolio strategy in global equity fund of funds，兴业证券经济与金融研究院整理

四、动态配置、决策学习与收益信号融合

Clare 等（2014）较早考察了风险平价在商品期货战术策略中的作用，后又将近这一比较扩展到全球股票、债券、商品和房地产。跨大类资产的风险平价以接近等权组合的收益，将波动率和最大回撤显著降低；风险平价再叠加趋势过滤后，风险调整后表现和回撤控制进一步改善。改变了风险平价的功能定位：风险平价主要负责稳定不同资产的风险规模，趋势和动量负责提供方向性收益或退出机制。由此产生的策略已经不是纯风险平价，而是“风险预算底层 + 战术信号覆盖层”。这一思路也延续到近期机器学习增强的 CVaR-RP：Sheng 等（2025）用机器学习预测资产涨跌，把预测下跌资产的权重置零，再将资金分配给预测上涨资产。

趋势和动量解决的是市场方向变化，但未显式优化未来交易路径。Li、Uysal 和 Mulvey（2022）通过模型预测控制建立多期风险平价：在每个时点规划未来若干期权重，只执行第一期交易，随后根据新信息滚动求解。模型使用隐马尔可夫状态估计资产参数，并把风险贡献偏差和市场冲击成本同时纳入目标。Liu、Zhou 和 Niu（2023）从现实约束角度补充多期研究，将动态风险偏好、最小交易手数、非线性交易成本和收益预测因子纳入平均—VaR 模型。模拟结果显示，动态交易和较长规划期可以改善结果，但交易成本提高后预测信号的价值下降。

传统动态配置通常先训练风险预测模型，再把预测值输入优化器；预测模型按统计误差训练，未必产生最好的最终组合。Anis 和 Kwon（2025）的端到端研究虽然针对带基数约束的最小方差组合而非风险平价，却提供了可迁移的方法。作者把连续松弛后的组合优化作为神经网络隐式层，直接按实现 Sharpe 所代表的决策质量训练因子风险模型。这一研究把动态风险平价可能的未来方向推进到

“直接提高最终风险预算决策质量”，使得风险平价成为预测模型、优化层和交易执行之间的接口。

(一) 全球资产配置中的风险平价、动量和趋势跟踪

Clare 等 (2016) 系统研究趋势跟踪 (TF)、动量 (MOM)、风险平价 (RP) 及波动率调整动量 (Vol-adj MOM) 在全球资产配置中的单独与组合效果。单纯的横截面动量策略虽然能够获取羊群效应带来的超额收益，但极易在市场反转时发生严重的动量崩溃，表现为深度回撤和负偏度；而单纯的风险平价策略虽然均衡了波动率，却无视了资产预期的收益方向。本文证明，通过在波动率调整后的动量排名体系之上，叠加时间序列的趋势跟踪过滤器作为天然的下行熔断机制，能够剔除动量策略的尾部风险。

核心模型框架

在模型构建部分，作者基于趋势跟踪与动量的生成信号，并引入了考虑高阶矩的效用函数评估模型。首先，针对风险平价的资金分配逻辑，为了防止高波动率资产主导投资组合的整体风险敞口，模型采用了基于已实现波动率倒数的加权算法。其次，对于核心的趋势跟踪模块，模型采用简单移动平均线构建二元交易信号。基于动量信号 $S_{i,t}$ ，单一资产层面的下一期趋势跟踪收益率 $R_{i,t+1}^{TF}$ 是风险资产收益率 $R_{i,t+1}^{Asset}$ 与无风险避险资产（美国 3 个月期国库券）收益率 R_{t+1}^{Cash} 的线性组合：

$$R_{i,t+1}^{TF} = S_{i,t} R_{i,t+1}^{Asset} + (1 - S_{i,t}) R_{t+1}^{Cash}$$

为了进一步优化横截面动量信号，作者定义了波动率调整后的动量评分，即过去 12 个月累计总收益率与同期波动率的比值：

$$MOM_{i,t} = \frac{R_{i,t-12 \rightarrow t}}{\sigma_{i,t-12 \rightarrow t}}$$

此外，鉴于趋势跟踪策略实质上改变了收益率的非正态分布特征，作者引入 Smetters 与 Zhang (2013) 提出的一般化效用度量标准。该指标直接源自常数相对风险厌恶的幂效用函数：

$$U(r) = \frac{(1+r)^{1-\gamma}}{1-\gamma}$$

通过该效用函数进行泰勒展开至第四阶矩，作者推导并应用了包含偏度和过度峰度的风险调整业绩评价：

$$SZ4 = \left[(1+r)^{-\gamma} SR^2 + \frac{\gamma(1+\gamma)}{6} (1+r)^{-(1+\gamma)} SR^3 \cdot Skew + \frac{\gamma(1+\gamma)(2+\gamma)}{24} (1+r)^{-(2+\gamma)} SR^4 (Kurt - 3) \right]$$

公式中SR为夏普比率， γ 是设定的相对风险厌恶系数。

实验设计、数据与实证结果

本文选取了时间跨度自 1993 年 1 月至 2015 年 3 月的月度总收益率数据，包含五大类核心资产（发达国家股票、新兴市场股票、政府债券、大宗商品、房地产信托基金 REITs），并进一步细分为 95 个国家或单一品种的底层指数。作为回测基础设定的比较基准，文章主要采用了传统的全样本等权重买入持有策略（EW）以及大类资产层面的被动风险平价配置（RP）。

实证结果证实了模型的风险控制能力。在五大类资产层面，等权组合年化收益 6.61%、波动率 12.09%、Sharpe 0.33、最大回撤 46.60%；风险平价年化收益 6.59%，但波动率降至 5.91%、Sharpe 升至 0.67、最大回撤降至 20.46%。风险平价再叠加趋势过滤后，年化收益为 6.92%、波动率 4.05%、Sharpe 1.06、最大回撤仅 4.92%。

表12、基础资产、趋势组合和风险平价策略表现

Panel A: Benchmark returns					
	Dev. equity	Emer. equity	Bonds	Comms.	REITs
Annualized return (%)	7.50	5.38	5.05	3.42	8.39
Annualized volatility (%)	15.05	23.29	2.99	15.60	18.04
Sharpe ratio	0.32	0.12	0.81	0.05	0.32
Max. monthly return (%)	11.32	17.14	3.44	13.00	20.70
Min. monthly return (%)	-18.93	-28.91	-1.89	-21.28	-27.85
Maximum drawdown (%)	53.65	61.44	4.69	57.44	67.20
Skew	-0.77	-0.71	-0.02	-0.51	-0.99
Panel B: Equal weight model					
	Equal wt	Trend following (signal length, months)			
		6	8	10	12
Annualized return (%)	6.61	7.45	8.09	8.02	7.72
Annualized volatility (%)	12.09	6.70	6.78	6.80	6.65
Sharpe ratio	0.33	0.72	0.80	0.79	0.76
Max. monthly return (%)	10.21	7.61	6.75	6.75	6.22
Min. monthly return (%)	-18.99	-6.55	-6.55	-6.55	-6.55
Maximum drawdown (%)	46.60	10.27	6.86	11.58	11.73
Skew	-1.06	-0.09	-0.16	-0.24	-0.40
Panel C: Risk parity					
	Risk parity	RP TF			
Annualized return (%)	6.59	6.92			
Annualized volatility (%)	5.91	4.05			
Sharpe ratio	0.67	1.06			
Max. monthly return (%)	3.96	3.80			
Min. monthly return (%)	-8.40	-4.92			
Maximum drawdown (%)	20.46	4.92			
Skew	-0.99	-0.55			

数据来源：The trend is our friend: Risk parity, momentum and trend following in global asset allocation，兴业证券经济与金融研究院整理

类内检验中，风险平价相对等权差异有限，趋势过滤却在五类资产中的四类改善表现。动量提高名义收益，但组合仍有明显回撤；动量叠加趋势后尾部特征改善，但风险调整后收益不一定超过单独趋势。

表13、大类资产内的波动率调整动量与趋势跟踪策略表现

	Number of positions								
	5	10	15	20	25	30	40	50	All
Annualized return (%)	13.21	13.55	13.78	13.80	13.46	13.27	12.23	11.07	8.02
Annualized volatility (%)	17.47	14.37	13.62	13.11	12.69	12.55	12.48	12.64	13.32
Sharpe ratio	0.61	0.76	0.82	0.85	0.85	0.85	0.77	0.67	0.40
Max. monthly return (%)	20.58	11.34	11.38	12.52	11.17	10.11	9.95	10.27	11.84
Min. monthly return (%)	-12.77	-15.40	-15.67	-14.37	-14.36	-14.79	-15.67	-18.80	-21.54
Maximum drawdown (%)	35.67	35.70	33.51	32.33	29.02	30.65	35.69	41.21	45.48
Skew	0.19	-0.13	-0.25	-0.30	-0.36	-0.37	-0.55	-0.82	-1.02

数据来源：The trend is our friend: Risk parity, momentum and trend following in global asset allocation，兴业证券经济与金融研究院整理

表14、跨资产类别的波动率调整动量与趋势跟踪复合策略的表现

	Number of positions								
	5	10	15	20	25	30	40	50	All
Annualized return (%)	13.86	14.08	14.46	14.53	13.64	13.38	12.31	11.16	8.73
Annualized volatility (%)	16.95	13.56	12.58	12.00	11.55	11.23	10.45	9.72	6.91
Sharpe ratio	0.66	0.84	0.94	0.99	0.95	0.96	0.93	0.88	0.88
Max. monthly return (%)	20.58	11.50	11.56	12.52	11.17	10.11	9.31	8.29	7.27
Min. monthly return (%)	-12.77	-11.02	-11.70	-11.46	-9.72	-9.17	-8.94	-8.71	-5.59
Maximum drawdown (%)	28.27	26.52	20.80	18.34	16.57	15.78	15.43	15.94	12.59
Skew	0.26	0.12	0.04	0.05	0.00	0.02	-0.02	-0.06	0.11

数据来源：The trend is our friend: Risk parity, momentum and trend following in global asset allocation，兴业证券经济与金融研究院整理

综合来看，风险平价适合跨越风险差异显著的大类资产，主要作用是降低风险集中；趋势控制更具有跨资产普适性，并更直接缓解回撤和收益次序风险。

（二）模型预测控制下的多期风险平价

Li 等（2022）将模型预测控制应用于多期风险平价优化，论文采用两阶段框架：第一阶段使用隐马尔可夫模型（HMM）识别市场状态（高/低波动），第二阶段通过 MPC 求解多期优化问题。由于风险平价条件本身的非线性特征，多期风险平价模型是一个复杂的非凸优化问题，极易陷入局部最优且计算耗时。为此，作者推导并提出了一种序列凸优化（Successive Convex Program）算法。该算法不仅保证了求解的稳健性与全局最优性，还在实证检验中实现了比原始非凸规划快 30 倍的计算速度，为需要高频调仓或大规模资产配置的量化策略提供了极具价值的算法基础。

核心模型框架

在模型构建部分，作者详细阐述了如何将风险平价与 MPC 融合。文章首先定义了波动率作为风险度量指标： $R(\pi) = \sqrt{\pi^T \Sigma \pi}$ 。基于欧拉分解，第 i 个资产的边际风险贡献定义为 $\partial_i R = (\Sigma \pi)_i / \sqrt{\pi^T \Sigma \pi}$ 。因此，第 i 个资产的绝对风险贡献（Risk Contribution）可以表示为：

$$RC_i(\pi) = \pi_i \partial_i R = \pi_i \cdot \frac{(\Sigma \pi)_i}{\sqrt{\pi^T \Sigma \pi}}$$

为了在多期决策中强制执行风险平价条件，作者将其转化为一个最小化风险贡献偏差平方和的目标函数，并结合了由 l_1 范数表示的交易成本惩罚项。在 MPC 框架下，给定时间 t 对未来 τ 期的协方差预测矩阵 $\widehat{\Sigma}_{\tau|t}$ ，多期风险平价基础模型（非凸版本）的优化目标设定为：

$$\text{Minimize}_{\pi_{t+1}, \dots, \pi_{t+H} \in \mathbb{R}^n} \sum_{\tau=t+1}^{\tau=t+H} \left[\sum_{i=1}^n \left(\frac{\pi_{\tau,i} (\widehat{\Sigma}_{\tau|t} \pi_{\tau})_i}{\pi_{\tau}^T \widehat{\Sigma}_{\tau|t} \pi_{\tau}} - b_i \right)^2 + \gamma^{\text{trade}} \|\pi_{\tau} - \pi_{\tau-1}\|_1 \right]$$

约束条件为做多限制 $\pi_{\tau} \geq 0$ 以及全额投资约束 $1^T \pi_{\tau} = 1$ 。公式中 H 代表预测步长， γ^{trade} 控制着换手率的惩罚力度， b_i 为风险预算（对于严格的风险平价，所有 $b_i = 1/n$ ）。面对上述模型带来的非凸性挑战，作者引入了序列凸优化算法。令 $g_{\tau,i}(\pi_{\tau,i}) = \frac{\pi_{\tau,i} (\widehat{\Sigma}_{\tau|t} \pi_{\tau})_i}{\pi_{\tau}^T \widehat{\Sigma}_{\tau|t} \pi_{\tau}} - b_i$ 表示偏离风险预算的程度。在第 k 次迭代中，算法在当前的权重向量 π_{τ}^k 处对 $g_{\tau,i}$ 进行一阶线性泰勒展开： $g_{\tau,i}(\pi_{\tau}) \approx g_{\tau,i}(\pi_{\tau}^k) + (\nabla g_{\tau,i}(\pi_{\tau}^k))^T (\pi_{\tau} - \pi_{\tau}^k)$ 。通过引入正则化项 δ_{τ} 并展开平方和，原始非凸目标函数被重构为一个严格的凸二次规划问题：

$$\text{Minimize}_{\pi_{\tau}} \sum_{\tau=t+1}^{\tau=t+H} \left[\left(\frac{1}{2} \pi_{\tau}^T Q_{\tau}^k \pi_{\tau} + \pi_{\tau}^T q_{\tau}^k \right) + \gamma^{\text{trade}} \|\pi_{\tau} - \pi_{\tau-1}\|_1 \right]$$


其中 Q_{τ}^k 是一个正定矩阵，确保了问题的凸性。算法通过不断迭代求解这个凸问题，稳定且快速地收敛到满足风险平价的全局最优投资组合权重。为了支持上述多期前瞻性参数的输入，文章还串联使用了一个两状态（正常与收缩）的隐马尔可夫模型（HMM）来生成未来每一期的收益率向量 $\hat{r}_{\tau|t}$ 与协方差矩阵 $\widehat{\Sigma}_{\tau|t}$ 的预测值。

实验设计、数据与实证结果

在实证部分，为了全面检验多期风险平价（MPO_RP）与多期均值方差（MPO）的表现，作者选取了涵盖 10 个大类资产（包括美股、全球股票、新兴市场股票、各期限美债、企业债、高收益债、原油、黄金和房地产）的日度数据，时间跨度为 1991 年至 2020 年。整个回测框架采用滚动窗口的方法：过去 2000 天的数据用于估计 HMM 状态转移矩阵和资产参数，随后在设定的计划跨度 H 内进行优化决策，并扣除每笔双边 10bps 的交易成本。

调优阶段，作者针对多期风险平价模型确定了 $H = 15$ （即向前展望 15 个交易日）以及交易惩罚系数 $\gamma^{\text{trade}} = 0.5$ ；而对于均值方差模型，为了避免其对预期收益率估计误差过于敏感，采取了保守的风险厌恶系数 $\gamma^{\text{risk}} = 5$ 以及较短的展望期 $H = 5$ 。

图10、风险平价组合超参数调优结果



数据来源：Multi-period portfolio optimization using model predictive control with mean-variance and risk parity frameworks，兴业证券经济与金融研究院整理

此外，实验首先验证了所提出算法的计算优势：当规划长度 $H = 30$ 且交易惩罚较高时，凸优化算法比非凸算法平均运算速度提升近 100 倍，且完全消除了算法不收敛的错误。下表展示了两两种算法平均单次迭代的计算耗时对比。

表15、两种算法平均单次迭代表现


Horizon (H)	Problem Type	γ^{trade}						
		10^{-6}	10^{-5}	10^{-4}	10^{-3}	0.01	0.05	0.1
Mean Running Time (sec)								
$H = 1$	Problem 3	0.01	0.01	0.01	0.01	0.01	0.02	0.03
	Problem 7	0.02	0.02	0.02	0.02	0.02	0.02	0.02
$H = 5$	Problem 3	0.12	0.11	0.11	0.15	0.19	0.41	0.55
	Problem 7	0.08	0.07	0.07	0.08	0.07	0.08	0.08
$H = 15$	Problem 3	1.20	1.19	1.18	1.30	2.58	6.13	7.82
	Problem 7	0.21	0.22	0.22	0.22	0.24	0.24	0.24
$H = 30$	Problem 3	5.50	5.64	5.48	5.41	11.54	34.47	47.59
	Problem 7	0.45	0.45	0.43	0.40	0.43	0.47	0.5

数据来源：Multi-period portfolio optimization using model predictive control with mean-variance and risk parity frameworks，兴业证券经济与金融研究院整理

扣除交易成本后，MPO_RP（多期风险平价）取得了高达 0.97 的夏普比率，而 MPO（多期均值方差）的夏普比率为 0.64。作为对比，传统的等权固收策略（ $1/n$ ）夏普比率仅为 0.57，60/40 股债组合也仅为 0.54。得益于 MPC 框架下的 γ^{trade} 惩罚机制，多期策略的换手率得到了有效控制，MPO 的换手率比 $1/n$ 基准大幅降低了 95%，MPO_RP 的换手率也降低了 42%。

针对 2020 年 3 月新冠疫情引发的极端市场环境，作者进行了深入的微观归因分析，下图展示了 MPO 与 MPO_RP 在疫情期间的资产表现与仓位变化。结果表明，面对系统性崩盘，MPO 模型大幅加仓了表现最好的美国长牛国债以追逐收益；而 MPO_RP 模型则从风险均衡的视角出发，避开了波动率剧烈放大的资产，将资金分散配置在具备低波动特征的稳健资产上。

图11、MPO 与 MPO_RP 在疫情期间的资产表现与仓位变化



数据来源：Multi-period portfolio optimization using model predictive control with mean-variance and risk parity frameworks，兴业证券经济与金融研究院整理

(三) 动态风险偏好、最小交易手数和交易成本

Liu 等（2023）则从另一个角度拓展多期框架。论文提出基于平均 VaR 的多期投资组合优化模型，整合了三个要素：（1）动态风险偏好——投资者风险厌恶系数随市场条件和过去投资结果动态变化，而非传统模型中的恒定值；（2）最低交易手数约束——证券持有量以整数手为单位，反映真实市场的不可分性；（3）不确定变量处理——使用不确定变量捕捉收益率估计中的不准确性。论文采用遗传算法求解混合整数规划问题，并通过蒙特卡洛回测框架评估。实证使用 2 种资产、1000 周期回测，设计了多种动态交易策略（DTf、DTp、DTfp 等），发现综合策略（DTcomb）在扣除交易成本后的净夏普比率最优。

核心模型框架

在模型构建部分，作者首先对金融资产的超额收益率及其内在的预测因子动态变化进行了数学刻画。假设市场中存在 n 种风险资产，其超额收益率序列由特定的预测因子驱动。在时间 $t+1$ 的超额收益率向量 R_{t+1} 被设定为由当前的因子状态向量 f_t 及其随机冲击项组合而成。具体而言，收益预测机制被建模为如下的自回归因子系统：

$$R_{t+1} = Bf_t + \epsilon_{t+1}^r$$

$$\Delta f_{t+1} = \Phi f_t + \epsilon_{t+1}^f$$

在上述公式中， R_{t+1} 表示资产超越无风险利率的超额收益向量； f_t 代表具备均值回归特性的预测因子矩阵； B 为因子载荷矩阵； Φ 为决定因子均值回归速度的参数矩阵； e_{t+1}^r 和 e_{t+1}^f 分别代表不可预测的资产收益率噪音与因子系统冲击。

在定义了市场环境后，模型引入了投资决策变量，即每个时期投资组合中各资产的权重向量序列 w_t 。为了贴近真实交易，作者详细构建了交易成本函数 TC 。有别于传统模型仅考虑简单的线性费率。对于二次交易成本结构，其矩阵形式表达为：

$$TC(\Delta w_t) = 0.5 \Delta w_t^T \lambda \Delta w_t$$

其中， Δw_t 表示在时期 t 进行的资产权重调整， λ 是一个 $n \times n$ 的正定对称矩阵，代表交易成本系数。如果考虑到更加复杂的市场冲击与滑点，单个资产的超线性交易成本则被建模为：

$$TC_i(u_i) = a_i|u_i| + b_i|u_i|^{1.5} + c_i u_i^2$$

这里的 u_i 代表归一化后的单个资产交易量，参数 a_i 、 b_i 、 c_i 共同决定了交易规模对成本的非线性放大效应。

基于上述收益预测与交易摩擦设定，作者将传统的单期均值-方差目标函数扩展到了一个具有无限视野的多期动态控制框架中。考虑到投资者风险偏好 γ 的动态属性，以及对未来现金流的贴现，核心的多期优化目标函数被设定为最大化扣除交易成本与风险惩罚后的期望效用现值：


$$\text{Max}_{w_0, w_1, \dots} \mathbb{E} \left[\sum_{t=0}^{+\infty} (1 - \rho)^{t+1} (w_t^T \mu_{t+1} - \frac{\gamma}{2} w_t^T \Sigma w_t) - (1 - \rho)^t \frac{1}{2} \Delta w_t^T \lambda \Delta w_t \right]$$

在这一核心公式中， $\rho \in (0,1)$ 代表跨期折现率，确保了无限期求和的数学收敛性； $w_t^T \mu_{t+1}$ 代表基于因子模型预测出的下一期期望超额收益； $w_t^T \Sigma w_t$ 代表投资组合的协方差风险度量； γ 则是随时间推移和账户状态可能发生漂移的动态风险厌恶系数。

实验设计、数据与实证结果

为了验证这一多期动态组合模型的实证效能，作者设计了一套蒙特卡洛模拟与回测实验框架，系统性地评估模型在各种生成路径下的鲁棒性。实验的回测周期长度被设定为 1000 个交易日。为了模拟真实的资产波动率与价格发现过程的复杂性，生成数据中注入了 15%强度的随机噪音，整个实验执行了 10^5 次独立模拟路径的测算。

图12、运行回测流程图




数据来源：Portfolio optimization: A multi-period model with dynamic risk preference and minimum lots of transaction，兴业证券经济与金融研究院整理

在对比基准与策略设计方面，实验并行测试了多种交易策略以剥离并验证因子预测与动态优化的贡献度，包括：仅关注慢速衰减因子的动态策略（ DT_f ）、仅关注快速均值回归因子的动态策略（ DT_p ）、将慢速与快速因子进行复合加权的综合动态策略（ DT_{fp} ），以及作为传统基准的单期朴素均值方差策略。回测的评价指标不仅包括了未扣除费用的毛夏普比率，更核心聚焦于扣除了二次或超线性摩擦成本后的净夏普比率，以及在险价值和投资组合的平均持仓周期。

实证结果揭示，在所有的策略中，综合动态交易策略 DT_{fp} 通过有效利用预测因子的均值回归速度与方差特征，在扣除摩擦成本后取得了最高的净夏普比率。下图展示在没有最低交易成本约束下，带做空机制的最高夏普比率策略的风险收益散点图分布。

图13、无最低交易费用的多期交易



数据来源：Portfolio optimization: A multi-period model with dynamic risk preference and minimum lots of transaction，兴业证券经济与金融研究院整理

与此同时，实验进行了针对交易成本敏感性的压力测试。数据清晰地表明，随着交易成本系数的增加，所有策略的夏普比率均不可避免地出现下滑。然而，动态风险模型的性能衰退曲线要比传统的静态均值方差基准来得平缓。这是由于多期动态模型具有内生的前瞻性，当它预知到市场交易成本昂贵时，会自动拉长资产的平均持有期以规避高昂的换手率损耗。此外，针对不同结构的交易成本，实证指出，非二次型（即包含一次绝对值和超线性项）的交易成本会对高频调仓

策略造成毁灭性的打击，而本文提出的多期动态平滑技术能够平衡捕捉短期因子 Alpha 与控制换手摩擦。

（四）按最终组合质量训练风险模型的端到端学习

Anis 和 Kwon (2022) 提出端到端 (E2E) 预测-优化网络，将因子模型参数估计与基数约束最小方差优化整合为统一的三层神经网络，损失函数直接采用基于决策的年化夏普比率。由于基数约束导致可行域不连续，论文设计了三种连续凸松弛 (Big-M、SOCP、SDP) 作为决策层。

核心模型框架

结合传统的资产收益线性因子模型，某一资产的收益率可表示为关于潜变量（系统性因子）的回归：

$$r_t = \alpha + Bf_t + \epsilon_t$$

其中， r_t 为资产收益向量， α 为截距项向量， $B \in \mathbb{R}^{N \times P}$ 为 N 个资产在 P 个因子上的载荷矩阵， f_t 为因子收益向量， ϵ_t 为残差收益向量。假设残差无偏且相互独立，其协方差矩阵为对角阵 $\Psi = \text{Diag}(\psi_1^2, \dots, \psi_N^2)$ 。基于此，整个投资组合的协方差矩阵可以被参数化表示为：

$$\Sigma(B, \Psi; \Sigma_f) = B \Sigma_f B^T + \Psi$$

在端到端框架中，作者试图让神经网络学习的参数正是 $\theta = \{B, \Psi\}$ ，以替代传统的最小二乘估计。

为了使带有基数约束 $\|w\|_0 \leq k$ 的组合优化问题变得在深度学习框架中可微，作者引入了连续松弛策略。论文重点构建并比较了三种能够转化为规范参数化规划的可微决策层：

- 1) 第一种是传统的 Big-M 松弛框架 (E2E_M)。该方法通过引入连续变量 $z \in [0, 1]^N$ ，并配合约束 $1^T w = 1$ 、 $1^T z = k$ 以及 $w \leq z$ 来近似原始的组合逻辑。虽然其连续松弛界限最为松散，但由于其保持了二次规划的简单形式，计算效率极高；
- 2) 第二种是二阶锥规划松弛框架 (E2E_{SOCP})。作者借鉴了文献中的透视函数 (Perspective function) 重构方法，将原本的组合方差利用拉格朗日分解技术剥离为系统性风险与异质性风险，并引入辅助变量 δ 重构了透视约束 $w_i^2 \leq \delta_i z_i$ 。为了满足 DPP 规则，作者进一步引入辅助变量 v 和 $\tilde{v}$ ，将模型转化为如下规范形式的决策层：

$$\min_{w, z, \delta, v, \tilde{v}} \tilde{v}^T \tilde{v} + \text{diag}(\Psi)^T \delta$$

受到 $\mathbf{1}^T \mathbf{w} = 1, \mathbf{1}^T \mathbf{z} \leq k, \mathbf{w} \leq \mathbf{z}, \mathbf{z} \leq \mathbf{1}$ 以及 $\tilde{\mathbf{v}} = \sum_f \frac{1}{f} \mathbf{v}, \mathbf{v} = \mathbf{B}^T \mathbf{w}$ 等约束，且满足二阶锥限制 $\mathbf{w}_i^2 \leq \delta_i z_i$ 。

3) 第三种是半正定规划松弛框架 (E2E_{SDP})。该方法基于互补性约束的松弛，通过定义 $\mathbf{W} = \mathbf{w}\mathbf{w}^T$ 并将其放宽为 $\mathbf{W} \geq \mathbf{w}\mathbf{w}^T$ ，使用舒尔补引理构建出更为紧密的凸半正定松弛。其目标函数利用迹内积改写为：

$$\langle \Sigma, \mathbf{W} \rangle = \langle \Sigma_f, \mathbf{B}^T (\mathbf{W}\mathbf{B}) \rangle + \langle \Psi, \mathbf{W} \rangle$$

在构建了上述可微决策层后，神经网络的前向传播输入因子数据的协方差 $\Sigma_f^{(j)}$ ，经由决策层求解输出当前参数下最优的投资权重 $\mathbf{w}^{*(j)}$ 。反向传播时，网络需要一个能够衡量决策质量的损失函数 $\mathcal{L}$ 。传统的回归关注均方误差(任务损失)，而本文为了最大化投资者的最终效用，选用了基于决策的已实现损失，即直接以外推样本计算的年化夏普比率的负值作为梯度下降的目标。其损失函数计算公式为：

$$\mathcal{L} = -\frac{(1 + \mu(r_p))^{365} - 1}{\sqrt{256} \times \sigma(r_p)}$$


通过隐式函数定理结合 KKT 条件计算出雅可比矩阵 $\frac{\partial \mathbf{w}}{\partial \theta}$ ，网络实现了从优化决策结果到协方差矩阵参数 θ 的端到端梯度回传 ($\nabla_{\theta} \mathcal{L}^{(j)} = \frac{\partial \mathcal{L}^{(j)}}{\partial \mathbf{w}} \frac{\partial \mathbf{w}}{\partial \theta}$)，从而训练出能够抵御线性模型偏差且以高夏普比率为直接导向的因子载荷矩阵。

实验设计、数据与实证结果

为了充分论证端到端深度优化框架的优越性，作者设计了滚动回测与参数评估实验。数据集选取了标普 500 指数中覆盖各个 GICS 行业板块的 50 只代表性成分股作为资产池，时间跨度覆盖从 2010 年 1 月 1 日至 2021 年 12 月 31 日的日度收盘数据转化而来的周度收益率。

由于深度神经网络的训练对数据量有极大渴求，传统的单一时间序列窗口会造成严重的样本匮乏与过拟合风险。作者应用了循环块自助抽样法，通过构建长度为 20 的数据块并循环拼接，作者生成了 2000 个伪时间序列样本 ($J = 2000$) 用于网络训练，每个 Epoch 动态更新损失梯度。如下图给出了 E2E 框架的计算图，展示输入层、可微决策层和损失函数的前向与反向传播过程。

图14、E2E 框架



数据来源：End-to-end, decision-based, cardinality-constrained portfolio optimization，兴业证券经济与金融研究院整理

在比较基准方面，作者设定了两个对照组：其一是线性因子回归模型(linReg)，即直接通过历史数据做普通最小二乘回归获得参数，再输入二次规划求解器；其二是名义模型 (nominal)，即完全摒弃因子结构，直接利用样本资产收益率估算样本协方差矩阵。回测采用滚动窗口机制，每三个月重平衡一次，每次使用过去五年的数据进行参数重估与网络再训练。实验针对三种不同的基数约束参数设定 ($k = 10, 15, 20$) 进行了全方位对比。

在样本外回测中，E2E 框架在取得更高年化收益率的同时，系统性地维持了更低的年化波动率水平。在下行风险与尾部风险度量上，虽然 nominal 模型在名义在险价值上表现尚可，但 E2E 模型在最大回撤和较低阶部分动差 (LPM) 上展现出更强的防御属性。

表16、 E2E 策略回测表现

	Cardinality	E2E _M	E2E _{SOC P}	E2E _{SDP}	linReg	nominal
annRet	10	0.19080	0.17757	0.16993	0.15346	0.16844
	15	0.17067	0.16969	0.16982	0.14241	0.15331
	20	0.17287	0.16871	0.17082	0.14410	0.15504
annVol	10	0.16739	0.16954	0.16969	0.17545	0.16856
	15	0.16855	0.16669	0.16701	0.17014	0.16797
	20	0.16870	0.16694	0.16820	0.16997	0.16735
VaR	10	0.01224	0.01214	0.01263	0.01281	0.01200
	15	0.01218	0.01232	0.01239	0.01269	0.01193
	20	0.01222	0.01236	0.01218	0.01278	0.01203
CVaR	10	0.02413	0.02445	0.02433	0.02509	0.02382
	15	0.02441	0.02438	0.02427	0.02446	0.02389
	20	0.02452	0.02436	0.02442	0.02445	0.02385
LPM ₂	10	0.08152	0.08452	0.08421	0.09267	0.08351
	15	0.08370	0.08246	0.08213	0.08736	0.08536
	20	0.08390	0.08262	0.08368	0.08679	0.08427
maxDD	10	0.31490	0.33608	0.33308	0.35852	0.34166
	15	0.33576	0.33465	0.32081	0.34914	0.36566
	20	0.33568	0.33481	0.33702	0.34761	0.36321
Turnover	10	5.17213	5.45467	5.91742	4.31490	5.37183
	15	4.27483	4.48355	4.57151	3.12208	4.54260
	20	3.90106	4.71012	4.76647	3.02471	4.39783

数据来源：End-to-end, decision-based, cardinality-constrained portfolio optimization，兴业证券经济与金融研究院整理

表17、不同基数约束下 E2E 模型回测表现

	Cardinality	E2E _M	E2E _{SOC P}	E2E _{SDP}	linReg	nominal
Sharpe	10	1.13985	1.00142	1.04737	0.87469	0.99929
	15	1.01257	1.01685	1.01799	0.83699	0.91276
	20	1.02472	1.01553	1.01061	0.84780	0.92645
Omega	10	0.04470	0.04130	0.03950	0.03410	0.04020
	15	0.03960	0.03939	0.03956	0.03225	0.03686
	20	0.04020	0.03929	0.03972	0.03281	0.03730
Calmar	10	0.60591	0.51018	0.52837	0.42804	0.49301
	15	0.50832	0.52936	0.50707	0.40787	0.41928
	20	0.51498	0.50684	0.50389	0.41454	0.42685
Sortino	10	2.34069	2.01794	2.10088	1.65596	2.01714
	15	2.03909	2.06766	2.05771	1.63005	1.79601
	20	2.06055	2.04128	2.04201	1.66023	1.83967
Information	10	0.19371	0.01329	0.01214	-0.11203	
	15	0.16284	0.15342	0.01232	-0.09414	
	20	0.16846	0.15226	0.01236	-0.09887	

数据来源：End-to-end, decision-based, cardinality-constrained portfolio optimization，兴业证券经济与金融研究院整理

此外，研究发现结构最为简单的 **Big-M** 框架 ($E2E_M$)，其样本外夏普比率、收益率以及信息比率击败了理论上更为严密且计算极度复杂的 **SOC**P 与 **SDP** 松弛框架。在单次 **Epoch** 训练耗时上， $E2E_M$ 仅需约 15 秒，而 $E2E_{SDP}$ 需要超过 6 个小时，效率差距达三个数量级。

五、总结

综合不同研究，可以看到当前海外风险平价研究呈现以下整体特征：

- 1) 研究目标从追求形式上的风险贡献相等，转向追求样本外有效的风险分散。传统模型可能在估计协方差下实现精确等风险，但如果风险度量不合适或参数误差较大，这种均衡未必真实。尾部风险、因子协方差和鲁棒优化都在弱化对单一估计值的依赖。
- 2) 风险预算对象从证券向风险来源迁移。行业风险、相关网络、风格因子和管理人 **alpha** 比单只资产更能解释组合为何承受风险。风险平价因此不仅是一种权重计算方法，也逐渐成为风险归因和组织投资决策的框架。
- 3) 风险平价由静态配置规则演变为动态决策过程。前瞻波动率、多期 **MPC**、机器学习方向信号和端到端训练使参数估计、权重形成和交易执行逐渐一体化。相应地，评价重点也从样本内风险贡献误差转向样本外收益、回撤、换手和成本后绩效。
- 4) 风险平价越来越多地与其他策略结合。趋势、动量、机器学习择时和指数跟踪并不属于传统风险平价本身，却能够围绕风险预算骨架提供收益来源、状态控制和产品化应用。这种融合提高了实用性，也增加了绩效归因难度。

但同时可以发现，现有文献并未形成“复杂模型统一优于传统风险平价”的结论。静态因子协方差计成本后可能优于动态模型；机器学习 **CVaR-RP** 并非在所有指标上领先；鲁棒 **RP** 的数值优势未必具有统计显著性；趋势策略的增益有时大于风险平价加权本身。未来风险平价研究的核心竞争不再是求解更精确的静态权重，而是能否建立一个在风险定义、参数估计、结构选择和动态交易之间保持一致、透明且样本外稳健的风险预算体系。

参考文献

- [1] CLARE A, SEATON J, SMITH P N, 等. Trend following, risk parity and momentum in commodity futures[J/OL]. International Review of Financial Analysis, 2014, 31: 1-12. DOI:10.1016/j.irfa.2013.10.001.
- [2] CLARE A, SEATON J, SMITH P N, 等. The trend is our friend: Risk parity, momentum and trend following in global asset allocation[J/OL]. Journal of Behavioral and Experimental Finance, 2016, 9: 63-80. DOI:10.1016/j.jbef.2016.01.002.

- [3] BELLINI F, CESARONE F, COLOMBO C, 等. Risk parity with expectiles[J/O L]. European Journal of Operational Research, 2021, 291(3): 1149-1163. DOI:10.1016/j.ejor.2020.10.009.
- [4] ANIS H T, KWON R H. Cardinality-constrained risk parity portfolios[J/OL]. European Journal of Operational Research, 2022, 302(1): 392-402. DOI:10.1016/j.ejor.2021.12.045.
- [5] ANIS H T, KWON R H. End-to-end, decision-based, cardinality-constrained portfolio optimization[J/OL]. European Journal of Operational Research, 2025, 320(3): 739-753. DOI:10.1016/j.ejor.2024.08.030.
- [6] LI X, UYSAL A S, MULVEY J M. Multi-period portfolio optimization using model predictive control with mean-variance and risk parity frameworks[J/OL]. European Journal of Operational Research, 2022, 299(3): 1158-1176. DOI:10.1016/j.ejor.2021.10.002.
- [7] ANIS H T, COSTA G, KWON R H. Risk-allocation-based index tracking[J/O L]. Computers & Operations Research, 2023, 154: 106219. DOI:10.1016/j.cor.2023.106219.
- [8] DI PERSIO L, GARBELLI M, MOTTAGHI F, 等. Volatility forecasting with hybrid neural networks methods for Risk Parity investment strategies[J/OL]. Expert Systems with Applications, 2023, 229: 120418. DOI:10.1016/j.eswa.2023.120418.
- [9] CHO Y, SONG J W. Hierarchical risk parity using security selection based on peripheral assets of correlation-based minimum spanning trees[J/OL]. Finance Research Letters, 2023, 53: 103608. DOI:10.1016/j.frl.2022.103608.
- [10] LIU Y, ZHOU Y, NIU J. Portfolio optimization: A multi-period model with dynamic risk preference and minimum lots of transaction[J/OL]. Finance Research Letters, 2023, 55: 103964. DOI:10.1016/j.frl.2023.103964.
- [11] LEE T K, SOHN S Y. Alpha-factor integrated risk parity portfolio strategy in global equity fund of funds[J/OL]. International Review of Financial Analysis, 2023, 88: 102654. DOI:10.1016/j.irfa.2023.102654.
- [12] CONLON T, COTTER J, KYNIGAKIS I. Asset allocation with factor-based covariance matrices[J/OL]. European Journal of Operational Research, 2025, 325(1): 189-203. DOI:10.1016/j.ejor.2025.03.015.
- [13] SHENG J, CHEN L, CHEN H, 等. CVaR-based risk parity model with machine learning[J/OL]. Pacific-Basin Finance Journal, 2025, 93: 102857. DOI:10.1016/j.pacfin.2025.102857.
- [14] LI Y, YE Z. Research on asset allocation strategies based on robust risk parity model[J/OL]. Finance Research Letters, 2026, 92: 109586. DOI:10.1016/j.frl.2026.109586.

风险提示：文献结论外推至 A 股存在市场制度与数据口径差异；报告结论基于历史数据，在市场环境转变时存在失效风险。

分析师声明

本人具有中国证券业协会授予的证券投资咨询执业资格并登记为证券分析师，以勤勉的职业态度，独立、客观地出具本报告。本报告清晰准确地反映了本人的研究观点。本人不曾因，不因，也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

投资评级说明

投资建议的评级标准	类别	评级	说明
报告中投资建议所涉及的评级分为股票评级和行业评级（另有说明的除外）。评级标准为报告发布日后的 12 个月内公司股价（或行业指数）相对同期相关证券市场代表性指数的涨跌幅。其中：沪深两市以沪深 300 指数为基准；北交所市场以北证 50 指数为基准；新三板市场以三板成指为基准；香港市场以恒生指数为基准；美国市场以标普 500 或纳斯达克综合指数为基准。	股票评级	买入	相对同期相关证券市场代表性指数涨幅大于 15%
		增持	相对同期相关证券市场代表性指数涨幅在 5% ~ 15% 之间
		中性	相对同期相关证券市场代表性指数涨幅在 -5% ~ 5% 之间
		减持	相对同期相关证券市场代表性指数涨幅小于 -5%
		无评级	由于我们无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使我们无法给出明确的投资评级
	行业评级	推荐	相对表现优于同期相关证券市场代表性指数
		中性	相对表现与同期相关证券市场代表性指数持平
		回避	相对表现弱于同期相关证券市场代表性指数

信息披露

本公司在知晓的范围内履行信息披露义务。客户可登录 www.xyzq.com.cn 内幕交易防控栏内查询静默期安排和关联公司持股情况。

使用本研究报告的风险提示以及法律声明

兴业证券股份有限公司经中国证券监督管理委员会批准，已具备证券投资咨询业务资格。

本公司不会因接收人收到本报告而视其为客户。本报告中的信息、意见等均仅供客户参考，不构成所述证券买卖的出价或征价邀请或要约，投资者自主作出投资决策并自行承担投资风险，任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效，任何有关本报告的摘要或节选都不代表本报告正式完整的观点，一切须以本公司向客户发布的本报告完整版本为准。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐。客户应当对本报告中的信息和意见进行独立评估，并应同时考量各自的投资目的、财务状况和特定需求，必要时就法律、商业、财务、税收等方面咨询专家的意见。对依据或者使用本报告所造成的一切后果，本公司及/或其关联人员均不承担任何法律责任。

本报告所载资料的来源被认为是可靠的，但本公司不保证其准确性或完整性，也不保证所包含的信息和建议不会发生任何变更。本公司并不对使用本报告所包含的材料产生的任何直接或间接损失或与此相关的其他任何损失承担任何责任。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌，过往表现不应作为日后的表现依据；在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告；本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的回报预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。本公司没有将此意见及建议向报告所有接收者进行更新的义务。本公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

本报告并非针对或意图发送予或为任何就发送、发布、可得到或使用此报告而使兴业证券股份有限公司及其关联子公司等违反当地的法律或法规或可致使兴业证券股份有限公司受制于相关法律或法规的任何地区、国家或其他管辖区域的公民或居民，包括但不限于美国及美国公民（1934 年美国《证券交易所》第 15a-6 条例定义为本「主要美国机构投资者」除外）。

本报告的版权归本公司所有。本公司对本报告保留一切权利。除非另有书面显示，否则本报告中的所有材料的版权均属本公司。未经本公司事先书面授权，本报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。未经授权的转载，本公司不承担任何转载责任。

特别声明

在法律许可的情况下，兴业证券股份有限公司可能会持有本报告中提及公司所发行的证券头寸并进行交易，也可能为这些公司提供或争取提供投资银行业务服务。因此，投资者应当考虑到兴业证券股份有限公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。

兴业证券研究

上海	北京	深圳
地址：上海浦东新区长柳路 36 号兴业证券大厦 15 层	地址：北京市朝阳区建国门外大街甲 6 号世界财富大厦 32 层 01-08 单元	地址：深圳市福田区皇岗路 5001 号深业上城 T2 座 52 楼
邮编：200135	邮编：100020	邮编：518035
邮箱： research@xyzq.com.cn	邮箱： research@xyzq.com.cn	邮箱： research@xyzq.com.cn