超星·期刊

2017年3月 运筹学学报 第21卷 第1期
Mar., 2017 Operations Research Transactions Vol.21 No.1

DOI: 10.15960/j.cnki.issn.1007-6093.2017.01.001

CVaR鲁棒均值-CVaR投资组合模型与求解*

康志林[1,3] 李仲飞[2,†]

摘要 传统的均值-风险(包括方差、VaR、CVaR等)组合选择模型在计算最优投资组合时, 常假定均值是已知的常值, 但在实际资产配置中, 收益的均值估计会有偏差, 即存在着估计风险. 在利用CVaR测度估计风险的基础上, 研究了CVaR鲁棒均值-CVaR投资组合选择模型, 给出了另外两种不同的求解方法, 即对偶法和光滑优化方法, 并探讨了它们的相关性质及特征, 数值实验表明在求解大样本或者大规模投资组合选择问题上, 对偶法和光滑优化方法在计算上是可行且有效的.

关键词 组合证券投资, CVaR鲁棒, 对偶法, 光滑化, 重采样

中图分类号 F830.9, O224.0

2010 数学分类号 90C26, 90C22, 65K05

CVaR robust mean-CVaR portfolio optimization model and the solving methods*

KANG Zhilin[1,3] LI Zhongfei[2,†]

Abstract When calculating the optimal portfolios, the traditional mean-risk (including variance, value-at-risk (VaR), conditional value at risk (CVaR)) optimization model often assumes that mean returns are known constant values. In actual asset allocation, however, estimation of mean return will have deviation, namely there exists risk of estimation. On the basis of estimating the risk measured by CVaR, this paper further studies CVaR robust mean-CVaR portfolio optimization model and presents two different optimization algorithms, namely, the dual method and the smoothing method. Moreover, we explore some properties and characteristics of the two methods. Finally, we give some numerical experiments to show the feasibility and effectiveness of these two methods.

Keywords portfolio selection, CVaR robust, dual method, smoothing method, resampling

收稿日期: 2016-09-14

*基金项目: 国家自然科学基金重点项目(No. 71231008), 福建省中青年教师教育科研项目(No. JA15041), 广东省自然科学基金团队项目(No. 2014A030312003)

1. 中山大学数学学院, 广州 510275; School of Mathematics, Sun Yat-sen University, Guangzhou 510275, China

2. 中山大学管理学院, 广州 510275; Sun Yat-sen Business School, Sun Yat-sen University, Guangzhou 510275, China

3. 华侨大学数学科学学院, 福建泉州 362021; School of Mathematical Science, Huaqiao University, Quanzhou 362021, Fujian, China

† 通信作者 E-mail: lnslzf@mail.sysu.edu.cn

超星·期刊

Chinese Library Classification F830.9, O224.0
2010 Mathematics Subject Classification 90C26, 90C22, 65K05

0 引 言

现代投资组合优化方法应具有以下良好的特征: 一是现实的收益分布; 二是合理的风险测度方式; 三是计算上可处理. Markowitz[1]于1952年提出了用均值和方差度量投资组合收益与风险的均值-方差 (M-V) 模型. 风险测度相对于收益是比较主观的, 基于此, 很多学者从不同的角度给出了风险的度量方式. VaR是金融机构在市场正常波动下衡量证券组合可能损失的一个统计测度, 亦称风险价值, 其含义是在给定置信水平下, 某一金融资产或证券组合在未来特定一段时间内的最大可能损失. 该测度能够以较大概率保证未来遭受的最大可能损失不超过某一值. 更具体地, 假设一个投资组合在未来一年内95%的在险价值为50万美元, 其含义是这笔资金在一年内, 由于市场价格变动而带来的最大损失超过50万美元的概率等于5%. 5%的概率水平反映了投资者的风险厌恶程度. 此外, 不同于VaR, CVaR指的是损失超过VaR的条件均值, 也称平均超额损失, 它代表了超额损失的平均水平, 反映了损失超过VaR阈值时可能遭受平均潜在损失的大小, 较之VaR更能体现潜在的风险价值. 由于VaR 不满足次可加性, 即证券组合的风险不一定小于各证券风险之和, 所以它不是一致性风险度量. 容易发现, VaR只依赖于单一的损失函数的分位数, 它不一定满足凸性, 而CVaR作为一致性风险度量[2], 它的计算可通过构造一个功能函数化为一个凸函数优化问题[3], 而且在计算CVaR的同时可获得VaR值.

传统的收益-风险(如方差、CVaR等)优化模型在计算最优投资组合都是假定收益的均值μ是已知的真实值. 在整个投资建模过程中, 这些参数(如均值、协方差矩阵等)往往被假定是常值, 且保持不变的, 这是一个非常强的假设. 实际上, 资产配置中模型所用的参数, 一般都是基于历史数据计算得到的点估计参数值. 在这个过程中, 由于对均值μ的估计会产生估计误差, 容易导致所得到的参数估计值会有较大的偏差. 因此, 用此参数值直接代入收益-风险模型所求得的组合权重会随着所代入估计值的不同而产生较大的波动, 且这些投资组合的样本外表现可能也会相当差. 基于此, 很多学者利用鲁棒优化思想(即对未来可能出现的最差情景做出一个最好的反应), 提出了不同形式的鲁棒收益-风险投资组合优化模型, 如鲁棒均值-方差优化模型[4-8], 鲁棒均值-VaR优化模型[9], 鲁棒均值-CVaR优化模型[10,11], 有兴趣的读者可进一步参阅文献[12,13].

由于无法观测到整个样本, 所以，组合投资优化模型中所用的均值常常是基于所选择的数据样本. 不同的数据样本段得到的是不同的参数估计值. 这意味着所得到的收益的均值, 它本身也是一随机变量. Zhu[14,15]考虑了期望收益估计的不确定性, 利用CVaR来度量投资组合的均值损失 $(-\mu^{\mathrm{T}}x)$, 构建了CVaR鲁棒均值-方差投资组合优化模型, 考察了其有效前沿对初始收益样本数据的敏感度, 并与经典的min-max 投资组合在有效前沿、多样性及有效性上进行了比较. 为了求解大规模的投资组合选择问题, 作者们还给出了一种光滑技术来提高算法的求解效果. 在此基础上, Salahi[16]考虑了CVaR鲁棒均值-CVaR投资组合优化模型, 数值实验分析表明, CVaR鲁棒投资在资产配置方式上会比传统的min-max鲁棒 (区间、椭球不确定集)投资组合更具多样性, 且随着估计风险厌恶参数水平的增加 (其对应着投资者更加厌恶估计风险), 多样化水平越高, 可实现的收益值越小. 此外，利用文献[17]与[18]的思想, 该文进一步研究了鲁棒优化模型的光滑优化方法.

超星·期刊

本文受文献[17-20]的启发, 基于CVaR风险度量函数, 进一步研究了Salahi[16]提出的CVaR鲁棒均值-CVaR投资组合优化模型, 给出了其对偶规划问题的形式. 此外, 借助最大熵函数及光滑优化思想, 给出了CVaR鲁棒均值-CVaR投资组合优化模型的光滑近似优化问题, 并探讨了该问题的一些性质和特征. 最后, 给出了对偶法和光滑化方法相应的数值算例分析.

1 CVaR鲁棒均值-CVaR投资组合优化

1.1 均值-CVaR投资组合优化

在传统收益-风险框架下, 均值-CVaR投资组合优化问题

$$\text{(MC)} \qquad \min_{x} \ -\mu^{\mathrm{T}}x + \lambda \mathrm{CVaR}_{\beta}(x),$$
$$\text{s.t.} \ \sum_{i=1}^{n} x_i = 1, \ x_i \geqslant 0,$$

其中$\mu \in \mathbb{R}^n$ 表示n个风险资产的期望收益向量, x_i为投资在第i个资产的比例, $x = (x_1, \cdots, x_n)^{\mathrm{T}} \in \mathbb{R}^n$, 等式约束表示投资者在投资过程中需要满足的预算约束, 且不允许卖空, λ为风险厌恶系数, β为CVaR风险度量的置信水平(一般地, 取$\beta \in [0.9, 1)$). 根据Rockafellar和Uryasev 在文[3]提出的方法, $\mathrm{CVaR}_{\beta}(x)$ 的值可以通过最小化如下函数:

$$F_{\beta}(x, \gamma) = \gamma + \frac{1}{1-\beta} \int_{r \in \mathbb{R}^n} [f(x, r) - \gamma]^{+} p(r) \mathrm{d}r,$$

其中$[t]^{+} = \max\{0, t\}$, 即

$$\mathrm{CVaR}_{\beta}(x) = \min_{\gamma \in \mathbb{R}} F_{\beta}(x, \gamma).$$

在实际资产配置中, 投资组合损失$f(x, r)$ (常取$f(x, r) = -r^{\mathrm{T}}x$)的其分布封闭形式的表达式是难以获得的, 通常$F_{\beta}(x, \gamma)$可以由经验分布函数近似

$$\widetilde{F}_{\beta}(x, \gamma) = \gamma + \frac{1}{(1-\beta)} \sum_{i=1}^{S} q_i [f(x, r_i) - \gamma]^{+},$$

其中S是资产收益情景数, $r_i \in \mathbb{R}^n (i = 1, \cdots, S)$表示资产收益第$i$个情景, q_i是情景i发生的概率, 满足$\sum\limits_{i=1}^{S} q_i = 1, q_i \geqslant 0$. 如果样本数$S$充分大, 由统计学上的大数定律, 可知$\widetilde{F}_{\beta}(x, \gamma)$是$F_{\beta}(x, \gamma)$的一个良好近似. 此外, 在数值计算中, 常假定各情景i的发生是等概率的, 即式中的q_i均等于$\frac{1}{S}$.

因此, 容易将均值-CVaR投资组合优化问题转化为

$$\min_{x, \gamma} \ -\mu^{\mathrm{T}}x + \lambda \Big(\gamma + \frac{1}{1-\beta} \sum_{i=1}^{S} q_i [-r_i^{\mathrm{T}}x - \gamma]^{+} \Big),$$
$$\text{s.t.} \ \sum_{i=1}^{n} x_i = 1, \ x_i \geqslant 0.$$

超星·期刊

通过引入辅助变量$z_i \geqslant 0(i=1,\cdots,S)$, 上述问题可进一步转化为

$$\begin{aligned}&\min_{x,z,\gamma} \quad -\mu^{\mathrm{T}}x+\lambda\Big(\gamma+\frac{1}{1-\beta}\sum_{i=1}^{S}q_i z_i\Big),\\&\text{s.t. } z_i \geqslant -r_i^{\mathrm{T}}x-\gamma, \quad i=1,\cdots,S,\\&\qquad \sum_{i=1}^{n}x_i=1,\ x_i\geqslant 0.\end{aligned}$$

在实际计算过程中, 对参数μ的估计会产生估计误差. 因此, 用此参数直接代入(MC)所求得的组合权重会随着所代入估计值的不同而产生较大的波动, 且这些投资组合的样本外表现可能会相当差.

1.2 CVaR鲁棒均值-CVaR投资组合优化

对于(MC)模型, 从另一角度看, 目标函数不仅对风险$\mathrm{CVaR}_\beta(x)$求最小化, 同时最小化均值损失$-\mu^{\mathrm{T}}x$. 由于期望收益估计的不确定性, 为了度量和控制估计μ的风险, 故将其作为一种特殊类型的风险引入到(MC)模型中并利用CVaR 来测度估计量μ的风险[14]. 因此, 在实际计算中可以假定μ是未知的, 通过考虑均值损失量$-\mu^{\mathrm{T}}x$ 的不确定性, CVaR鲁棒均值-CVaR 投资组合优化问题即为

$$\begin{aligned}\text{(CRMC)}\qquad &\min_{x,\gamma} \quad \mathrm{CVaR}_\alpha^{\mu}(-\mu^{\mathrm{T}}x)+\lambda\Big(\gamma+\frac{1}{1-\beta}\sum_{i=1}^{S}q_i[-r_i^{\mathrm{T}}x-\gamma]^{+}\Big),\\&\text{s.t. } \sum_{i=1}^{n}x_i=1,\ x_i\geqslant 0,\end{aligned}$$

其中$\mathrm{CVaR}_\alpha^{\mu}(-\mu^{\mathrm{T}}x)$表示投资组合均值损失的$(1-\alpha)$-尾部平均值. 对于该模型, 置信水平$\alpha$可以被解释为估计风险厌恶参数. 调整厌恶参数水平$\alpha$对应着投资者对估计风险容忍度的调整. 当$\alpha$值增加时, 投资组合均值损失的$\mathrm{CVaR}_\alpha^{\mu}$值会相应地增加. 特别是当$\alpha$趋近于1时, 该优化进程更关注的是由于$\mu$的不确定性所带来的极端平均损失, 同时这也意味着投资者在对均值μ的估计过程中所带来的估计风险是具有较高的厌恶度. 反之, 随着α的减小趋近于零时, 投资者将较少的重点放在最坏的平均损失情景下, 且对估计风险具有较高的容忍度. 总而言之, CVaR鲁棒技术主要还是用来处理期望收益估计的困难, 进而减少估计过程中可能带来的估计风险.

假定$p(\mu)$是资产期望收益随机变量的概率密度函数, $\mu_i \in \mathbb{R}^n(i=1,\cdots,m)$ 为从该分布中抽取的独立样本(即资产期望收益第i个样本值), $p_i(i=1,\cdots,m)$是每个独立样本μ_i发生的概率(在计算上, 可假定$p_i=\frac{1}{m}$), 则CVaR鲁棒均值-CVaR 投资组合优化问题(CRMC), 其对应的经验分布优化问题为

$$\begin{aligned}&\min_{x,\eta,\gamma} \quad \widetilde{F}(x,\eta,\gamma),\\&\text{s.t. } \sum_{i=1}^{n}x_i=1,\ x_i\geqslant 0,\end{aligned}$$

超星·期刊

其中

$$\widetilde{F}(x,\eta,\gamma)=\eta+\frac{1}{1-\alpha}\sum_{i=1}^{m}p_i[-\mu_i^{\mathrm{T}}x-\eta]^+ +\lambda\Big(\gamma+\frac{1}{1-\beta}\sum_{i=1}^{S}q_i[-r_i^{\mathrm{T}}x-\gamma]^+\Big).$$

进一步地, 引入辅助变量$v_i\geqslant 0(i=1,\cdots,m)$, 可得

$$\begin{aligned}\text{(CRMC-P)}\qquad &\min_{x,z,v,\gamma,\eta}\ \eta+\frac{1}{1-\alpha}\sum_{i=1}^{m}p_iv_i+\lambda\Big(\gamma+\frac{1}{1-\beta}\sum_{i=1}^{S}q_iz_i\Big),\\ &\text{s.t. } z_i\geqslant-\sum_{j=1}^{n}r_{ij}x_j-\gamma,\quad i=1,\cdots,S, &(1.1)\\ &\qquad v_i\geqslant-\sum_{j=1}^{n}\mu_{ij}x_j-\eta,\quad i=1,\cdots,m, &(1.2)\\ &\qquad\sum_{i=1}^{n}x_i=1,\ \ x_i\geqslant 0,\ i=1,\cdots,n,\\ &\qquad z_i\geqslant 0,i=1,\cdots,S,v_i\geqslant 0,i=1,\cdots,m,\end{aligned}$$

其中μ_{ij}表示资产j在第i个样本下期望收益的实现值, r_{ij}是资产j在情景i下资产收益的实现值, S是期望收益的总样本数. 显然, 问题 (CRMC-P) 是具有$O(m+n+S)$阶个变量和$O(m+S)$阶个约束的线性规划, 即变量和约束个数是按线性阶递增的.

2 CVaR鲁棒均值-CVaR组合选择问题优化方法

CVaR鲁棒均值-CVaR组合优化问题的求解在文献[16]中已有相关的讨论. 本文的意图, 是通过对CVaR鲁棒均值-CVaR组合优化问题的进一步研究, 探讨不同于现有文献解决该投资组合优化问题的两种求解思路, 并与现有的方法在计算的可行性与有效性上进行比较.

2.1 对偶法

利用线性规划的对偶理论, 容易得到

定理 2.1 鲁棒均值-CVaR投资组合优化问题 (CRMC-P), 其对偶优化问题为

$$\begin{aligned}\text{(CRMC-D)}\qquad &\max_{s\in\mathbb{R}^S,t\in\mathbb{R}^m,\delta\in\mathbb{R}}\ \ \delta\\ &\text{s.t. }\sum_{i=1}^{S}r_{ij}s_i+\sum_{i=1}^{m}\mu_{ij}t_i+\delta\leqslant 0,\quad j=1,\cdots,n,\\ &\qquad 0\leqslant s_i\leqslant\frac{\lambda q_i}{1-\beta},\quad i=1,\cdots,S,\\ &\qquad 0\leqslant t_i\leqslant\frac{p_i}{1-\alpha},,\quad i=1,\cdots,m,\\ &\qquad\sum_{i=1}^{S}s_i=\lambda,\ \ \sum_{i=1}^{m}t_i=1,\end{aligned}$$

超星·期刊

其中$s_i(i=1,\cdots,S), t_i(i=1,\cdots,m)$分别为对应于约束 (1.1) 和 (1.2)的拉格朗日乘子, 且模型 (CRMC-P)与模型 (CRMC-D)具有零对偶间隙, 即原问题 (CRMC-P)与对偶问题 (CRMC-D)具有相同的目标函数值.

证明 利用线性规划对偶理论(强对偶定理)即得.

可以发现, 模型 (CRMC-D) 是具有$O(m+S)$阶个变量和$O(n)$阶个约束的线性规划问题. 事实上, 可以发现投资组合资产数n的增加会导致该问题约束个数的增加, 即(CRMC-D)约束的个数是与投资的资产个数n成正比, 而与情景个数m和S是相互独立的. 这实际上为后续的数值计算带来了很大的便利. 因为在实际计算过程中, 为了获得问题更精确的解, 往往需要取较大的m和S. 因此, 在情景数目较多的情况下, 该方法从理论上是可以保证计算上是有效的. 然而, 值得注意的是, 对偶转换并不能直接应用到具有非凸结构的实际投资优化问题中, 比如带有非凸交易费用的混合整数投资组合问题.

2.2 光滑近似法

模型 (CRMC-P)是在引入两个松弛变量$z\in\mathbb{R}^S$和$v\in\mathbb{R}^m$的基础上, 将CVaR鲁棒均值-CVaR投资组合优化模型 (CRMC)转化为线性规划. 通过进一步考虑该模型的对偶问题 (CRMC-D), 可以很大程度上将模型变量的维度降低, 从而提高计算的有效性. 另一种方法是直接应用光滑逼近法来求解, 而不需要引入松弛变量和其他新的约束条件. 对于最大值函数

$$h(x)=\max_{1\leqslant i\leqslant k}\{h_i(x)\},\ x\in\mathbb{R}^n,$$

根据文献[17]的结论, 通过引入参数$\rho>0$, 可以构造该函数的光滑化函数

$$h_\rho(x)=\rho\ln\Big(\sum_{i=1}\mathrm{e}^{\frac{h_i(x)}{\rho}}\Big),$$

称此函数为最大熵函数. 该函数具有如下良好的性质.

引理 2.1[19] 对任意给定的$\rho>0$, $h_\rho(x)$具有如下性质:

(1) $h_\rho(x)$关于ρ单调递增, 即对于任意的$\rho_1>\rho_2>0$, 有$h_{\rho_1}(x)\geqslant h_{\rho_2}(x)$.

(2) $0\leqslant h_\rho(x)-h(x)\leqslant\rho\ln k$, 且$\lim\limits_{\rho\to0}h_\rho(x)=h(x)$.

(3) $h_\rho(x)$关于ρ是二次连续可微的, 且

$$\begin{aligned}\bigtriangledown_x h_\rho(x)=&\sum_{i=1}^k a_i(\rho,x)\nabla h_i(x),\\ \bigtriangledown_x^2 h_\rho(x)=&\sum_{i=1}^k\Big[a_i(\rho,x)\nabla h_i^2(x)+\frac{1}{\rho}a_i(\rho,x)\nabla h_i(x)\nabla h_i(x)^{\mathrm{T}}\Big]\\ &-\frac{1}{\rho}\Big(\sum_{i=1}^k a_i(\rho,x)\nabla h_i(x)\Big)\Big(\sum_{i=1}^k a_i(\rho,x)\nabla h_i(x)\Big)^{\mathrm{T}},\end{aligned}$$

其中$a_i(\rho,x)=\dfrac{\mathrm{e}^{\frac{h_i(x)}{\rho}}}{\sum\limits_{i=1}^m\mathrm{e}^{\frac{h_i(x)}{\rho}}}$. 此外, 如果$h_i(x)(i=1,\cdots,k)$为线性函数, 则对所有的$\rho>0$, $h_\rho(x)$是无限阶可微凸函数.

超星·期刊

通过引入参数$\rho_1>0$和$\rho_2>0$, 可对CVaR鲁棒均值-CVaR投资组合优化问题 (CRMC)的目标函数进行光滑化, 即对$\mathrm{CVaR}_\alpha^\mu(-\mu^{\mathrm{T}}x)$式子中隐含的$[-\mu^{\mathrm{T}}x-\eta]^+$项和$\mathrm{CVaR}_\beta\ (-r^{\mathrm{T}}x)$式子中隐含的$[-r^{\mathrm{T}}x-\gamma]^+$ 项利用最大熵函数进行光滑化处理. 现定义函数

$$g_{1s}^i(x,\eta)=\rho_1\ln(\mathrm{e}^{\frac{-\mu_i^{\mathrm{T}}x-\eta}{\rho_1}}+1),\quad i=1,\cdots,m,$$

$$g_{2s}^i(x,\gamma)=\rho_2\ln(\mathrm{e}^{\frac{-r_i^{\mathrm{T}}x-\gamma}{\rho_2}}+1),\quad i=1,\cdots,S,$$

其中$\rho_1>0,\rho_2>0$. 特别地, 当样本值m和情景值S很大时, 光滑优化函数是$[\cdot]^+$函数良好的近似. 由此, 容易得到以下定理.

定理 2.2 对于CVaR鲁棒均值-CVaR投资组合优化问题 (CRMC), 其光滑近似优化问题可表示为

$$\text{(CRMC-S)}\qquad \min_{x\in\mathbb{R}^n,\eta\in\mathbb{R},\gamma\in\mathbb{R}}\tilde{F}_s(x,\eta,\gamma)$$
$$\text{s.t. }\sum_{i=1}^n x_i=1,\ x_i\geqslant 0,\quad i=1,\cdots,n, \tag{2.1}$$

其中目标函数$\tilde{F}_s(x,\eta,\gamma)=\eta+\frac{1}{1-\alpha}\sum\limits_{i=1}^m p_i g_{1s}^i(x,\eta)+\lambda(\gamma+\frac{1}{1-\beta}\sum\limits_{i=1}^S q_i g_{2s}^i(x,\gamma))$.

显然, 模型 (CRMC-S)是具有$O(n)$阶个变量和$O(1)$阶个约束的非线性优化问题. 以下定理进一步说明了问题 (CRMC-S)是光滑的凸优化问题, 这为模型 (CRMC-S)的求解带来了极大的便利.

定理 2.3 若

$$\tilde{F}_s^1(x,\eta)=\eta+\frac{1}{1-\alpha}\sum_{i=1}^m p_i g_{1s}^i(x,\eta),\quad \tilde{F}_s^2(x,\gamma)=\gamma+\frac{1}{1-\beta}\sum_{i=1}^S q_i g_{2s}^i(x,\gamma),$$

则函数$\tilde{F}_s^1(x,\eta)$关于变量x,η是凸的, $\tilde{F}_s^2(x,\gamma)$关于变量x,γ是凸的, 且函数

$$\tilde{F}_s(x,\eta,\gamma)=\tilde{F}_s^1(x,\eta)+\tilde{F}_s^2(x,\gamma)$$

关于变量x,η,γ是凸函数. 此外, $\tilde{F}_s(x,\eta,\gamma)$是连续可微的, 即

$$\begin{aligned}\nabla_x\tilde{F}_s(x,\eta,\gamma)=&\frac{1}{1-\alpha}\sum_{i=1}^m p_i\frac{\mathrm{e}^{(-\mu_i^{\mathrm{T}}x-\eta)/\rho_1}}{\mathrm{e}^{(-\mu_i^{\mathrm{T}}x-\eta)/\rho_1}+1}(-\mu_i)\\&+\frac{1}{1-\beta}\sum_{i=1}^S q_i\frac{\mathrm{e}^{(-r_i^{\mathrm{T}}x-\gamma)/\rho_2}}{\mathrm{e}^{(-r_i^{\mathrm{T}}x-\gamma)/\rho_2}+1}(-r_i),\\ \nabla_\eta\tilde{F}_s(x,\eta,\gamma)=&1-\frac{1}{1-\alpha}\sum_{i=1}^m p_i\frac{\mathrm{e}^{(-\mu_i^{\mathrm{T}}x-\eta)/\rho_1}}{\mathrm{e}^{(-\mu_i^{\mathrm{T}}x-\eta)/\rho_1}+1},\\ \nabla_\gamma\tilde{F}_s(x,\eta,\gamma)=&1-\frac{1}{1-\beta}\sum_{i=1}^S q_i\frac{\mathrm{e}^{(-r_i^{\mathrm{T}}x-\gamma)/\rho_2}}{\mathrm{e}^{(-r_i^{\mathrm{T}}x-\gamma)/\rho_2}+1}.\end{aligned}$$

证明 令$\vec{\eta}=(x^{\mathrm{T}},\eta)^{\mathrm{T}}\in\mathbb{R}^{n+1}$, 则

$$g_{1s}^i(x,\eta)=g_{1s}^i(\vec{\eta})=\rho_1\ln(\mathrm{e}^{\frac{g_1^i(\vec{\eta})}{\rho_1}}+1),$$

超星·期刊

其中$g_1^i(\vec{\eta}) = -\mu_i^{\mathrm{T}}x - \eta$. 由引理2.1, 容易推得

$$\begin{aligned}\bigtriangledown_{\vec{\eta}}^2 g_{1s}^i(\vec{\eta}) =& a_1(\rho_1,\vec{\eta})\nabla^2 g_1^i(\vec{\eta}) + \frac{1}{\rho_1}a_1(\rho_1,\vec{\eta})\nabla g_1^i(\vec{\eta})(\nabla g_1^i(\vec{\eta}))^{\mathrm{T}}\\ &- \frac{1}{\rho_1}(a_1(\rho_1,\vec{\eta})\nabla g_1^i(\vec{\eta}))(a_1(\rho_1,\vec{\eta})\nabla g_1^i(\vec{\eta}))^{\mathrm{T}},\end{aligned}$$

其中$a_1(\rho_1,\vec{\eta}) = \frac{\mathrm{e}^{\frac{g_1^i(\vec{\eta})}{\rho_1}}}{\sum\limits_{i=1}^{m}\mathrm{e}^{\frac{g_1^i(\vec{\eta})}{\rho_1}}}$. 对任意$d \in \mathbb{R}^{n+1}$, 由于$g_1^i(\vec{\eta})$关于变量$\vec{\eta}$是凸的, 且$a_1(\rho_1,\vec{\eta}) \in [0,1]$. 因此, 有

$$d^{\mathrm{T}}\bigtriangledown_{\vec{\eta}}^2 g_{1s}^i(\vec{\eta})d = a_1(\rho_1,\vec{\eta})d^{\mathrm{T}}\nabla^2 g_1^i(\vec{\eta})d + \frac{1}{\rho_1}a_1(\rho_1,\vec{\eta})(1-a_1(\rho_1,\vec{\eta}))(d^{\mathrm{T}}\nabla g_1^i(\vec{\eta}))^2 \geqslant 0,$$

即$\tilde{F}_s^1(x,\eta)$关于变量x,η是凸函数. 类似可以证明, 函数$\tilde{F}_s^2(x,\gamma)$关于变量x,γ也是凸函数.

进一步地, 令$z = (x^{\mathrm{T}},\eta,\gamma)^{\mathrm{T}} \in \mathbb{R}^{n+2}$, 则对任意的实数$\theta \in (0,1)$, 有

$$\begin{aligned}\tilde{F}_s(\theta z_1 + (1-\theta)z_2) &= \tilde{F}_s(\theta x_1 + (1-\theta)x_2, \theta\eta_1 + (1-\theta)\eta_2, \theta\gamma_1 + (1-\theta)\gamma_2)\\ &= \tilde{F}_s^1(\theta x_1 + (1-\theta)x_2, \theta\eta_1 + (1-\theta)\eta_2)\\ &\quad +\tilde{F}_s^1(\theta x_1 + (1-\theta)x_2, \theta\gamma_1 + (1-\theta)\gamma_2)\\ &\leqslant \theta\tilde{F}_s^1(x_1,\eta_1) + (1-\theta)\tilde{F}_s^1(x_2,\eta_2) + \theta\tilde{F}_s^2(x_1,\gamma_1)\\ &\quad +(1-\theta)\tilde{F}_s^2(x_2,\gamma_2)\\ &= \theta\tilde{F}_s(x_1,\eta_1,\gamma_1) + (1-\theta)\tilde{F}_s(x_2,\eta_2,\gamma_2)\\ &= \theta\tilde{F}_s(z_1) + (1-\theta)\tilde{F}_s(z_2).\end{aligned}$$

由此可知, $\tilde{F}_s(x,\eta,\gamma)$关于变量$x,\eta,\gamma$是凸的. 此外, 直接对函数$\tilde{F}_s(x,\eta,\gamma)$ 求导, 容易得到它是连续可微的.

进一步, 通过简单计算, 有以下定理成立.

定理 2.4 对任意给定的$\rho_1 > 0, \rho_2 > 0$, 有

$$0 \leqslant \tilde{F}_s(x,\eta,\gamma) - \tilde{F}(x,\eta,\gamma) \leqslant \Big(\frac{\rho_1}{1-\alpha} + \frac{\lambda\rho_2}{1-\beta}\Big)\ln 2,$$

且当ρ_1,ρ_2趋近于0时, $\tilde{F}_s(x,\eta,\gamma)$趋近于$\tilde{F}(x,\eta,\gamma)$, 即

$$\lim_{(\rho_1,\rho_2)\to 0}\tilde{F}_s(x,\eta,\gamma) = \tilde{F}(x,\eta,\gamma).$$

注 2.1 由定理2.3可知, 问题 (CRMC-S)是一个非线性凸规划问题, 它可以保证获得CVaR鲁棒均值-CVaR 投资组合优化问题的全局最优解. 特别是当ρ_1, ρ_2取值比较小时, 由定理2.4, 光滑化函数$\tilde{F}_s(x,\eta,\gamma)$是函数$\tilde{F}(x,\eta,\gamma)$的一个良好近似.

注 2.2 由于函数$-\mu^{\mathrm{T}}x - \eta$和$-r^{\mathrm{T}}x - \gamma$是线性的, 根据引理2.1, 易知 (CRMC-S)中的目标是无限阶可微的. 因此, 在求解 (CRMC-S)时可以根据该问题的特性构造光滑优化算法, 如序列二次规划方法(SQP).

超星·期刊

3 数值分析

由于CVaR鲁棒均值-CVaR投资优化模型的计算依赖于均值随机变量μ和资产收益随机变量r的分布, 在实际投资实践中, 两者的分布通常都是未知的. 对于资产收益的均值, 类似于Zhu[14,15]的方法, 利用重采样技术产生μ合理的样本实现值$\mu_1, \mu_2, \cdots, \mu_m$. 对于资产收益, 可利用计算机仿真生成$r$不同的情景数$r_1, r_2, \cdots, r_S$.

3.1 重采样技术及情景生成

容易发现, 计算CVaR鲁棒投资组合需要事先知道μ的分布信息, 基于不同μ的分布假设, Zhu[15] 利用两种抽样技术生成期望收益μ可能/合理的实现值: 一种是重抽样技术(RS technique), 另一种是卡方抽样技术(CHI technique). 重采样技术通常是指从一个假定的概率分布, 比如多元正态分布, 再现模拟的历史. 该仿真是基于Jorin[21]的理念, 并被Michaud[22]引入到稳健投资中, 且已经得到广泛的应用. 本文中, 所使用的重采样方法可简要概述如下:

步骤1 给定的均值和协方差矩阵, 按正态分布抽取n个资产的S个样本.

步骤2 对这S个收益样本, 计算均值样本μ.

步骤3 重复步骤1和步骤2至m次, 得到m个收益的均值样本序列:

$$\mu_1, \mu_2, \cdots, \mu_m.$$

在已有的研究文献中, 用于生成资产收益情景数的方法有很多, 主要有(等概率)历史情景法、蒙特卡洛模拟法、自助法和矩匹配方法. 在这些方法中, 最简单的情景生成法是历史情景法, 该方法主要是基于过去收益实现值可以代表未来收益这样的前提假设. 蒙特卡洛方法是从指定的分布中生成情景数的一种参数法. 复杂一点的方法是从历史数据中进行随机重抽样, 如自助法, 或者从一个已选定的多元分布函数中进行随机抽样, 如蒙特卡洛模拟法, 或者对未来收益进行预测的方法. 矩匹配方法是产生一组随机变量的离散情景数, 使得边际分布的一阶至四阶矩(均值, 标准偏差, 偏度和峰度), 以及相关系数匹配指定的目标值. 这些目标值可以从历史数据中估计得到. 该方法可以完全控制生成情景数的矩. 以上这些都是基于单阶段情景数生成方法的介绍, 有兴趣的读者可进一步参阅文献[23]. 此外, 关于多阶段情景数的生成, 可参阅文献[24]. 众所周知, 影响股票价格变化的因素主要有股票价格随时间上涨的趋势和股票价格的平均波动率. 本文中, 我们采用标准的金融资产价格模型, 即几何布朗运动产生资产收益的情景数. 设P^j表示第j 个资产的价格, μ_j表示资产预期收益率, σ_j 表示波动率, 且μ_j, σ_j均为常数, t表示时间, w为标准布朗运动, 则有

$$\mathrm{d}P^j(t) = \mu_j P^j \mathrm{d}t + \sigma_j P^j \mathrm{d}w,\ j = 1, \cdots, n,$$

其中$\mathrm{d}w = \varepsilon\sqrt{\mathrm{d}t}$, $\varepsilon \sim \mathcal{N}(0,1)$. 由此, 第$j$个资产的模拟收益率$r_i^j (i = 1, \cdots, S)$为

$$r_i^j = \frac{P_{i+1}^j - P_i^j}{P_i^j},$$

其中$P_0^j = 1$. 由此, 可以得到n个资产的S个收益情景序列: $r_1, r_2, \cdots, r_S$.

所有测试都在Matlab 7.6.0下, 且基于Intel(R) Core(TM) i5-5300U, CPU @ 2.30 GHz, 8GB内存的环境下进行, 并使用CPLEX-12.5.1优化包求解(CRMC-P) 和(CRMC-D). 本文中, 在R软件的基础上利用重采样技术生成不同数目期望收益μ的样本数m, 基于Matlab环

超星·期刊

境利用几何布朗运动通过计算机仿真生成不同数目收益r的情景数S, 并采用Matlab优化工具箱的fmincon函数求解(CRMC)的光滑优化问题(CRMC-S).

3.2 计算有效性

为了便于比较(CRMC-P), (CRMC-D) 和 (CRMC-S)不同方法的有效性, 按照3.1节的论述, 在给定8个资产的期望收益和协方差矩阵下(见表1, 数据取自文献[14]或[16]), 采用重抽样技术生成μ样本, 并利用几何布朗运动通过计算机仿真生成不同资产收益的情景.

表 1 8个资产投资组合的均值与协方差矩阵

0.01 ×	A1	A2	A3	A4	A5	A6	A7	A8
均值	1.016 0	0.474 6	0.475 6	0.473 4	0.474 2	–0.050 0	–0.112 0	0.036 0
A1	0.098 0	0.065 9	0.071 4	0.010 5	0.005 8	–0.023 6	–0.016 4	0.000 4
A2	0.065 9	0.154 9	0.091 1	0.005 8	0.037 9	–0.026 0	0.007 9	–0.024 8
A3	0.071 4	0.091 1	0.273 8	–0.006 2	–0.011 6	0.008 3	0.005 9	0.007 7
A4	0.010 5	0.005 8	–0.006 2	0.009 7	0.008 2	–0.021 5	–0.000 3	–0.002 6
A5	0.005 8	0.037 9	–0.011 6	0.008 2	0.046 1	–0.031 5	0.007 6	–0.030 4
A6	–0.023 6	–0.026 0	0.008 3	–0.021 5	–0.031 5	0.269 1	–0.008 0	0.015 9
A7	–0.016 4	0.007 9	0.005 9	–0.000 3	0.007 6	–0.008 0	0.092 5	–0.009 5
A8	0.000 4	–0.024 8	0.007 7	–0.002 6	–0.030 4	0.015 9	–0.009 5	0.024 5

在数值计算中, 模型 (CRMC-P), (CRMC-D) 和 (CRMC-S)中的一些参数是需要预先设定的. 相比于 (CRMC-P) 和 (CRMC-D), 模型 (CRMC-S) 增加了两个光滑化参数ρ_1和ρ_2. 据此, 各模型参数设置如下(见表2).

表 2 模型CRMC-P, CRMC-D, CRMC-S的参数设置

参数	α	β	λ	ρ_1	ρ_2
CRMC-P	0.95	0.95	1	×	×
CRMC-D	0.95	0.95	1	×	×
CRMC-S	0.95	0.95	1	0.000 1	0.000 1

为了更好地说明模型 (CRMC-D), (CRMC-S)在计算上的有效性, 选取了不同维度的样本数m和情景数S, 并将其与模型 (CRMC-P) 在CPU计算时间上进行比较. 其结果如下.

表 3 模型CRMC-P, CRMC-D, CRMC-S的CPU时间(秒)

(m, S)	CRMC-P	CRMC-D	CRMC-S
(2 000,200)	6.406 7	0.674 3	4.154 0
(5 000,500)	15.682 8	0.690 8	9.944 4
(8 000,800)	34.551 1	0.855 9	11.799 3
(10 000,1 000)	47.890 6	1.072 9	16.358 3
(25 000,3 000)	307.455 4	2.812 2	38.139 4
(50 000,10 000)	1 393.9	14.518 6	132.962 2

从表3中容易发现, 直接求解对偶模型 (CRMC-D)在CPU计算时间上具有非常明显的优势. 如对于样本数和情景数为(8 000,800)的情形, (CRMC-D)仅需要0.855 9秒, (CRMC-

超星·期刊

P)则需要34.551 1秒, 且对于其他各种不同维度的样本和情景数(m,S), 模型 (CRMC-D)在计算的时间上都比 (CRMC-P) 和 (CRMC-S)低, 且维持在一个较低的水平上. 此外, 从整体上看, 模型 (CRMC-D)与模型 (CRMC-S)优于 (CRMC-P), 且模型 (CRMC-P)随着样本和情景维度的增加, 所需要的CPU时间也显著增加. 因此, 从某种程度上说, 对偶法和光滑化法在确定CVaR鲁棒投资组合是相对有效的.

为了进一步比较光滑优化方法 (CRMC-S)与线性优化方法 (CRMC-P)的异同, 定义投资组合的(平均)相对偏差函数

$$\mathrm{error}_{x_i^*}=\left|\frac{x_{i,s}^*-x_{i,p}^*}{x_{i,p}^*}\right|\times 100\%,\quad \mathrm{error}_{x^*}=\frac{1}{n}\sum_{i=1}^{n}\mathrm{error}_{x_i^*},$$

其中$x_{i,s}^*$和$x_{i,p}^*$分别对应于 (CRMC)光滑优化问题 (CRMC-S)和线性优化问题 (CRMC-P)的最优解. 类似地, 定义CVaR值的相对偏差如下

$$\mathrm{error}_{\alpha}=\left|\frac{\mathrm{CVaR}_{\alpha,s}^{\mu}-\mathrm{CVaR}_{\alpha,p}^{\mu}}{\mathrm{CVaR}_{\alpha,p}^{\mu}}\right|\times 100\%,\quad \mathrm{error}_{\beta}=\left|\frac{\mathrm{CVaR}_{\beta,s}-\mathrm{CVaR}_{\beta,p}}{\mathrm{CVaR}_{\beta,p}}\right|\times 100\%,$$

其中$\mathrm{CVaR}_{\alpha,s}^{\mu}$和$\mathrm{CVaR}_{\alpha,p}^{\mu}$分别对应于光滑优化问题 (CRMC-S)和线性优化问题 (CRMC-P) 的$\mathrm{CVaR}_{\alpha}^{\mu}$ 值, $\mathrm{CVaR}_{\beta,s}$和$\mathrm{CVaR}_{\beta,p}$分别对应于光滑优化问题(CRMC-S)和线性优化问题(CRMC-P) 的CVaR_{β}值. 为了讨论上的方便, 只选取样本数和情景数(m,S)为$(10\,000,1\,000)$和$(50\,000,10\,000)$两种情形, 相关结果见表4和表5.

表 4 CRMC-P方法和CRMC-S方法结果比较$(m=50\,000,S=10\,000)$

	CRMC-P	CRMC-S	error(%)
x^*			1.186 5
$\mathrm{CVaR}_{\alpha}^{\mu}(x^*)$	–0.007 547	–0.007 535	0.160 7
$\mathrm{CVaR}_{\beta}(x^*)$	0.002 294	0.002 325	1.336 2
objective	–0.005 252	–0.005 209	0.814 8

表 5 CRMC-P方法和CRMC-S方法结果比较$(m=50\,000,S=10\,000)$

	CRMC-P	CRMC-S	error(%)
x^*			1.127 9
$\mathrm{CVaR}_{\alpha}^{\mu}(x^*)$	–0.008 202	–0.008 198	0.044 3
$\mathrm{CVaR}_{\beta}(x^*)$	0.002 106	0.002 154	2.267 8
objective	–0.006 096	–0.006 044	0.843 2

从表4和表5可以发现, 随着样本数m和情景数S的增加, 模型CRMC-P和模型CRMC-S对应解的误差也逐渐减小, 当(m,S)取$(10\,000,1\,000)$ 时, 投资组合(平均)相对偏差为1.186 5%, 而当(m,S)取$(50\,000,10\,000)$时, (平均)相对偏差为1.127 9%. 此外, 对应目标函数值的误差均小于1%.

4 结 论

本文基于分位数风险度量CVaR考虑了均值-CVaR投资组合优化模型, 基于期望收益估计的不确定性, 利用CVaR测度期望收益的估计风险, 进一步研究了CVaR鲁棒均值-CVaR投资组合优化模型, 探讨了两种新的求解方法, 即对偶法和光滑法, 并探讨了它们

超星·期刊

的相关性质及特征. 数值实验表明, 对偶法和光滑化法是可行的, 且对于各种不同维度的期望收益样本数和收益情景数, 模型(CRMC-D)与(CRMC-S)在CPU计算时间上均优于模型(CRMC-P). 特别是在求解大样本或者大规模投资组合选择问题上, 对偶法和光滑优化方法在计算上有其明显的优越性.

参 考 文 献

[1] Markowitz H. Portfolio selection [J]. *Journal of Finance*, 1952, **7**(1): 77-91.
[2] Artzner P, Delbaen F, Eber J M, et al. Coherent measures of risk [J]. *Mathematical Finance*, 1999, **9**(3): 203-228.
[3] Rockafellar R T, Uryasev S. Optimization of conditional value-at-risk [J]. *Journal of Risk*, 2000, **2**: 21-41.
[4] Lobo M S, Boyd S. The worst-case risk of a portfolio [J]. *Journal of Economic Dynamics and Control*, 2000, **26**(3): 1159-1193.
[5] Goldfarb D, Iyengar G. Robust portfolio selection problems [J]. *Mathematics of Operations Research*, 2003, **28**(1): 1-38.
[6] Tutuncu R H, Koenig M. Robust asset allocation [J]. *Annals of Operations Research*, 2004, **132**(1-4): 157-187.
[7] Garlappi L, Uppal R, Wang T. Portfolio selection with parameter and model uncertainty: a multi-prior approach [J]. *Review of Financial Studies*, 2007, **20**(1): 41-81.
[8] Ye K, Parpas P, Rustem B. Robust portfolio optimization: a conic programming approach [J]. *Computational Optimization and Applications*, 2012, **52**(2): 463-481.
[9] Ghaoui L E, Oks M, Oustry F. Worst-case value-at-risk and robust portfolio optimization: a conic programming approach [J]. *Operations Research*, 2003, **51**(4): 543-556.
[10] Quaranta A G, Zaffaroni A. Robust optimization of conditional value at risk and portfolio selection [J]. *Journal of Banking Finance*, 2008, **32**(10): 2046-2056.
[11] Zhu S, Fukushima M. Worst-case conditional value-at-risk with application to robust portfolio management [J]. *Operations Research*, 2009, **57**(5): 1155-1168.
[12] Kim J H, Kim W C, Fabozzi F J. Recent developments in robust portfolios with a worst-case approach [J]. *Journal of Optimization Theory and Applications*, 2014, **161**(1): 103-121.
[13] 梁锡坤, 徐成贤, 郑冬. 鲁棒投资组合选择优化问题的研究进展 [J]. 运筹学学报, 2014, **18**(2): 87-95.
[14] Zhu L, Coleman T F, Li Y. Min-max robust and CVaR robust mean-variance portfolios [J]. *Journal of Risk*, 2009, **11**: 1-31.
[15] Zhu L. Optimal portfolio selection under the estimation risk in mean return [D]. Waterloo: University of Waterloo, 2008.
[16] Salahi M, Mehrdoust F, Piri F. CVaR robust mean-CVaR portfolio optimization [J]. *ISRN Applied Mathematics*, 2013, Article ID 570950.
[17] Li X S, Pan S. Solving the finite min-max problem via an exponential penalty method [J]. *Computational Technologies*, 2003, **8**(2): 3-15.
[18] Alexander S, Coleman T F, Li Y. Minimizing CVaR and VaR for a portfolio of derivatives [J]. *Journal of Banking Finance*, 2006, **30**(2): 583-605.
[19] Tong X, Qi L, Wu F, et al. A smoothing method for solving portfolio optimization with CVaR and applications in allocation of generation asset [J]. *Applied Mathematics and Computation*, 2010, **216**(6): 1723-1740.
[20] Ogryczak W, Sliwinski T. On solving the dual for portfolio selection by optimizing conditional value at risk [J]. *Computational Optimization and Applications*, 2011, **50**(3): 591-595.
[21] Jorion P. Portfolio optimization in practice [J]. *Financial Analysts Journal*, 1992, **48**(1): 68-74.
[22] Michaud R O, Michaud R. *Efficient Asset Management* [M]. Boston: Harvard Business School Press, 1998.
[23] Guastaroba G, Mansini R, Speranza M G. On the effectiveness of scenario generation techniques in single-period portfolio optimization [J]. *European Journal of Operational Research*, 2009, **192**(2): 500-511.
[24] 赵大萍, 房勇. 基于贝叶斯修正的多阶段情景元素生成 [J]. 系统工程理论与实践, 2016, **36**(8): 1928-1936.