

西南财经大学

本科毕业论文（设计）



论文题目： 宽松风险平价在全球 ETF
资产配置中的改进与实证研究

所在学院： 特拉华数据科学学院

专 业： 金融数学（金融服务与量化分析方向）

学生姓名： 许哲圣

学 号： 42353012

年 级： 2023 级

指导教师： 王磊

2026 年 5 月

学术声明

本人郑重声明：所呈交的毕业论文是在指导教师指导下独立完成的研究成果。论文中引用他人已经发表或未发表成果，均已在正文和参考文献中作出明确标注。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文研究作出重要贡献的个人和集体，均已在文中以明确方式说明。

摘要

长期资产配置面对的根本问题不是预测单一资产的短期涨跌，而是在市场不确定时如何维持合理的风险分散。风险平价以风险预算为基础，降低了对预期收益估计的依赖，但当资产池扩展至全球多资产 ETF 时，相关结构动态变化、严格等风险贡献约束的非凸性以及交易成本的累积都构成实际问题。

本文围绕宽松风险平价思想，以 30 支可交易全球多资产 ETF 为研究对象，构建统一的回测框架。资产池覆盖债券、A 股宽基、中国科技、中国行业与消费、港股、全球股票和大宗商品七大类风险来源，其中中国科技板块细分为半导体、人工智能、机器人、新能源、中韩半导体、科创 50 和云计算共七支主题 ETF。绩效评价区间为 2019-01-01 至 2026-05-15，共 88 个按月观察点，采用月度调仓、3 bps 交易成本扣减和无前视设计。在同一回测框架下，本文比较了 Global RRP、Convex Adaptive Global RRP、Improved Convex Adaptive Global RRP 以及层次化基准 HRP、HERC 的表现。

Global RRP 净年化收益为 4.78%，夏普比率为 0.721，最大回撤为 -7.14%，平均月度换手率为 22.81%，是宽松风险预算在全球 ETF 资产池中的基础版本。Improved Convex Adaptive Global RRP 净年化收益为 5.66%，年化波动率为 2.61%，夏普比率为 1.471，Sortino 比率为 2.172，最大回撤为 -3.70%，平均月度换手率仅为 2.25%。HRP 与 HERC 净年化收益分别为 1.69% 与 2.25%，夏普比率分别为 -0.748 与 0.748。Improved Convex Adaptive Global RRP 在收益、回撤与换手控制之间取得了较为均衡的结果，但这并不意味着它在每个指标上都占优。

本文所有实证结论均基于特定历史评价区间和约束设定，不构成对未来收益的保证。

关键词：宽松风险平价；全球多资产配置；CVaR；换手约束；凸优化；ETF

Abstract

Long-term asset allocation is fundamentally a problem of managing risk over time, not predicting returns. Risk parity sidesteps expected-return estimation by budgeting risk instead, but when the universe expands to global multi-asset ETFs, practical complications multiply: correlations shift across regimes, exact equal-risk-contribution constraints are non-convex, and transaction costs erode enough of net return to matter at monthly rebalancing frequency.

This undergraduate thesis studies a Relaxed Risk Parity framework using 30 tradable global multi-asset ETFs. The universe spans seven asset groups: bonds, China broad equity, China technology and growth (seven thematic ETFs covering semiconductors, artificial intelligence, robotics, new energy, China-Korea cross-border semiconductors, STAR Market 50, and cloud computing), China sector and consumption, Hong Kong equity, global equity (US, Japan, Europe), and commodities. The evaluation window runs from 2019-01-01 to 2026-05-15 (88 monthly observations) with monthly rebalancing, a 3-basis-point transaction cost, and no-lookahead controls. Models compared include Global RRP, Convex Adaptive Global RRP, Improved Convex Adaptive Global RRP, HRP, and HERC.

Global RRP produces a 4.78% net annual return, a Sharpe ratio of 0.721, and a maximum drawdown of -7.14%. Average monthly turnover of 22.81% creates a visible cost drag. In Improved Convex Adaptive Global RRP, the addition of CVaR constraints, a low-turnover penalty, and group weight limits reduces turnover to 2.25% while raising net annual return to 5.66%, Sharpe to 1.471, Sortino to 2.172, and limiting drawdown to -3.70%. HRP and HERC post Sharpe ratios of -0.748 and 0.748 respectively, but both keep most of the portfolio in bonds throughout the sample, so their risk-adjusted performance mainly reflects low volatility rather than broad diversification. Improved Convex Adaptive Global RRP does not lead on every metric, but it remains the most balanced specification among the implementable alternatives considered here.

All empirical findings are conditional on the historical evaluation period and constraint settings reported here, and do not constitute a guarantee of future performance.

Keywords: Relaxed Risk Parity; Global Multi-Asset Allocation; CVaR; Turnover Constraint; Convex Optimization; ETF

目录

1	绪论	1
1.1	研究背景与意义	1
1.2	研究问题与研究思路	1
1.3	研究内容与章节安排	2
1.4	可能的边际贡献	2
2	文献综述与理论基础	2
2.1	现代投资组合理论与估计误差	2
2.2	风险平价与宽松风险平价	4
2.3	CVaR、交易成本与组合约束	5
2.4	HRP/HERC 与国内实践	5
2.5	文献评述与本文切入点	6
3	理论框架与模型方法	7
3.1	统一符号	7
3.2	标准风险平价	8
3.3	宽松风险平价与 Global RRP	9
3.4	凸优化改进模型	9
3.5	协方差估计方法	11
3.6	HRP 与 HERC 基准模型	11
4	数据、变量与研究设计	13
4.1	ETF 资产池构建原则	13
4.2	样本构造与预处理	15
4.3	收益率、权重、交易成本与换手率定义	16
4.4	组合约束与调仓规则	16
4.5	评价指标体系	17
4.6	回测流程与无前视设计	17

4.7	可靠性与诊断层	18
4.8	描述性统计与资产特征分析	18
5	实证结果分析	20
5.1	主模型绩效比较	20
5.2	HRP/HERC 基准模型对比	21
5.3	净值路径与回撤分析	22
5.4	换手率与权重结构分析	23
5.5	CVaR 尾部风险分析	27
5.6	因子暴露与收益归因	28
5.7	小结	30
6	稳健性检验与过拟合诊断	31
6.1	子区间与压力期检验	31
6.2	交易成本与参数敏感性	33
6.3	协方差估计与过拟合诊断	35
6.4	分块自助法检验	37
6.5	成对夏普差异显著性检验	38
6.6	小结	40
7	结论与展望	40
7.1	主要结论	40
7.2	研究不足	42
7.3	后续研究方向	42
7.4	与桥水全天候策略的横向对比	43
A	主要指标定义汇总	45
B	CSCV 候选参数网格	47
	参考文献	49

1. 绪论

1.1 研究背景与意义

资产配置在很大程度上决定了长期组合的风险收益特征^[1]。与短期择时策略相比，长期资产配置更关注不同资产类别间的风险来源、回撤控制和流动性管理。保险资金、养老金和银行理财等长期资金通常需要在多年时间维度上维持稳定的风险暴露，管理难度不只在收益水平，如何说清楚收益来自哪里、风险分散到什么程度、调仓成本是否可控，同样是实际问题。

风险平价和风险预算方法正是针对这类需求发展起来的。其核心思想不是资本金额的均匀分配，而是使不同资产对组合总风险的贡献更加均衡。这种方法对收益预测的依赖程度较低，适合构建可解释性强的长期配置框架^[2-3]。扩展到全球 ETF 后，问题变得复杂：不同市场收盘时间不一致，海外 ETF 带汇率暴露，各标的上市时间参差不齐，商品和权益的尾部行为差异明显。交易成本和换手的累积尤其重要，月度调仓在长周期内会侵蚀相当一部分净收益。

从理论层面看，将风险平价从严格等风险贡献条件扩展至更灵活的宽松风险预算框架，能够把权重上限、资产组约束、换手约束和 CVaR 尾部风险度量统一纳入可计算的凸优化框架。从实践层面看，以可交易 ETF 替代部分原始指数，使回测结果更贴近真实组合执行，有助于讨论执行纪律和交易成本对长期收益的实际影响。

1.2 研究问题与研究思路

本文围绕四个问题展开。宽松风险平价能否在 30 支全球 ETF 中建立风险来源清晰的配置框架？加入 CVaR 约束和换手惩罚后，收益、回撤与换手率之间的权衡是否确实改善？HRP 和 HERC 在同一样本中表现如何，与主模型是何种关系？稳健性检验能否识别出结论对样本期和参数选择的依赖程度？

本文先梳理均值-方差、风险预算、CVaR 和层次化配置方法的理论联系，再建立可交易 ETF 资产池和统一回测标准，然后在相同研究设计下比较各模型，最后

用多维度稳健性检验和过拟合诊断约束结论的适用范围。

1.3 研究内容与章节安排

论文分七章。第二章综述均值-方差、风险预算、CVaR 和层次化配置文献，说明本文的切入点。第三章给出模型符号和定位汇总。第四章说明 ETF 资产池、数据处理和回测规则。第五章比较各模型的绩效、净值路径和权重结构。第六章从子区间、参数扰动、协方差估计和过拟合诊断多个角度检验结论稳健性。第七章总结结论并指出研究局限。

1.4 可能的边际贡献

本文的边际贡献主要有三点。其一是数据选择：以可交易 ETF 替代不可交易指数，使回测更贴近实际组合执行，而不是停留在指数层面。其二是方法整合：把风险预算偏离惩罚、CVaR 约束、换手约束和资产组限制放进同一个凸优化框架，允许同时处理多个实施约束。其三是验证角度：将多种稳健性诊断串联起来，把结论的适用范围限定在具体的样本区间和参数设定上，而不是笼统宣称模型有效。

2. 文献综述与理论基础

2.1 现代投资组合理论与估计误差

现代投资组合理论奠基于 Markowitz (1959)^[4] 的均值-方差框架，该框架首次将资产配置问题转化为以期望收益与协方差矩阵为输入的可计算二次规划。Sharpe (1964)^[5] 在此基础上建立资本资产定价模型，将个别资产收益率与市场系统性风险相联系。

然而，均值-方差最优化对输入参数的高度敏感性长期制约其实际效果。Michaud (1989)^[6] 将这一现象概括为“马科维茨之谜”：收益率估计的微小扰动足以导致最优权重的剧烈变动，使样本内优化退化为样本外噪声放大器。Jorion (1986)^[7] 通过 Bayes-Stein 收缩方法系统量化了参数不确定性对组合绩效的损耗，Chopra 与 Ziemba (1993)^[8] 进一步揭示，收益率估计误差对组合效用的影响约为协方差估计误差的十倍，收益率预测的高风险性由此在计量层面得到确认。Black 与 Litterman (1992)^[9] 尝试以市场均衡隐含收益叠加主观观点的方式缓解输入不稳定性，但所引入的先验设定本身仍难以在无模型环境中验证。

在这一背景下，DeMiguel 等 (2009)^[10] 对 14 种优化策略的系统比较表明，有限样本条件下等权重 (1/N) 组合在夏普比率与确定性等价财富等多项指标上均与复杂优化相当甚至更优，有力支持了简单基准的比较价值。Jagannathan 与 Ma (2003)^[11] 则指出，对大规模资产池施加卖空约束在数学上等价于对协方差矩阵实施隐式收缩，可有效压制样本协方差的估计噪声，这一等价性为权重上下限约束的合理性提供了理论依据。

协方差矩阵的估计质量独立构成一条研究脉络。Laloux 等 (1999)^[12] 将随机矩阵理论引入金融协方差分析，证明样本协方差矩阵的大量特征值落入 Marchenko-Pastur 噪声带，仅少数特征值携带真实信息，从而为协方差清洁提供了理论基础。在此之上，Johansson 等 (2023)^[13] 提出 CM-IEWMA 方法，通过凸优化将多个衰减参数不同的指数加权移动平均估计器线性组合，在样本外预测误差上系统优于多元 GARCH，与本文采用的指数加权协方差估计方向一致。Tzikas 等 (2026)^[14] 进一步在既有风险模型基础上叠加时变瞬时统计因子，以适应金融时间序列的结构性变化；Conlon 等 (2025)^[15] 则从因子结构视角出发，表明基于因子的协方差矩阵在样本外能有效压制噪声、改善权重稳定性。近期，Bongiorno 等 (2025)^[16] 将端到端深度学习引入这一问题，通过神经网络直接学习随机矩阵清洁后的协方差估计器，并以梯度回传优化方差最小化目标，在大规模资产池中取得显著改善；然而，端到端框架对历史样本的依赖及其难以纳入可解释硬约束的局限，促使本文保留传统凸优化路径。综合上述研究，收益预测的不确定性难以消除，而协方差估计方法的选取对样本外绩效具有实质性影响，本文因此以风险预算为主线，不引入显式收益预测，并在稳健性检验中系统比较多种协方差估计器。

2.2 风险平价与宽松风险平价

风险平价的核心思想是以风险贡献而非资金比例衡量分散化程度。Qian (2005)^[2] 最早阐明，当各资产对组合总风险的贡献相等时，组合分散化效率最高，这一思想奠定了风险平价的概念基础。Maillard 等 (2010)^[3] 对等风险贡献 (ERC) 组合的数学性质进行了系统分析，证明其存在唯一性，并揭示 ERC 权重介于等权与最小方差之间的夏普比率特征。Roncalli (2013)^[17] 将风险贡献推广为完整的风险预算框架，允许对不同资产或资产类别设定差异化的风险配额；Bruder 与 Roncalli (2012)^[18] 进一步发展了多约束条件下风险预算问题的数值求解策略，为复杂实务场景提供了计算基础。

从实证角度，Asness 等 (2012)^[19] 从杠杆厌恶的行为金融视角解释了风险平价潜在超额收益的来源：低波动率资产长期被市场低估，风险平价通过加杠杆持有债券类资产可捕获这一定价偏差。Chaves 等 (2011)^[20] 的跨资产类别回测则确认，风险平价在多数样本外时段优于等权与市值加权组合，验证了其样本外有效性。Paolella 等 (2025)^[21] 在重尾分布与机制切换假设下进一步表明，风险平价权重对参数扰动的敏感性低于均值-方差最优解，在市场压力期呈现更小的回撤幅度。

宽松风险平价将严格等式约束替换为二次惩罚项，以允许可量化的预算偏离换取约束灵活性。Gambeta 与 Kwon (2020)^[22] 系统分析了偏离惩罚形式的数学性质，包括解的存在唯一性与惩罚参数对权重稳定性的影响，其框架是本文模型设计的核心出发点。Cetingoz 与 Guéant (2024)^[23] 提出资产层与因子层风险预算的统一平衡框架，将多层级预算约束纳入同一凸规划体系。Bessler 等 (2021)^[24] 的实证研究表明，以资产类别为分组单位的风险预算在样本外鲁棒性上不弱于更精细的因子分解。Fassino 与 Uberti (2026)^[25] 在一般风险度量下给出了风险预算解的存在性证明与基于单纯形的收敛保证。本文将 CVaR 约束、换手惩罚和资产组上限统一纳入宽松风险平价框架，在保留风险预算逻辑内核的同时兼顾约束多样性与求解稳定性。

2.3 CVaR、交易成本与组合约束

条件风险价值（CVaR）在风险度量理论中兼具次可加性与凸性，是尾部损失约束的自然选择。Rockafellar 与 Uryasev（2000；2002）^[26-27] 通过引入辅助变量，将原本涉及分位数的非光滑 CVaR 约束等价转化为关于损失场景的线性规划，并将这一结果推广至一般损失分布，从而使尾部风险约束在大规模优化中具备计算可行性。Boyd 与 Vandenberghe（2004）^[28] 的凸优化理论则为同时纳入线性不等式约束、 ℓ_1 范数换手惩罚与辅助变量的混合优化问题提供了统一数学框架。

交易成本方面，Almgren 与 Chriss（2001）^[29] 建立了将价格冲击与时间价值权衡纳入调仓决策的最优执行模型，揭示了换手速率与市场冲击成本之间的根本张力。本文对交易成本采用固定费率线性近似，以保持模型的凸结构；这一近似在月频调仓、资产规模适中的情境下具有合理性，但在高频或大规模执行场景下需进一步精细化。

在尾部风险的情景生成方面，Uhl 等（2024）^[30] 提出基于自然语言处理的 AI 尾部事件识别框架，通过文本情绪信号识别极端市场情境，为历史模拟之外的情景补充提供了新思路；Alouadi 等（2026）^[31] 进一步将 Schrödinger Bridge 引入合成金融时间序列生成，所得路径不依赖历史分布假设，可系统扩充压力情景库。与上述基于情景扩充的路径不同，Bajo Traver（2026）^[32] 提出以机会成本（遗憾值）及其离散程度的最小化替代方差或 CVaR 作为组合优化目标，其理论依据在于投资者对“本可更优”结果的心理损失往往超过对绝对亏损的厌恶。然而，CVaR 的线性重表述与本文凸优化框架直接兼容，在约束可扩展性与计算稳定性上具有明确优势，故本文以 CVaR 作为尾部风险的主要约束工具，并在风险分析章节用于事后诊断。

2.4 HRP/HERC 与国内实践

层次风险平价（HRP）由 López de Prado（2016）^[33] 提出，利用相关矩阵的层次聚类结构对资产进行准对角化排列，再通过递归二分将风险预算分配至叶节点，从根本上回避了对协方差矩阵求逆的数值不稳定问题。Raffinot（2018）^[34] 在 HRP 框架基础上提出层次等风险贡献（HERC），在簇间分配阶段引入风险贡献逻辑，使

各聚类的风险暴露更为均衡。此后，多项研究对层次化框架进行了扩展：Lohre 等（2020）^[35] 将尾部依赖结构引入聚类距离矩阵，改善了压力期的聚类稳健性；Cho 与 Song（2023）^[36] 通过最小生成树（MST）对外围节点进行预筛选，在优化聚类质量的同时降低权重集中度；Ciciretti 与 Pallotta（2024）^[37] 则将最小生成树网络直接用于权重生成，在资产数量较多时取得突出的样本外表现。这类方法有一个共同制约：层次化分配机制难以直接纳入 CVaR 上界约束或换手惩罚，在多目标约束场景下适用范围因此较为有限。

国内实践研究为本文提供了重要的市场背景与工具约束依据。华泰证券系列研究（2020—2024）^[38-41] 系统梳理了风险平价理论在国内低利率环境下的实施难点，涵盖工具约束、再平衡频率与杠杆可得性等现实问题，并对 HRP 在国内多资产组合中的落地效果进行了实证评估。中信建投（2025）^[42] 从大类资产配置的产品层面比较了各类配置方法；中金公司（2026）^[43] 的量化研究对国内主流配置策略进行了系统的方法论比较；兴业证券（2026）^[44] 则系统梳理了国内 ETF 市场品类扩容的最新进展，本文 30 支 ETF 覆盖八大资产类别的资产池构建参考了其中的品种统计。本文将 HRP 与 HERC 纳入统一回测框架，在相同评价口径下与宽松风险平价系列模型就夏普比率、最大回撤与权重集中度展开系统比较。

2.5 文献评述与本文切入点

均值-方差优化作为现代投资组合理论的基础范式，提供了收益-风险权衡的规范语言，但其对收益率预测的高度敏感性导致样本外权重极不稳定，大量实证研究表明其在无模型估计条件下难以持续优于简单基准。严格等风险贡献方法以风险贡献平等作为分散化标准，在单一约束情形下具有良好的理论性质与实证表现，然而当需同时施加权重上下限、资产类别上限、CVaR 上界和换手惩罚时，严格等式约束使问题难以纳入标准凸优化求解器，计算鲁棒性显著下降。HRP 与 HERC 以层次聚类为核心，绕开协方差矩阵直接求逆的数值困难，但层次化分配的结构决定了其无法显式表达尾部风险约束与换手成本，限制了其在多目标风险管理场景中的应用边界。国内现有实践研究在工具选择与市场约束层面提供了有益参照，但尚缺乏跨资产类别的统一风险预算框架，难以在严格的回测条件下系统比较各方法的实际绩效。端到端神经网络优化路径（Bongiorno et al., 2025）^[16] 展示了以深度学习直接优化投资组合目标的技术可行性，但模型参数对历史样本量的高度

依赖、对硬约束的不兼容性，以及决策过程的不可解释性，制约了其在实务合规与风险归因场景中的推广。

本文以宽松风险平价为主线，将 CVaR 尾部约束、 ℓ_1 换手惩罚和资产类别上限统一纳入可稳定求解的凸优化框架，同时以等权、HRP 和 HERC 作为评价基准，在涵盖 30 支 ETF、跨越八大资产类别的统一可交易回测环境中，通过多维度实证验证各方法在当前样本期内的适用边界与绩效特征。

3. 理论框架与模型方法

3.1 统一符号

表 3-1 主要符号说明

符号	含义
n	资产数量
T	历史窗口长度
w_t	第 t 期调仓后的组合权重
w_{t-1}^+	第 t 期调仓前经收益漂移后的权重
r_t	第 t 日资产收益率向量
R_t	再平衡日前可获得的历史收益率窗口
Σ_t	基于 R_t 估计的协方差矩阵
μ_t	调仓日前历史窗口 R_t 的样本均值年化估计；不含主观预测信号。
b_t	风险预算或参考权重向量

符号	含义
RC_i	第 i 个资产对组合波动率的风险贡献
l_i, u_i	单资产权重下限和上限
L_g, U_g	资产组权重下限和上限
G	资产组映射矩阵
TO_t	第 t 期换手率
c	单位交易成本率
η	CVaR 辅助变量
α	CVaR 置信水平

除特别说明外，本文所有模型均在长仓、权重归一、滚动估计、月度调仓和交易成本扣减框架下比较。最终权重由透明优化流程给出，不依赖机器学习或状态识别模块直接生成交易信号。

3.2 标准风险平价

设组合权重为 w ，协方差矩阵为 Σ ，组合波动率为：

$$\sigma_p = (w^T \Sigma w)^{1/2}$$

第 i 个资产的边际风险贡献为：

$$MRC_i = \frac{\partial \sigma_p}{\partial w_i} = \frac{(\Sigma w)_i}{\sigma_p}$$

总风险贡献为：

$$RC_i = w_i MRC_i = w_i \frac{(\Sigma w)_i}{\sigma_p}$$

由 Euler 齐次函数性质可得：

$$\sum_{i=1}^n RC_i = \frac{w^T \Sigma w}{\sigma_p} = \sigma_p$$

标准风险平价要求各资产风险贡献与目标预算 b_i 匹配：

$$RC_i = b_i \sigma_p, \quad i = 1, \dots, n, \quad \sum_i b_i = 1$$

当 $b_i = 1/n$ 时，模型退化为等风险贡献组合。标准风险平价的优势在于风险贡献定义明确且对收益预测依赖较弱。但只要加上权重上下限、组别约束和交易成本，直接求解就不再容易，本文只把它作为理论参照。

3.3 宽松风险平价与 Global RRP

宽松风险平价不是放弃风险预算，而是把严格风险贡献等式改为偏离惩罚：

$$\min_w \sum_i (RC_i/\sigma_p - b_i)^2 + \lambda_{reg} \|w - w_0\|_2^2$$

$$\sum_i w_i = 1, \quad l_i \leq w_i \leq u_i$$

其中，第一项刻画风险贡献相对预算的偏离，第二项刻画与参考权重或上一期权重的距离。这个表达允许在风险预算、权重稳定性和现实约束之间做折中，而不是强迫三者同时精确满足。

Local Relaxed Risk Parity 表示本地资产池中的宽松风险预算模型。Global RRP 表示扩展到全球多资产 ETF 后的基准宽松风险预算模型，将债券、可转债、中国权益、港股、海外权益和商品放入统一风险预算框架。它的问题在于换手较高，交易成本对净收益的影响比较明显，基础版本没有 CVaR 约束。

3.4 凸优化改进模型

Convex Adaptive Global RRP 将风险预算思想转化为凸化近似，使模型可以更自然地纳入换手率、CVaR、资产上限和组别约束。其简化目标函数为：

$$\min_w J(w)$$

$$J(w) = \lambda_{var} w^T \Sigma_t w + \lambda_{budget} \|w - b_t\|_2^2$$

$$+ \lambda_{turnover} \|w - w_{t-1}^+\|_1 + \lambda_{cvar} CVaR_\alpha(w) - \lambda_{return} \mu_t^T w$$

$$\sum_i w_i = 1, \quad 0 \leq w_i \leq u_i, \quad L_g \leq \sum_{i \in g} w_i \leq U_g$$

目标函数中各项分工明确：方差项控制整体波动；预算跟踪项让权重不偏离风险预算太远； L_1 换手惩罚项直接压低交易频率；CVaR 项把历史尾部损失纳入考量。

需特别指出：Convex Adaptive Global RRP 默认设 $\lambda_{cvar} = 0$ ，CVaR 惩罚项实际上并未启用；CVaR 约束在 Improved Convex Adaptive Global RRP 中才被显式激活（ $\lambda_{cvar} = 0.080$ ），这是后者相对前者的关键差异之一。凸化表达的优点是可以加入线性约束、 L_1 换手惩罚和组别约束，便于稳定求解。

关于收益倾斜项 $-\lambda_{return}\mu_t^T w$ ，其定位需要在哲学层面加以说明。风险平价的核心思想是放弃对收益率的精确预测、将配置决策的依据完全置于风险端，第二章文献综述亦援引 Chopra 与 Ziemba（1993）^[8] 的研究——收益率估计误差对组合效用的损耗约为协方差估计误差的十倍——作为“放弃收益预测”这一设计选择的计量依据。在此背景下，目标函数中保留历史均值输入项在逻辑链条上存在内在张力，需要明确解释。

本文的处理方式如下：该项在目标函数中的定位是**方向性正则项**，而非均值一方差框架意义上的收益预测机制。其权重 $\lambda_{return} = 0.05$ 远小于方差项（ λ_{var} ）和预算跟踪项（ λ_{budget} ），在数量级上不足以主导最优权重的走向； μ_t 仅为调仓日前历史窗口 R_t 的样本均值年化值，既无前视性，也无择时意图，其作用在于轻微排除样本期内具有持续系统性负收益的极端配置方向，而非将组合积极拉向期望收益最大化的解。换言之，模型的主承重结构完整地建立在风险端四项约束之上，历史均值项仅作为防止解退化的辅助稳定机制存在。参数扰动检验中特别纳入了 $\lambda_{return} = 0$ 的对照情形，若去除该项后主要绩效指标无实质变化，则可进一步确认上述定性判断；相关敏感性分析结果汇报于第六章。

Improved Convex Adaptive Global RRP 是本文重点讨论的可实施改进，其改进体现在低换手、CVaR 约束、资产组约束和权重路径稳定四个方面。若历史情景损失为 $L_s = -r_s^T w$ ，CVaR 可表示为^[26,28]：

$$CVaR_\alpha(L) = \min_{\eta} \left[\eta + \frac{1}{(1-\alpha)T} \sum_{s=1}^T \max(L_s - \eta, 0) \right]$$

在当前样本中，Improved Convex Adaptive Global RRP 的平均月度换手率为 2.25%。相比 Global RRP 的 22.81%， L_1 换手惩罚将月度调仓幅度压缩至较低水平，在长期配置语境下有助于降低执行摩擦成本，但相应地，当市场相关结构快速变化时，组合调整速度也会放慢。

3.5 协方差估计方法

协方差矩阵的质量直接影响风险预算分配和权重求解。本文在不同模型和稳健性检验中使用三类估计器。

样本协方差矩阵是最直接的方法：给定历史收益率窗口 $R_t \in \mathbb{R}^{T \times n}$,

$$S_t = \frac{1}{T-1} (R_t - \bar{r}_t \mathbf{1}^T)^T (R_t - \bar{r}_t \mathbf{1}^T)$$

在资产数量 n 较大或历史窗口 T 较短时，样本协方差矩阵的估计噪声较大、条件数较差，容易导致极端权重。Laloux 等人的随机矩阵理论研究表明，金融资产相关矩阵中大量特征值落入噪声区间^[12]，这是样本估计不稳定的根本来源。

Ledoit-Wolf 收缩估计^[45]将样本协方差矩阵向结构化目标 F_t 做加权平均：

$$\hat{\Sigma}_t = (1 - \delta) S_t + \delta F_t$$

其中 F_t 通常取等方差对角矩阵，最优收缩系数 $\delta \in [0, 1]$ 通过 Oracle 近似方法求解。收缩使极端特征值向均值压缩，降低权重对样本误差的敏感度。Ledoit 和 Wolf 在后续研究中将线性收缩推广至二次收缩框架，从理论上给出更接近最优非线性收缩的可计算近似^[46]；本文默认使用线性 Ledoit-Wolf 收缩，二次收缩可作为后续扩展。

指数加权移动平均（EWMA）通过对近期观测赋予更高权重，捕捉协方差的时变性：

$$\hat{\Sigma}_t = (1 - \lambda) \sum_{s=0}^{T-1} \lambda^s r_{t-s} r_{t-s}^T, \quad \lambda = e^{-\ln 2 / \tau}$$

其中 τ 为半衰期参数。本文在稳健性检验中测试 $\tau \in \{20, 60, 120\}$ 三种设定，分别对应短期、中期和长期时间尺度。

主模型默认使用 Ledoit-Wolf 收缩估计，第六章协方差稳健性检验系统比较三类估计器对主要绩效指标的影响。

3.6 HRP 与 HERC 基准模型

HRP 基准模型的流程包括：基于收益率估计相关矩阵，将相关性转化为距离矩阵，进行层次聚类，按照聚类顺序进行准对角化，最后通过递归二分分配权重^[33]。

HERC 基准模型在层次结构中加入风险贡献思想，使簇内和簇间风险分配更接近风险预算逻辑^[34]。

HRP 与 HERC 的设计哲学与本文主模型存在本质差异，理解这一差异是正确解读后文实证结果的前提。层次化方法的分配逻辑完全由协方差矩阵的聚类结构驱动：在无收益输入、无显式分散约束的条件下，递归二分机制对波动率差异悬殊的混合资产池（如同时包含债券与权益的 30 支 ETF）会产生自然的集中效应——低波动率资产（债券类）在分配阶段系统性地获得更高权重，组合趋向全局最小方差解。这一结果并非算法缺陷，而是层次化分配在无约束条件下的必然归宿。

与之形成对照的是，凸优化框架的核心优势不在于任何单一绩效指标的数值高低，而在于它具备**硬约束的表达能力**：CVaR 尾部约束、 ℓ_1 换手惩罚、资产组权重上下限均可以直接写入求解器，强制实现跨类别分散，而这些业务约束在层次化框架中从结构上无法被显式表达。本文将 HRP 与 HERC 纳入统一回测框架的目的，正是通过相同评价口径揭示这一架构差异的实证后果：两者在约束缺失下的债券集中，是层次化方法应用于多约束场景时的代表性局限，而非个别样本期的偶然结果。两类方法因此构成配置思路层面的对照，而非可与主模型在同一排序坐标下直接比较的替代方案。

表 3-2 模型定位汇总

Model	Role in Thesis	Main Advantage	Main Limitation
Standard Risk Parity	理论参照	风险贡献清晰	多约束下求解困难
Local Relaxed Risk Parity	本地宽松风险预算	降低严格等式刚性	资产池较窄
Global RRP	基准宽松风险预算模型	全球资产分散与风险预算清楚	换手较高
Convex Adaptive Global RRP	凸化风险预算近似	兼容换手和组别约束	不是经典 RP 精确等价
Improved Convex Adaptive Global RRP	可实施性改进模型	低换手、CVaR 约束	参数依赖与样本依赖
HRP Benchmark	层次化基准模型	聚类解释直观	聚类稳定性敏感
HERC Benchmark	层次化风险贡献基准模型	引入层次风险贡献	难直接表达 CVaR 和换手

4. 数据、变量与研究设计

4.1 ETF 资产池构建原则

本文使用可交易 ETF 构建全球多资产池。选择标准主要是可交易性和跨资产覆盖。用 ETF 而非不可交易指数，回测结论更贴近实际组合执行，但流动性冲击、申赎成本和大额交易的滑点都没有纳入。

表 4-3 ETF 资产池

ETF	Ticker	Asset Class
可转债 ETF	511380.SH	convertible bond
国债 ETF	511010.SH	government bond
信用债 ETF	511030.SH	credit bond
日利 ETF	511880.SH	money market
沪深 300ETF	510300.SH	china equity
中证 500ETF	510500.SH	china equity
中证 1000ETF	512100.SH	china equity
创业板 ETF	159915.SZ	china equity
红利 ETF	510880.SH	china equity dividend
半导体 ETF	512480.SH	china tech equity
人工智能 ETF	159819.SZ	china tech equity
机器人 ETF	562500.SH	china advanced manufactur- ing
新能源 ETF	516160.SH	china new energy
中韩半导体 ETF	513310.SH	china tech equity
科创 50ETF	588000.SH	china tech equity

ETF	Ticker	Asset Class
云计算 ETF	516980.SH	china tech equity
证券 ETF	512880.SH	china finance
军工 ETF	512660.SH	china defense
消费 ETF	159928.SZ	china consumer
恒生 ETF	159920.SZ	hong kong equity
白银 LOF	161226.SZ	commodity
纳指 ETF	159941.SZ	global equity
标普 500ETF	513500.SH	global equity
日经 225ETF	513880.SH	global equity
欧洲 ETF	513030.SH	global equity
黄金 ETF	518880.SH	commodity
有色 ETF	159980.SZ	commodity equity
豆粕 ETF	159985.SZ	commodity
煤炭 ETF	515220.SH	commodity
原油 ETF	162411.SZ	commodity

资产池包含 30 支可交易 ETF，覆盖七大类风险来源。债券类包含可转债、国债、信用债和日利 ETF，提供久期与流动性梯度。A 股宽基涵盖大、中、小盘及创业板与红利风格五支 ETF。中国科技与增长类包含半导体、人工智能、机器人、新能源、中韩半导体、科创 50 和云计算 ETF 共七支，分别捕捉硬件算力、软件服务、工业自动化、清洁能源、跨境存储芯片与韩元汇率分散、STAR 板科技蓝筹和云服务等独立成长因子。中国行业与消费类补充证券、军工和消费 ETF，覆盖金融周期、国防制造与内需主线。港股类纳入恒生 ETF，代表香港整体市场。全球股票类包含纳指、标普 500、日经 225 和欧洲 ETF，使全球地区暴露覆盖美国、日本与欧洲。大宗商品类通过黄金、白银、有色金属、豆粕、煤炭和原油 ETF 提供贵金属、工业金属、农产品与传统能源的多元暴露。

图 4-1 展示了资产池在平静期与主要压力期前后的跨类别相关结构变化。债




图 4-1 资产池跨类别相关结构（平静期与压力期对比）

券类（日利、国债、信用债）与权益、商品的相关性在压力期通常有所上升，典型的分散化效果有所削弱；黄金在多数压力期仍保持与权益的低相关或负相关，是当前资产池中分散效果最稳定的品种之一。全球股票类与中国 A 股之间的相关性在 2020 年初流动性危机和 2022 年下行期明显走高，这也是协方差估计器需要兼顾近期和历史信息的一个具体原因。不同压力情景下相关结构的变化路径，是协方差稳健性检验的重要背景。

以 2022 年为具体案例，可以较清晰地观察到协方差矩阵变化如何驱动权重调整。2022 年初俄乌冲突爆发后，原油、黄金等商品波动率骤然上升，同期全球股票与 A 股宽基的相关性走高，债券类的防御价值出现压缩。本文所用 Ledoit-Wolf 收缩估计器以 252 日历史窗口为主要信息来源，在 2022 年上半年逐步将上述相关性变化纳入协方差矩阵，使权益类资产的协方差贡献在估计层面相应放大。优化器在更新的协方差矩阵输入下，结合资产组权重上限约束，将权益类配置从 2021—2022 阶段的约 5%–16% 压缩至更低水平，同时因 L_1 换手惩罚的存在，调仓幅度受到约束，避免了对短期信号的过度追随。黄金 ETF 因与权益相关性在此期间仍相对稳定而保持稳定配置。这一机制说明，“协方差驱动权重调整”并非黑箱操作，其逻辑链条可在权重路径图（图 5-5）与阶段性权重统计（表 5-7）中得到印证。

4.2 样本构造与预处理

本文使用经复权处理后的可比价格序列，并据此计算相邻交易日收益率，同时对不同 ETF 的交易日进行对齐。上市前缺失价格不作填补；若某 ETF 在再平衡日前的可用历史记录不足 60 个交易日，则不参与当期优化，满足门槛后方可进入

可投资宇宙。价格数据通过 Tushare 接口获取，原始序列覆盖 2010 年至 2026 年 4 月；受限于各 ETF 上市时间，资产池中大多数品种的有效数据始于 2018 年初，部分晚上市品种更短。本文绩效评价区间自 2019-01-01 起，将评价起点设定为该日期而非上市首日，是为保证多数资产在进入评价期前已积累足够的协方差估计历史窗口，避免初期样本不足带来的估计偏误。逐点时间宇宙过滤在每个再平衡日排除历史数据不足的 ETF，以避免前视信息泄露。部分资产如中证 1000 ETF 上市时间较晚，因此其历史统计特征和模型参与频率与早上市 ETF 不完全一致，这一点在描述性统计与回测设计中已有体现。

4.3 收益率、权重、交易成本与换手率定义

设第 i 个 ETF 在第 t 日价格为 $P_{i,t}$ ，日收益率为：

$$r_{i,t} = \frac{P_{i,t}}{P_{i,t-1}} - 1$$

调仓后权重为 w_t ，调仓前经收益漂移后的权重为 w_{t-1}^+ ，组合毛收益为：

$$r_{p,t}^{gross} = w_{t-1}^T r_t$$

第 t 个调仓日换手率定义为：

$$TO_t = \sum_i |w_{i,t} - w_{i,t-1}^+|$$

若单位交易成本率为 c ，则交易成本为 $TC_t = c \cdot TO_t$ ，组合净收益为 $r_{p,t}^{net} = r_{p,t}^{gross} - TC_t$ 。本文默认交易成本为 3 bps，在结果中区分毛收益和净收益。该处理未覆盖冲击成本、买卖价差和申赎费用。

4.4 组合约束与调仓规则

本文模型在长仓约束下比较，权重和为 1，不允许卖空。模型包含单资产权重上限、资产组边界和月度调仓规则。月度调仓意味着模型在每个月末附近的再平衡点使用当时可获得的历史窗口估计风险输入，适合长期配置研究，也能避免过高交易频率导致的执行成本问题。

4.5 评价指标体系

累计净值定义为 $NAV_t = \prod_{s \leq t} (1 + r_{p,s}^{net})$ 。净年化收益衡量整个评价期内净值增长速度，受样本起止点影响。年化波动率衡量收益波动程度。夏普比率定义为净年化收益除以年化波动率¹。最大回撤定义为：

$$MDD = \min_t \left(\frac{NAV_t}{\max_{s \leq t} NAV_s} - 1 \right)$$

Calmar 比率为净年化收益除以最大回撤绝对值。平均月度换手率衡量组合执行稳定性。95% 日度 CVaR 衡量历史日度损失超过 95% 分位后的平均损失，是尾部风险诊断指标，不是未来极端损失预测。

4.6 回测流程与无前视设计

本文回测流程如下：第一，在每个调仓日确定历史窗口；第二，使用调仓日前数据估计协方差、预算或状态；第三，求解目标权重；第四，计算调仓换手和交易成本；第五，使用调仓后的未来收益计算组合净值；第六，进入下一个月度调仓点。压力期识别只用于事后评价，不作为交易信号。稳健性检验不参与主模型重新选择，其作用是约束结论强度。评价区间 2019-01-01 至 2026-04-30 共约 88 个月，月末再平衡日共 89 个。协方差矩阵在评价期首个再平衡日之前已完成预热（使用 2018 年历史数据窗口），评价期内每个月末均有完整的权重求解结果。

无前视设计的时序实现可从代码层面加以说明。设第 T 个月末为调仓日，协方差矩阵与风险预算估计所使用的收益率序列严格截止于 $T - 1$ 日，即 T 日当日价格（当日收益率 r_T ）不进入本期估计窗口。 T 日优化求解完成后所得权重 w_T 从 $T + 1$ 日起生效，组合净值依据 $T + 1$ 日及之后实现的收益率 $r_{T+1}, r_{T+2}, \dots$ 进行计算。对于上市时间较短的新 ETF（如中韩半导体、机器人），可投资宇宙的纳入判断同样仅依赖截至 $T - 1$ 日已观测到的历史记录：若某 ETF 在 $T - 1$ 日前的可用交易日数不足 60 日，则在 T 日调仓中将其排除，无论其在 T 日当天或之后的表现如何。上述时序规则在回测引擎的数据切片逻辑中逐日强制执行，是保证无前视设计在实现层面不发生信息泄露的关键环节。

¹夏普比率分子使用净年化收益减去 1.82% 年化无风险利率，该利率取自 2019-01-01 至 2026-04-30 评价区间内中国 1 年期国债收益率的算术平均值^[47]。

4.7 可靠性与诊断层

为提高结果披露的完整性，并把过去容易被求解过程掩盖的问题显式呈现出来，本文在主回测路径之外设置了一套独立的可靠性诊断层。该诊断层不参与模型选择，也不改变主模型排序，只用于记录回测执行过程中可能影响结果解释的数值现象。诊断内容主要包括三个方面：其一是求解器诊断，记录各类优化问题的收敛状态、目标函数值、异常信息以及是否发生回退；其二是协方差诊断，跟踪样本长度与资产数量之比、半正定修复触发情况和条件数等指标，用于识别估计矩阵是否存在显著数值不稳定；其三是可投资资产池诊断，确保每个再平衡日的纳入决策仅依赖当时可见的信息，并在下一个再平衡日前保持不变。诊断结果表明，在 Global RRP 的静态回测路径上，约 44.3% 的再平衡日出现了求解器回退，主要对应带杠杆约束下的局部数值失稳。这一现象说明，若缺少显式诊断，部分模型结果虽然能够被产出，但其形成过程未必足够透明。

除上述诊断层外，本文还从参数选择、风险叠加敏感性、数据快照一致性和夏普差异显著性四个方面补充方法严谨性检验。这些辅助检验与主模型权重计算相互独立，其作用不是重新挑选最优模型，而是判断结论在不同设定下是否仍然保持一致。就本文结果看，主模型的优势并非来自单一参数的偶然命中，但其解释范围仍然应限定在已检验的样本区间和约束条件之内。

4.8 描述性统计与资产特征分析

表 4-4 汇报各 ETF 自上市至 2026-04-30 的有效观测数及主要统计特征。评价区间为 2019-01-01 至 2026-04-30，2018 年全年作为协方差估计预热期；观测数不足 60 个交易日的品种将被逐期排除在优化之外。早期上市的宽基与债券 ETF 可用历史约 1992 个交易日，近期上市的科技主题 ETF 观测数相对较少；权益和商品资产的波动率与回撤通常显著高于债券类资产。

表 4-4 主要资产描述性统计

ETF	Obs.	Ann. Return	Ann. Vol.	Max DD
可转债 ETF	1470	6.10%	8.57%	-15.90%

ETF	Obs.	Ann. Return	Ann. Vol.	Max DD
国债 ETF	1992	3.29%	1.65%	-4.92%
信用债 ETF	1678	2.58%	1.65%	-4.47%
日利 ETF	1992	1.97%	0.19%	-0.20%
沪深 300ETF	1992	4.12%	16.59%	-42.13%
中证 500ETF	1992	6.45%	18.65%	-39.43%
中证 1000ETF	1991	6.75%	21.41%	-46.35%
创业板 ETF	1991	11.14%	25.46%	-56.58%
红利 ETF	1992	5.18%	14.18%	-20.28%
半导体 ETF	1669	20.08%	32.45%	-62.49%
人工智能 ETF	1355	11.25%	27.79%	-45.21%
机器人 ETF	1049*	1.01%	26.29%	-45.42%
新能源 ETF	1266	0.92%	27.76%	-67.31%
中 韩 半 导 体 ETF	811*	55.13%	26.40%	-22.68%
科创 50ETF	1323	2.25%	24.24%	-59.64%
云计算 ETF	1173*	1.09%	20.40%	-38.73%
证券 ETF	1992	1.47%	24.08%	-45.00%
军工 ETF	1992	8.49%	27.23%	-50.95%
消费 ETF	1992	3.65%	21.71%	-56.32%
恒生 ETF	1992	0.35%	18.88%	-45.96%
白银 LOF	1990	15.58%	22.74%	-53.61%
纳指 ETF	1992	19.60%	20.72%	-31.10%
标普 500ETF	1991	14.80%	15.63%	-29.67%
日经 225ETF	1661	9.88%	16.87%	-28.89%
欧洲 ETF	1991	6.15%	17.14%	-39.16%

ETF	Obs.	Ann. Return	Ann. Vol.	Max DD
黄金 ETF	1992	16.85%	12.37%	-24.89%
有色 ETF	1538	11.99%	15.56%	-32.86%
豆粕 ETF	1551	13.05%	16.99%	-26.60%
煤炭 ETF	1495	19.88%	28.89%	-33.22%
原油 ETF	1992	7.06%	29.17%	-71.14%

* 近期上市 ETF，可用历史较短，仅在积累足够观测后参与优化。

这些统计只是帮助理解资产池结构差异，不直接用于模型选择。日利 ETF 年化波动仅 0.19%，是资产池的现金管理层；而科技和新能源 ETF 的波动率普遍超过 25%，最大回撤多超 50%。黄金 ETF 在评价区间内年化收益 16.85%、年化波动 12.37%，与权益资产相关性较低，是跨资产分散的主要来源。白银 LOF 年化收益 15.58%，年化波动 22.74%，与黄金同属贵金属板块，进一步丰富了大宗商品类的分散化覆盖。创业板 ETF 年化收益 11.14%，历史数据覆盖自 2018 年起，在 A 股宽基类提供了覆盖较完整的成长风格敞口。中韩半导体 ETF 自 2022 年 12 月上市，可用历史 811 个交易日，经 48 周滚动协方差预热后约于 2024 年初正式参与优化。近期上市品种（机器人、云计算、中韩半导体 ETF 等）在历史数据不足阶段会按照样本可投资性筛选规则被排除在当期优化之外。

5. 实证结果分析

5.1 主模型绩效比较

表 5-5 汇报核心模型在 2019-01-01 至 2026-04-30 评价区间内的绩效指标，共 89 个按月观察点。夏普比率点估计的近似标准误为 $\sqrt{(1 + 0.5\hat{S}^2)/T} \approx 0.13$ ($T = 89$)

月)；§6.5 给出基于分块自助法的配对显著性检验。Global RRP 的净年化收益率为 4.78%，年化波动率为 4.11%，夏普比率为 0.721，最大回撤为 -7.14%，平均月度换手率为 22.81%。这一换手水平在实务中并不轻松；若按 3 bps 费率估计，相关交易成本每年约会侵蚀 0.65 个百分点的净收益。

Convex Adaptive Global RRP 的净年化收益为 6.96%，夏普比率为 0.978，最大回撤为 -6.65%，平均月度换手率降至 1.21%。与 Global RRP 相比，换手率明显下降。Improved Convex Adaptive Global RRP 的净年化收益进一步提高到 5.66%，夏普比率为 1.471，Sortino 比率为 2.172，最大回撤为 -3.70%，平均月度换手率仅为 2.25%。这一模型的优势不在于单一指标的极致领先，而在于收益、回撤与换手控制之间取得了更稳妥的平衡。

表 5-5 核心模型绩效（评价区间 2019-01-01 至 2026-04-30）

Model	Net Return	Sharpe	Max DD	Calmar	Monthly TO
Global RRP	4.78%	0.721	-7.14%	0.670	22.81%
Defensive Dynamic RRP [†]	4.95%	0.698	-7.11%	0.695	24.57%
Convex Adaptive Global RRP	6.96%	0.978	-6.65%	1.047	1.21%
Improved Convex Adaptive Global RRP	5.66%	1.471	-3.70%	1.531	2.25%
Equal Weight	10.81%	0.811	-13.91%	0.777	1.24%
60/40 Benchmark	8.10%	0.705	-14.58%	0.556	1.43%

[†] Defensive Dynamic RRP 为防御型风险覆盖实验模型，仅作补充对比，不是本文主要研究对象。

Equal Weight 和 60/40 Benchmark 为朴素基准，交易成本按相同 3 bps 费率计算。

5.2 HRP/HERC 基准模型对比

表 5-6 展示了在相同评价口径下计算的 HRP 和 HERC 基准模型绩效。HRP 基准模型实现了 1.69% 的净年化收益，夏普比率为 -0.748，最大回撤仅为 -0.08%，Calmar 比率达到 20.716，平均月度换手率为 1.08%。HERC 基准模型的净年化收益为 2.25%，夏普比率为 0.748，最大回撤为 -0.58%，Calmar 比率为 3.860，平均月度换手率为 5.55%。

HRP 的负夏普比率主要源于其净年化收益（1.69%）略低于同期无风险利率




图 5-2 核心模型累计净值路径比较

水平（约 1.82%），这并非真实亏损而是相对表现。HERC 基准模型的夏普比率为 0.748，在当前样本里是有实质意义的正值。

不过，较高的夏普比率并不足以说明其可以替代主模型。HRP 和 HERC 的绝对年化收益分别只有 1.69% 和 2.25%，与 Improved Convex Adaptive Global RRP 的 5.66% 仍有明显差距。这一结果主要来自极低的波动水平，例如 HRP 的年化波动率仅为 0.18%，而不是来自更充分的多资产分散。后文的权重路径也表明，两者在大部分时间里几乎都维持债券重仓。与此同时，HRP 和 HERC 的月度换手率分别为 1.08% 和 5.55%，同样显著高于 Improved Convex Adaptive Global RRP 的 2.25%。

表 5-6 HRP/HERC 基准模型绩效（评价区间 2019-01-01 至 2026-04-30）

Benchmark	Net Return	Sharpe	Max DD	Calmar	Monthly TO
HRP Benchmark	1.69%	-0.748	-0.08%	20.716 [‡]	1.08%
HERC Benchmark	2.25%	0.748	-0.58%	3.860	5.55%

[‡] HRP 最大回撤分母（-0.08%）接近零，Calmar 比率数值极大，不可与其他模型直接比较。

5.3 净值路径与回撤分析

图 5-2 给出了六个核心模型在统一评价区间内的累计净值路径。Convex Adaptive Global RRP 与 Improved Convex Adaptive Global RRP 在多数阶段都保持更高的




图 5-3 核心模型回撤路径比较

累计净值，其中后者的路径更平稳。HRP 和 HERC 的曲线则更接近斜率较缓的直线，这与其近乎全仓债券的配置结构一致。净值路径能够直观呈现收益积累过程，但若判断模型优劣，仍需结合回撤深度和换手成本一并考察。

最大回撤反映投资者在历史净值曲线上所经历的峰值到谷值的最大跌幅，长期资金对此指标关注程度较高。Improved Convex Adaptive Global RRP 的最大回撤为 -3.70%，相比 Global RRP 的 -7.14% 有所改善。两个模型最深的回撤都出现在 2022 年市场下行期间。

5.4 换手率与权重结构分析

换手率直接影响交易费用总额，也关系到组合日常管理的复杂程度。Global RRP 和 Defensive Dynamic RRP 的平均月度换手率分别达到 22.81% 和 24.57%，说明在缺少换手约束时，基础风险预算模型的调仓频率往往较高。Improved Convex Adaptive Global RRP 在引入 L_1 惩罚后，换手率控制在 2.25%，显著低于 HRP (1.08%) 和 HERC (5.55%)。不过，低换手并非没有代价；当市场相关结构快速变化时，组合调整速度也会相应放慢。

各色带宽度反映该 ETF 在当月末的实际配置权重，纵轴为持仓占比 (0–100%)。从图中可以观察到几个结构性特征：日利 ETF（货币市场层，最宽的淡蓝色带）长期占据约 40–45% 底仓，承担现金管理与稳定器作用；黄金 ETF 维持稳定但有限的商品配置，平均权重约为 6–8%；A 股和科技类 ETF 的权重在 2020–2021 年阶段




图 5-4 核心模型平均月度换手率比较




图 5-5 Improved Convex Adaptive Global RRP、Global RRP、HRP 基准模型与 HERC 基准模型的资产组权重路径




图 5-6 改进型凸适应性全局宽松风险平价模型月末单 ETF 持仓权重变化（2019-01-01 至 2026-04-30，共 89 个再平衡日）。每条色带对应一只 ETF，颜色编码遵循资产类别分组：蓝色系为债券类，红色系为 A 股宽基，橙色系为中国科技与成长，绿色系为全球股票，黄色系为大宗商品。

相对较高，随后随市场波动上升而被压缩至接近零点。整体而言，权重路径呈现低频调整特征，换手惩罚有效限制了调仓幅度，避免了因协方差矩阵短期变动引发的过度交易。

表 5-7 主要模型阶段性资产组平均权重（2021–2022 与 2023–2025）

Model	Stage	Bonds	China Eq.	HK Eq.	Global Eq.	Commodities
Improved Convex	2021–2022	76.08%	5.58%	0.14%	4.45%	13.75%
Improved Convex	2023–2025	74.79%	1.30%	1.29%	9.83%	12.11%
Global RRP	2021–2022	32.56%	16.06%	1.91%	6.84%	7.76%
Global RRP	2023–2025	82.64%	4.65%	0.54%	3.11%	3.44%
HRP	2021–2022	99.93%	0.02%	0.00%	0.02%	0.03%
HRP	2023–2025	99.92%	0.02%	0.00%	0.01%	0.04%
HERC	2021–2022	95.47%	1.47%	0.18%	0.94%	1.93%
HERC	2023–2025	95.16%	1.74%	0.24%	0.83%	2.04%

图 5-5 和表 5-7 说明各模型绩效差异从何而来。Improved Convex Adaptive Global RRP 的权重路径较为平滑，其债券底仓在两个阶段都稳定在约 75% 附近，其中日利 ETF（货币市场层）和国债 ETF 共同承担现金与久期管理职责；商品组配置稳定在 12–14% 区间，主要由黄金 ETF 贡献。这种稳定性来自换手惩罚和资

产组边界的约束，而不是模型自发保守。

Global RRP 在没有换手约束的情况下更直接地响应协方差变化，其债券组权重从 2021–2022 阶段的 32.56% 显著上升至 2023–2025 阶段的 82.64%，反映出基础风险预算模型在权益类波动放大后会快速向防御性资产倾斜，调仓幅度大，换手代价也明显高于约束化版本。

HRP/HERC 的权重路径更为直接：两个阶段的债券权重均维持在 95–99% 之间，权益与商品的配置合计不超过 5%。这一结果并非模型表现失常，而是层次化算法在当前资产池条件下的结构性必然：在无收益输入且无显式跨类别约束的情况下，递归二分机制面对波动率悬殊的 30 支 ETF，会沿协方差特征向低方差端自然收敛，最终趋近全局最小方差解。夏普比率因此主要反映债券仓位的低波动属性，而非多资产分散所产生的风险调整效率。

这一现象的意义在于它直接验证了本文采用凸优化框架的架构动机：如果不在求解器层面显式写入资产组下限约束 ($L_g \leq \sum_{i \in g} w_i$)，则在混合波动率资产池中实现真正意义上的跨类别分散在算法层面是无法保证的。HRP/HERC 的债券集中是约束语言缺失的可预期后果，而非样本期选择的偶然产物；在同一资产池的不同历史窗口或参数设定下，同样的集中效应将重复出现。因此，将 HRP/HERC 与主模型进行夏普比率排序，在配置逻辑层面并不对等——前者在事实上执行的是低波动率债券组合，而后者承载的是受硬约束强制分散的多资产风险预算结构。两类方法的比较价值在于揭示约束有无对配置结果的系统性影响，而非判断其在同一维度上的绩效优劣。

为使波动率口径可比，若将 Improved Convex Adaptive Global RRP 的日收益率按比例压缩至 HRP 的年化波动率水平 (0.18%)，对应的波动对齐后净年化收益仅为 0.38%，远低于无风险利率，对应夏普比率降至 -8.195。这表明 HRP 的夏普指标优势本质上来自其极低的组合波动，而非更优越的多资产分散效率；在相同的绝对风险预算下，Improved Convex Adaptive Global RRP 能够承载更多元的资产类别暴露，产生更高的绝对净收益。




图 5-7 核心模型 95% 日度 CVaR 比较

5.5 CVaR 尾部风险分析

表 5-8 核心模型 95% 日度 CVaR（评价区间 2019-01-01 至 2026-04-30）

Model	95% Daily CVaR
Global RRP	0.64%
Defensive Dynamic RRP	0.65%
Convex Adaptive Global RRP	0.60%
Improved Convex Adaptive Global RRP	0.63%
HRP Benchmark	0.02%
HERC Benchmark	0.06%

表 5-8 汇报了各模型的 CVaR 数值。CVaR 与最大回撤反映的并不是同一件事：前者刻画的是历史日度损失超过某一分位点后的平均损失，后者反映的是整条净值路径上的最深跌幅。二者都具有参考意义，但不能相互替代。与此同时，历史 CVaR 仍然受样本所限，无法覆盖历史中从未出现过的极端情景。




图 5-8 核心模型因子暴露汇总（全样本回归）

5.6 因子暴露与收益归因

为进一步理解各模型收益的来源结构，本文使用五个代理因子（权益、债券、大宗商品/黄金、防御性资产、全球风险）对主模型的日收益率进行时间序列回归，并分解各因子对总收益和总方差的贡献。

图 5-8 和表 5-9 展示全样本因子暴露回归结果。Global RRP 对债券因子的暴露显著 ($\bar{\beta}_{bond} = 1.682$)，对权益因子暴露极低 ($\bar{\beta}_{equity} = 0.022$)， $R^2 = 0.485$ ，全样本调整后年化 $\alpha = 2.82\%$ ($t = 2.70$)。Improved Convex Adaptive Global RRP 的因子结构更为均衡：债券因子暴露降至 $\bar{\beta}_{bond} = 0.901$ ，商品/黄金因子暴露上升至 $\bar{\beta}_{commodity} = 0.175$ ，权益因子暴露约为 $\bar{\beta}_{equity} = 0.119$ ；模型 $R^2 = 0.895$ ，年化 $\alpha = 1.87\%$ ($t = 3.51$)，说明五因子能较好解释其收益变动，且存在统计上显著的正截距。

表 5-9 核心模型全样本因子暴露与 α （五因子时间序列回归）

Model	β_{eq}	β_{bond}	β_{com}	β_{def}	β_{global}	R^2	α (Annualized)
Global RRP	0.022	1.682	0.058	-0.014	0.248	0.485	2.82%
Improved Convex	0.119	0.901	0.175	0.006	0.227	0.895	1.87%

因子均为代理因子，不对应特定标准化指数。

图 5-9 展示 Improved Convex Adaptive Global RRP 与 Global RRP 在 252 日滚




图 5-9 Improved Convex Adaptive Global RRP 滚动因子暴露（252 日窗口）




图 5-10 Improved Convex Adaptive Global RRP 收益来源分解

动窗口下的因子暴露时序变化。Improved Convex 的债券暴露范围为 $[-0.16, 2.06]$ ，商品暴露范围为 $[0.11, 0.22]$ ，相对稳定；全球风险因子暴露维持在 $[0.15, 0.31]$ ，表明模型对全球权益系统性风险有持续但适度的暴露。Global RRP 的债券暴露均值更高 ($\bar{\beta}_{bond} = 1.682$)，时序波动也更大，范围 $[-0.71, 4.11]$ ，反映其在没有换手约束情况下对协方差变化的更直接响应。

表 5-10 整理了 Improved Convex Adaptive Global RRP 的收益与方差归因结果。从收益来源看，商品/黄金因子贡献最大（43.2%），其次为债券（27.0%）和权益（25.3%），防御性资产贡献约 4.6%。这一格局与权重路径一致：黄金和大宗商品 ETF 在样本期表现突出，是净收益的主要来源。从风险来源（方差份额）看，权益因子贡献最大（59.1%），商品/黄金次之（33.8%），债券方差贡献极低（0.8%），反




图 5-11 Improved Convex Adaptive Global RRP 风险来源分解

映债券端整体波动较低。

表 5-10 Improved Convex Adaptive Global RRP 收益与方差归因（五因子分解）

Factor	Return Share	Variance Share
权益	25.3%	59.1%
债券	27.0%	0.8%
商品/黄金	43.2%	33.8%
防御性	4.6%	6.2%

收益与风险归因结果表明，Improved Convex Adaptive Global RRP 的多资产分散并非表面现象。其收益来源分布在权益、债券和商品三个方向，方差的主要承担者则是权益和商品；债券的风险贡献极低，但收益贡献仍接近 27%，这与将低波动债券纳入风险预算的思路相一致。相比之下，HRP/HERC 几乎始终维持债券重仓，收益与风险都更集中于单一来源，从因子归因角度看并不能体现同等程度的多资产分散。

5.7 小结

各模型绩效差异背后是不同的配置逻辑。Improved Convex Adaptive Global RRP 在当前样本期内收益、回撤和换手三个维度上都没有明显短板；HRP 和 HERC 夏普比率有竞争力，但回撤幅度、换手频率和暴露集中度与主模型差异显著。比




图 6-12 子区间夏普比率稳健性




图 6-13 子区间最大回撤稳健性

较这几个模型时，最好同时看指标和权重路径，而不是只看排名。

6. 稳健性检验与过拟合诊断

6.1 子区间与压力期检验

图 6-12 和图 6-13 展示了不同子区间下的夏普比率和最大回撤。与全样本结果相比，子区间指标通常波动更大，因为短样本更容易受到市场状态变化的影响。这组图的意义在于观察结论在哪些阶段较为稳固、在哪些阶段有所减弱，而不是据此反向寻找所谓的”最优子区间”。




图 6-14 压力期表现检验




图 6-15 交易成本敏感性检验

跨 5 个子区间的分散度检验表明，Improved Convex Adaptive Global RRP 的子区间夏普比率范围为 [0.959, 1.741]，均值 1.246，无一子区间出现负值。其最弱子区间为 2021 年后的收紧期（post_2021），对应全球权益和债券双杀的市场环境；在该子区间内 Global RRP 的夏普比率降至 0.162，而 Improved Convex 仍维持在 0.959，展示出较强的下行防护能力，但这也是主模型在子区间内表现最逊色的阶段，需要明确披露。

压力期检验用于观察极端阶段组合反应。压力期标签是事后贴上去的，只用于观察组合在特定阶段的行为，不作为调参依据。

6.2 交易成本与参数敏感性

图 6-15 比较不同交易成本假设下的模型表现。Global RRP 随费率上升净收益下降更快，而 Improved Convex Adaptive Global RRP 因换手极低，对成本假设基本不敏感。在已测试的 $[0, 50]$ bps 月单边费率扫描范围内，Improved Convex Adaptive Global RRP 相对于 Global RRP 的净年化收益优势始终为正，两者持平的盈亏平衡点估计高于 >50 bps；本文 3 bps 的设定显著低于该阈值，说明主要结论对成本假设的合理变动具有稳健性。当前成本设定是固定费率，实际成本还包括冲击成本和买卖价差，后者没有纳入。

主模型 CVaR 参数的选取遵循先验惯例，而非来自回测调优。置信水平 $\alpha = 0.95$ 是金融风险管理的行业基准：巴塞尔协议将 99% VaR 作为市场风险资本要求的标准计量基准，而 95% CVaR 在期望损失覆盖上与之接近，同时在 Rockafellar 与 Uryasev (2000)^[26] 的凸化 CVaR 优化框架中具有良好的数值性质，是组合优化文献中最常用的置信水平。回望窗口 252 日对应一个自然历年的标准交易日数，是时间序列分析中“一年”的惯用代理变量，选取该值无需任何样本期绩效信息。换言之，若在回测启动前即确定 $\alpha = 0.95$ 、窗口 252 日，所得结果与当前完全一致——这两个参数不依赖结果反向校准。

CVaR 参数敏感性分析在 $\beta \in \{0.90, 0.95, 0.975, 0.99\}$ 和回望窗口 $\in \{126, 252, 504\}$ 两个维度上共测试 12 个变体，以 Improved Convex Adaptive Global RRP 为基础模型，其余参数保持一致。表 6-11 汇报各变体均值指标。




图 6-16 参数扰动敏感性检验

表 6-11 CVaR 参数敏感性分析（12 变体，基于 Improved Convex Adaptive Global RRP）

Dimension	Value	Sharpe Mean	Net Return	Max DD Mean	Monthly TO Mean
置信水平 β	0.90	1.119	6.80%	-5.80%	1.51%
	0.95	1.117	6.78%	-5.80%	1.51%
	0.975	1.117	6.76%	-5.78%	1.51%
	0.99	1.130	6.80%	-5.80%	1.50%
回望窗口（交易日）	126	1.131	6.59%	-5.68%	1.68%
	252	1.082	6.66%	-5.83%	1.46%
	504	1.149	7.09%	-5.87%	1.39%
全部 12 变体均值	—	1.121	6.78%	-5.79%	1.51%

各行为对应参数水平下的多个变体均值，评价区间与主模型一致。

12 个变体的夏普比率范围为 1.08–1.16，净年化收益范围为 6.59%–7.09%，最大回撤均在 -5.68% 至 -5.87% 之间，整体结论对 CVaR 参数选择不敏感。回望窗口的影响略大于置信水平：504 日长窗口的净年化收益最高（7.09%），但换手率也最低，反映更长历史窗口使协方差估计更稳定，调仓幅度更小。

参数扰动采用单因素变化方式，用于观察模型是否对某一参数表现出过度敏感。在已测试的扰动范围内，主模型表现总体稳定；至于该范围之外的参数区域，本文不作外推判断。




图 6-17 不同协方差估计下的夏普比率

收益倾斜项 λ_{return} 的零值测试需要单独说明，因为第三章已承诺在此处提供实证证据。将 λ_{return} 完全设为 0（即从目标函数中彻底移除历史均值输入项），在 2019-01-01 至评价期末的完整评价窗口内，夏普比率从基准的 1.471 降至 1.391（降幅约 0.08），净年化收益从 5.66% 降至 5.02%，最大回撤从 -3.70% 扩大至 -4.48%，求解器回退率与基准一致（1.0%）。模型在 $\lambda_{return} = 0$ 下绩效有所下降但并未坍塌，夏普比率 1.391 仍处于合理可用范围，这一结果支持第三章的定性判断： $\lambda_{return} = 0.06$ 对组合产生温和的方向性修正，但模型的风险调整收益基础主要来自方差控制、风险预算跟踪、CVaR 约束和换手惩罚四项风险端设计，而非历史收益的主动追踪。

6.3 协方差估计与过拟合诊断

本文比较了 sample covariance、Ledoit-Wolf 收缩估计以及不同半衰期的 EWMA（halflife 20/60/120）。图 6-17–6-19 表明，主要结论并不依赖单一协方差估计方法，但估计器的选择仍会影响权重细节和换手水平。至于哪一种估计器在未来环境中更优，现有样本尚不足以定论。

回测中的多重假设检验问题长期存在。White 的现实检验法通过自助法比较最优策略与随机基准的胜出概率，是处理数据窥探偏差的早期统计框架^[48]；Harvey 和 Liu 进一步梳理了多次回测搜索造成统计显著性失真的机制^[49]。本文采用 CSCV/PBO 来估计候选参数选择带来的过拟合概率^[50-51]。本次运行使用 36 个候选和 35 个区块分割，得到的 PBO 为 0.429。PBO 低于 0.5，说明样本内表现靠前的




图 6-18 不同协方差估计下的回撤表现




图 6-19 不同协方差估计下的换手表现




图 6-20 过拟合诊断




图 6-21 分块自助法夏普比率分布（200 个自助样本）

候选在样本外排序中仍大致位于中位数以上；中位逻辑秩为 0.288，也高于随机基准。这一结果支持主模型结论具有一定稳健性，但它仍然只是对参数选择偏差程度的估计，不能被理解为对未来样本外表现的保证。

滚动前向验证 (Walk-Forward) 包含 23 个测试切片，净年化收益为 $7.18\% \pm 8.33\%$ (P5: -7.12%, P95: 22.52%)，夏普比率为 1.116 ± 1.678 (P5: -1.487, P95: 5.135)，最大回撤均值为 -2.07%。切片较短，指标波动较大，应作为滚动诊断证据而非机械外推依据。冻结样本外检验 (Frozen OOS) 区间为 2025-01-02 至 2026-04-30，所用参数配置 (candidate_09) 为：历史窗口 252 日、协方差方法 ewma、单资产权重上限 45.00%、换手上限 80.00%、换手惩罚 $\lambda_{to} = 0.020$ 、CVaR 惩罚 $\lambda_{cvar} = 0.080$ 、预算惩罚 $\lambda_{budget} = 0.100$ 、CVaR 置信水平 $\beta = 0.950$ 、收益倾斜 $\lambda_{return} = 0.050$ 。该结果受到样本期内全球权益修复、黄金等分散资产支撑等因素的共同影响，应理解为特定市场背景下的条件性外样本证据。

6.4 分块自助法检验

移动分块自助法 (Moving Block Bootstrap) 通过对历史收益率时间序列进行有放回的随机分块重抽样，生成保留序列自相关结构的伪样本，从而检验绩效指标的抽样分布特征。本文使用 200 个自助样本，分块长度 21 个交易日（约等于一个月度调仓周期），所有检验仅在验证区间内进行。

表 6-12 汇报各主要模型分块自助法的夏普比率和最大回撤分布统计量。




图 6-22 分块自助法最大回撤分布（200 个自助样本）

表 6-12 分块自助法绩效分布（200 次重抽样，块长 21 日）

Model	Sharpe Mean	Sharpe P5	Sharpe P50	Sharpe P95	MDD Mean	MDD P5
Global RRP	0.506	-0.156	0.524	1.144	-6.89%	-11.65%
Convex Adaptive	0.843	0.262	0.818	1.494	-5.81%	-8.87%
Improved Convex	1.096	0.510	1.101	1.712	-6.45%	-9.76%

P5/P50/P95 为对应分位数，MDD P5 为最大回撤的第 5 百分位（最差情形）。

图 6-21–6-22 和表 6-12 的关键发现有两点。第一，Improved Convex Adaptive Global RRP 的夏普比率 P5 分位为 0.510，在 200 个自助样本中最差的 5% 情形下仍保持正值；Global RRP 的 P5 分位为 -0.156，表明在不利抽样区间下存在一定亏损风险。第二，Improved Convex 的 Sharpe P50 中位数（1.101）与全样本结果（1.511）的差距反映了样本外泛化折扣，属于正常幅度。Convex Adaptive 的自助 P5 为 0.262，也全程保持正值，说明凸化约束对下尾绩效有一定保护作用。

分块自助法的局限在于，重抽样保留了历史数据的自相关结构，但无法生成历史中从未出现过的极端情景，也不能替代真实样本外检验。它的作用是估计历史数据抽样变异性对结论的影响程度，而非预测未来绩效分布。

6.5 成对夏普差异显著性检验

单一路径上的夏普比率受抽样误差影响较大，仅根据点估计宣称模型间夏普差异需附带显著性检验。本文对头条声明使用移动分块自助法（Politis & Romano

1994) 做配对差异检验, 对每一对模型在共同评价日上抽取 21 日块 (≈ 1 个月度调仓周期), 重抽 2000 次, 分别计算每次重抽下两模型的夏普比率差, 并据此估计 95% 置信区间与双侧 p 值。原假设为两模型在评价区间内的真实夏普差为 0; 当区间不跨过 0 时拒绝原假设。

表 6-13 展示主要配对的结果。Improved Convex Adaptive Global RRP 相对于 Global RRP 的观察夏普差为 0.749, 95% CI 为 [0.236, 1.247], 双侧 p 值 0.004, 在 95% 水平上显著; 相对于 Defensive Dynamic RRP 的观察夏普差为 0.864, CI [0.365, 1.399], p 值 0.001, 显著; 相对于等权基准的观察夏普差为 0.716, CI [0.211, 1.278], p 值 0.009, 显著。作为反例, Global RRP 与等权基准的差为 -0.033, CI [-0.504, 0.544], p 值 0.900, 不显著, 与“未加约束的宽松风险平价的夏普并未显著高于等权”的预期一致。

表 6-13 成对夏普差异分块自助法检验 (2000 次重抽, 块长 21 日, 95% 置信水平)

Model A	Model B	Observed Diff.	CI Low	CI High	p Value
Improved Convex Adaptive RRP	Global RRP	0.749	0.236	1.247	0.004
Improved Convex Adaptive RRP	Defensive Dynamic RRP	0.864	0.365	1.399	0.001
Improved Convex Adaptive RRP	Equal Weight	0.716	0.211	1.278	0.009
Global RRP	Equal Weight	-0.033	-0.504	0.544	0.900
Defensive Dynamic RRP	Equal Weight	-0.118	-0.595	0.382	0.629

注: p Value 为双侧检验结果; 区间不跨过 0 视为在 95% 水平显著。

该检验并不替代过拟合诊断和无前视设计, 因为它回答的是另一类问题: 在给定评价区间内, 主模型相对于参照系的夏普优势是否足以超过抽样噪声。结果表明, Improved Convex Adaptive Global RRP 相对于各参照系的夏普优势在 95% 水平上均具有显著性; 相比之下, 未加约束的 Global RRP 相对于等权基准的夏普差并不显著, 这与表 5-5 的点估计结论一致。

6.6 小结

以上检验共同做的事情是把结论限定在具体条件下——特定评价区间、特定成本假设、特定参数选择。没有哪项检验能消除过拟合的可能性，只能说目前的证据在已测试的多个维度上是自洽的。

7. 结论与展望

7.1 主要结论

本文的四个研究问题都得到了相对明确的实证回答，不过每个答案都附带条件。

宽松风险平价在可交易全球 ETF 资产池中确实可以建立一个风险来源清晰的配置框架。Global RRP 净年化收益 4.78%，最大回撤 -7.14%，在没有 CVaR 和换手约束的情况下已经可以运行，但 22.81% 的月度换手是个实际问题。

加入 CVaR 约束、换手惩罚和资产组边界后，Improved Convex Adaptive Global RRP 净年化收益为 5.66%，最大回撤 -3.70%，换手 2.25%，Sharpe 达到 1.471。这不是每项指标都领先，而是没有明显短板。

HRP 和 HERC 在当前样本中夏普比率不低，但原因需要说清楚：两者几乎全仓债券，夏普比率来自极低的波动，而不是多资产分散。这和主模型是两种不同的配置思路，本文没有把它们放在同一个评价坐标上排序。

稳健性检验方面， $PBO = 0.429$ 说明候选选择带来的过拟合风险在可接受范围内，协方差估计器的选择不改变主要结论。但这些检验只能覆盖已测试的维度，所有结论都依赖当前的评价区间（2019–2026）和成本假设。

需要特别说明的是，本文所有实证结论均在**纯多头、无杠杆**约束下取得。这与桥水全天候等经典风险平价策略的运作方式存在本质差异：标准风险平价依赖

加杠杆持有债券类低波动资产以平衡各资产的绝对风险贡献，而本文的权重约束 $\sum_i w_i = 1, w_i \geq 0$ 明确排除了杠杆和卖空。这一约束并非研究的技术妥协，而是对国内公募基金监管环境的主动适应。根据中国证监会《公开募集证券投资基金运作管理办法》，普通开放式基金总资产不得超过基金净资产的 140%（即杠杆不超过 0.4 倍），封闭式及定期开放基金在封闭期内不得超过 200%（即杠杆不超过 1 倍），货币市场基金则不得超过 120%。上述杠杆红线使得标准风险平价”加杠杆平抑权益波动”的核心机制在公募语境下受到严格限制。本文的研究贡献因此具有特定的现实定位：在无杠杆、有交易成本、有权重上限的严格执行约束下，引入 CVaR 约束和换手惩罚的宽松风险平价框架仍能产生 Sharpe 1.471、最大回撤 -3.70% 的组合表现，为公募 FOF、银行理财子及保险委外等不允许或不宜使用杠杆的稳健型资金提供了一条可执行的多资产风险预算路径。

这些数字放在国内机构资金的语境里更具体。2025 年一年期定存利率约 1.5%，银行理财子 R2 级产品年化收益普遍在 2% 至 3% 之间，保险委外的绝对收益要求一般在 3% 至 5%。对这类资金而言，考核指标不是跑赢股市，而是在回撤约束下持续跑赢无风险利率。本模型在无杠杆、全额扣除 3 bps 单边成本后，净年化 5.66%、最大回撤 -3.70%，相对于上述绝对收益基准有持续可验证的溢价，回撤路径也在机构内控通常要求的边界内。

HRP 夏普比率看起来不低，但有必要说清楚：它几乎全仓债券，低波动率是单一资产类别的特性而非多资产分散的结果，两种方法不在同一个评价坐标上。本模型 1.471 的 Sharpe 来自 CVaR 约束对尾部损失的直接锚定，以及收益倾斜项 λ_{return} 向权益和商品风险溢价的适度倾斜——是多资产风险分散驱动的，不是靠压低分母。最大回撤 -3.70% 覆盖了 2022 年美联储激进加息和 A 股深度调整，对于净值有明确回撤限制的结构性产品或险资委外，这是有直接合规参考意义的实证数据。

月均换手率 2.25% 直接来自 L1 惩罚项的截断效应。目标函数中的 $\lambda_{to} \|\mathbf{w}_t - \mathbf{w}_{t-1}\|_1$ 使得调仓收益低于惩罚阈值时，对应权重变动被截断为零。这在实践中做了两件事：过滤掉协方差估计噪声驱动的无效调仓（月频协方差估计本身有显著抽样误差，无约束时优化器会把噪声误读为有效信号），以及将实际交易频次压缩到组合真正需要再平衡的程度。对大额管理资金而言，买卖价差和市场冲击成本往往远超名义费率，低换手是模型在真实执行环境中可持续运营的工程基础。

7.2 研究不足

当前数据缺少买卖价差、成交量和基金资产规模等微观结构字段，无法估计大额资金进出的冲击成本和实际投资容量上限。固定 3 bps 费率是简化，冲击成本没有纳入。

本文从资产端视角讨论长期资金配置，未引入负债现金流预测、久期缺口匹配和偿付能力资本占用规则，结论不能直接套用到资产负债管理场景。

部分 ETF 上市时间较晚，历史有限，限制了跨越更长经济周期的系统性比较；本研究已通过逐点时间宇宙过滤加以控制，但该局限仍值得后续关注。

所有实证结论依赖特定评价区间（2019-01-01 至 2026-04-30）和当前市场相关性结构。如果未来市场结构发生实质性变化，模型表现可能随之改变。这些是条件性陈述，不构成对未来长期表现的预测。

7.3 后续研究方向

最直接的后继工作是改善成本建模。引入买卖价差和基于成交量的冲击成本函数，比固定费率更接近机构执行环境，也能让成本敏感性分析的结论更可信。

延长样本也值得做。当更多 ETF 积累足够历史数据后，重复当前比较并检验结论是否稳定，本身就价值。

将研究推进到负债端需要引入现金流预测、久期缺口和资本占用规则，这超出了本科论文的范围，但是一个自然的扩展方向。

从资产端风险预算扩展到因子层面是另一条路径。华泰证券从风险平价出发讨论了向因子配置演进的中国版全天候增强框架^[52]。机器学习和深度强化学习方法也开始进入这一领域：Millea 和 Edalat 将深度强化学习与 HRP 结合用于动态配置^[53]；Yang 验证了深度强化学习在多资产组合管理中的自适应调整可行性^[54]；Agal 等人从机器学习视角讨论了风险导向型资产配置的权重生成思路^[55]。这类方法在低换手约束和样本外稳健性方面的系统检验，是与本文方法进行有意义比较的前提。

衍生品工具是另一个值得探索的方向。本文的无杠杆假设迫使债券端占用大量资本权重（日利 ETF 底仓约 45.4%），这是 Capital Allocation 范式的内生限制。

对于不受公募杠杆上限约束的券商自营或私募资金，可以尝试用中金所国债期货（T/TF 合约）替代国债 ETF，借助保证金制度在极低资金占用下建立债券端风险暴露，从而将释放出的资本配置到权益或商品端。这涉及名义敞口优化和展期成本的精确建模，是本模型向更高收益全天候策略演进的关键。

本文已实施了一次初步验证：将国债、信用债、豆粕、原油 ETF 替换为对应的中金所/大商所/上期能源期货连续合约，在相同的 Improved Convex 参数下运行三个场景对比，结果见表 7-14。

表 7-14 期货替换对照实验三场景绩效比较（评价区间 2019–2026）

场景	净年化收益	年化波动率	Sharpe	最大回撤	月均换手
场景 0：ETF 基准（Improved Convex）	5.66%	2.61%	1.471	−3.70%	0.11%
场景 1：期货替换，无杠杆	5.54%	4.18%	0.889	−5.32%	0.19%
场景 2：期货 + 1.5 倍杠杆	7.00%	6.28%	0.826	−8.11%	0.19%

注：场景 1 用中金所国债期货（T/TF/TS/TL）替换国债/信用债 ETF，用大商所豆粕期货（M）和上期能源原油期货（SC）替换对应 ETF，其余 ETF 保持不变。场景 2 在场景 1 基础上施加 1.5 倍名义杠杆，扣除年化 2.5% 融资成本。SHFE 黄金、白银、铜等品种因 Tushare 数据权限限制未纳入替换范围。

场景 1 收益与基准相近（5.54% vs 5.66%），但波动率从 2.61% 上升至 4.18%，Sharpe 从 1.471 降至 0.889。原因直接：期货日内波动比 ETF 大，无杠杆场景下这种额外波动没有被对应的收益补偿。场景 2 将年化收益推至 7.00%，但 Sharpe 仍低于基准（0.826 vs 1.471），回撤扩大至 −8.11%。要让期货的资金效率优势转化为风险调整收益，需要同时精细化管理展期成本并设定合适的杠杆倍数，而非简单按固定倍数放大。这是衍生品延伸路径的方向合理，但落地有条件。

7.4 与桥水全天候策略的横向对比

本节将本模型与桥水（Bridgewater Associates）中国版全天候策略（All Weather China）并排对比。两者都以风险平价为底层逻辑，但在牌照约束、工具选择和资金效率哲学上差异显著。

表 7-15 本论文改进凸模型与桥水全天候策略横向对比

对比维度	本论文改进凸模型（公募视角）	桥水全天候策略（外资私募视角）
牌照与杠杆红线	公募基金/银行理财子/保险委外受限资金。《公募基金运作管理办法》：开放式基金总资产不超过净资产 140%；本文实证严格设定为无杠杆（ $\sum w_i = 1, w_i \geq 0$ ），主动对标监管红线以下运营。	以私募证券投资基金管理人（PFM）牌照在中国境内运营，不受公募杠杆上限约束；名义敞口通常为净值 2-3 倍，通过基金合同和流动性压力测试自律管理。
底层工具选择	30 支中国本土上市、可公开申赎的全球多资产 ETF（纯多头现货）；工具箱受限于交易所上市品种，不涉及衍生品。	全球现货资产打底，叠加利率互换（IRS）、国债期货、商品期货、股指期货等场外及场内衍生品；境内可用中金所国债期货（T/TF/TS）和商品期货。
债券端处理方式	通过分配大额资本权重至日利 ETF（底仓约 45.4%）和国债 ETF，以绝对资本量的大头配置实现债券端风险贡献的平价。本质是“以量换贡献”，存在显著的机会成本。	债券现货配合国债正回购（Repo）滚动加杠杆，并叠加国债期货保证金交易放大久期敞口；约 2%-5% 的保证金占用即可建立等同面值 100% 的久期暴露，资金效率远高于现货配置。
商品端处理方式	以黄金 ETF（主底仓）、豆粕 ETF 等商品现货 ETF 做多持有，无法捕获期货展期收益（Roll Yield）或实施多空对冲。	全口径大宗商品期货多空合约，覆盖农产品、能源、贵金属、工业金属；精细管理展期策略以降低正价差环境下的展期损耗；可灵活构建多空组合捕获相对价值。
资金利用率哲学	Capital Allocation（资本分配）范式：100% 资金预算为硬约束，凸优化在此约束下求解；靠压低组合波动保护绝对收益，净值敞口上限锁定于 1 倍，无法突破。	Notional Allocation（名义敞口分配）范式：保证金池实现名义敞口 2-3 倍于净值；剩余现金作为收益增强底层（货币市场工具）；在真正风险预算配平的同时，大幅拓宽绝对收益天花板。

风险平价不是一种固定组合，而是随工具约束和杠杆环境变形的风险预算方

法。在公募无杠杆语境下，Capital Allocation 范式迫使债券端以大量资本填补其风险贡献——日利 ETF 约 45.4% 的底仓正是这一结构的外化。这笔资金不是“闲置”，而是在承担债券端风险贡献平衡的功能性任务；但它没能配置到更高收益资产，这个机会成本是无杠杆框架下的内生效率损耗。

桥水中国版全天候策略的处理方式不同：国债期货的保证金制度将债券端资金占用从资产本金级别压缩至保证金级别，在 1 倍净值的资金池内实现 2 至 3 倍的多资产风险暴露。这是经典全天候策略能在无风险利率之上实现稳定绝对收益的结构性原因。

上述差异不是技术优劣的问题，而是两者面对的约束集合不同。本文模型在 $\sum w_i = 1, w_i \geq 0$ 约束下，实现了 Sharpe 1.471、最大回撤 -3.70% 的组合表现，为国内受监管资金提供了一条无杠杆条件下可执行的多资产配置路径。桥水策略的高绝对收益依赖衍生品杠杆和专业展期管理，其前提条件（PFM 牌照、衍生品交易能力、保证金管理体系）在国内公募语境下不具备普遍可及性。这是比较两类策略时需要先说清楚的前提。

A. 主要指标定义汇总

表 A-16 主要指标含义

Metric	Definition and Use
Net Return	扣除交易成本后的年化收益，衡量净值增长速度
Sharpe	净年化收益除以年化波动率，衡量单位波动收益
Max DD	历史净值峰谷最大跌幅，衡量路径风险
Calmar	净年化收益除以最大回撤绝对值，强调回撤调整收益

Metric	Definition and Use
Turnover	调仓前后权重变化绝对值之和，衡量执行强度
CVaR	给定置信水平下尾部损失均值，衡量历史尾部风险

B. CSCV 候选参数网格

本文 CSCV/PBO 过拟合诊断共使用 36 个候选参数配置。表 B-17 完整列出每个候选的核心参数，供验证时复现。其中 candidate_09 即为冻结样本外检验（Frozen OOS）中使用的参数配置。列说明：Look.= 回看窗口（日），Cov.= 协方差方法（ewma/sample），MaxW= 单资产权重上限，TO Cap= 换手上限， λ_{to} = 换手惩罚， λ_{budget} = 预算惩罚， λ_{cvar} =CVaR 惩罚， β =CVaR 置信水平， λ_{ret} = 收益倾斜权重。

表 B-17 CSCV 候选参数网格（共 36 个候选）

ID	Look.	Cov.	MaxW	TO Cap	λ_{to}	λ_{budget}	λ_{cvar}	β	λ_{ret}
candidate_01	180	ewma	40%	35%	0.020	0.350	0.200	0.95	0.050
candidate_02	252	ewma	45%	80%	0.010	0.100	0.080	0.95	0.050
candidate_03	252	ewma	40%	60%	0.020	0.250	0.150	0.95	0.060
candidate_04	252	ewma	40%	60%	0.020	0.250	0.150	0.95	0.060
candidate_05	252	ewma	40%	60%	0.020	0.250	0.150	0.95	0.060
candidate_06	120	ewma	45%	80%	0.010	0.050	0.080	0.95	0.050
candidate_07	120	ewma	45%	80%	0.010	0.100	0.080	0.95	0.050
candidate_08	180	ewma	45%	80%	0.010	0.050	0.080	0.95	0.050
candidate_09	180	ewma	45%	80%	0.010	0.100	0.080	0.95	0.050
candidate_10	252	ewma	45%	80%	0.010	0.050	0.080	0.95	0.050
candidate_11	252	ewma	45%	80%	0.000	0.100	0.080	0.95	0.050
candidate_12	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.050
candidate_13	252	ewma	45%	80%	0.030	0.100	0.080	0.95	0.050
candidate_14	252	ewma	45%	35%	0.010	0.100	0.080	0.95	0.050
candidate_15	252	ewma	45%	100%	0.010	0.100	0.080	0.95	0.050
candidate_16	252	ewma	45%	—	0.010	0.100	0.080	0.95	0.050

ID	Look.	Cov.	MaxW	TO Cap	λ_{to}	λ_{budget}	λ_{cvar}	β	λ_{ret}
candidate_17	252	ewma	45%	80%	0.010	0.100	0.050	0.95	0.050
candidate_18	252	ewma	45%	80%	0.010	0.100	0.100	0.95	0.050
candidate_19	252	ewma	45%	80%	0.010	0.100	0.200	0.95	0.050
candidate_20	252	ewma	45%	80%	0.010	0.100	0.080	0.95	0.060
candidate_21	252	ewma	45%	80%	0.010	0.100	0.080	0.95	0.080
candidate_22	252	ewma	45%	80%	0.010	0.100	0.080	0.95	0.100
candidate_23	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.060
candidate_24	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.060
candidate_25	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.080
candidate_26	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.080
candidate_27	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.100
candidate_28	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.100
candidate_29	252	ewma	40%	80%	0.010	0.100	0.080	0.95	0.050
candidate_30	252	sample	45%	80%	0.010	0.100	0.080	0.95	0.050
candidate_31	252	ewma	45%	80%	0.010	0.100	0.080	0.90	0.050
candidate_32	180	ewma	40%	35%	0.020	0.350	0.100	0.95	0.050
candidate_33	180	ewma	40%	80%	0.010	0.100	0.080	0.95	0.050
candidate_34	120	ewma	45%	100%	0.000	0.050	0.050	0.95	0.060
candidate_35	252	ewma	40%	35%	0.030	0.350	0.200	0.90	0.050
candidate_36	120	sample	40%	—	0.020	0.100	0.100	0.95	0.050

加粗行为 Frozen OOS 使用的候选（candidate_09）。"—"表示换手上限无约束。

参考文献

- [1] BRINSON G P, HOOD L R, BEEBOWER G L. Determinants of portfolio performance[J/OL]. Financial Analysts Journal, 1986, 42(4): 39-44. DOI: 10.2469/faj.v42.n4.39.
- [2] QIAN E. Risk parity portfolios: efficient portfolios through true diversification[R]. PanAgora Asset Management, 2005.
- [3] MAILLARD S, RONCALLI T, TEILETCHE J. The properties of equally weighted risk contribution portfolios[J]. The Journal of Portfolio Management, 2010, 36(4): 60-70.
- [4] MARKOWITZ H M. Portfolio selection: efficient diversification of investments [M]. New York: John Wiley & Sons, 1959.
- [5] SHARPE W F. Capital asset prices: a theory of market equilibrium under conditions of risk[J]. The Journal of Finance, 1964, 19(3): 425-442.
- [6] MICHAUD R O. The Markowitz optimization enigma: Is ‘Optimized’ optimal? [J/OL]. Financial Analysts Journal, 1989, 45(1): 31-42. DOI: 10.2469/faj.v45.n1.31.
- [7] JORION P. Bayes-stein estimation for portfolio analysis[J]. Journal of Financial and Quantitative Analysis, 1986, 21(3): 279-292.
- [8] CHOPRA V K, ZIEMBA W T. The effect of errors in means, variances, and covariances on optimal portfolio choice[J]. The Journal of Portfolio Management, 1993, 19(2): 6-11.
- [9] BLACK F, LITTERMAN R. Global portfolio optimization[J]. Financial Analysts Journal, 1992, 48(5): 28-43.
- [10] DEMIGUEL V, GARLAPPI L, UPPAL R. Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy?[J]. The Review of Financial Studies, 2009, 22(5): 1915-1953.
- [11] JAGANNATHAN R, MA T. Risk reduction in large portfolios: Why imposing the wrong constraints helps[J/OL]. The Journal of Finance, 2003, 58(4): 1651-1683.

DOI: 10.1111/1540-6261.00580.

- [12] LALOUX L, CIZEAU P, BOUCHAUD J P, et al. Noise dressing of financial correlation matrices[J/OL]. *Physical Review Letters*, 1999, 83(7): 1467-1470. DOI: 10.1103/PhysRevLett.83.1467.
- [13] JOHANSSON K, OGUT M G, PELGER M, et al. A simple method for predicting covariance matrices of financial returns[A/OL]. *arXiv* (2023). <https://arxiv.org/abs/2305.19484>.
- [14] TZIKAS A E, CANDÈS E J, HASTIE T, et al. Enhancing a risk model by adding transient statistical factors[A/OL]. *arXiv* (2026). <https://arxiv.org/abs/2605.12977>.
- [15] CONLON T, COTTER J, KYNIGAKIS I. Asset allocation with factor-based covariance matrices[J/OL]. *European Journal of Operational Research*, 2025, 325(1): 189-203. DOI: 10.1016/j.ejor.2025.03.015.
- [16] BONGIORNO C, MANOLAKIS E, MANTEGNA R N. End-to-end large portfolio optimization for variance minimization with neural networks through covariance cleaning[A/OL]. *arXiv* (2025). <https://arxiv.org/abs/2507.01918>. DOI: 10.48550/arXiv.2507.01918.
- [17] RONCALLI T. *Introduction to risk parity and budgeting*[M]. Boca Raton: Chapman and Hall/CRC, 2013.
- [18] BRUDER B, RONCALLI T. *Managing risk exposures using the risk budgeting approach*[R]. Lyxor Asset Management, 2012.
- [19] ASNESS C S, FRAZZINI A, PEDERSEN L H. Leverage aversion and risk parity [J/OL]. *Financial Analysts Journal*, 2012, 68(1): 47-59. DOI: 10.2469/faj.v68.n1.1.
- [20] CHAVES D B, HSU J C, LI F, et al. Risk parity portfolio vs. other asset allocation heuristic portfolios[J]. *The Journal of Investing*, 2011, 20(1): 108-118.
- [21] PAOLELLA M S, POLAK P, WALKER P S. Risk parity portfolio optimization under heavy-tailed returns and dynamic correlations[J/OL]. *Journal of Time Series Analysis*, 2025, 46(2): 353-377. DOI: 10.1111/jtsa.12792.
- [22] GAMBETA V, KWON R. Risk return trade-off in relaxed risk parity portfolio optimization[J/OL]. *Journal of Risk and Financial Management*, 2020, 13(10): 237. DOI: 10.3390/jrfm13100237.
- [23] CETINGOZ A R, GUÉANT O. Asset and factor risk budgeting: a balanced ap-

- proach[A/OL]. arXiv (2024). <https://arxiv.org/abs/2312.11132>.
- [24] BESSLER W, TAUSHANOV G, WOLFF D. Factor investing and asset allocation strategies: a comparison of factor versus sector optimization[J/OL]. *Journal of Asset Management*, 2021, 22(6): 488-506. DOI: 10.1057/s41260-021-00225-1.
 - [25] FASSINO C, UBERTI P. Some general results on risk budgeting portfolios[A/OL]. arXiv (2026). <https://arxiv.org/abs/2603.15511>.
 - [26] ROCKAFELLAR R T, URYASEV S. Optimization of conditional value-at-risk[J]. *Journal of Risk*, 2000, 2(3): 21-41.
 - [27] ROCKAFELLAR R T, URYASEV S. Conditional Value-at-Risk for general loss distributions[J/OL]. *Journal of Banking & Finance*, 2002, 26(7): 1443-1471. DOI: 10.1016/S0378-4266(02)00271-6.
 - [28] BOYD S, VANDENBERGHE L. Convex optimization[M]. Cambridge: Cambridge University Press, 2004.
 - [29] ALMGREN R, CHRISS N. Optimal execution of portfolio transactions[J/OL]. *Journal of Risk*, 2001, 3(2): 5-39. DOI: 10.21314/JOR.2001.041.
 - [30] UHL M W, JURT F, WALLISER S. Can AI detect tail events? Stock performance around tail events during different sentiment regimes[J]. *Journal of Behavioral Finance*, 2024.
 - [31] ALOUADI A, et al. SBBTS: a unified Schrödinger–Bass framework for synthetic financial time series[A/OL]. arXiv (2026). <https://arxiv.org/abs/2604.07159>.
 - [32] BAJO TRAVER M. Regret-based portfolio allocation: minimizing opportunity cost and its dispersion[J]. Working paper, 2026.
 - [33] LÓPEZ DE PRADO M. Building diversified portfolios that outperform out of sample[J]. *The Journal of Portfolio Management*, 2016, 42(4): 59-69.
 - [34] RAFFINOT T. The hierarchical equal risk contribution portfolio[J]. *SSRN Electronic Journal*, 2018.
 - [35] LOHRE H, ROTHER C, SCHÄFER K A. Hierarchical risk parity: Accounting for tail dependencies in multi-asset multi-factor allocations[M/OL]//JURCZENKO E. *Machine Learning for Asset Management: New Developments and Financial Applications*. Wiley, 2020: 329-368. DOI: 10.1002/9781119751182.ch9.
 - [36] CHO Y, SONG J W. Hierarchical risk parity using security selection based on pe-

- ripheral assets of correlation-based minimum spanning trees[J/OL]. *Finance Research Letters*, 2023, 53: 103608. DOI: 10.1016/j.frl.2022.103608.
- [37] CICIRETTI V, PALLOTTA A. Network risk parity: graph theory-based portfolio construction[J/OL]. *Journal of Asset Management*, 2024, 25(2): 136-146. DOI: 10.1057/s41260-023-00347-8.
- [38] 林晓明, 黄晓彬, 源洁莹. 风险平价模型的常见理解误区剖析: “风险”的界定、度量与“平价”、杠杆的实现[R]. 华泰证券研究所, 2020.
- [39] 林晓明, 黄晓彬, 张泽. 风险平价之标的优选与层次化风险估计[R]. 华泰证券研究所, 2021.
- [40] 张继强, 陶冶, 何颖雯. 风险平价的理念与国内实践: 资产配置方法论系列[R]. 华泰证券研究所, 2024.
- [41] 张继强, 陶冶, 何颖雯. 低利率环境下的绝对收益路径: 资产配置方法论系列[R]. 华泰证券研究所, 2025.
- [42] 中信证券研究部. 多资产 ETF 的海外经验与国内展望[R]. 中信证券股份有限公司, 2025.
- [43] 陈宜筠, 郑文才, 周萧潇, 等. 量化配置模型 (一): 海内外大类资产配置量化实测[R]. 中国国际金融股份有限公司, 2026.
- [44] 兴业证券研究所. 年度复盘 & 展望八——ETF 篇: 鹏北海, 凤朝阳, 又携书剑路茫茫[R]. 兴业证券股份有限公司, 2026.
- [45] LEDOIT O, WOLF M. A well-conditioned estimator for large-dimensional covariance matrices[J]. *Journal of Multivariate Analysis*, 2004, 88(2): 365-411.
- [46] LEDOIT O, WOLF M. Quadratic shrinkage for large covariance matrices[J/OL]. *Bernoulli*, 2022, 28(3): 1519-1547. DOI: 10.3150/20-BEJ1315.
- [47] 中国人民银行. 中国国债收益率曲线 (1 年期) 历史数据[Z]. 2026.
- [48] WHITE H. A reality check for data snooping[J/OL]. *Econometrica*, 2000, 68(5): 1097-1126. DOI: 10.1111/1468-0262.00152.
- [49] HARVEY C R, LIU Y. Backtesting[J/OL]. *The Journal of Portfolio Management*, 2015, 42(1): 13-28. DOI: 10.3905/jpm.2015.42.1.013.
- [50] BAILEY D H, BORWEIN J M, LÓPEZ DE PRADO M, et al. The probability of backtest overfitting[J]. *Journal of Computational Finance*, 2014, 20(4): 39-69.
- [51] BAILEY D H, LÓPEZ DE PRADO M. The deflated sharpe ratio: correcting for

- selection bias, backtest overfitting, and non-normality[J]. *The Journal of Portfolio Management*, 2014, 40(5): 94-107.
- [52] 华泰证券研究所. 从资产配置走向因子配置：中国版全天候增强策略[R]. 华泰证券研究所, 2025.
- [53] MILLEA A, EDALAT A. Using deep reinforcement learning with hierarchical risk parity for portfolio optimization[J/OL]. *International Journal of Financial Studies*, 2023, 11(1): 10. DOI: 10.3390/ijfs11010010.
- [54] YANG S. Deep reinforcement learning for portfolio management[J/OL]. *Knowledge-Based Systems*, 2023, 278: 110905. DOI: 10.1016/j.knosys.2023.110905.
- [55] AGAL S, RAULJI K, ODEDRA N D. A machine learning approach to risk based asset allocation in portfolio optimization[J/OL]. *Scientific Reports*, 2025, 15: 42263. DOI: 10.1038/s41598-025-26337-x.