

西南财经大学

本科毕业论文（设计）



论文题目： 宽松风险平价在全球 ETF
资产配置中的改进与实证研究

所在学院： 特拉华数据科学学院

专 业： 金融数学（金融服务与量化分析方向）

学生姓名： 许哲圣

学 号： 42353012

年 级： 2023 级

指导教师： 王磊

2026 年 8 月

学术声明

本人郑重声明：所呈交的毕业论文是在指导教师指导下独立完成的研究成果。论文中引用他人已经发表或未发表成果，均已在正文和参考文献中作出明确标注。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文研究作出重要贡献的个人和集体，均已在文中以明确方式说明。

摘要

长期资产配置要解决的问题不是预测下一期涨跌，而是在市场不确定时维持有效的风险分散。风险平价用风险预算替代收益预测，理论上更稳健，但在全球多资产 ETF 资产池中落地时，相关结构的时变性、等风险贡献约束的非凸性和月频调仓的成本积累，都是绕不开的实际问题。

本文以 30 支可交易全球多资产 ETF 构建统一回测框架，资产池覆盖八大类风险来源：债券、A 股宽基、中国科技（半导体、人工智能、新能源与科创主题）、中国行业与消费、港股、全球股票、贵金属和大宗商品。评价区间 2018-01-02 至 2026-07-31（共 103 个月度观察点），月度调仓，单边交易成本 3 bps，全程无前视。在统一框架下对比 Global RRP、Convex Adaptive Global RRP、Improved Convex Adaptive Global RRP 和层次化基准 HERC。

主要结果如下。Global RRP 净年化收益 4.28%、Sharpe 0.534、最大回撤 -6.32%，但月均换手率 24.51% 带来可见的成本拖累。引入 CVaR 约束、换手惩罚和资产组上限后，Improved Convex Adaptive Global RRP 将换手率压至 1.96%，净年化收益升至 5.60%，Sharpe 1.186，Sortino 1.699，最大回撤 -3.81%。HERC 的 Sharpe 为 0.646，收益 2.57%，其高 Sharpe 来自近乎全仓债券的极低波动，而非多资产分散。Improved Convex Adaptive Global RRP 没有在每项指标上都领先，其主要价值在于以有限绝对收益弹性换取较低波动、较浅回撤和可控换手。

以上结论基于特定历史区间和约束设定，不构成对未来收益的预测。

关键词：宽松风险平价；全球多资产配置；CVaR；换手约束；凸优化；ETF

Abstract

Risk parity replaces expected-return estimation with risk budgeting, which makes it theoretically more robust. In practice, applying it to a global multi-asset ETF universe introduces three problems that don't go away: time-varying correlations, the non-convexity of exact equal-risk-contribution constraints, and transaction costs that add up meaningfully at monthly rebalancing frequency.

This thesis tests a Relaxed Risk Parity framework on 30 tradable ETFs spanning eight asset groups—bonds, China broad equity, China technology, China sector/consumption, Hong Kong equity, global equity, precious metals, and commodities. The evaluation window is 2018-01-02 to 2026-07-31 (103 monthly observations), with 3-bp one-way transaction costs and no lookahead. Four models are compared: Global RRP, Convex Adaptive Global RRP, Improved Convex Adaptive Global RRP, and HERC. HRP remains a benchmark; its money-market concentration produces low volatility and limited return opportunity.

Global RRP earns 4.28% net annual return at a Sharpe of 0.534, but its 24.51% average monthly turnover creates a real cost drag. Adding CVaR constraints, a turnover penalty, and group weight bounds in Improved Convex Adaptive Global RRP cuts turnover to 1.96% while lifting net return to 5.60%, Sharpe to 1.186, Sortino to 1.699, and capping drawdown at -3.81%. HERC posts a Sharpe of 0.646—that number comes from near-zero portfolio volatility via heavy bond concentration, not from multi-asset diversification. Improved Convex does not win on every single metric, but it has no obvious weak spot across return, drawdown, and turnover.

All results are conditional on this evaluation period and constraint settings. They do not predict future performance.

Keywords: Relaxed Risk Parity; Global Multi-Asset Allocation; CVaR; Turnover Constraint; Convex Optimization; ETF

目录

1	绪论	1
1.1	研究背景与意义	1
1.2	研究问题与研究思路	1
1.3	研究内容与章节安排	2
1.4	可能的边际贡献	2
2	文献综述与理论基础	2
2.1	现代投资组合理论与估计误差	2
2.2	风险平价与宽松风险平价	4
2.3	CVaR、交易成本与组合约束	5
2.4	HRP/HERC 与国内实践	5
2.5	文献评述与本文切入点	6
3	理论框架与模型方法	7
3.1	统一符号	7
3.2	标准风险平价	8
3.3	宽松风险平价与 Global RRP	9
3.4	凸优化改进模型	9
3.5	防御型风险覆盖层 (Risk Overlay)	11
3.6	协方差估计方法	11
3.7	HERC 基准模型	13
4	数据、变量与研究设计	14
4.1	ETF 资产池构建原则	14
4.2	样本构造与预处理	17
4.3	收益率、权重、交易成本与换手率定义	18
4.4	组合约束与调仓规则	18
4.5	评价指标体系	18

4.6	回测流程与无前视设计	19
4.7	可靠性与诊断层	19
4.8	描述性统计与资产特征分析	20
5	实证结果分析	22
5.1	主模型绩效比较	22
5.2	与沪深 300ETF 的月度收益对比	23
5.3	HRP 与 HERC 基准模型对比	24
5.4	净值路径与回撤分析	24
5.5	换手率与权重结构分析	25
5.6	CVaR 尾部风险分析	28
5.7	因子暴露与收益归因	28
5.8	小结	31
6	稳健性检验与过拟合诊断	32
6.1	子区间与压力期检验	32
6.2	交易成本与参数敏感性	33
6.3	协方差估计与过拟合诊断	36
6.4	统计显著性检验	38
6.5	小结	39
7	结论与展望	40
7.1	主要结论	40
7.2	研究不足	41
7.3	后续研究方向	41
A	主要指标定义汇总	43
B	CSCV 候选参数网格	44
C	自适应风险预算超参数	46
	参考文献	47
	致谢	52

1. 绪论

1.1 研究背景与意义

资产配置在很大程度上决定了长期组合的风险收益特征^[1]。与短期择时策略相比，长期资产配置更关注不同资产类别间的风险来源、回撤控制和流动性管理。保险资金、养老金和银行理财等长期资金通常需要在多年时间维度上维持稳定的风险暴露，管理难度不只在收益水平，如何说清楚收益来自哪里、风险分散到什么程度、调仓成本是否可控，同样是实际问题。

风险平价和风险预算方法正是针对这类需求发展起来的。其核心思想不是资本金额的均匀分配，而是使不同资产对组合总风险的贡献更加均衡。这种方法对收益预测的依赖程度较低，适合构建可解释性强的长期配置框架^[2-3]。扩展到全球 ETF 后，问题变得复杂：不同市场收盘时间不一致，海外 ETF 带汇率暴露，各标的上市时间参差不齐，商品和权益的尾部行为差异明显。交易成本和换手的累积尤其重要，月度调仓在长周期内会侵蚀相当一部分净收益。

从理论层面看，将风险平价从严格等风险贡献条件扩展至更灵活的宽松风险预算框架，能够把权重上限、资产组约束、换手约束和 CVaR 尾部风险度量统一纳入可计算的凸优化框架。从实践层面看，以可交易 ETF 替代部分原始指数，使回测结果更贴近真实组合执行，有助于讨论执行纪律和交易成本对长期收益的实际影响。

1.2 研究问题与研究思路

本文围绕四个问题展开。宽松风险平价能否在 30 支全球 ETF 中建立风险来源清晰的配置框架？加入 CVaR 约束和换手惩罚后，收益、回撤与换手率之间的权衡是否确实改善？HERC 等层次化基准在同一样本中表现如何，与主模型是何种关系？稳健性检验能否识别出结论对样本期和参数选择的依赖程度？

本文先梳理均值-方差、风险预算、CVaR 和层次化配置方法的理论联系，再建立可交易 ETF 资产池和统一回测标准，然后在相同研究设计下比较各模型，最后

用多维度稳健性检验和过拟合诊断约束结论的适用范围。

1.3 研究内容与章节安排

论文分七章。第二章综述均值-方差、风险预算、CVaR 和层次化配置文献，说明本文的切入点。第三章给出模型符号和定位汇总。第四章说明 ETF 资产池、数据处理和回测规则。第五章比较各模型的绩效、净值路径和权重结构。第六章从子区间、参数扰动、协方差估计和过拟合诊断多个角度检验结论稳健性。第七章总结结论并指出研究局限。

1.4 可能的边际贡献

本文的边际贡献有三。数据上，以可交易 ETF 替代不可交易指数，让回测的成本和权重更贴近真实执行，而非停留在指数层面。方法上，把风险预算偏离惩罚、CVaR 约束、换手约束和资产组限制放进同一个凸优化框架，允许同时处理多个实施约束。验证上，把多种稳健性诊断串联起来，将结论明确限定在具体的样本区间和参数设定上。

2. 文献综述与理论基础

2.1 现代投资组合理论与估计误差

现代投资组合理论莫基于 Markowitz (1959)^[4] 的均值-方差框架，该框架首次将资产配置问题转化为以期望收益与协方差矩阵为输入的可计算二次规划。Sharpe (1964)^[5] 随后建立资本资产定价模型，将个别资产收益率与市场系统性风险相联系。

然而，均值-方差最优化对输入参数的高度敏感性长期制约其实际效果。Michaud (1989)^[6] 将这一现象概括为“马科维茨之谜”：收益率估计的微小扰动足以导致最优权重的剧烈变动，使样本内优化退化为样本外噪声放大器。Jorion (1986)^[7] 通过 Bayes-Stein 收缩方法系统量化了参数不确定性对组合绩效的损耗，Chopra 与 Ziemba (1993)^[8] 进一步揭示，收益率估计误差对组合效用的影响约为协方差估计误差的十倍，收益率预测的高风险性由此在计量层面得到确认。Black 与 Litterman (1992)^[9] 尝试以市场均衡隐含收益叠加主观观点的方式缓解输入不稳定性，但所引入的先验设定本身仍难以在无模型环境中验证。

在这一背景下，DeMiguel 等 (2009)^[10] 对 14 种优化策略的系统比较表明，有限样本条件下等权重 (1/N) 组合在夏普比率与确定性等价财富等多项指标上均与复杂优化相当甚至更优，有力支持了简单基准的比较价值。Jagannathan 与 Ma (2003)^[11] 则指出，对大规模资产池施加卖空约束在数学上等价于对协方差矩阵实施隐式收缩，可有效压制样本协方差的估计噪声，这一等价性为权重上下限约束的合理性提供了理论依据。

协方差矩阵的估计质量独立构成一条研究脉络。Laloux 等 (1999)^[12] 将随机矩阵理论引入金融协方差分析，证明样本协方差矩阵的大量特征值落入 Marchenko-Pastur 噪声带，仅少数特征值携带真实信息，从而为协方差清洁提供了理论基础。在此之上，Johansson 等 (2023)^[13] 提出 CM-IEWMA 方法，通过凸优化将多个衰减参数不同的指数加权移动平均估计器线性组合，在样本外预测误差上系统优于多元 GARCH，与本文采用的指数加权协方差估计方向一致。Tzikas 等 (2026)^[14] 进一步在既有风险模型基础上叠加时变瞬时统计因子，以适应金融时间序列的结构性变化；Conlon 等 (2025)^[15] 则从因子结构视角出发，表明基于因子的协方差矩阵在样本外能有效压制噪声、改善权重稳定性。近期，Bongiorno 等 (2025)^[16] 将端到端深度学习引入这一问题，通过神经网络直接学习随机矩阵清洁后的协方差估计器，并以梯度回传优化方差最小化目标，在大规模资产池中取得显著改善；然而，端到端框架对历史样本的依赖及其难以纳入可解释硬约束的局限，促使本文保留传统凸优化路径。上述研究的共同指向是：收益预测的不确定性难以消除，而协方差估计方法的选取对样本外绩效有实质影响。本文以风险预算为主线，不引入显式收益预测，并在稳健性检验中系统比较多种协方差估计器。

2.2 风险平价与宽松风险平价

风险平价的核心思想是以风险贡献而非资金比例衡量分散化程度。Qian (2005)^[2] 最早阐明，当各资产对组合总风险的贡献相等时，组合分散化效率最高，这一思想奠定了风险平价的概念基础。Maillard 等 (2010)^[3] 对等风险贡献 (ERC) 组合的数学性质进行了系统分析，证明其存在唯一性，并揭示 ERC 权重介于等权与最小方差之间的夏普比率特征。Roncalli (2013)^[17] 将风险贡献推广为完整的风险预算框架，允许对不同资产或资产类别设定差异化的风险配额；Bruder 与 Roncalli (2012)^[18] 进一步发展了多约束条件下风险预算问题的数值求解策略，为复杂实务场景提供了计算基础。

从实证角度，Asness 等 (2012)^[19] 从杠杆厌恶的行为金融视角解释了风险平价潜在超额收益的来源：低波动率资产长期被市场低估，风险平价通过加杠杆持有债券类资产可捕获这一定价偏差。Chaves 等 (2011)^[20] 的跨资产类别回测则确认，风险平价在多数样本外时段优于等权与市值加权组合，验证了其样本外有效性。Paolella 等 (2025)^[21] 在重尾分布与机制切换假设下进一步表明，风险平价权重对参数扰动的敏感性低于均值-方差最优解，在市场压力期呈现更小的回撤幅度。

宽松风险平价将严格等式约束替换为二次惩罚项，以允许可量化的预算偏离换取约束灵活性。Gambeta 与 Kwon (2020)^[22] 系统分析了偏离惩罚形式的数学性质，包括解的存在唯一性与惩罚参数对权重稳定性的影响，其框架是本文模型设计的核心出发点。Ardia 等 (2018)^[23] 提出“超越纯风险基组合”的视角，在等风险贡献的基础上引入绩效与风险贡献的可调权衡机制，证明在受控偏离严格等风险贡献的前提下，组合的样本外风险调整收益可以系统性改善，这为宽松风险平价“以可量化偏离换取收益效率”的设计逻辑提供了直接的实证依据。Cetingoz 与 Guéant (2024)^[24] 提出资产层与因子层风险预算的统一平衡框架，将多层级预算约束纳入同一凸规划体系。Bessler 等 (2021)^[25] 的实证研究表明，以资产类别为分组单位的风险预算在样本外鲁棒性上不弱于更精细的因子分解。Fassino 与 Uberti (2026)^[26] 在一般风险度量下给出了风险预算解的存在性证明与基于单纯形的收敛保证。本文将 CVaR 约束、换手惩罚和资产组上限统一纳入宽松风险平价框架，在保留风险预算逻辑内核的同时兼顾约束多样性与求解稳定性。

2.3 CVaR、交易成本与组合约束

条件风险价值（CVaR）在风险度量理论中兼具次可加性与凸性，是尾部损失约束的自然选择。Rockafellar 与 Uryasev（2000；2002）^[27-28] 通过引入辅助变量，将原本涉及分位数的非光滑 CVaR 约束等价转化为关于损失场景的线性规划，并将这一结果推广至一般损失分布，从而使尾部风险约束在大规模优化中具备计算可行性。Boyd 与 Vandenberghe（2004）^[29] 的凸优化理论则为同时纳入线性不等式约束、 ℓ_1 范数换手惩罚与辅助变量的混合优化问题提供了统一数学框架。

交易成本方面，Almgren 与 Chriss（2001）^[30] 建立了将价格冲击与时间价值权衡纳入调仓决策的最优执行模型，揭示了换手速率与市场冲击成本之间的根本张力。本文对交易成本采用固定费率线性近似，以保持模型的凸结构；这一近似在月频调仓、资产规模适中的情境下具有合理性，但在高频或大规模执行场景下需进一步精细化。

在尾部风险的情景生成方面，Uhl 等（2024）^[31] 提出基于自然语言处理的 AI 尾部事件识别框架，通过文本情绪信号识别极端市场情境，为历史模拟之外的情景补充提供了新思路；Alouadi 等（2026）^[32] 进一步将 Schrödinger Bridge 引入合成金融时间序列生成，所得路径不依赖历史分布假设，可系统扩充压力情景库。与上述基于情景扩充的路径不同，Bajo Traver（2026）^[33] 提出以机会成本（遗憾值）及其离散程度的最小化替代方差或 CVaR 作为组合优化目标，其理论依据在于投资者对“本可更优”结果的心理损失往往超过对绝对亏损的厌恶。然而，CVaR 的线性重表述与本文凸优化框架直接兼容，在约束可扩展性与计算稳定性上具有明确优势，故本文以 CVaR 作为尾部风险的主要约束工具，并在风险分析章节用于事后诊断。

2.4 HRP/HERC 与国内实践

层次风险平价（HRP）由 López de Prado（2016）^[34] 提出，利用相关矩阵的层次聚类结构对资产进行准对角化排列，再通过递归二分将风险预算分配至叶节点，从根本上回避了对协方差矩阵求逆的数值不稳定问题。Raffinot（2018）^[35] 在 HRP 框架基础上提出层次等风险贡献（HERC），在簇间分配阶段引入风险贡献逻辑，使

各聚类的风险暴露更为均衡。此后，多项研究对层次化框架进行了扩展：Lohre 等 (2020)^[36] 将尾部依赖结构引入聚类距离矩阵，改善了压力期的聚类稳健性；Cho 与 Song (2023)^[37] 通过最小生成树 (MST) 对外围节点进行预筛选，在优化聚类质量的同时降低权重集中度；Ciciretti 与 Pallotta (2024)^[38] 则将最小生成树网络直接用于权重生成，在资产数量较多时取得突出的样本外表现。这类方法有一个共同制约：层次化分配机制难以直接纳入 CVaR 上界约束或换手惩罚，在多目标约束场景下适用范围因此较为有限。

国内实践研究为本文提供了重要的市场背景与工具约束依据。华泰证券系列研究 (2020—2024)^[39-42] 系统梳理了风险平价理论在国内低利率环境下的实施难点，涵盖工具约束、再平衡频率与杠杆可得性等现实问题，并对 HRP 在国内多资产组合中的落地效果进行了实证评估。中信建投 (2025)^[43] 从大类资产配置的产品层面比较了各类配置方法；中金公司 (2026)^[44] 的量化研究对国内主流配置策略进行了系统的方法论比较；兴业证券 (2026)^[45] 则系统梳理了国内 ETF 市场品类扩容的最新进展，本文 30 支 ETF 覆盖八大资产类别的资产池构建参考了其中的品种统计。本文将 HRP 与 HERC 纳入统一回测框架，在相同评价口径下与宽松风险平价系列模型就夏普比率、最大回撤与权重集中度展开系统比较。

2.5 文献评述与本文切入点

均值-方差优化作为现代投资组合理论的基础范式，提供了收益-风险权衡的规范语言，但其对收益率预测的高度敏感性导致样本外权重极不稳定，大量实证研究表明其在无模型估计条件下难以持续优于简单基准。严格等风险贡献方法以风险贡献平等作为分散化标准，在单一约束情形下具有良好的理论性质与实证表现，然而当需同时施加权重上下限、资产类别上限、CVaR 上界和换手惩罚时，严格等式约束使问题难以纳入标准凸优化求解器，计算鲁棒性显著下降。HRP 与 HERC 以层次聚类为核心，绕开协方差矩阵直接求逆的数值困难，但层次化分配的结构决定了其无法显式表达尾部风险约束与换手成本，限制了其在多目标风险管理场景中的应用边界。国内现有实践研究在工具选择与市场约束层面提供了有益参照，但尚缺乏跨资产类别的统一风险预算框架，难以在严格的回测条件下系统比较各方法的实际绩效。端到端神经网络优化路径 (Bongiorno et al., 2025)^[16] 展示了以深度学习直接优化投资组合目标的技术可行性，但模型参数对历史样本量的高度

依赖、对硬约束的不兼容性，以及决策过程的不可解释性，制约了其在实务合规与风险归因场景中的推广。

本文以宽松风险平价为主线，将 CVaR 尾部约束、 ℓ_1 换手惩罚和资产类别上限统一纳入可稳定求解的凸优化框架，同时以等权和 HERC 作为评价基准，在涵盖 30 支 ETF、跨越八大资产类别的统一可交易回测环境中，通过多维度实证验证各方法在当前样本期内的适用边界与绩效特征。

3. 理论框架与模型方法

3.1 统一符号

表 3-1 主要符号说明

符号	含义
n	资产数量
T	历史窗口长度
w_t	第 t 期调仓后的组合权重
w_{t-1}^+	第 t 期调仓前经收益漂移后的权重
r_t	第 t 日资产收益率向量
R_t	再平衡日前可获得的历史收益率窗口
Σ_t	基于 R_t 估计的协方差矩阵
μ_t	调仓日前历史窗口 R_t 的样本均值年化估计；不含主观预测信号。
b_t	风险预算或参考权重向量

符号	含义
RC_i	第 i 个资产对组合波动率的风险贡献
l_i, u_i	单资产权重下限和上限
L_g, U_g	资产组权重下限和上限
G	资产组映射矩阵
TO_t	第 t 期换手率
c	单位交易成本率
η	CVaR 辅助变量
α	CVaR 置信水平

除特别说明外，本文所有模型均在长仓、权重归一、滚动估计、月度调仓和交易成本扣减框架下比较。最终权重由透明优化流程给出，不依赖机器学习或状态识别模块直接生成交易信号。

3.2 标准风险平价

设组合权重为 w ，协方差矩阵为 Σ ，组合波动率为：

$$\sigma_p = (w^T \Sigma w)^{1/2}$$

第 i 个资产的边际风险贡献为：

$$MRC_i = \frac{\partial \sigma_p}{\partial w_i} = \frac{(\Sigma w)_i}{\sigma_p}$$

总风险贡献为：

$$RC_i = w_i MRC_i = w_i \frac{(\Sigma w)_i}{\sigma_p}$$

由 Euler 齐次函数性质可得：

$$\sum_{i=1}^n RC_i = \frac{w^T \Sigma w}{\sigma_p} = \sigma_p$$

标准风险平价要求各资产风险贡献与目标预算 b_i 匹配：

$$RC_i = b_i \sigma_p, \quad i = 1, \dots, n, \quad \sum_i b_i = 1$$

当 $b_i = 1/n$ 时，模型退化为等风险贡献组合。标准风险平价的优势在于风险贡献定义明确且对收益预测依赖较弱。但只要加上权重上下限、组别约束和交易成本，直接求解就不再容易，本文只把它作为理论参照。

3.3 宽松风险平价与 Global RRP

宽松风险平价不是放弃风险预算，而是把严格风险贡献等式改为偏离惩罚：

$$\min_w \sum_i (RC_i/\sigma_p - b_i)^2 + \lambda_{reg} \|w - w_0\|_2^2$$

$$\sum_i w_i = 1, \quad l_i \leq w_i \leq u_i$$

其中，第一项刻画风险贡献相对预算的偏离，第二项刻画与参考权重或上一期权重的距离。这个表达允许在风险预算、权重稳定性和现实约束之间做折中，而不是强迫三者同时精确满足。

Local Relaxed Risk Parity 表示本地资产池中的宽松风险预算模型。Global RRP 表示扩展到全球多资产 ETF 后的基准宽松风险预算模型，将债券、可转债、中国权益、港股、海外权益和商品放入统一风险预算框架。它的问题在于换手较高，交易成本对净收益的影响比较明显，基础版本没有 CVaR 约束。

3.4 凸优化改进模型

Convex Adaptive Global RRP 将风险预算思想转化为凸化近似，使模型可以更自然地纳入换手率、CVaR、资产上限和组别约束。其简化目标函数为：

$$\min_w J(w)$$

$$J(w) = \lambda_{var} w^T \Sigma_t w + \lambda_{budget} \|w - b_t\|_2^2$$

$$+ (\lambda_{turnover} + \lambda_{tc} \cdot c) \|w - w_{t-1}^+\|_1 + \lambda_{cvar} CVaR_\alpha(w) - \lambda_{return} \mu_t^T w$$

$$\sum_i w_i = 1, \quad 0 \leq w_i \leq u_i, \quad L_g \leq \sum_{i \in g} w_i \leq U_g$$

目标函数中各项分工明确：方差项控制整体波动；预算跟踪项约束权重偏离；换手惩罚项压低交易频率；CVaR 项纳入历史尾部损失。公开低换手候选族统一采用

$\lambda_{turnover} = 0.02$ 、 $\lambda_{cvar} = 0.15$ 、单边交易成本 $c = 0.0003$ ，并将现金类资产组合权重限制在 30% 以内。Convex Adaptive Global RRP 的 $\lambda_{cvar} = 0$ ，而 Improved Convex Adaptive Global RRP 显式启用 CVaR 惩罚，这是二者的重要差异。

公开主结果不是固定候选的全样本回测，而是自 2018-01-02 起连续拼接的滚动样本外路径。每个季度仅使用此前完成的训练窗和验证窗，先构造最高历史夏普附近的 95% 置信候选集，再按预先声明的低换手顺序解决统计并列；只有挑战者的历史夏普改善超过单侧 95% 阈值时才切换。完整 36 组参数网格仅用于探索与过拟合诊断，不直接覆盖公开路径。

关于收益倾斜项 $-\lambda_{return}\mu_t^T w$ ，其定位需要在哲学层面加以说明。风险平价的核心思想是放弃对收益率的精确预测、将配置决策的依据完全置于风险端，第二章文献综述亦援引 Chopra 与 Ziemba (1993)^[8] 的研究——收益率估计误差对组合效用的损耗约为协方差估计误差的十倍——作为“放弃收益预测”这一设计选择的计量依据。在此背景下，目标函数中保留历史均值输入项在逻辑链条上存在内在张力，需要明确解释。

本文将该项定位为**方向性正则项**，而非均值一方差框架意义上的收益预测机制。公开低换手候选族采用 $\lambda_{return} = 0.06$ ； μ_t 仅由调仓日前历史窗口估计，不接触未来数据。该项只用于轻微排除历史窗口内持续负收益的极端配置方向，模型的主要结构仍来自方差、风险预算、CVaR 与换手约束。第六章通过对该权重进行上下 25% 的单因素扰动评估这一判断。

Improved Convex Adaptive Global RRP 是本文重点讨论的可实施改进，其改进体现在低换手、CVaR 约束、资产组约束和权重路径稳定四个方面。若历史情景损失为 $L_s = -r_s^T w$ ，CVaR 可表示为^[27,29]：

$$CVaR_\alpha(L) = \min_{\eta} \left[\eta + \frac{1}{(1-\alpha)T} \sum_{s=1}^T \max(L_s - \eta, 0) \right]$$

在当前样本中，Improved Convex Adaptive Global RRP 的平均月度换手率为 1.96%。相比 Global RRP 的 24.51%， L_1 换手惩罚将月度调仓幅度压缩至较低水平，在长期配置语境下有助于降低执行摩擦成本，但相应地，当市场相关结构快速变化时，组合调整速度也会放慢。

3.5 防御型风险覆盖层（Risk Overlay）

防御型动态 RRP 在标准优化框架之外叠加了一个**事后规则层**（Risk Overlay），该层独立于优化器运行，对优化器输出权重 $\hat{w}_t$ 进行比例缩放：

$$w_t = s_t \cdot \hat{w}_t, \quad 1 - s_t \text{ 部分分配至货币市场 ETF (511880.SH)}$$

缩放系数 $s_t \in [0.5, 1.0]$ 由当期最大回撤深度 DD_t 决定，映射规则如表 3-2 所示。

表 3-2 回撤缩放映射表

回撤区间	缩放系数 s_t	降仓幅度
$DD_t < 2.5\%$	1.00	不降仓
$2.5\% \leq DD_t < 4.0\%$	0.75	降仓 25%
$4.0\% \leq DD_t < 8.0\%$ （线性插值）	—	—
$DD_t \geq 8.0\%$	0.50	降仓 50%

需要强调的是：回撤控制**并非**作为约束变量写入优化目标函数，而是作为事后规则在优化完成后独立执行。这一设计使优化器维持凸性与完整投资约束（ $\sum w_i = 1$ ），同时通过外部规则层对极端下行期的组合暴露进行动态收缩。

EMA 偏差信号 $d_i = \ln p_i - \ln \text{EMA}_i$ 在优化调用前将权重上界收紧（超买 $d_i > 15\%$ 时 $u_i \rightarrow 20\%$ ，止损 $d_i < -5\%$ 时 $u_i \rightarrow 5\%$ ，否则维持默认上界 45%），作为绑定约束参与 KKT 条件求解，而非事后过滤。第五章中防御型动态 RRP 的低最大回撤来自该覆盖层的降仓操作，与 CVaR 约束驱动的尾部控制机制不同。

3.6 协方差估计方法

协方差矩阵的质量直接影响风险预算分配和权重求解。本文在不同模型和稳健性检验中使用三类估计器。

样本协方差矩阵是最直接的方法：给定历史收益率窗口 $R_t \in \mathbb{R}^{T \times n}$ ，

$$S_t = \frac{1}{T-1} (R_t - \bar{r}_t \mathbf{1}^T)^T (R_t - \bar{r}_t \mathbf{1}^T)$$

在资产数量 n 较大或历史窗口 T 较短时，样本协方差矩阵的估计噪声较大、条件数较差，容易导致极端权重。Laloux 等人的随机矩阵理论研究表明，金融资产相关矩阵中大量特征值落入噪声区间^[12]，这是样本估计不稳定的根本来源。

Ledoit-Wolf 收缩估计^[46]将样本协方差矩阵向结构化目标 F_t 做加权平均：

$$\hat{\Sigma}_t = (1 - \delta)S_t + \delta F_t$$

其中 F_t 通常取等方差对角矩阵，最优收缩系数 $\delta \in [0, 1]$ 通过 Oracle 近似方法求解。收缩使极端特征值向均值压缩，降低权重对样本误差的敏感度。Ledoit 和 Wolf 在后续研究中将线性收缩推广至二次收缩框架，从理论上给出更接近最优非线性收缩的可计算近似^[47]；本文默认使用线性 Ledoit-Wolf 收缩，二次收缩可作为后续扩展。

指数加权移动平均（EWMA）通过对近期观测赋予更高权重，捕捉协方差的时变性：

$$\hat{\Sigma}_t = (1 - \lambda) \sum_{s=0}^{T-1} \lambda^s r_{t-s} r_{t-s}^T, \quad \lambda = e^{-\ln 2 / \tau}$$

其中 τ 为半衰期参数。本文在稳健性检验中测试 $\tau \in \{20, 60, 120\}$ 三种设定，分别对应短期、中期和长期时间尺度。

上述三类估计器均建立在无条件协方差的假设之上，即把平静期与压力期的收益混合为单一分布进行估计。在存在状态切换的市场中，这一假设会系统地低估对冲资产仅在危机期才显现的尾部协同，从而削弱风险预算的稳健性。Ielpo 等（2024）^[48] 提出”状态平价”（regime parity）组合，将各状态内的风险平价解按状态稳态概率线性加权，证明该构造能缓解无条件矩无法同时刻画混合分布两种模式的缺陷，对罕见但严重的不利状态具有更强的抵抗力；Bouyé 与 Teiletche（2025）^[49] 将宏观状态建模为分布的混合，论证基于状态条件矩的配置方法在样本外可优于无条件的资产基组合；Fleming 等（2001）^[50] 更早地从确定性等价的角度证明了波动率择时（即对协方差时变性的利用）具有可量化的经济价值。受上述研究启发，本文构建状态条件协方差估计器作为补充稳健性检验：以窗口内等权组合的滚动已实现波动作为点内（point-in-time）状态代理，将历史交易日划分为平静与压力两态、分别估计组内协方差，再按状态频率先验 π 加权合成 $\hat{\Sigma}_t = (1 - \pi)\hat{\Sigma}_{\text{calm}} + \pi\hat{\Sigma}_{\text{stress}}$ ；其中将经验状态频率向偏高的危机先验收缩，等价于对罕见但严重的压力态进行加权，是对无条件估计的一种状态条件收缩。需要说明的是，Ielpo 等在组合层面对各状态的风险平价权重直接加权，本文则在协方差层面合成状态条件矩、再代

入统一的凸优化求解一次权重，是其思想在本文凸框架下的协方差层近似实现，从而能与 CVaR 约束、换手惩罚等既有约束保持兼容。

主模型默认使用 Ledoit-Wolf 收缩估计，第六章协方差稳健性检验系统比较三类无条件估计器及上述状态条件估计器对主要绩效指标的影响。

3.7 HERC 基准模型

HERC 基准模型在层次聚类结构中加入风险贡献思想，使簇内和簇间风险分配更接近风险预算逻辑^[35]。与本文主模型相比，HERC 不支持直接写入 CVaR 约束、 ℓ_1 换手惩罚和资产组权重上下限，其分配逻辑完全由协方差矩阵的聚类结构驱动。

本文还实现了 HRP^[34]，但在汇报结果时未将其列为主要对比基准。原因在于：当资产池同时包含货币市场 ETF（年化波动率约 0.19%）和权益类 ETF（年化波动率 20%–55%）时，层次化递归二分机制在无约束条件下系统性地将绝大多数权重分配至货币市场 ETF，导致 HRP 组合退化为准现金（实测组合年化波动率 0.17%，年化收益 1.68%，Sharpe 比率 -0.828 ）。这一行为是 HRP 在波动率差异悬殊的混合资产池中的必然结果，而非绩效不佳的随机样本，因此与主模型的直接绩效对比缺乏可比性，从基准组合中予以移除。HERC 通过在层次结构中引入风险贡献平衡机制，部分缓解了上述集中效应，仍可作为有参考价值的对照基准。

凸优化框架的核心优势不在于任何单一绩效指标的数值高低，而在于它具备**硬约束的表达能力**：CVaR 尾部约束、 ℓ_1 换手惩罚、资产组权重上下限均可以直接写入求解器，强制实现跨类别分散，而这些约束在层次化框架中从结构上无法被显式表达。HERC 因此构成配置思路层面的对照，而非可与主模型在同一排序坐标下直接比较的替代方案。

表 3-3 模型定位汇总

Model	Role in Thesis	Main Advantage	Main Limitation
Standard Risk Parity	理论参照	风险贡献清晰	多约束下求解困难
Local Relaxed Risk Parity	本地宽松风险预算	降低严格等式刚性	资产池较窄
Global RRP	基准宽松风险预算模型	全球资产分散与风险预算清楚	换手较高
Convex Adaptive Global RRP	凸化风险预算近似	兼容换手和组别约束	不是经典 RP 精确等价
Improved Convex Adaptive Global RRP	可实施性改进模型	低换手、CVaR 约束	参数依赖与样本依赖
HERC Benchmark	层次化风险贡献基准模型	引入层次风险贡献	难直接表达 CVaR 和换手

4. 数据、变量与研究设计

4.1 ETF 资产池构建原则

本文使用可交易 ETF 构建全球多资产池。选择标准主要是可交易性和跨资产覆盖。用 ETF 而非不可交易指数，回测结论更贴近实际组合执行，但流动性冲击、申赎成本和大额交易的滑点都没有纳入。

表 4-4 ETF 资产池

ETF	Ticker	资产类别
可转债 ETF	511380.SH	债券类

ETF	Ticker	资产类别
国债 ETF	511010.SH	债券类
10 年国债 ETF	511260.SH	债券类
信用债 ETF	511030.SH	债券类
日利 ETF	511880.SH	债券类
沪深 300ETF	510300.SH	A 股宽基
中证 500ETF	510500.SH	A 股宽基
中证 1000ETF	512100.SH	A 股宽基
中证 2000ETF	563300.SH	A 股宽基
创业板 ETF	159915.SZ	A 股宽基
红利 ETF	510880.SH	A 股宽基
半导体 ETF	512480.SH	中国科技与增长
人工智能 ETF	159819.SZ	中国科技与增长
新能源 ETF	516160.SH	中国科技与增长
科创 50ETF	588000.SH	中国科技与增长
证券 ETF	512880.SH	中国行业与消费
军工 ETF	512660.SH	中国行业与消费
消费 ETF	159928.SZ	中国行业与消费
恒生 ETF	159920.SZ	港股
白银 LOF	161226.SZ	大宗商品
纳指 ETF	159941.SZ	全球股票
标普 500ETF	513500.SH	全球股票
日经 225ETF	513880.SH	全球股票
欧洲 ETF	513030.SH	全球股票
黄金 ETF	518880.SH	大宗商品




图 4-1 资产池跨类别相关结构（平静期与压力期对比）

ETF	Ticker	资产类别
有色金属期货 ETF	159980.SZ	大宗商品
能源化工期货 ETF	159981.SZ	大宗商品
豆粕 ETF	159985.SZ	大宗商品
煤炭 ETF	515220.SH	大宗商品
原油 ETF	162411.SZ	大宗商品

资产池包含 30 支可交易 ETF，覆盖八类风险来源。债券与现金类包含可转债、国债、10 年国债、信用债和日利 ETF，提供久期、信用与流动性梯度。A 股宽基类涵盖沪深 300、中证 500、中证 1000、中证 2000、创业板与红利六支 ETF。中国科技与增长类包含半导体、人工智能、新能源和科创 50 四支 ETF；中国行业与消费类补充证券、军工和消费三支 ETF。港股类纳入恒生 ETF。全球股票类包含纳指、标普 500、日经 225 和欧洲 ETF。贵金属类包含黄金 ETF 与白银 LOF；大宗商品与资源类包含有色金属期货、能源化工期货、豆粕、煤炭和原油五支 ETF。另设 30 年国债、中韩半导体、证券公司先锋策略、沙特、巴西和机器人六支候选 ETF，仅用于 36 支资产的 Barra-style 代理敞口与相关性诊断，不进入任何回测。

图 4-1 展示了资产池在平静期与主要压力期前后的跨类别相关结构变化。债券类（日利、国债、信用债）与权益、商品的相关性在压力期通常有所上升，典型的分散化效果有所削弱；黄金在多数压力期仍保持与权益的低相关或负相关，是

当前资产池中分散效果最稳定的品种之一。全球股票类与中国 A 股之间的相关性在 2020 年初流动性危机和 2022 年下行期明显走高，这也是协方差估计器需要兼顾近期和历史信息的一个具体原因。不同压力情景下相关结构的变化路径，是协方差稳健性检验的重要背景。

以 2022 年为具体案例，可以较清晰地观察到协方差矩阵变化如何驱动权重调整。2022 年初俄乌冲突爆发后，原油、黄金等商品波动率骤然上升，同期全球股票与 A 股宽基的相关性走高，债券类的防御价值出现压缩。本文所用 Ledoit-Wolf 收缩估计器以 252 日历史窗口为主要信息来源，在 2022 年上半年逐步将上述相关性变化纳入协方差矩阵，使权益类资产的协方差贡献在估计层面相应放大。优化器在更新的协方差矩阵输入下，结合资产组权重上限约束，将权益类配置从 2021—2022 阶段的约 8%—17% 压缩至更低水平，同时因 L_1 换手惩罚的存在，调仓幅度受到约束，避免了对短期信号的过度追随。黄金 ETF 因与权益相关性在此期间仍相对稳定而保持稳定配置。这一机制说明，“协方差驱动权重调整”并非黑箱操作，其逻辑链条可在权重路径图（图 5-6）与阶段性权重统计（表 5-8）中得到印证。

4.2 样本构造与预处理

本文使用经复权处理后的可比价格序列，并据此计算相邻交易日收益率，同时对不同 ETF 的交易日进行对齐。上市前缺失价格不作填补；若某 ETF 在再平衡日前的可用历史记录不足 60 个交易日，则不参与当期优化，满足门槛后方可进入可投资宇宙。价格数据通过 Tushare 接口获取，当前缓存中最早有效价格观测为 2007-01-18，最新缓存日期为 2026-07-31；受限于各 ETF 上市时间，部分晚上市品种的有效样本更短。本文绩效评价区间自 2018-01-02 起，至 2026-07-31 止，将评价起点设定为该日期而非上市首日，是为保证多数资产在进入评价期前已积累足够的协方差估计历史窗口，避免初期样本不足带来的估计偏误。逐点时间宇宙过滤在每个再平衡日排除历史数据不足的 ETF，以避免前视信息泄露。部分资产如中证 1000 ETF 上市时间较晚，因此其历史统计特征和模型参与频率与早上市 ETF 不完全一致，这一点在描述性统计与回测设计中已有体现。

4.3 收益率、权重、交易成本与换手率定义

设第 i 个 ETF 在第 t 日价格为 $P_{i,t}$ ，日收益率为：

$$r_{i,t} = \frac{P_{i,t}}{P_{i,t-1}} - 1$$

调仓后权重为 w_t ，调仓前经收益漂移后的权重为 w_{t-1}^+ ，组合毛收益为：

$$r_{p,t}^{gross} = w_{t-1}^T r_t$$

第 t 个调仓日换手率定义为：

$$TO_t = \sum_i |w_{i,t} - w_{i,t-1}^+|$$

若单位交易成本率为 c ，则交易成本为 $TC_t = c \cdot TO_t$ ，组合净收益为 $r_{p,t}^{net} = r_{p,t}^{gross} - TC_t$ 。本文默认交易成本为 3 bps，在结果中区分毛收益和净收益。该处理未覆盖冲击成本、买卖价差和申赎费用。

4.4 组合约束与调仓规则

本文模型在长仓约束下比较，权重和为 1，不允许卖空。模型包含单资产权重上限、资产组边界和月度调仓规则。月度调仓意味着模型在每个月末附近的再平衡点使用当时可获得的历史窗口估计风险输入，适合长期配置研究，也能避免过高交易频率导致的执行成本问题。

4.5 评价指标体系

累计净值定义为 $NAV_t = \prod_{s \leq t} (1 + r_{p,s}^{net})$ 。净年化收益衡量整个评价期内净值增长速度，受样本起止点影响。年化波动率衡量收益波动程度。令 y_{m-1} 为上一月最后有效的 1 年期中债国债到期收益率，日度无风险收益为 $r_{f,d} = (1 + y_{m-1})^{1/243} - 1$ 。夏普比率和 Sortino 比率均以日期对齐的日度超额收益 $r_{p,d}^{net} - r_{f,d}$ 计算；前者使用组合日收益标准差，后者使用超额收益下行均方根^[51]。若任一评价月份缺少对应利率，流水线失败退出，不以 Shibor、LPR 或固定常数替代。最大回撤定义为：

$$MDD = \min_t \left(\frac{NAV_t}{\max_{s \leq t} NAV_s} - 1 \right)$$

Calmar 比率为净年化收益除以最大回撤绝对值。平均月度换手率衡量组合执行稳定性。95% 日度 CVaR 衡量历史日度损失超过 95% 分位后的平均损失，是尾部风险诊断指标，不是未来极端损失预测。

4.6 回测流程与无前视设计

本文回测流程如下：第一，在每个调仓日确定历史窗口；第二，使用调仓日前数据估计协方差、预算或状态；第三，求解目标权重；第四，计算调仓换手和交易成本；第五，使用调仓后的未来收益计算组合净值；第六，进入下一个月度调仓点。压力期识别只用于事后评价，不作为交易信号。稳健性检验不参与主模型重新选择，其作用是约束结论强度。评价区间 2018-01-02 至 2026-07-31 共约 103 个月，月末再平衡日共 103 个。评价起点之前的实际可得行情仅用于滚动窗口预热；每支 ETF 仍须累计达到 60 个有效观察后才可进入组合。

无前视设计的时序实现可从代码层面加以说明。设第 T 个月末为调仓日，协方差矩阵与风险预算估计所使用的收益率序列严格截止于 $T - 1$ 日，即 T 日当日价格（当日收益率 r_T ）不进入本期估计窗口。 T 日优化求解完成后所得权重 w_T 从 $T + 1$ 日起生效，组合净值依据 $T + 1$ 日及之后实现的收益率 $r_{T+1}, r_{T+2}, \dots$ 进行计算。对于上市时间较短的主池 ETF（如中证 2000、能源化工期货 ETF），可投资宇宙的纳入判断仅依赖截至 $T - 1$ 日已观测到的历史记录：若有效观察不足 60 日，则在 T 日调仓中排除。六支候选 ETF 则在整个回测中固定隔离。上述时序规则在回测引擎的数据切片逻辑中逐日强制执行，是保证无前视设计在实现层面不发生信息泄露的关键环节。

4.7 可靠性与诊断层

为提高结果披露的完整性，并把过去容易被求解过程掩盖的问题显式呈现出来，本文在主回测路径之外设置了一套独立的可靠性诊断层。该诊断层不参与模型选择，也不改变主模型排序，只用于记录回测执行过程中可能影响结果解释的数值现象。诊断内容主要包括三个方面：其一是求解器诊断，记录各类优化问题的收敛状态、目标函数值、异常信息以及是否发生回退；其二是协方差诊断，跟踪样本长度与资产数量之比、半正定修复触发情况和条件数等指标，用于识别估计矩

阵是否存在显著数值不稳定；其三是可投资资产池诊断，确保每个再平衡日的纳入决策仅依赖当时可见的信息，并在下一个再平衡日前保持不变。诊断结果表明，在 Global RRP 的静态回测路径上，约 44.3% 的再平衡日出现了求解器回退，主要对应带杠杆约束下的局部数值失稳。这一现象说明，若缺少显式诊断，部分模型结果虽然能够被产出，但其形成过程未必足够透明。

除上述诊断层外，本文还从参数选择、风险叠加敏感性、数据快照一致性和夏普差异显著性四个方面补充方法严谨性检验。这些辅助检验与主模型权重计算相互独立，其作用不是重新挑选最优模型，而是判断结论在不同设定下是否仍然保持一致。就本文结果看，主模型的优势并非来自单一参数的偶然命中，但其解释范围仍然应限定在已检验的样本区间和约束条件之内。

4.8 描述性统计与资产特征分析

表 4-5 汇报各 ETF 自上市至 2026-07-31 的有效观测数及主要统计特征。评价区间为 2018-01-02 至 2026-07-31；评价起点前的实际历史用于参数预热，观测数不足 60 个交易日的品种将被逐期排除在优化之外。权益和商品资产的波动率与回撤通常显著高于债券类资产。

表 4-5 主要资产描述性统计

ETF	Obs.	Ann. Return	Ann. Vol.	Max DD
可转债 ETF	1533	5.36%	8.74%	-15.90%
国债 ETF	2600	2.76%	1.67%	-4.92%
10 年国债 ETF	2167	3.86%	2.23%	-4.62%
信用债 ETF	1741	2.54%	1.61%	-4.47%
日利 ETF	2600	2.18%	0.19%	-0.20%
沪深 300ETF	2600	3.65%	16.32%	-42.16%
中证 500ETF	2600	1.24%	18.98%	-47.39%
中证 1000ETF	2365	0.67%	20.76%	-50.97%
中证 2000ETF	695*	9.43%	25.61%	-32.76%

ETF	Obs.	Ann. Return	Ann. Vol.	Max DD
创业板 ETF	2599	2.36%	25.33%	-58.01%
红利 ETF	2600	5.50%	13.90%	-24.16%
半导体 ETF	1732	20.78%	33.95%	-62.49%
人工智能 ETF	1417	10.50%	28.70%	-45.21%
新能源 ETF	1328	-4.48%	28.12%	-67.30%
科创 50ETF	1385	2.94%	26.10%	-59.64%
证券 ETF	2423	0.98%	22.35%	-45.45%
军工 ETF	2423	0.72%	25.84%	-50.95%
消费 ETF	2600	6.65%	20.86%	-59.97%
恒生 ETF	2600	3.38%	17.85%	-47.05%
白银 LOF	2598	6.83%	21.53%	-67.64%
纳指 ETF	2600	18.77%	19.41%	-31.10%
标普 500ETF	2599	14.06%	15.25%	-29.67%
日经 225ETF	1724	10.76%	17.73%	-28.89%
欧洲 ETF	2599	6.79%	16.29%	-41.52%
黄金 ETF	2600	13.28%	12.11%	-30.52%
有色金属期货 ETF	1600	11.80%	15.53%	-32.86%
能源化工期货 ETF	1583	6.42%	20.77%	-48.36%
豆粕 ETF	1613	11.93%	17.06%	-26.60%
煤炭 ETF	1558	17.33%	29.18%	-33.22%
原油 ETF	2600	3.88%	28.05%	-72.08%

* 近期上市 ETF，可用历史较短，仅在积累足够观测后参与优化。

这些统计只是帮助理解资产池结构差异，不直接用于模型选择。日利 ETF 是资产池的现金管理层；科技、新能源及商品类 ETF 的波动与回撤通常显著高于债券类资产。黄金 ETF 与白银 LOF 提供贵金属风险源；有色金属期货 ETF 与能源化工期货 ETF 直接承载商品期货价格风险，区别于商品企业股票。主池内晚上市品种在累计达到 60 个有效观察后动态进入；六支候选品种仅参与代理敞口与相关性诊断，不参与权重优化。

5. 实证结果分析

5.1 主模型绩效比较

表 5-6 汇报核心模型在 2018-01-02 至 2026-07-31 评价区间内的绩效指标，共 103 个按月观察点。夏普比率点估计的近似标准误为 $\sqrt{(1 + 0.5\hat{S}^2)/T} \approx 0.13$ ($T = 103$ 月)；§6.4 给出基于分块自助法的配对显著性检验。Global RRP 的净年化收益率为 4.28%，年化波动率为 4.13%，夏普比率为 0.534，最大回撤为 -6.32%，平均月度换手率为 24.51%。这一换手水平在实务中并不轻松；若按 3 bps 费率估计，相关交易成本每年约会侵蚀 0.65 个百分点的净收益。

Convex Adaptive Global RRP 的净年化收益为 9.35%，夏普比率为 0.484，最大回撤为 -28.87%，平均月度换手率降至 0.00%。与 Global RRP 相比，换手率明显下降。Improved Convex Adaptive Global RRP 的净年化收益进一步提高到 5.60%，夏普比率为 1.186，Sortino 比率为 1.699，最大回撤为 -3.81%，平均月度换手率为 1.96%。这一模型的优势不在于单一指标的极致领先，而在于收益、回撤与换手控制之间取得了更稳妥的平衡；相应不足是权益上涨阶段的收益弹性有限，可能阶段性落后高 beta 权益资产。

表 5-6 核心模型绩效（评价区间 2018-01-02 至 2026-07-31）

Model	Net Return	Sharpe	Max DD	Calmar	Monthly TO
Global RRP	4.28%	0.534	-6.32%	0.677	24.51%
Defensive Dynamic RRP [†]	5.09%	0.637	-6.64%	0.767	24.58%
Convex Adaptive Global RRP	9.35%	0.484	-28.87%	0.324	0.00%
Improved Convex Adaptive Global RRP	5.60%	1.186	-3.81%	1.469	1.96%
Equal Weight	7.73%	0.561	-12.89%	0.599	0.96%
60/40 Benchmark	6.34%	0.466	-19.55%	0.324	0.93%

[†] Defensive Dynamic RRP 为防御型风险覆盖实验模型，仅作补充对比，不是本文主要研究对象。

Equal Weight 和 60/40 Benchmark 为朴素基准，交易成本按相同 3 bps 费率计算。

5.2 与沪深 300ETF 的月度收益对比




图 5-2 Improved Convex Adaptive Global RRP 与沪深 300ETF 的月度表现对比

图 5-2展示了 2018-01 至 2026-07 期间 Improved Convex Adaptive Global RRP 与沪深 300ETF 的月度净值和月度超额收益。Improved Convex Adaptive Global RRP

累计收益为 59.97%，沪深 300ETF 为 66.50%；但策略月度波动率仅 0.79%，低于沪深 300ETF 的 4.63%。日频最大回撤分别为 -3.81%（2020-03-19）和 -38.85%（2024-02-02）。策略在 53/103 个月跑赢沪深 300ETF，月度相关系数为 0.565。该结果说明，本文模型并非以捕捉 A 股权益贝塔为目标；其优势主要体现为显著压低波动和回撤，在权益强上涨月份往往牺牲一定进攻弹性。

5.3 HRP 与 HERC 基准模型对比

表 5-7 展示了在相同评价口径下计算的 HRP 和 HERC 基准模型绩效。如第 3.7 节所述，HRP 在本资产池中退化为准现金配置（组合年化波动率 0.26%，Sharpe -0.117），仍列入此处供参照。HERC 基准模型的净年化收益为 2.57%，夏普比率为 0.646，最大回撤为 -0.69%，Calmar 比率为 3.727，平均月度换手率为 9.12%。

HERC 的绝对年化收益（2.57%）与 Improved Convex Adaptive Global RRP 的 5.60% 仍有明显差距。HERC 年化波动率为 0.72%，在评价期内维持较高比例的债券配置；凸优化框架通过 CVaR 约束和资产组权重上限，将权益和商品的分散化维持在更高水平。

表 5-7 HRP 与 HERC 基准模型绩效（评价区间 2018-01-02 至 2026-07-31）

Benchmark	Net Return	Volatility	Sharpe	Max DD	Calmar	Monthly TO
HRP Benchmark	2.07%	0.26%	-0.117	-0.19%	10.958	2.34%
HERC Benchmark	2.57%	0.72%	0.646	-0.69%	3.727	9.12%

HRP 组合波动率较低并集中于货币市场层，列此供结构对比参考。

5.4 净值路径与回撤分析

图 5-3 展示了六个核心模型在评价区间内的累计净值路径。Convex Adaptive 与 Improved Convex Adaptive Global RRP 在多数阶段净值较高，后者路径更平稳；HERC 的曲线接近缓斜直线，与其近乎全仓债券的结构一致。图 5-4 中，Improved Convex Adaptive Global RRP 最大回撤为 -3.81%，优于 Global RRP 的 -6.32%，两




图 5-3 核心模型累计净值路径比较




图 5-4 核心模型回撤路径比较




图 5-5 核心模型平均月度换手率比较

者最深回撤均发生于 2022 年市场下行期。

5.5 换手率与权重结构分析

换手率直接影响交易费用总额，也关系到组合日常管理的复杂程度。Global RRP 和 Defensive Dynamic RRP 的平均月度换手率分别达到 24.51% 和 24.58%，说明在缺少换手约束时，基础风险预算模型的调仓频率往往较高。Improved Convex Adaptive Global RRP 在引入 L_1 惩罚后，换手率控制在 1.96%，显著低于 HERC (9.12%)。不过，低换手并非没有代价；当市场相关结构快速变化时，组合调整速度也会相应放慢。

各色带宽度反映该 ETF 在当月末的实际配置权重，纵轴为持仓占比 (0–100%)。从图中可以观察到几个结构性特征：日利 ETF（货币市场层，最宽的淡蓝色带）受现金组 30% 上限约束，长期承担现金管理与稳定器作用；黄金 ETF 维持稳定但有限的商品配置；A 股和科技类 ETF 的权重随历史波动和相关结构变化而调整。整




图 5-6 Improved Convex Adaptive Global RRP、Global RRP 与 HERC 基准模型的资产组权重路径




图 5-7 改进型凸适应性全局宽松风险平价模型月末单 ETF 持仓权重变化（2018-01-02 至 2026-07-31，共 103 个再平衡日）。每条色带对应一只 ETF，颜色编码遵循资产类别分组：蓝色系为债券类，红色系为 A 股宽基，橙色系为中国科技与成长，绿色系为全球股票，黄色系为大宗商品。

体而言，权重路径呈现低频调整特征，换手惩罚有效限制了调仓幅度，避免了因协方差矩阵短期变动引发的过度交易。

表 5-8 主要模型阶段性资产组平均权重（2021–2022 与 2023–2025）

Model	Stage	Bonds	China Eq.	HK Eq.	Global Eq.	Commodities
Improved Convex	2021–2022	71.70%	8.19%	0.60%	5.65%	13.86%
Improved Convex	2023–2025	70.35%	6.85%	0.28%	6.89%	15.63%
Global RRP	2021–2022	66.28%	16.45%	1.36%	6.25%	8.05%
Global RRP	2023–2025	92.16%	3.11%	0.32%	3.47%	3.47%
HERC	2021–2022	95.05%	1.61%	0.16%	0.89%	1.88%
HERC	2023–2025	94.86%	1.76%	0.16%	0.97%	1.54%

图 5-6 和表 5-8 说明各模型绩效差异从何而来。Improved Convex Adaptive Global RRP 的权重路径较为平滑，其债券底仓在两个阶段稳定在约 70%–72%，其中日利 ETF（货币市场层）和国债 ETF 共同承担现金与久期管理职责；商品组配置约为 14%–16%。这种稳定性来自换手惩罚和资产组边界的约束，而不是模型自发保守。

Global RRP 在没有换手约束的情况下更直接地响应协方差变化，其债券组权重从 2021–2022 阶段的 66.28% 显著上升至 2023–2025 阶段的 92.16%，反映出基础风险预算模型在权益类波动放大后会快速向防御性资产倾斜，调仓幅度大，换手代价也明显高于约束化版本。

HERC 两个阶段的债券权重均维持在约 95%，权益与商品合计约为 5%，是递归二分机制在波动率悬殊资产池中向低方差端自然收敛的结构性结果（详见 §3.7）。这说明，若不在求解器层面显式写入资产组下限约束，混合波动率资产池中的跨类别分散在算法层面无法保证；两类方法的比较价值在于揭示约束有无对配置的系统性影响，而非在同一夏普坐标上排序。

货币市场 ETF（511880.SH，日利 ETF）在两个阶段的平均权重均为 30.0%，达到现金组上限，是最大单一持仓；商品组平均权重约 14%–16%，历史收益贡献份额约为 30.0%（见 §5.7）。权重与收益贡献的不对称是风险预算在混合资产池中的典型特征。




图 5-8 核心模型 95% 日度 CVaR 比较

5.6 CVaR 尾部风险分析

表 5-9 核心模型 95% 日度 CVaR（评价区间 2018-01-02 至 2026-07-31）

Model	95% Daily CVaR
Global RRP	0.68%
Defensive Dynamic RRP	0.73%
Convex Adaptive Global RRP	2.41%
Improved Convex Adaptive Global RRP	0.40%
HERC Benchmark	0.10%

表 5-9 汇报了各模型的 CVaR 数值。CVaR 与最大回撤反映的并不是同一件事：前者刻画的是历史日度损失超过某一分位点后的平均损失，后者反映的是整条净值路径上的最深跌幅。二者都具有参考意义，但不能相互替代。与此同时，历史 CVaR 仍然受样本所限，无法覆盖历史中从未出现过的极端情景。

5.7 因子暴露与收益归因

为进一步理解各模型收益的来源结构，本文使用五个代理因子（权益、债券、大宗商品/黄金、防御性资产、全球风险）对主模型的日收益率进行时间序列回归，




图 5-9 核心模型因子暴露汇总（全样本回归）

并分解各因子对总收益和总方差的贡献。

图 5-9 和表 5-10 展示资产类别平均资金暴露与五因子代理回归诊断。Global RRP 的权益、债券与商品/黄金平均资金暴露分别为 0.147、0.099 与 0.049，回归 $R^2 = 0.531$ ，年化 $\alpha = 0.33\%$ ($t = 0.50$)。Improved Convex Adaptive Global RRP 的对应暴露分别为 0.131、0.392 与 0.139，回归 $R^2 = 0.757$ ，年化 $\alpha = 1.78\%$ ($t = 3.25$)。因子由同一 ETF 资产池构造，代理因子之间存在共线性，回归系数本身不宜作结构性解释，因此表中采用更直观的资金暴露并同时披露回归拟合与 alpha 诊断。

表 5-10 核心模型资产类别平均资金暴露与五因子回归诊断

Model	Equity	Bond	Commodity	Defensive	Max Class	R^2	α (Annualized)
Global RRP	0.147	0.099	0.049	0.026	0.147	0.531	0.33%
Improved Convex	0.131	0.392	0.139	0.037	0.392	0.757	1.78%

因子均为代理因子，不对应特定标准化指数。

图 5-10 展示两模型在 252 日滚动窗口下的代理因子回归系数。滚动系数的幅度和符号均明显时变，且在代理因子共线时会被放大，因此这里只将其作为历史诊断，不把单个 beta 解释为稳定的未来暴露，也不将其输入组合权重生成过程。

表 5-11 汇总了归因结果。收益方面，权益与商品/黄金贡献接近，分别为 30.0% 和 30.0%，债券贡献 24.5%。风险方面，权益资产类别方差份额最高（53.6%），商品/黄金为 30.3%，债券为 4.5%。这说明主模型并非没有权益风险，而是通过债券、




图 5-10 Improved Convex Adaptive Global RRP 滚动因子暴露（252 日窗口）




图 5-11 Improved Convex Adaptive Global RRP 收益来源分解




图 5-12 Improved Convex Adaptive Global RRP 风险来源分解

商品和防御性资产降低了单一风险来源的集中度。

表 5-11 Improved Convex Adaptive Global RRP 收益与方差归因（五因子分解）

Factor	Return Share	Variance Share
权益	30.0%	53.6%
债券	24.5%	4.5%
商品/黄金	30.0%	30.3%
防御性	4.9%	11.5%

归因结果说明 Improved Convex Adaptive Global RRP 的历史收益并非由单一资产类别主导，权益、商品/黄金与债券三类的已归因收益份额较为接近；未归因残差约占 10.6%。债券风险份额仅 4.5%，体现了低波动资产在风险预算框架中的缓冲作用。HERC 债券集中度高，收益与风险来源均较单一。

5.8 小结

各模型绩效差异背后是不同的配置逻辑。Improved Convex Adaptive Global RRP 在当前样本期内体现为低波动、浅回撤和可控换手之间的折中，而不是最高收益模型；HERC 夏普比率有竞争力，但回撤幅度、换手频率和暴露集中度与主模型差异显著。比较这几个模型时，最好同时看指标和权重路径，而不是只看排名。




图 6-13 子区间夏普比率稳健性




图 6-14 子区间最大回撤稳健性




图 6-15 压力期表现检验

6. 稳健性检验与过拟合诊断

6.1 子区间与压力期检验

图 6-13–6-14 展示各子区间的夏普比率和最大回撤。子区间指标通常比全样本波动更大，这里的用途是观察结论在哪些阶段有所减弱，而非寻找“最优子区间”。

跨 5 个固定子区间的分散度检验表明，Improved Convex Adaptive Global RRP 的子区间夏普比率范围为 [0.570, 1.239]，均值 0.949，无一子区间出现负值。其最弱子区间为 2021 年后的收紧期（post_2021），对应全球权益和债券同步承压的市场环境；在该子区间内 Global RRP 的夏普比率降至 0.034，而 Improved Convex 仍维持在 0.570，展示出相对较强的下行防护能力，但这也是主模型在固定子区间内表现最弱的阶段，需要明确披露。

压力期检验用于观察极端阶段组合反应。压力期标签是事后贴上去的，只用于观察组合在特定阶段的行为，不作为调参依据。




图 6-16 交易成本敏感性检验

6.2 交易成本与参数敏感性

图 6-16 比较不同交易成本假设下的模型表现。Global RRP 随费率上升净收益下降更快，而 Improved Convex Adaptive Global RRP 因换手显著低于 Global RRP，对成本假设相对不敏感。在已测试的 $[0, 50]$ bps 月单边费率扫描范围内，Improved Convex Adaptive Global RRP 相对于 Global RRP 的净年化收益优势始终为正，两者持平的盈亏平衡点估计高于 >50 bps；本文 3 bps 的设定显著低于该阈值，说明主要结论对成本假设的合理变动具有稳健性。当前成本设定是固定费率，实际成本还包括冲击成本和买卖价差，后者没有纳入。

调仓频率敏感性。除交易成本费率外，调仓频率本身也会影响收益、风险和可实施性。本文保持已发布的滚动样本外选择日历不变，仅改变调仓日历，比较周度、双周、月度和季度四种频率。表 6-12 与图 6-17 显示，周度与双周调仓的净年化收益分别为 5.38% 和 5.36%，Sharpe 分别为 1.118 和 1.109，月均换手率分别为 3.06% 和 2.54%；月度调仓的净年化收益为 5.60%，Sharpe 为 1.186，月均换手率为 1.96%。季度调仓换手率进一步降至 1.69%，净年化收益和 Sharpe 分别为 5.26% 和 1.042。月度调仓在本次刷新中恰好取得四种频率中的最高净收益和 Sharpe，但研究设计仍将其视为兼顾响应速度、交易成本和权重稳定性的实施选择，而不是依据本次事后排名重新选择的参数。




图 6-17 调仓频率敏感性检验

表 6-12 调仓频率敏感性检验（固定 Improved Convex Adaptive Global RRP 参数）

调仓频率	调仓次数	净年化收益	Sharpe	最大回撤	月均换手	求解器回退率
周度	439	5.38%	1.118	-3.65%	3.06%	0.00%
双周	219	5.36%	1.109	-3.65%	2.54%	0.00%
月度	103	5.60%	1.186	-3.81%	1.96%	0.00%
季度	35	5.26%	1.042	-3.77%	1.69%	0.00%

仅改变调仓日历，不重新选择候选参数；月均换手按评价窗口内总换手除以月数计算。

主模型的 CVaR 置信水平 $\alpha = 0.95$ （组合优化文献惯用水平）和回望窗口 252 日（自然年交易日数）均依先验惯例确定，不依赖回测结果反向校准^[27]。敏感性分析在 $\beta \in \{0.90, 0.95, 0.975, 0.99\}$ 和窗口 $\in \{126, 252, 504\}$ 上共测试 12 个变体，结果见表 6-13。




图 6-18 参数扰动敏感性检验

表 6-13 CVaR 参数敏感性分析（12 变体，基于 Improved Convex Adaptive Global RRP）

Dimension	Value	Sharpe Mean	Net Return	Max DD Mean	Monthly TO Mean
置信水平 β	0.90	1.161	5.29%	-4.35%	4.03%
	0.95	1.158	5.28%	-4.35%	4.02%
	0.975	1.153	5.26%	-4.34%	4.02%
	0.99	1.155	5.26%	-4.34%	4.00%
回望窗口（交易日）	126	1.174	5.34%	-4.36%	4.74%
	252	1.172	5.32%	-4.33%	3.79%
	504	1.124	5.15%	-4.35%	3.52%
全部 12 变体均值	—	1.157	5.27%	-4.35%	4.02%

各行为对应参数水平下的多个变体均值，评价起点与主模型一致，样本截至 2026-07-31。

12 个变体的夏普比率范围为 1.118–1.184，净年化收益范围为 5.14%–5.36%，最大回撤均在 -4.38% 至 -4.32% 之间，整体结论对 CVaR 参数选择不敏感。回望窗口的影响略大于置信水平：126 日窗口换手率较高，504 日长窗口换手率最低且 Sharpe 略低，反映更长历史窗口使协方差估计更稳定、调仓幅度更小，但也降低了响应速度。

参数扰动采用单因素变化方式，用于观察模型是否对某一参数表现出过度敏感。在已测试的扰动范围内，主模型表现总体稳定；至于该范围之外的参数区域，




图 6-19 不同协方差估计下的夏普比率




图 6-20 不同协方差估计下的回撤表现




图 6-21 不同协方差估计下的换手表现

本文不作外推判断。

收益倾斜项 λ_{return} 的单因素扰动在统一的 2018-01-02 至 2026-07-31 评价窗口内进行。检验将该权重分别调整为基准值的 75% 和 125%，保持已发布的滚动样本外选择日历不变，因此属于机制敏感性分析而非重新选模。其用途是判断历史均值输入附近是否存在明显参数悬崖，而不是以事后最优参数替换公开主路径。

6.3 协方差估计与过拟合诊断

本文比较了 sample covariance、Ledoit-Wolf 收缩以及不同半衰期 EWMA (half-life 20/60/120)。图 6-19–6-21 显示主要结论不依赖单一协方差估计器，但选择不同估计器会影响权重细节和换手水平。

在三类无条件估计器之外，本文进一步检验状态条件协方差估计器。为避免以完整样本绩效反向挑选先验，先验仅在 2018 年至 2023 年设计窗内按验证打分函数选定，随后固定到 2024 年和 2025 年起始的两个时间序贯评价窗。设计窗选




图 6-22 过拟合诊断

出的危机先验为 $\pi = 0.60$ 、先验权重为 0.75；选择阶段不接触后续评价窗数据。

在 2024-01-02 至 2026-07-31 的评价窗内，选定状态条件估计器的 Sharpe 为 1.715，低于标准 EWMA 的 1.816；95% CVaR 从 0.380% 小幅降至 0.368%，但最大回撤由 -1.95% 扩大至 -2.66% 。在 2025-01-02 起始的更短评价窗内，其 Sharpe 为 1.504，同样低于 EWMA 的 1.688。完整评价窗中的状态条件版本也未超过对应 EWMA 配置。结果表明压力态加权能轻微改变尾部损失，但没有形成一致的风险调整收益改进，因此只保留为稳健性诊断，不替换公开滚动样本外主路径。

回测中的多重假设检验问题长期存在。White 的现实检验法通过自助法比较最优策略与随机基准的胜出概率，是处理数据窥探偏差的早期统计框架^[52]；Harvey 和 Liu 进一步梳理了多次回测搜索造成统计显著性失真的机制^[53]。本文采用 CSCV/PBO 来估计候选参数选择带来的过拟合概率^[54-55]。增强版诊断使用 36 个候选、10 个时间区块和 12 个组合分割，得到的 PBO 为 0.167，平均样本外相对秩为 0.387。PBO 低于 0.5，说明在这些分割中，样本内胜出候选落入样本外后半区的比例低于一半。这一结果支持主模型结论具有一定稳健性，但它仍然只是对参数选择偏差程度的估计，不能被理解为对未来样本外表现的保证。¹

公开模型采用连续滚动样本外路径：2015 年至 2017 年的窗口只用于执行预热，2018-01-02 起重新初始化公开选择状态，此后每个季度仅依据已完成的历史验证窗决定下一测试窗。完整选择记录、置信集规模、换手门槛和切换原因保存在滚动样本外选择权威表中。传统 Walk-Forward 表仅作为额外切片诊断，不参与公

¹增强版 CSCV 使用完整的 36 个候选集合，但为控制路径依赖回测的计算量，仅抽取 12 个组合分割；组合数量有限会降低估计精度。因此，本文将 PBO 理解为参考性诊断，而非严格的过拟合概率上界。




图 6-23 分块自助法夏普比率分布（200 个自助样本）




图 6-24 分块自助法最大回撤分布（200 个自助样本）

开主路径选择。

6.4 统计显著性检验

本节用两个互补的检验方法评估绩效指标的抽样稳定性。第一个是移动分块自助法（Moving Block Bootstrap）：对历史收益率进行有放回随机分块重抽样（200 个样本，块长 21 日，仅在验证区间内进行），检验绩效指标的抽样分布。

表 6-14 汇报各主要模型的分布统计量。

表 6-14 分块自助法绩效分布（200 次重抽样，块长 21 日）

Model	Sharpe Mean	Sharpe P5	Sharpe P50	Sharpe P95	MDD Mean	MDD P5
Global RRP	0.499	0.157	0.503	0.839	-7.59%	-12.04%
Convex Adaptive	0.606	0.272	0.605	0.955	-31.28%	-44.71%
Improved Convex	1.147	0.655	1.108	1.781	-3.88%	-5.80%

P5/P50/P95 为对应分位数，MDD P5 为最大回撤的第 5 百分位（最差情形）。

关键发现：Improved Convex Adaptive Global RRP 的 Sharpe P5 分位为 0.655，Global RRP 的 P5 为 0.157；两者在本次 200 次分块重抽样中的第 5 百分位均高于零，但主模型下界更高。Improved Convex 的 P50 中位数为 1.108，低于全样本 Sharpe（1.186），说明分块重抽样下的路径扰动会削弱但未消除其风险调整收益优势。分块自助法不能替代真实样本外检验，它估计的是历史数据抽样变异对结论的影响幅度。

第二个是成对夏普差异检验。对每一配对在共同评价日上抽取 21 日块，重抽 2000 次（Politis & Romano 1994），估计 95% 置信区间与双侧 p 值。原假设为两模

型真实夏普差为 0；区间不跨 0 时拒绝。

表 6-15 展示主要配对的结果。Improved Convex Adaptive Global RRP 相对于 Global RRP 的观察夏普差为 0.655，95% CI 为 [0.218, 1.057]，双侧 p 值 0.003，在 95% 水平上显著；相对于 Defensive Dynamic RRP 的观察夏普差为 0.712，CI [0.304, 1.088]， p 值 0.000，显著；相对于等权基准的观察夏普差为 0.725，CI [0.292, 1.085]， p 值 0.001，显著。作为反例，Global RRP 与等权基准的差为 0.071，CI [-0.411, 0.506]， p 值 0.756，不显著，与“未加约束的宽松风险平价的夏普并未显著高于等权”的预期一致。

表 6-15 成对夏普差异分块自助法检验（2000 次重抽，块长 21 日，95% 置信水平）

Model A	Model B	Observed Diff.	CI Low	CI High	p Value
Improved Convex Adaptive RRP	Global RRP	0.655	0.218	1.057	0.003
Improved Convex Adaptive RRP	Defensive Dynamic RRP	0.712	0.304	1.088	0.000
Improved Convex Adaptive RRP	Equal Weight	0.725	0.292	1.085	0.001
Global RRP	Equal Weight	0.071	-0.411	0.506	0.756
Defensive Dynamic RRP	Equal Weight	0.072	-0.353	0.472	0.712

注： p Value 为双侧检验结果；区间不跨过 0 视为在 95% 水平显著。

Improved Convex Adaptive Global RRP 相对各参照系的夏普优势在 95% 水平上均显著；Global RRP 相对等权基准的夏普差不显著，与表 5-6 的点估计一致。该检验与过拟合诊断回答的是不同问题：前者检验评价区间内的抽样变异，后者估计参数选择偏差。

6.5 小结

以上检验把结论限定在具体条件下——特定评价区间、成本假设和参数选择。没有哪项检验能消除过拟合的可能性，目前的证据在已测试的多个维度上是自洽的。

7. 结论与展望

7.1 主要结论

本文的四个研究问题都得到了相对明确的实证回答，不过每个答案都附带条件。

宽松风险平价在可交易全球 ETF 资产池中确实可以建立一个风险来源清晰的配置框架。Global RRP 净年化收益 4.28%，最大回撤 -6.32%，在没有 CVaR 和换手约束的情况下已经可以运行，但 24.51% 的月度换手是个实际问题。

加入 CVaR 约束、换手惩罚和资产组边界后，Improved Convex Adaptive Global RRP 净年化收益为 5.60%，最大回撤 -3.81%，换手 1.96%，Sharpe 达到 1.186。这不是每项指标都领先，而是在当前样本期内形成了低波动、浅回撤和可控换手之间的折中；其代价是权益强势阶段收益弹性不足。

HERC 在当前样本中夏普比率不低，但原因需要说清楚：几乎全仓债券，夏普比率来自极低的波动，而不是多资产分散。这和主模型是两种不同的配置思路，本文没有把它们放在同一个评价坐标上排序。

稳健性检验方面，增强版 $PBO = 0.167$ 表明候选选择风险在已测试分割中低于随机中位基准，协方差估计器的选择不改变主要结论；月度调仓在本次频率检验中恰好取得最高净收益和 Sharpe，但其研究定位仍是低换手和响应速度之间的实施折中，而非依据事后排名重新选择的参数。这些检验只能覆盖已测试的维度，所有结论都依赖当前的评价区间（2018-01-02 至 2026-07-31）和成本假设。

本文所有实证结论均在**纯多头、无杠杆**约束下取得。根据证监会《公开募集证券投资基金运作管理办法》，普通开放式基金杠杆不超过 0.4 倍，封闭期内不超过 1 倍，货币市场基金不超过 0.2 倍，标准风险平价”加杠杆平抑权益波动”的核心机制因此在公募语境下受到严格限制。本文的定位是：在无杠杆、有交易成本、有权重上限的约束下，引入 CVaR 约束和换手惩罚的宽松风险平价框架能产生 Sharpe 1.186、最大回撤 -3.81% 的表现，为公募 FOF、银行理财子及保险委外等无法使用杠杆的稳健型资金提供可执行的多资产风险预算路径。

对稳健型长期资金而言，考核重点通常是在回撤约束下取得高于无风险利率

的长期风险溢价，而非逐月跑赢权益指数。本模型在无杠杆、扣除 3 bps 单边成本后取得净年化 5.60%、最大回撤 -3.81%；是否满足具体机构的收益目标、资本约束和流动性要求，仍需结合其负债结构与投资政策单独评估。

Sharpe 1.186 同时受到收益路径和较低波动率的影响；CVaR 约束、收益倾斜、现金组上限与多资产分散共同作用，无法仅凭回测结果把改善因果归于单一项。最大回撤 -3.81% 覆盖了 2022 年全球利率快速上行和权益调整阶段。月均换手率 1.96% 反映 L_1 换手惩罚对调仓幅度的约束；对大额资金而言，较低换手有助于降低固定费率模型未完全覆盖的执行摩擦。

7.2 研究不足

当前数据缺少买卖价差、成交量和基金资产规模等微观结构字段，无法估计大额资金进出的冲击成本和实际投资容量上限。固定 3 bps 费率是简化，冲击成本没有纳入。

本文从资产端视角讨论长期资金配置，未引入负债现金流预测、久期缺口匹配和偿付能力资本占用规则，结论不能直接套用到资产负债管理场景。

部分 ETF 上市时间较晚，历史有限，限制了跨越更长经济周期的系统性比较；本研究已通过逐点时间宇宙过滤加以控制，但该局限仍值得后续关注。

此外，2026 年 5 月和 6 月主模型连续录得小幅负收益，而沪深 300ETF 同期上涨，说明该框架在权益强势修复阶段存在收益弹性不足的问题。这一现象并不改变本文关于低波动和回撤控制的主结论，但进一步限定了模型的适用语境：它更适合作为稳健型长期配置框架，而非权益牛市中的收益追逐策略。

所有实证结论依赖特定评价区间（2018-01-02 至 2026-07-31）和当前市场相关性结构。如果未来市场结构发生实质性变化，模型表现可能随之改变。这些是条件性陈述，不构成对未来长期表现的预测。

7.3 后续研究方向

最直接的改进是成本建模和样本延伸：引入买卖价差和基于成交量的冲击成本函数比固定费率更贴近机构执行环境；当更多 ETF 积累足够历史数据后，跨越更长经济周期重复当前比较也有价值。将研究推进到负债端（现金流预测、久期

缺口、资本占用规则）是自然的扩展方向，但超出了本科论文范围。

从资产端风险预算扩展到因子层面是另一条路径，华泰证券对此已有框架性讨论^[56]。机器学习和深度强化学习方法也开始进入这一领域（Millea & Edalat^[57]；Yang^[58]；Agal et al.^[59]），但这类方法在低换手约束和样本外稳健性方面的系统检验，是与本文框架进行有意义比较的前提。后续研究应优先延长可交易 ETF 的实盘历史、完善冲击成本估计，并在不改变透明优化权重生成逻辑的前提下检验更细粒度的因子风险预算。

A. 主要指标定义汇总

表 A-16 主要指标含义

Metric	Definition and Use
Net Return	扣除交易成本后的年化收益，衡量净值增长速度
Sharpe	净年化收益除以年化波动率，衡量单位波动收益
Max DD	历史净值峰谷最大跌幅，衡量路径风险
Calmar	净年化收益除以最大回撤绝对值，强调回撤调整收益
Turnover	调仓前后权重变化绝对值之和，衡量执行强度
CVaR	给定置信水平下尾部损失均值，衡量历史尾部风险

B. CSCV 候选参数网格

本文 CSCV/PBO 过拟合诊断共使用 36 个候选参数配置。表 B-17 列出完整探索网格；其中 candidate_03、candidate_04 与 candidate_05 构成预先声明的低换手公开候选族，区别为 2.5%、3.0% 和 3.5% 的组合波动上限。公开路径的每次选择均由当时可得历史数据决定，表中全样本得分不用于回填历史选择。

表 B-17 CSCV 候选参数网格（共 36 个候选）

ID	Look.	Cov.	MaxW	TO Cap	λ_{to}	λ_{budget}	λ_{cvar}	β	λ_{ret}
candidate_01	180	ewma	40%	35%	0.020	0.350	0.200	0.95	0.050
candidate_02	252	ewma	45%	80%	0.010	0.100	0.080	0.95	0.050
candidate_03	252	ewma	40%	60%	0.020	0.250	0.150	0.95	0.060
candidate_04	252	ewma	40%	60%	0.020	0.250	0.150	0.95	0.060
candidate_05	252	ewma	40%	60%	0.020	0.250	0.150	0.95	0.060
candidate_06	120	ewma	45%	80%	0.010	0.050	0.080	0.95	0.050
candidate_07	120	ewma	45%	80%	0.010	0.100	0.080	0.95	0.050
candidate_08	180	ewma	45%	80%	0.010	0.050	0.080	0.95	0.050
candidate_09	180	ewma	45%	80%	0.010	0.100	0.080	0.95	0.050
candidate_10	252	ewma	45%	80%	0.010	0.050	0.080	0.95	0.050
candidate_11	252	ewma	45%	80%	0.000	0.100	0.080	0.95	0.050
candidate_12	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.050
candidate_13	252	ewma	45%	80%	0.030	0.100	0.080	0.95	0.050
candidate_14	252	ewma	45%	35%	0.010	0.100	0.080	0.95	0.050
candidate_15	252	ewma	45%	100%	0.010	0.100	0.080	0.95	0.050
candidate_16	252	ewma	45%	—	0.010	0.100	0.080	0.95	0.050
candidate_17	252	ewma	45%	80%	0.010	0.100	0.050	0.95	0.050
candidate_18	252	ewma	45%	80%	0.010	0.100	0.100	0.95	0.050
candidate_19	252	ewma	45%	80%	0.010	0.100	0.200	0.95	0.050
candidate_20	252	ewma	45%	80%	0.010	0.100	0.080	0.95	0.060
candidate_21	252	ewma	45%	80%	0.010	0.100	0.080	0.95	0.080
candidate_22	252	ewma	45%	80%	0.010	0.100	0.080	0.95	0.100
candidate_23	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.060
candidate_24	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.060
candidate_25	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.080
candidate_26	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.080
candidate_27	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.100
candidate_28	252	ewma	45%	80%	0.020	0.100	0.080	0.95	0.100

ID	Look.	Cov.	MaxW	TO Cap	λ_{to}	λ_{budget}	λ_{cvar}	β	λ_{ret}
candidate_29	252	ewma	40%	80%	0.010	0.100	0.080	0.95	0.050
candidate_30	252	sample	45%	80%	0.010	0.100	0.080	0.95	0.050
candidate_31	252	ewma	45%	80%	0.010	0.100	0.080	0.90	0.050
candidate_32	180	ewma	40%	35%	0.020	0.350	0.100	0.95	0.050
candidate_33	180	ewma	40%	80%	0.010	0.100	0.080	0.95	0.050
candidate_34	120	ewma	45%	100%	0.000	0.050	0.050	0.95	0.060
candidate_35	252	ewma	40%	35%	0.030	0.350	0.200	0.90	0.050
candidate_36	120	sample	40%	—	0.020	0.100	0.100	0.95	0.050

加粗斜体行为预先声明的低换手候选族中，2018 年公开滚动样本外路径初始化所选的 **candidate_03**；该标记不代表以完整样本事后指定候选。”—”表示换手上限无约束。

C. 自适应风险预算超参数

自适应风险预算模块通过合成压力评分动态调整各模型期间的风险预算目标。表 C-18 列出全部超参数的取值与含义。这些参数在开发阶段通过先验判断设定，不依赖回测窗口内的收益数据调优。

表 C-18 自适应风险预算超参数汇总

参数	取值	含义
波动率压力权重	0.45	合成压力评分中，年化波动率分项的权重
损失压力权重	0.30	合成压力评分中，21 日累积损失分项的权重
图压力权重	0.25	合成压力评分中，相关性集中度（图统计量）分项的权重
状态平滑系数	0.80	上期压力状态在合成评分中的惯性权重，用于抑制状态频繁切换
波动率压力阈值	18%	对应最大压力（评分 = 1.0）的年化波动率上界
损失压力阈值	8%	对应最大压力（评分 = 1.0）的 21 日累积损失上界
低风险状态乘数	0.75	低压力状态下各资产风险预算目标的缩放系数
中风险状态乘数	1.00	基准状态（无调整），风险预算维持等风险
高风险状态乘数	1.35	高压状态下，对低波动资产（债券/货币市场）的预算偏移系数
图压力合成方式	$0.65 \times \rho_{\text{avg}} + 0.35 \times \text{HHI}$	图统计量由资产平均相关系数和赫芬达尔集中度指数线性合成

所有参数在回测启动前固定，评价区间内不更新。

参考文献

- [1] BRINSON G P, HOOD L R, BEEBOWER G L. Determinants of portfolio performance[J/OL]. Financial Analysts Journal, 1986, 42(4): 39-44. DOI: 10.2469/faj.v42.n4.39.
- [2] QIAN E. Risk parity portfolios: efficient portfolios through true diversification[R]. PanAgora Asset Management, 2005.
- [3] MAILLARD S, RONCALLI T, TEILETCHE J. The properties of equally weighted risk contribution portfolios[J]. The Journal of Portfolio Management, 2010, 36(4): 60-70.
- [4] MARKOWITZ H M. Portfolio selection: efficient diversification of investments [M]. New York: John Wiley & Sons, 1959.
- [5] SHARPE W F. Capital asset prices: a theory of market equilibrium under conditions of risk[J]. The Journal of Finance, 1964, 19(3): 425-442.
- [6] MICHAUD R O. The Markowitz optimization enigma: Is ‘Optimized’ optimal? [J/OL]. Financial Analysts Journal, 1989, 45(1): 31-42. DOI: 10.2469/faj.v45.n1.31.
- [7] JORION P. Bayes-stein estimation for portfolio analysis[J]. Journal of Financial and Quantitative Analysis, 1986, 21(3): 279-292.
- [8] CHOPRA V K, ZIEMBA W T. The effect of errors in means, variances, and covariances on optimal portfolio choice[J]. The Journal of Portfolio Management, 1993, 19(2): 6-11.
- [9] BLACK F, LITTERMAN R. Global portfolio optimization[J]. Financial Analysts Journal, 1992, 48(5): 28-43.
- [10] DEMIGUEL V, GARLAPPI L, UPPAL R. Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy?[J]. The Review of Financial Studies, 2009, 22(5): 1915-1953.
- [11] JAGANNATHAN R, MA T. Risk reduction in large portfolios: Why imposing the wrong constraints helps[J/OL]. The Journal of Finance, 2003, 58(4): 1651-1683.

DOI: 10.1111/1540-6261.00580.

- [12] LALOUX L, CIZEAU P, BOUCHAUD J P, et al. Noise dressing of financial correlation matrices[J/OL]. *Physical Review Letters*, 1999, 83(7): 1467-1470. DOI: 10.1103/PhysRevLett.83.1467.
- [13] JOHANSSON K, OGUT M G, PELGER M, et al. A simple method for predicting covariance matrices of financial returns[A/OL]. *arXiv* (2023). <https://arxiv.org/abs/2305.19484>.
- [14] TZIKAS A E, CANDÈS E J, HASTIE T, et al. Enhancing a risk model by adding transient statistical factors[A/OL]. *arXiv* (2026). <https://arxiv.org/abs/2605.12977>.
- [15] CONLON T, COTTER J, KYNIGAKIS I. Asset allocation with factor-based covariance matrices[J/OL]. *European Journal of Operational Research*, 2025, 325(1): 189-203. DOI: 10.1016/j.ejor.2025.03.015.
- [16] BONGIORNO C, MANOLAKIS E, MANTEGNA R N. End-to-end large portfolio optimization for variance minimization with neural networks through covariance cleaning[A/OL]. *arXiv* (2025). <https://arxiv.org/abs/2507.01918>. DOI: 10.48550/arXiv.2507.01918.
- [17] RONCALLI T. *Introduction to risk parity and budgeting*[M]. Boca Raton: Chapman and Hall/CRC, 2013.
- [18] BRUDER B, RONCALLI T. *Managing risk exposures using the risk budgeting approach*[R]. Lyxor Asset Management, 2012.
- [19] ASNESS C S, FRAZZINI A, PEDERSEN L H. Leverage aversion and risk parity [J/OL]. *Financial Analysts Journal*, 2012, 68(1): 47-59. DOI: 10.2469/faj.v68.n1.1.
- [20] CHAVES D B, HSU J C, LI F, et al. Risk parity portfolio vs. other asset allocation heuristic portfolios[J]. *The Journal of Investing*, 2011, 20(1): 108-118.
- [21] PAOLELLA M S, POLAK P, WALKER P S. Risk parity portfolio optimization under heavy-tailed returns and dynamic correlations[J/OL]. *Journal of Time Series Analysis*, 2025, 46(2): 353-377. DOI: 10.1111/jtsa.12792.
- [22] GAMBETA V, KWON R. Risk return trade-off in relaxed risk parity portfolio optimization[J/OL]. *Journal of Risk and Financial Management*, 2020, 13(10): 237. DOI: 10.3390/jrfm13100237.
- [23] ARDIA D, BOUDT K, NGUYEN G. Beyond risk-based portfolios: balancing per-

- formance and risk contributions in asset allocation[J/OL]. *Quantitative Finance*, 2018, 18(8): 1249-1259. DOI: 10.1080/14697688.2018.1424349.
- [24] CETINGOZ A R, GUÉANT O. Asset and factor risk budgeting: a balanced approach[A/OL]. arXiv (2024). <https://arxiv.org/abs/2312.11132>.
- [25] BESSLER W, TAUSHANOV G, WOLFF D. Factor investing and asset allocation strategies: a comparison of factor versus sector optimization[J/OL]. *Journal of Asset Management*, 2021, 22(6): 488-506. DOI: 10.1057/s41260-021-00225-1.
- [26] FASSINO C, UBERTI P. Some general results on risk budgeting portfolios[A/OL]. arXiv (2026). <https://arxiv.org/abs/2603.15511>.
- [27] ROCKAFELLAR R T, URYASEV S. Optimization of conditional value-at-risk[J]. *Journal of Risk*, 2000, 2(3): 21-41.
- [28] ROCKAFELLAR R T, URYASEV S. Conditional Value-at-Risk for general loss distributions[J/OL]. *Journal of Banking & Finance*, 2002, 26(7): 1443-1471. DOI: 10.1016/S0378-4266(02)00271-6.
- [29] BOYD S, VANDENBERGHE L. Convex optimization[M]. Cambridge: Cambridge University Press, 2004.
- [30] ALMGREN R, CHRISS N. Optimal execution of portfolio transactions[J/OL]. *Journal of Risk*, 2001, 3(2): 5-39. DOI: 10.21314/JOR.2001.041.
- [31] UHL M W, JURT F, WALLISER S. Can AI detect tail events? Stock performance around tail events during different sentiment regimes[J]. *Journal of Behavioral Finance*, 2024.
- [32] ALOUADI A, et al. SBBTS: a unified Schrödinger–Bass framework for synthetic financial time series[A/OL]. arXiv (2026). <https://arxiv.org/abs/2604.07159>.
- [33] BAJO TRAVER M. Regret-based portfolio allocation: minimizing opportunity cost and its dispersion[J]. Working paper, 2026.
- [34] LÓPEZ DE PRADO M. Building diversified portfolios that outperform out of sample[J]. *The Journal of Portfolio Management*, 2016, 42(4): 59-69.
- [35] RAFFINOT T. The hierarchical equal risk contribution portfolio[J]. *SSRN Electronic Journal*, 2018.
- [36] LOHRE H, ROTHER C, SCHÄFER K A. Hierarchical risk parity: Accounting for tail dependencies in multi-asset multi-factor allocations[M/OL]//JURCZENKO

- E. Machine Learning for Asset Management: New Developments and Financial Applications. Wiley, 2020: 329-368. DOI: 10.1002/9781119751182.ch9.
- [37] CHO Y, SONG J W. Hierarchical risk parity using security selection based on peripheral assets of correlation-based minimum spanning trees[J/OL]. Finance Research Letters, 2023, 53: 103608. DOI: 10.1016/j.frl.2022.103608.
- [38] CICIRETTI V, PALLOTTA A. Network risk parity: graph theory-based portfolio construction[J/OL]. Journal of Asset Management, 2024, 25(2): 136-146. DOI: 10.1057/s41260-023-00347-8.
- [39] 林晓明, 黄晓彬, 源洁莹. 风险平价模型的常见理解误区剖析: “风险”的界定、度量与“平价”、杠杆的实现[R]. 华泰证券研究所, 2020.
- [40] 林晓明, 黄晓彬, 张泽. 风险平价之标的优选与层次化风险估计[R]. 华泰证券研究所, 2021.
- [41] 张继强, 陶冶, 何颖雯. 风险平价的理念与国内实践: 资产配置方法论系列[R]. 华泰证券研究所, 2024.
- [42] 张继强, 陶冶, 何颖雯. 低利率环境下的绝对收益路径: 资产配置方法论系列[R]. 华泰证券研究所, 2025.
- [43] 中信证券研究部. 多资产 ETF 的海外经验与国内展望[R]. 中信证券股份有限公司, 2025.
- [44] 陈宜筠, 郑文才, 周萧潇, 等. 量化配置模型 (一): 海内外大类资产配置量化实测[R]. 中国国际金融股份有限公司, 2026.
- [45] 兴业证券研究所. 年度复盘 & 展望八——ETF 篇: 鹏北海, 凤朝阳, 又携书剑路茫茫[R]. 兴业证券股份有限公司, 2026.
- [46] LEDOIT O, WOLF M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 2004, 88(2): 365-411.
- [47] LEDOIT O, WOLF M. Quadratic shrinkage for large covariance matrices[J/OL]. Bernoulli, 2022, 28(3): 1519-1547. DOI: 10.3150/20-BEJ1315.
- [48] IELPO F, MUHAMMETGULYYEVA S, ROYER J. Regime parity[R]. Lombard Odier Investment Managers and Centre d'Économie de la Sorbonne, 2024.
- [49] BOUYÉ E, TEILETCHE J. Regime-based strategic asset allocation[J/OL]. Financial Analysts Journal, 2025, 81(4): 84-102. DOI: 10.1080/0015198X.2025.2558354.

- [50] FLEMING J, KIRBY C, OSTDIEK B. The economic value of volatility timing [J/OL]. *The Journal of Finance*, 2001, 56(1): 329-352. DOI: 10.1111/0022-1082.00327.
- [51] 中央国债登记结算有限责任公司. 中债国债收益率曲线（1 年期）历史数据 [Z]. 2026.
- [52] WHITE H. A reality check for data snooping[J/OL]. *Econometrica*, 2000, 68(5): 1097-1126. DOI: 10.1111/1468-0262.00152.
- [53] HARVEY C R, LIU Y. Backtesting[J/OL]. *The Journal of Portfolio Management*, 2015, 42(1): 13-28. DOI: 10.3905/jpm.2015.42.1.013.
- [54] BAILEY D H, BORWEIN J M, LÓPEZ DE PRADO M, et al. The probability of backtest overfitting[J]. *Journal of Computational Finance*, 2014, 20(4): 39-69.
- [55] BAILEY D H, LÓPEZ DE PRADO M. The deflated sharpe ratio: correcting for selection bias, backtest overfitting, and non-normality[J]. *The Journal of Portfolio Management*, 2014, 40(5): 94-107.
- [56] 华泰证券研究所. 从资产配置走向因子配置：中国版全天候增强策略[R]. 华泰证券研究所, 2025.
- [57] MILLEA A, EDALAT A. Using deep reinforcement learning with hierarchical risk parity for portfolio optimization[J/OL]. *International Journal of Financial Studies*, 2023, 11(1): 10. DOI: 10.3390/ijfs11010010.
- [58] YANG S. Deep reinforcement learning for portfolio management[J/OL]. *Knowledge-Based Systems*, 2023, 278: 110905. DOI: 10.1016/j.knosys.2023.110905.
- [59] AGAL S, RAULJI K, ODEDRA N D. A machine learning approach to risk based asset allocation in portfolio optimization[J/OL]. *Scientific Reports*, 2025, 15: 42263. DOI: 10.1038/s41598-025-26337-x.

致谢

本文得以完成，首先要感谢指导老师王磊教授。从选题方向的确定、研究框架的搭建，到实证方法的细化与论文的反复修改，王老师在每一个关键节点都给予了耐心细致的指导与建设性意见，使我对量化资产配置领域的认识不断深化。王老师严谨的学术态度和对学生的真诚关怀，是我在整个研究过程中最重要的精神支撑。

感谢特拉华数据科学学院和金融数学专业的各位任课老师，你们在数学基础、金融理论与编程实践方面的悉心教导，为本文的研究工作打下了坚实的基础。感谢同门同学在学习与讨论中给予的启发与帮助。

最后，衷心感谢父母多年来的理解、支持与付出。你们的鼓励始终是我前行最大的动力。