

西南财经大学

本科毕业论文（设计）



论宽权风险平价在全球 ETF 资产配置中的改进与实证研究

所在学院：_____特拉华数据科学学院_____

专 业：金融数学（金融服务与量化分析方向）

学生姓名：_____许哲圣_____

学 号：_____42353012_____

年 级：_____2023 级_____

指导教师：_____王磊_____

2026 年 5 月

学术声明

本人郑重声明：所呈交的毕业论文是在指导教师指导下独立完成的研究成果。论文中引用他人已经发表或未发表成果，均已在正文和参考文献中作出明确标注。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文研究作出重要贡献的个人和集体，均已在文中以明确方式说明。

摘要

长期资产配置面对的根本问题不是预测单一资产的短期涨跌，而是在市场不确定时如何维持合理的风险分散。风险平价以风险预算为基础，降低了对预期收益估计的依赖，但当资产池扩展至全球多资产 ETF 时，相关结构动态变化、严格等风险贡献约束的非凸性以及交易成本的累积都构成实际问题。

本文围绕宽松风险平价思想，以 30 支可交易全球多资产 ETF 为研究对象，构建统一的回测框架。数据来源于 Tushare ETF 接口，资产池覆盖短久期信用债、可转债、A 股宽基、中国科技与新能源、港股、全球股票和大宗商品八类风险来源。绩效评价区间为 2019-01-01 至 2026-05-07，共 86 个月度观测，采用月度调仓、交易成本扣减（3 bps）和无前视设计。在同一回测框架下，本文比较了 Global RRP、Convex Adaptive Global RRP、Improved Convex Adaptive Global RRP 和层次化基准 HRP、HERC 的表现。

Global RRP 净年化收益为 4.71%，夏普比率为 0.693，最大回撤为 -6.83%，月度换手率为 18.0%，是宽松风险预算在全球 ETF 资产池中的基础版本。Improved Convex Adaptive Global RRP 净年化收益为 7.79%，年化波动率为 4.50%，夏普比率为 1.326，Sortino 比率为 1.976，最大回撤为 -5.83%，平均月度换手率仅为 0.51%。HRP 与 HERC 净年化收益分别为 1.81% 与 2.37%，夏普比率分别为 -0.042 与 1.184。Improved Convex Adaptive Global RRP 在收益和回撤上表现尚可，换手极低，但这并不意味着它在每个指标上都是最优解。

本文所有实证结论均基于特定历史评价区间和约束设定，不构成对未来收益的保证。

关键词：宽松风险平价；全球多资产配置；CVaR；换手约束；凸优化；ETF

Abstract

Long-term asset allocation is fundamentally a problem of managing risk over time, not predicting returns. Risk parity sidesteps expected-return estimation by budgeting risk instead, but when the universe expands to global multi-asset ETFs, practical complications multiply: correlations shift across regimes, exact equal-risk-contribution constraints are non-convex, and transaction costs erode enough of net return to matter at monthly rebalancing frequency.

This undergraduate thesis studies a Relaxed Risk Parity framework using 30 tradable global multi-asset ETFs. Data are sourced from the Tushare ETF interface; the universe covers eight asset classes including short-duration credit, convertible bonds, China equities across styles, Hong Kong equities, global equities, and commodities. The evaluation window runs from 2019-01-01 to 2026-05-07 (86 monthly observations) with monthly rebalancing, a 3-basis-point transaction cost, and no-lookahead controls. Models compared include Global RRP, Convex Adaptive Global RRP, Improved Convex Adaptive Global RRP, HRP, and HERC.

Global RRP produces a 4.71% net annual return, Sharpe 0.693, and maximum drawdown of -6.83% — workable numbers, but monthly turnover of 18.0% creates meaningful cost drag. Adding CVaR constraints, a low-turnover penalty, and group weight limits in Improved Convex Adaptive Global RRP brings the turnover down to 0.51% while lifting net return to 7.79%, Sharpe to 1.326, Sortino to 1.976, and compressing drawdown to -5.83%. HRP and HERC post Sharpe ratios of -0.042 and 1.184 respectively, but both allocate over 90% to bonds throughout the sample — their risk-adjusted performance reflects low volatility rather than broad diversification. Improved Convex Adaptive Global RRP does not dominate on every single metric, but holds up better across the three dimensions that matter most for an implementable long-term portfolio.

All empirical findings are conditional on the historical evaluation period and constraint settings reported here, and do not constitute a guarantee of future performance.

Keywords: Relaxed Risk Parity; Global Multi-Asset Allocation; CVaR; Turnover Constraint; Convex Optimization; ETF

目录

1	绪论	1
1.1	研究背景与意义	1
1.2	研究问题与研究思路	1
1.3	研究内容与章节安排	2
1.4	可能的边际贡献	2
2	文献综述与理论基础	2
2.1	现代投资组合理论与估计误差	2
2.2	风险平价与宽松风险平价	3
2.3	CVaR、交易成本与组合约束	4
2.4	HRP/HERC 与国内实践	5
2.5	文献评述与本文切入点	5
3	理论框架与模型方法	6
3.1	统一符号	6
3.2	标准风险平价	7
3.3	宽松风险平价与 Global RRP	7
3.4	凸优化改进模型	8
3.5	协方差估计方法	9
3.6	HRP 与 HERC 基准模型	10
4	数据、变量与研究设计	11
4.1	ETF 资产池构建原则	11
4.2	数据来源与处理流程	13
4.3	收益率、权重、交易成本与换手率定义	13
4.4	组合约束与调仓规则	14
4.5	评价指标体系	14
4.6	回测流程与无前视设计	14

4.7	描述性统计与资产特征分析	15
5	实证结果分析	17
5.1	主模型绩效比较	17
5.2	HRP/HERC 基准模型对比	17
5.3	净值路径与回撤分析	18
5.4	换手率与权重结构分析	19
5.5	CVaR 尾部风险分析	22
5.6	因子暴露与收益归因	23
5.7	小结	25
6	稳健性检验与过拟合诊断	26
6.1	子区间与压力期检验	26
6.2	交易成本与参数敏感性	27
6.3	协方差估计与过拟合诊断	29
6.4	分块自助法检验	31
6.5	小结	33
7	结论与展望	33
7.1	主要结论	33
7.2	研究不足	34
7.3	后续研究方向	34
A	主要指标定义汇总	35
	参考文献	36

1. 绪论

1.1 研究背景与意义

资产配置在很大程度上决定了长期组合的风险收益特征^[1]。与短期择时策略相比，长期资产配置更关注不同资产类别间的风险来源、回撤控制和流动性管理。保险资金、养老金和银行理财等长期资金通常需要在多年时间维度上维持稳定的风险暴露，管理难度不只在收益水平，如何说清楚收益来自哪里、风险分散到什么程度、调仓成本是否可控，同样是实际问题。

风险平价和风险预算方法正是针对这类需求发展起来的。其核心思想不是资本金额的均匀分配，而是使不同资产对组合总风险的贡献更加均衡。这种方法对收益预测的依赖程度较低，适合构建可解释性强的长期配置框架^[2-3]。扩展到全球 ETF 后，问题变得复杂：不同市场收盘时间不一致，海外 ETF 带汇率暴露，各标的上市时间参差不齐，商品和权益的尾部行为差异明显。交易成本和换手的累积尤其重要，月度调仓在长周期内会侵蚀相当一部分净收益。

从理论层面看，将风险平价从严格等风险贡献条件扩展至更灵活的宽松风险预算框架，能够把权重上限、资产组约束、换手约束和 CVaR 尾部风险度量统一纳入可计算的凸优化框架。从实践层面看，以可交易 ETF 替代部分原始指数，使回测结果更贴近真实组合执行，有助于讨论执行纪律和交易成本对长期收益的实际影响。

1.2 研究问题与研究思路

本文围绕四个问题展开。宽松风险平价能否在 30 支全球 ETF 中建立风险来源清晰的配置框架？加入 CVaR 约束和换手惩罚后，收益、回撤与换手率之间的权衡是否确实改善？HRP 和 HERC 在同一样本中表现如何，与主模型是何种关系？稳健性检验能否识别出结论对样本期和参数选择的依赖程度？

本文先梳理均值-方差、风险预算、CVaR 和层次化配置方法的理论联系，再建立可交易 ETF 资产池和统一回测标准，然后在相同研究设计下比较各模型，最后

用多维度稳健性检验和过拟合诊断约束结论的适用范围。

1.3 研究内容与章节安排

论文分七章。第二章综述均值-方差、风险预算、CVaR 和层次化配置文献，说明本文的切入点。第三章给出模型符号和定位汇总。第四章说明 ETF 资产池、数据处理和回测规则。第五章比较各模型的绩效、净值路径和权重结构。第六章从子区间、参数扰动、协方差估计和过拟合诊断多个角度检验结论稳健性。第七章总结结论并指出研究局限。

1.4 可能的边际贡献

本文的边际贡献主要有三点。其一是数据选择：以可交易 ETF 替代不可交易指数，使回测更贴近实际组合执行，而不是停留在指数层面。其二是方法整合：把风险预算偏离惩罚、CVaR 约束、换手约束和资产组限制放进同一个凸优化框架，允许同时处理多个实施约束。其三是验证角度：将多种稳健性诊断串联起来，把结论的适用范围限定在具体的样本区间和参数设定上，而不是笼统宣称模型有效。

2. 文献综述与理论基础

2.1 现代投资组合理论与估计误差

Markowitz 的均值-方差理论是现代资产配置研究的基础^[4]。该框架通过预期收益向量和协方差矩阵描述组合收益与风险之间的权衡，使资产配置从经验判断转向可计算优化。Sharpe 的 CAPM 进一步把个体资产收益与市场系统性风险联系起来^[5]。Black-Litterman 模型试图把市场均衡和主观观点结合起来，缓解均值输入

不稳定问题^[6]。这些工作为” 如何把收益预期与风险代价写进同一个优化问题” 提供了基础语言。

然而，均值-方差框架在实证应用中长期面临输入参数敏感性问题。Jorion 的 Bayes-Stein 收缩估计、Chopra 和 Ziemba 关于均值与协方差误差影响的研究均表明，预期收益估计中的微小误差可能导致最优权重发生显著变化^[7-8]。Grinold 和 Kahn 强调，预期收益信号必须与风险模型和约束相结合使用^[9]。DeMiguel 等人通过比较等权组合与多种优化方法发现，在有限样本下复杂优化未必优于简单多元化策略^[10]。Michaud 将这一现象概括为” 马科维茨优化之谜”，指出最优化结果对输入参数的微小变化极为敏感，常导致样本外表现退化^[11]。Jagannathan 和 Ma 进一步发现，卖空约束等看似” 错误” 的约束在大规模资产池中反而有助于压制样本协方差噪声、降低组合风险^[12]。Laloux 等人借助随机矩阵理论证明，金融资产相关矩阵的绝大多数特征值落入噪声区间，这从理论上揭示了样本协方差矩阵包含大量噪声的根本来源，为收缩估计方法提供了直接支撑^[13]。此外，Herculano 的贝叶斯参数化组合策略通过在策略系数上设置先验，绕过显式收益和协方差建模，为估计误差条件下的组合构建提供了贝叶斯路径^[14]；Hellum 等人在理论层面表明，特定条件下高维资产池中均值-方差组合的样本外表现可能随资产数量增加而改善^[15]。

以上研究的共同含义是：输入参数质量是限制组合表现的主要约束，协方差估计方法的选择对结果有实质影响。本文选择以风险预算为主线，同时在稳健性检验中比较不同协方差估计器。

2.2 风险平价与宽松风险平价

风险平价的核心不是资金等权，而是风险贡献分散。Qian 将风险平价解释为通过真实分散化提高组合效率的配置思想^[2]。Maillard、Roncalli 和 Teiletche 系统研究了等风险贡献组合的性质，说明风险贡献可作为资产配置权重之外的另一种分散化标准^[3]。Roncalli 进一步给出完整风险预算框架，将风险贡献目标推广为一组可解释的风险预算约束^[16]；Bruder 和 Roncalli 在此基础上系统推导了多约束条件下的数值求解策略^[17]。Asness、Frazzini 和 Pedersen 从杠杆厌恶视角解释了风险平价的潜在超额收益来源——多数投资者不愿使用杠杆，导致低风险资产系统性定价偏低，风险平价通过加杠杆持有低波动资产可获取这一溢价^[18]。Chaves 等人的比较研究表明，风险平价组合在多数样本外时段的风险调整收益优于等权和市

值加权等启发式策略^[19]。国内研究强调，风险平价中的“风险”不应被狭义理解为资产波动率本身，而应理解为组合的宏观风险暴露；实际落地中，协方差口径、杠杆限制和可投资标的范围都会显著改变策略形态^[20-21]。

宽松风险平价的动机是把严格风险贡献匹配转化为可容忍偏离的优化目标。Gambeta 和 Kwon 的研究表明，宽松风险平价可以在保留风险预算特征的同时，显式引入收益目标与风险预算偏离之间的权衡^[22]。Cetingoz 和 Guéant 进一步表明，资产层和因子层风险预算之间可以被放入更一般的平衡框架，为风险预算扩展到更复杂约束提供了理论启发^[23]。Bessler、Taushanov 和 Wolff 的实证研究表明，以资产类别为基础的组合构造在样本外鲁棒性上并不弱于纯粹的因子层面分解^[24]。

宽松处理是一种近似，不是经典风险平价的精确等价。本文采用 relaxed 而非 exact ERC，是为了把 CVaR、换手约束和资产组限制放进可求解的框架里。

2.3 CVaR、交易成本与组合约束

CVaR 关注超越 VaR 分位点之后的平均尾部损失水平。Rockafellar 和 Uryasev 的研究提出可计算的 CVaR 优化框架，通过引入辅助变量使尾部损失约束能够进入优化问题^[25]；后续研究将该框架推广至更一般的损失分布，并讨论了尾部显著非正态情形下的数值性质^[26]。Boyd 和 Vandenberghe 的凸优化理论表明，凸目标函数和凸约束集合有利于获得稳健的数值求解，并便于纳入线性约束、范数惩罚项和辅助变量^[27]。交易成本建模方面，Almgren 和 Chriss 建立了最优组合执行模型，将市场冲击成本纳入调仓决策框架，为固定费率假设之外的更精细成本估计提供了理论基础^[28]。

CVaR 的准确性依赖于历史回看窗口和置信水平的设定，历史样本之外的极端市场状态仍可能低估实际尾部风险。Uhl、Jurt 和 Walliser 借助自然语言处理构建了基于 AI 的尾部事件识别框架，为尾部风险的情境识别提供了机器学习视角的补充证据^[29]。Alouadi 等人提出的 SBBTS 框架通过 Schrödinger Bridge 与 Bass 鞅原理联合校准漂移和随机波动率生成合成时间序列，为组合策略的压力情景模拟提供了不依赖历史分布假设的新路径^[30]。

本文用 CVaR 做约束和风险诊断，不是用它来承诺收益。实际作用是把尾部损失的历史信息放进优化目标，但它无法覆盖历史中从未发生过的极端情景。

2.4 HRP/HERC 与国内实践

López de Prado 提出的 HRP 方法利用相关矩阵构造距离矩阵，再通过层次聚类、准对角化和递归二分生成权重^[31]。Raffinot 提出的 HERC 在层次结构中引入风险贡献思想，使簇内和簇间配置更接近风险预算逻辑^[32]。Ciciretti 和 Pallotta 将图论工具引入风险平价框架，提出基于最小生成树的网络风险平价方法，在资产数量较多时样本外表现尤为突出^[33]。Lohre、Rother 和 Schäfer 在层次化框架中进一步引入尾部依赖结构，表明压力期相关性上升的信息可提升多资产多因子配置的样本外稳健性^[34]。Cho 和 Song 将最小生成树的外围节点识别用于证券预筛选，再对保留资产运行 HRP，实验表明这一组合能改善聚类质量并降低集中度风险^[35]。这类方法的优势在于避免直接求逆协方差矩阵，但对聚类结构和样本区间敏感，且难以直接表达 CVaR 和换手约束。

国内实践研究指出，在中国市场语境下，风险平价必须面对低利率、工具约束和执行频率等现实问题，ETF 工具丰富化为风险平价落地提供了现实基础^[36,21,37-38]。本文把 HRP/HERC 当作真正有竞争力的基准——后文的夏普比率、回撤和权重集中度比较都是认真对待它们的。

2.5 文献评述与本文切入点

以上文献各自在其问题上有贡献，但每种方法都有局限：均值-方差对收益预测过度依赖，严格等风险贡献约束在多约束场景下难以直接求解，层次化模型无法直接处理 CVaR 和换手约束。本文的做法是把这些方法放进同一个可交易 ETF 回测框架里比较，用实证数据和多维度验证检查它们在当前样本中各自能走多远。

3. 理论框架与模型方法

3.1 统一符号

表 3-1 主要符号说明

符号	含义
n	资产数量
T	历史窗口长度
w_t	第 t 期调仓后的组合权重
w_{t-1}^+	第 t 期调仓前经收益漂移后的权重
r_t	第 t 日资产收益率向量
R_t	再平衡日前可获得的历史收益率窗口
Σ_t	基于 R_t 估计的协方差矩阵
μ_t	基于 R_t 估计的预期收益输入
b_t	风险预算或参考权重向量
RC_i	第 i 个资产对组合波动率的风险贡献
l_i, u_i	单资产权重下限和上限
L_g, U_g	资产组权重下限和上限
G	资产组映射矩阵
TO_t	第 t 期换手率
c	单位交易成本率
η	CVaR 辅助变量
α	CVaR 置信水平

除特别说明外，本文所有模型均在长仓、权重归一、滚动估计、月度调仓和交易成本扣减框架下比较。最终权重由透明优化流程给出，不依赖机器学习或状态识别模块直接生成交易信号。

3.2 标准风险平价

设组合权重为 w ，协方差矩阵为 Σ ，组合波动率为：

$$\sigma_p = (w^T \Sigma w)^{1/2}$$

第 i 个资产的边际风险贡献为：

$$MRC_i = \frac{\partial \sigma_p}{\partial w_i} = \frac{(\Sigma w)_i}{\sigma_p}$$

总风险贡献为：

$$RC_i = w_i MRC_i = w_i \frac{(\Sigma w)_i}{\sigma_p}$$

由 Euler 齐次函数性质可得：

$$\sum_{i=1}^n RC_i = \frac{w^T \Sigma w}{\sigma_p} = \sigma_p$$

标准风险平价要求各资产风险贡献与目标预算 b_i 匹配：

$$RC_i = b_i \sigma_p, \quad i = 1, \dots, n, \quad \sum_i b_i = 1$$

当 $b_i = 1/n$ 时，模型退化为等风险贡献组合。标准风险平价的好处是定义干净、对收益预测依赖很小。但只要加上权重上下限、组别约束和交易成本，直接求解就不再容易，本文只把它作为理论参照。

3.3 宽松风险平价与 Global RRP

宽松风险平价不是放弃风险预算，而是把严格风险贡献等式改为偏离惩罚：

$$\begin{aligned} \min_w \sum_i (RC_i / \sigma_p - b_i)^2 + \lambda_{reg} \|w - w_0\|_2^2 \\ \sum_i w_i = 1, \quad l_i \leq w_i \leq u_i \end{aligned}$$

其中，第一项刻画风险贡献相对预算的偏离，第二项刻画与参考权重或上一期权重的距离。这个表达允许在风险预算、权重稳定性和现实约束之间做折中，而不是强迫三者同时精确满足。

Local Relaxed Risk Parity 表示本地资产池中的宽松风险预算模型。Global RRP 表示扩展到全球多资产 ETF 后的基准宽松风险预算模型，将债券、可转债、中国权益、港股、海外权益和商品放入统一风险预算框架。它的问题在于换手较高，交易成本对净收益的影响比较明显，基础版本没有 CVaR 约束。

3.4 凸优化改进模型

Convex Adaptive Global RRP 将风险预算思想转化为凸化近似，使模型可以更自然地纳入换手率、CVaR、资产上限和组别约束。其简化目标函数为：

$$\begin{aligned} \min_w J(w) \\ J(w) = \lambda_{var} w^T \Sigma_t w + \lambda_{budget} \|w - b_t\|_2^2 \\ + \lambda_{turnover} \|w - w_{t-1}^+\|_1 + \lambda_{cvar} CVaR_\alpha(w) - \lambda_{return} \mu_t^T w \\ \sum_i w_i = 1, \quad 0 \leq w_i \leq u_i, \quad L_g \leq \sum_{i \in g} w_i \leq U_g \end{aligned}$$

目标函数中各项分工明确：方差项控制整体波动；预算跟踪项让权重不偏离风险预算太远； L_1 换手惩罚项直接压低交易频率；CVaR 项把历史尾部损失纳入考量；收益倾斜项权重固定为 0.05，只提供温和的收益输入。凸化表达的优点是可以加入线性约束、 L_1 换手惩罚和组别约束，便于稳定求解。 μ_t 仅基于调仓日前历史窗口 R_t 计算的样本均值年化输入； $\lambda_{return} = 0.05$ 为固定小权重，而非择时信号。参数扰动检验中特别纳入了 $\lambda_{return} = 0$ 的对照情形，用于比较去除收益倾斜项后模型表现是否发生实质变化。

Improved Convex Adaptive Global RRP 是本文重点讨论的可实施改进，其改进体现在低换手、CVaR 约束、资产组约束和权重路径稳定四个方面。若历史情景损失为 $L_s = -r_s^T w$ ，CVaR 可表示为^[25,27]：

$$CVaR_\alpha(L) = \min_\eta \left[\eta + \frac{1}{(1-\alpha)T} \sum_{s=1}^T \max(L_s - \eta, 0) \right]$$

在当前样本中，Improved Convex Adaptive Global RRP 的平均月度换手率为 0.51%。0.51% 的月度换手基本意味着每月只微调少量头寸，对长期资金友好，但代价是对市场结构变化的响应会慢一些。

3.5 协方差估计方法

协方差矩阵的质量直接影响风险预算分配和权重求解。本文在不同模型和稳健性检验中使用三类估计器。

样本协方差矩阵是最直接的方法：给定历史收益率窗口 $R_t \in \mathbb{R}^{T \times n}$,

$$S_t = \frac{1}{T-1} (R_t - \bar{r}_t \mathbf{1}^T)^T (R_t - \bar{r}_t \mathbf{1}^T)$$

在资产数量 n 较大或历史窗口 T 较短时，样本协方差矩阵的估计噪声较大、条件数较差，容易导致极端权重。Laloux 等人的随机矩阵理论研究表明，金融资产相关矩阵中大量特征值落入噪声区间^[13]，这是样本估计不稳定的根本来源。

Ledoit-Wolf 收缩估计^[39]将样本协方差矩阵向结构化目标 F_t 做加权平均：

$$\hat{\Sigma}_t = (1 - \delta) S_t + \delta F_t$$

其中 F_t 通常取等方差对角矩阵，最优收缩系数 $\delta \in [0, 1]$ 通过 Oracle 近似方法求解。收缩使极端特征值向均值压缩，降低权重对样本误差的敏感度。Ledoit 和 Wolf 在后续研究中将线性收缩推广至二次收缩框架，从理论上给出更接近最优非线性收缩的可计算近似^[40]；本文默认使用线性 Ledoit-Wolf 收缩，二次收缩可作为后续扩展。

指数加权移动平均（EWMA）通过对近期观测赋予更高权重，捕捉协方差的时变性：

$$\hat{\Sigma}_t = (1 - \lambda) \sum_{s=0}^{T-1} \lambda^s r_{t-s} r_{t-s}^T, \quad \lambda = e^{-\ln 2 / \tau}$$

其中 τ 为半衰期参数。本文在稳健性检验中测试 $\tau \in \{20, 60, 120\}$ 三种设定，分别对应短期、中期和长期时间尺度。

主模型默认使用 Ledoit-Wolf 收缩估计，第六章协方差稳健性检验系统比较三类估计器对主要绩效指标的影响。

3.6 HRP 与 HERC 基准模型

HRP 基准模型的流程包括：基于收益率估计相关矩阵，将相关性转化为距离矩阵，进行层次聚类，按照聚类顺序进行准对角化，最后通过递归二分分配权重^[31]。HERC 基准模型在层次结构中加入风险贡献思想，使簇内和簇间风险分配更接近风险预算逻辑^[32]。

当前样本中 HRP/HERC 夏普比率不弱，但回撤和换手率都高于 Improved Convex Adaptive Global RRP。两类方法各有逻辑，HRP/HERC 的主要限制是对聚类结构的选择敏感，且没有直接处理 CVaR 和换手约束的机制。

表 3-2 模型定位汇总

Model	Role in Thesis	Main Advantage	Main Limitation
Standard Risk Parity	理论参照	风险贡献清晰	多约束下求解困难
Local Relaxed Risk Parity	本地宽松风险预算	降低严格等式刚性	资产池较窄
Global RRP	基准宽松风险预算模型	全球资产分散与风险预算清楚	换手较高
Convex Adaptive Global RRP	凸化风险预算近似	兼容换手和组别约束	不是经典 RP 精确等价
Improved Convex Adaptive Global RRP	可实施性改进模型	低换手、CVaR 约束	参数依赖与样本依赖
HRP Benchmark	层次化基准模型	聚类解释直观	聚类稳定性敏感
HERC Benchmark	层次化风险贡献基准模型	引入层次风险贡献	难直接表达 CVaR 和换手

4. 数据、变量与研究设计

4.1 ETF 资产池构建原则

本文使用可交易 ETF 构建全球多资产池。选择标准主要是可交易性和跨资产覆盖。用 ETF 而非不可交易指数，回测结论更贴近实际组合执行，但流动性冲击、申赎成本和大额交易的滑点都没有纳入。

表 4-3 ETF 资产池

ETF	Ticker	Asset Class
短融 ETF	511360.SH	short-duration credit
可转债 ETF	511380.SH	convertible bond
国债 ETF	511010.SH	government bond
信用债 ETF	511030.SH	credit bond
银华日利 ETF	511880.SH	money market
沪深 300ETF	510300.SH	china equity
中证 500ETF	510500.SH	china equity
中证 1000ETF	512100.SH	china equity
科创 50ETF	588000.SH	china equity
红利 ETF	510880.SH	china equity dividend
半导体 ETF	512480.SH	china tech equity
芯片 ETF	159995.SZ	china tech equity
机器人 ETF	562500.SH	china advanced manufacturing
人工智能 ETF	159819.SZ	china tech equity
卫星 ETF	159206.SZ	china tech equity

ETF	Ticker	Asset Class
光伏 ETF	515790.SH	china new energy
新能源 ETF	516160.SH	china new energy
证券 ETF	512880.SH	china finance
恒生 ETF	159920.SZ	hong kong equity
创新药 ETF	516080.SH	china pharma
纳指 ETF	159941.SZ	global equity
军工 ETF	512660.SH	china defense
标普 500ETF	513500.SH	global equity
日经 225ETF	513880.SH	global equity
道琼斯 ETF	513400.SH	global equity
黄金 ETF	518880.SH	commodity
有色 ETF	159980.SZ	commodity equity
豆粕 ETF	159985.SZ	commodity
油气 ETF	513350.SH	commodity
煤炭 ETF	515220.SH	commodity

资产池包含 30 支可交易 ETF，覆盖八类风险来源。债券类包含短融、可转债、国债、信用债和银华日利 ETF；A 股宽基涵盖大、中、小盘及科创与红利风格；中国科技类包含半导体、芯片、人工智能和卫星 ETF；中国先进制造类包含机器人 ETF；中国新能源类涵盖光伏与新能源宽基；中国行业类补充券商周期因子；港股与医药类分别覆盖香港市场权益和创新药；全球股票类包含纳指、标普 500、日经 225 和道琼斯 ETF；大宗商品类通过黄金、有色、豆粕、油气和煤炭 ETF 提供多元大宗商品暴露。

图 4-1 展示了资产池在平静期与主要压力期前后的跨类别相关结构变化。债券类（短融、国债）与权益、商品的相关性在压力期通常有所上升，典型的分散化效果有所削弱；黄金在多数压力期仍保持与权益的低相关或负相关，是当前资产池中分散效果最稳定的品种之一。全球股票类与中国 A 股之间的相关性在 2020




图 4-1 资产池跨类别相关结构（平静期与压力期对比）

年初流动性危机和 2022 年下行期明显走高，这也是协方差估计器需要兼顾近期和历史信息的一个具体原因。不同压力情景下相关结构的变化路径，是协方差稳健性检验的重要背景。

4.2 数据来源与处理流程

价格数据来自 Tushare ETF 数据接口，使用经复权处理后的可比价格序列。日收益率按相邻交易日价格变化计算，并对不同 ETF 的交易日进行对齐。上市前缺失价格不进行填补；若某 ETF 在再平衡日前历史窗口不足，则不参与当期优化。本文绩效评价区间自 2019-01-01 起，30 支 ETF 中最早上市者于 2018-01-30 开始交易，评价起点设定于此以确保多数资产同时可投。逐点时间宇宙过滤在每个再平衡日自动排除历史数据不足的 ETF，确保无前视信息泄露。部分资产如中证 1000 ETF 上市时间较晚，其历史统计和模型参与频率与早上市 ETF 不完全一致，本文通过描述性统计和无前视设计予以披露。

4.3 收益率、权重、交易成本与换手率定义

设第 i 个 ETF 在第 t 日价格为 $P_{i,t}$ ，日收益率为：

$$r_{i,t} = \frac{P_{i,t}}{P_{i,t-1}} - 1$$

调仓后权重为 w_t ，调仓前经收益漂移后的权重为 w_{t-1}^+ ，组合毛收益为：

$$r_{p,t}^{gross} = w_{t-1}^T r_t$$

第 t 个调仓日换手率定义为：

$$TO_t = \sum_i |w_{i,t} - w_{i,t-1}^+|$$

若单位交易成本率为 c ，则交易成本为 $TC_t = c \cdot TO_t$ ，组合净收益为 $r_{p,t}^{net} = r_{p,t}^{gross} - TC_t$ 。本文默认交易成本为 3 bps，在结果中区分毛收益和净收益。该处理未覆盖冲击成本、买卖价差和申赎费用。

4.4 组合约束与调仓规则

本文模型在长仓约束下比较，权重和为 1，不允许卖空。模型包含单资产权重上限、资产组边界和月度调仓规则。月度调仓意味着模型在每个月末附近的再平衡点使用当时可获得的历史窗口估计风险输入，适合长期配置研究，也能避免过高交易频率导致的执行成本问题。

4.5 评价指标体系

累计净值定义为 $NAV_t = \prod_{s \leq t} (1 + r_{p,s}^{net})$ 。净年化收益衡量整个评价期内净值增长速度，受样本起止点影响。年化波动率衡量收益波动程度。夏普比率定义为净年化收益除以年化波动率。最大回撤定义为：

$$MDD = \min_t \left(\frac{NAV_t}{\max_{s \leq t} NAV_s} - 1 \right)$$

Calmar 比率为净年化收益除以最大回撤绝对值。平均月度换手率衡量组合执行稳定性。95% 日度 CVaR 衡量历史日度损失超过 95% 分位后的平均损失，是尾部风险诊断指标，不是未来极端损失预测。

4.6 回测流程与无前视设计

本文回测流程如下：第一，在每个调仓日确定历史窗口；第二，使用调仓日前数据估计协方差、预算或状态；第三，求解目标权重；第四，计算调仓换手和交易成本；第五，使用调仓后的未来收益计算组合净值；第六，进入下一个月度调仓

点。压力期识别只用于事后评价，不作为交易信号。稳健性检验不参与主模型重新选择，其作用是约束结论强度。

4.7 描述性统计与资产特征分析

表 4-4 展示 30 支 ETF 上市后有效观测数、年化收益、年化波动和最大回撤。资产池历史长度差异较大：国债、沪深 300 等早期上市 ETF 拥有超过 2000 个观测，而中证 1000、光伏、新能源等 ETF 因数据接口覆盖限制观测数较少；权益和商品资产波动率与回撤通常远高于债券类资产。

表 4-4 主要资产描述性统计

ETF	Obs.	Ann. Return	Ann. Vol.	Max DD
短融 ETF	1354	2.23%	0.27%	-1.06%
可转债 ETF	1471	6.32%	8.58%	-15.90%
国债 ETF	2000	3.28%	1.65%	-4.92%
信用债 ETF	1679	2.56%	1.65%	-4.47%
银华日利 ETF	2000	1.97%	0.19%	-0.20%
沪深 300ETF	2000	3.52%	16.62%	-42.13%
中证 500ETF	2000	5.48%	18.68%	-39.43%
中证 1000ETF	1999	5.59%	21.46%	-46.35%
科创 50ETF	1324	3.24%	24.35%	-59.64%
红利 ETF	2000	4.73%	14.22%	-23.40%
半导体 ETF	1670	20.92%	32.50%	-62.49%
芯片 ETF	1512	13.03%	31.70%	-61.55%
机器人 ETF	1051*	2.43%	26.36%	-45.42%
人工智能 ETF	1357	12.43%	27.83%	-45.21%
卫星 ETF	277*	78.01%	32.21%	-28.90%

ETF	Obs.	Ann. Return	Ann. Vol.	Max DD
光伏 ETF	1301	1.23%	31.03%	-67.07%
新能源 ETF	1268	1.34%	27.77%	-67.31%
证券 ETF	2000	0.49%	24.11%	-45.00%
恒生 ETF	2000	-0.19%	18.88%	-45.96%
创新药 ETF	1260*	-7.13%	24.11%	-57.97%
纳指 ETF	2000	19.10%	20.78%	-31.10%
军工 ETF	2000	7.14%	27.24%	-50.95%
标普 500ETF	1999	13.89%	15.66%	-29.67%
日经 225ETF	1663	11.13%	16.92%	-28.89%
道琼斯 ETF	541*	9.53%	16.16%	-20.46%
黄金 ETF	2000	16.59%	12.37%	-24.89%
有色 ETF	1539	12.47%	15.60%	-32.86%
豆粕 ETF	1552	12.99%	16.99%	-26.60%
油气 ETF	586	11.14%	27.14%	-38.53%
煤炭 ETF	1496	19.93%	28.88%	-33.22%

* 近期上市 ETF，可用历史较短，仅在积累足够观测后参与优化。

这些统计只是帮助理解资产池结构差异，不直接用于模型选择。银华日利 ETF 年化波动仅 0.19%，而科技和新能源 ETF 的波动率普遍超过 25%，最大回撤多超 60%。黄金和部分商品 ETF 与权益资产相关性较低，是跨资产分散的主要来源。创新药 ETF 样本内年化收益为 -7.13%，医药板块在评价区间内整体处于调整期。近期上市品种（机器人、卫星、道琼斯、创新药 ETF）在历史数据不足阶段由 `investable_columns` 过滤自动排除。

5. 实证结果分析

5.1 主模型绩效比较

表 5-5 展示了核心模型的实证绩效指标，评价区间为 2019-01-01 至 2026-05-07，共 86 个月度观测。Global RRP 净年化收益率为 4.71%，年化波动率为 4.17%，夏普比率为 0.693，最大回撤为 -6.83%，平均月度换手率为 18.0%。月度换手率 18.0% 是个实际问题——按 3 bps 费率，这部分成本每年大约侵蚀 0.65 个百分点的净收益。

Convex Adaptive Global RRP 取得了 6.43% 的净年化收益，夏普比率为 1.166，最大回撤为 -5.22%，平均月度换手率降至 1.82%。换手从 18.0% 降至 1.82%。Improved Convex Adaptive Global RRP 进一步达到了 7.79% 的净年化收益，夏普比率为 1.326，Sortino 比率为 1.976，最大回撤为 -5.83%，平均月度换手率仅为 0.51%。这个模型的好处不是某一项指标特别突出，而是三个维度上都没有明显短板。

表 5-5 核心模型绩效（评价区间 2019-01-01 至 2026-05-07）

Model	Net Return	Sharpe	Max DD	Calmar	Monthly TO
Global RRP	4.71%	0.693	-6.83%	0.690	18.0%
Defensive Dynamic RRP [†]	4.09%	0.541	-7.47%	0.548	17.1%
Convex Adaptive Global RRP	6.43%	1.166	-5.22%	1.229	1.82%
Improved Convex Adaptive Global RRP	7.79%	1.326	-5.83%	1.336	0.51%

[†] Defensive Dynamic RRP 为防御型风险覆盖实验模型，仅作补充对比，不是本文主要研究对象。

5.2 HRP/HERC 基准模型对比

表 5-6 展示了在相同评价口径下计算的 HRP 和 HERC 基准模型绩效。HRP 基准模型实现了 1.81% 的净年化收益，夏普比率为 -0.042，最大回撤仅为 -0.08%，Calmar 比率达到 22.12，平均月度换手率为 5.60%。HERC 基准模型的净年化收益

为 2.37%，夏普比率为 1.184，最大回撤为 -0.39%，Calmar 比率为 6.011，平均月度换手率为 9.24%。

HRP 的负夏普比率主要源于其净年化收益（1.81%）略低于同期无风险利率水平（约 1.82%），这并非真实亏损而是相对表现。HERC 基准模型的夏普比率为 1.184，在当前样本里是有实质意义的正值。

但夏普比率高不等于可以替代主模型。HRP 和 HERC 的绝对年化收益（分别为 1.81% 与 2.37%）与 Improved Convex Adaptive Global RRP 的 7.79% 相比差距显著，主要来源于极低的波动水平（HRP 的年化波动仅为 0.17%），而不是多资产分散的结果。权重路径（见后文）也说明两者几乎全仓债券。另外，HRP 和 HERC 的月度换手率（5.60% 和 9.24%）都远高于 Improved Convex Adaptive Global RRP 的 0.51%。

表 5-6 HRP/HERC 基准模型绩效（评价区间 2019-01-01 至 2026-05-07）

Benchmark	Net Return	Sharpe	Max DD	Calmar	Monthly TO
HRP Benchmark	1.81%	-0.042	-0.08%	22.12	5.60%
HERC Benchmark	2.37%	1.184	-0.39%	6.011	9.24%

5.3 净值路径与回撤分析




图 5-2 核心模型累计净值路径比较

图 5-2 展示了六个核心模型在统一评价区间内的累计净值路径。Convex Adaptive Global RRP 与 Improved Convex Adaptive Global RRP 在多数阶段保持更高的累计净值水平，其中 Improved Convex Adaptive Global RRP 的路径更平稳。HRP 和 HERC 的路径较平，接近一条斜率温和的直线，与它们近全仓债券的配置结构一致。仅看净值路径不足以判断哪个模型更好，还需要结合回撤深度和换手成本。




图 5-3 核心模型回撤路径比较

最大回撤反映投资者在历史净值曲线上所经历的峰值到谷值的最大跌幅，长期资金对此指标关注程度较高。Improved Convex Adaptive Global RRP 的最大回撤为 -5.83%，相比 Global RRP 的 -6.83% 有所改善。两个模型最深的回撤都出现在 2022 年市场下行期间。

5.4 换手率与权重结构分析

换手率直接影响交易费用总额和组合日常管理的复杂程度。Global RRP 和 Defensive Dynamic RRP 的平均月度换手率分别达到 18.0% 和 17.1%，基础风险预算模型在没有换手约束的情况下换手自然较高。Improved Convex Adaptive Global RRP 加入 L_1 惩罚后基本稳定在低水平，换手率控制在 0.51%，显著低于 HRP (5.60%) 和 HERC (9.24%)。当然，换手极低也有代价：市场相关结构快速变化时，组合调整会比较迟缓。

图 5-5 和表 5-7 说明各模型绩效差异从何而来。Improved Convex Adaptive Global RRP 的权重路径更平滑，其债券底仓在两个阶段都稳定在约 50% 附近，短




图 5-4 核心模型平均月度换手率比较




图 5-5 Improved Convex Adaptive Global RRP、Global RRP、HRP 基准模型与 HERC 基准模型的资产组权重路径

表 5-7 主要模型阶段性资产组平均权重（2021–2022 与 2023–2025）

Model	Stage	Bonds	China Eq.	HK Eq.	Global Eq.	Commodities
Improved Convex	2021–2022	50.55%	14.56%	1.50%	14.68%	18.70%
Improved Convex	2023–2025	50.74%	14.50%	1.48%	13.02%	20.26%
Global RRP	2021–2022	54.03%	9.75%	1.65%	10.35%	6.76%
Global RRP	2023–2025	44.38%	11.38%	5.39%	13.36%	11.90%
HRP	2021–2022	99.77%	0.06%	0.02%	0.05%	0.10%
HRP	2023–2025	99.80%	0.04%	0.01%	0.03%	0.11%
HERC	2021–2022	92.92%	1.68%	0.57%	1.67%	3.15%
HERC	2023–2025	93.13%	1.55%	0.53%	1.57%	3.22%

融 ETF 维持在约 45%，黄金配置基本稳定在 7% 左右。这种稳定性来自换手惩罚和资产组边界的约束，而不是模型自发保守。

Global RRP 在没有换手约束的情况下更直接地响应协方差变化，其债券组权重从 54.03% 下降到 44.38%，商品组从 6.76% 抬升到 11.90%，适应性强，换手代价也更高。

HRP/HERC 的情况更直接：两个阶段债券权重都在 93–99%。它们的夏普比率主要来自低波动债券仓位，而不是跨资产分散。这不是批评——在这个样本区间里重债券本来就不差——但和主模型的配置逻辑是完全不同的两件事。




图 5-6 核心模型 95% 日度 CVaR 比较

5.5 CVaR 尾部风险分析

表 5-8 核心模型 95% 日度 CVaR (评价区间 2019-01-01 至 2026-05-07)

模型	95% 日度 CVaR
Global RRP	0.64%
Defensive Dynamic RRP	0.65%
Convex Adaptive Global RRP	0.60%
Improved Convex Adaptive Global RRP	0.63%
HRP Benchmark	0.02%
HERC Benchmark	0.06%

表 5-8 展示了各模型的 CVaR 数值。CVaR 和最大回撤衡量的是不同的东西：最大回撤看整条净值路径上最深的跌幅，CVaR 是历史日度损失超过某分位点后的均值。两者都有参考价值，但不可替换。历史 CVaR 对历史中从未出现过的极端情景无能为力。

5.6 因子暴露与收益归因

为进一步理解各模型收益的来源结构，本文使用五个代理因子（权益、债券、大宗商品/黄金、防御性资产、全球风险）对主模型的日收益率进行时间序列回归，并分解各因子对总收益和总方差的贡献。




图 5-7 核心模型因子暴露汇总（全样本回归）

图 5-7 和表 5-9 展示全样本因子暴露回归结果。Global RRP 对债券因子的暴露显著 ($\bar{\beta}_{bond} = 1.682$)，对权益因子暴露极低 ($\bar{\beta}_{equity} = 0.022$)， $R^2 = 0.485$ ，全样本调整后年化 $\alpha = 2.82\%$ ($t = 2.70$)。Improved Convex Adaptive Global RRP 的因子结构更为均衡：债券因子暴露降至 $\bar{\beta}_{bond} = 0.901$ ，商品/黄金因子暴露上升至 $\bar{\beta}_{commodity} = 0.175$ ，权益因子暴露约为 $\bar{\beta}_{equity} = 0.119$ ；模型 $R^2 = 0.895$ ，年化 $\alpha = 1.87\%$ ($t = 3.51$)，说明五因子能较好解释其收益变动，且存在统计上显著的正截距。

表 5-9 核心模型全样本因子暴露与 α （五因子时间序列回归）

模型	β_{eq}	β_{bond}	β_{com}	β_{def}	β_{global}	R^2	α (年化)
Global RRP	0.022	1.682	0.058	-0.014	0.248	0.485	2.82%
Improved Convex	0.119	0.901	0.175	0.006	0.227	0.895	1.87%

因子均为代理因子，不对应特定标准化指数。

图 5-8 展示 Improved Convex Adaptive Global RRP 与 Global RRP 在 252 日滚




图 5-8 Improved Convex Adaptive Global RRP 滚动因子暴露（252 日窗口）

动窗口下的因子暴露时序变化。Improved Convex 的债券暴露范围为 $[-0.16, 2.06]$ ，商品暴露范围为 $[0.11, 0.22]$ ，相对稳定；全球风险因子暴露维持在 $[0.15, 0.31]$ ，表明模型对全球权益系统性风险有持续但适度的暴露。Global RRP 的债券暴露均值更高 ($\bar{\beta}_{bond} = 1.682$)，时序波动也更大，范围 $[-0.71, 4.11]$ ，反映其在没有换手约束情况下对协方差变化的更直接响应。



图 5-9 Improved Convex Adaptive Global RRP 收益来源分解

表 5-10 整理了 Improved Convex Adaptive Global RRP 的收益与方差归因结果。从收益来源看，商品/黄金因子贡献最大（43.2%），其次为债券（27.0%）和权益（25.3%），防御性资产贡献约 4.6%。这一格局与权重路径一致：黄金和大宗商品 ETF 在样本期表现突出，是净收益的主要来源。从风险来源（方差份额）看，权益因子贡献最大（59.1%），商品/黄金次之（33.8%），债券方差贡献极低（0.8%），反




图 5-10 Improved Convex Adaptive Global RRP 风险来源分解

映债券端整体波动较低。

表 5-10 Improved Convex Adaptive Global RRP 收益与方差归因（五因子分解）

因子	收益贡献份额	方差贡献份额
权益	25.3%	59.1%
债券	27.0%	0.8%
商品/黄金	43.2%	33.8%
防御性	4.6%	6.2%

收益与风险归因结果说明 Improved Convex Adaptive Global RRP 的多资产分散是真实的：收益来源分布在权益、债券和商品三个方向，方差的主要承担者是权益和商品，债券的风险贡献极低但收益贡献约 27%，这正是把低波动债券纳入风险预算的本意。与 HRP/HERC 比较，后者几乎全仓债券，收益和风险都高度集中于单一来源，在因子归因上并不构成真正的多资产分散。

5.7 小结

各模型绩效差异背后是不同的配置逻辑。Improved Convex Adaptive Global RRP 在当前样本期内收益、回撤和换手三个维度上都没有明显短板；HRP 和 HERC 夏普比率有竞争力，但回撤幅度、换手频率和暴露集中度与主模型差异显著。比

较这几个模型时，最好同时看指标和权重路径，而不是只看排名。

6. 稳健性检验与过拟合诊断

6.1 子区间与压力期检验




图 6-11 子区间夏普比率稳健性




图 6-12 子区间最大回撤稳健性

图 6-11 和图 6-12 展示不同子区间的夏普比率和最大回撤。子区间结果通常比

全样本结果波动更大，因为短样本受市场状态影响更明显。这些图的用途是看模型结论在哪些区间成立、在哪些区间减弱，而不是用来寻找”最优子区间”。




图 6-13 压力期表现检验

压力期检验用于观察极端阶段组合反应。压力期标签是事后贴上去的，只用于观察组合在特定阶段的行为，不作为调参依据。

6.2 交易成本与参数敏感性




图 6-14 交易成本敏感性检验

图 6-14 比较不同交易成本假设下的模型表现。Global RRP 随费率上升净收益下降更快，而 Improved Convex Adaptive Global RRP 因换手极低，对成本假设基本不敏感。当前成本设定是固定费率，实际成本还包括冲击成本和买卖价差，后者没有纳入。

CVaR 参数敏感性分析在 $\beta \in \{0.90, 0.95, 0.975, 0.99\}$ 和回望窗口 $\in \{126, 252, 504\}$ 两个维度上共测试 12 个变体，以 Improved Convex Adaptive Global RRP 为基础模型，其余参数保持一致。表 6-11 汇报各变体均值指标。

表 6-11 CVaR 参数敏感性分析（12 变体，基于 Improved Convex Adaptive Global RRP）

维度	参数值	夏普均值	净年化收益	最大回撤均值	月度换手均值
置信水平 β	0.90	1.119	6.80%	-5.80%	1.51%
	0.95	1.117	6.78%	-5.80%	1.51%
	0.975	1.117	6.76%	-5.78%	1.51%
	0.99	1.130	6.80%	-5.80%	1.50%
回望窗口（交易日）	126	1.131	6.59%	-5.68%	1.68%
	252	1.082	6.66%	-5.83%	1.46%
	504	1.149	7.09%	-5.87%	1.39%
全部 12 变体均值	—	1.121	6.78%	-5.79%	1.51%

各行为对应参数水平下的多个变体均值，评价区间与主模型一致。

12 个变体的夏普比率范围为 1.08–1.15，净年化收益范围为 6.59%–7.09%，最大回撤均在 -5.68% 至 -5.87% 之间，整体结论对 CVaR 参数选择不敏感。回望窗口的影响略大于置信水平：504 日长窗口的净年化收益最高（7.09%），但换手率也最低，反映更长历史窗口使协方差估计更稳定，调仓幅度更小。




图 6-15 参数扰动敏感性检验

参数扰动采用单因素变化方式，观察模型是否对某一个参数过度敏感。在已测试的扰动范围内较为稳定；测试范围以外是未知的。

6.3 协方差估计与过拟合诊断




图 6-16 不同协方差估计下的夏普比率




图 6-17 不同协方差估计下的回撤表现

本文比较 sample covariance、Ledoit-Wolf 收缩估计和不同半衰期 EWMA (halfliife 20/60/120)。图 6-16–6-18 结果表明主要结论不依赖单一协方差估计方法，但协方差选择会影响权重细节和换手率。哪个估计器在未来更优没有定论。

回溯中的多重假设检验问题由来已久：White 的现实检验法通过自助法对比最




图 6-18 不同协方差估计下的换手表现




图 6-19 过拟合诊断

优策略与随机基准的胜出概率，是处理数据窥探偏差的早期统计框架^[41]；Harvey 和 Liu 进一步系统梳理了多次回测搜索导致统计显著性失真的机制^[42]。本文采用的 CSCV/PBO 用于估计候选参数选择带来的过拟合概率^[43-44]。本次运行使用 36 个候选、35 个区块分割，PBO 为 0.429。PBO 低于 0.5 表明样本内优胜候选在样本外排名中位居中位数以上，是有利信号；中位逻辑秩为 0.288，高于随机基准零点。这是个有利信号，但不是保证——CSCV 只是估计参数选择偏差的程度，不代表样本外表现可以预测。

滚动前向验证（Walk-Forward）包含 23 个测试切片，测试窗口平均净年化收益为 7.18%，平均夏普比率为 1.12，平均最大回撤为 -2.07%。切片较短，指标波动较大，应作为滚动诊断证据而非机械外推依据。冻结样本外检验（Frozen OOS）区间为 2025-01-02 至 2026-04-30，候选 candidate_09 净年化收益为 13.56%，夏普比率为 2.48，最大回撤为 -3.32%。该结果受到样本期内全球权益修复、黄金等分散资产支撑等因素的共同影响，应理解为特定市场背景下的条件性外样本证据。

6.4 分块自助法检验

移动分块自助法（Moving Block Bootstrap）通过对历史收益率时间序列进行有放回的随机分块重抽样，生成保留序列自相关结构的伪样本，从而检验绩效指标的抽样分布特征。本文使用 200 个自助样本，分块长度 21 个交易日（约等于一个月度调仓周期），所有检验仅在验证区间内进行。




图 6-20 分块自助法夏普比率分布（200 个自助样本）

表 6-12 汇报各主要模型分块自助法的夏普比率和最大回撤分布统计量。




图 6-21 分块自助法最大回撤分布（200 个自助样本）

表 6-12 分块自助法绩效分布（200 次重抽样，块长 21 日）

模型	Sharpe 均值	Sharpe P5	Sharpe P50	Sharpe P95	MDD 均值	MDD P5
Global RRP	0.506	-0.156	0.524	1.144	-6.89%	-11.65%
Convex Adaptive	0.843	0.262	0.818	1.494	-5.81%	-8.87%
Improved Convex	1.096	0.510	1.101	1.712	-6.45%	-9.76%

P5/P50/P95 为对应分位数，MDD P5 为最大回撤的第 5 百分位（最差情形）。

图 6-20–6-21 和表 6-12 的关键发现有两点。第一，Improved Convex Adaptive Global RRP 的夏普比率 P5 分位为 0.510，在 200 个自助样本中最差的 5% 情形下仍保持正值；Global RRP 的 P5 分位为 -0.156，表明在不利抽样区间下存在一定亏损风险。第二，Improved Convex 的 Sharpe P50 中位数（1.101）与全样本结果（1.326）的差距反映了样本外泛化折扣，属于正常幅度。Convex Adaptive 的自助 P5 为 0.262，也全程保持正值，说明凸化约束对下尾绩效有一定保护作用。

分块自助法的局限在于，重抽样保留了历史数据的自相关结构，但无法生成历史中从未出现过的极端情景，也不能替代真实样本外检验。它的作用是估计历史数据抽样变异性对结论的影响程度，而非预测未来绩效分布。

6.5 小结

以上检验共同做的事情是把结论限定在具体条件下——特定评价区间、特定成本假设、特定参数选择。没有哪项检验能消除过拟合的可能性，只能说目前的证据在已测试的多个维度上是自洽的。

7. 结论与展望

7.1 主要结论

本文的四个研究问题都得到了相对明确的实证回答，不过每个答案都附带条件。

宽松风险平价在可交易全球 ETF 资产池中确实可以建立一个风险来源清晰的配置框架。Global RRP 净年化收益 4.71%，最大回撤 -6.83%，在没有 CVaR 和换手约束的情况下已经可以运行，但 18.0% 的月度换手是个实际问题。

加入 CVaR 约束、换手惩罚和资产组边界后，Improved Convex Adaptive Global RRP 净年化收益升至 7.79%，最大回撤 -5.83%，换手降至 0.51%。这不是每项指标都领先，而是没有明显短板。

HRP 和 HERC 在当前样本中夏普比率不低，但原因需要说清楚：两者几乎全仓债券，夏普比率来自极低的波动，而不是多资产分散。这和主模型是两种不同的配置思路，本文没有把它们放在同一个评价坐标上排序。

稳健性检验方面， $PBO = 0.429$ 说明候选选择带来的过拟合风险在可接受范围内，协方差估计器的选择不改变主要结论。但这些检验只能覆盖已测试的维度，所有结论都依赖当前的评价区间（2019–2026）和成本假设。

7.2 研究不足

当前可获取的数据缺少买卖价差、成交量和基金资产规模等市场微观结构字段，无法严谨估计大额资金进出可能产生的冲击成本和实际投资容量上限。固定费率是对真实市场结构的简化，冲击成本没有纳入。

本文从资产端视角讨论长期资金配置，尚未引入负债现金流预测、资产负债久期缺口匹配和偿付能力资本占用规则，所以结论不能直接套用到资产负债管理场景。

部分 ETF 上市时间较晚，限制了在更长经济周期上进行系统性比较的可能。若要跨越更完整的经济周期，需要在严格控制前视偏差的前提下研究 ETF 上市前数据的衔接方法。

所有实证结论均基于特定历史评价区间（2019-01-01 至 2026-05-07）和当前市场相关性结构，若未来市场结构发生实质性变化，模型表现可能随之改变，本文结论为条件性实证陈述，不构成对未来长期表现的预测。

7.3 后续研究方向

最直接的后续工作是改善成本建模。引入买卖价差和基于成交量的冲击成本函数，比固定费率更接近机构执行环境，也能让成本敏感性分析的结论更有说服力。

另一个值得做的方向是延长样本。当更多 ETF 积累足够历史数据后，重复当前比较并检验结论是否稳定，本身就是有价值的工作。

把研究推进到负债端需要引入现金流预测、久期缺口和资本占用规则——这超出了本科论文的范围，但是一个逻辑上合理的扩展方向。

从资产端的风险预算扩展到因子层面是另一条可探索的路径。华泰证券的研究从风险平价出发，讨论了向因子配置演进的中国版全天候增强框架^[45]，为资产配置与因子投资的衔接提供了国内市场的实践参考。机器学习和深度强化学习方法也开始进入这一领域：Millea 和 Edalat 将深度强化学习与 HRP 结合用于动态配置，在样本外测试中取得了有竞争力的风险调整收益^[46]；Yang 在多资产组合管理中验证了深度强化学习策略自适应调整的可行性^[47]；Agal 等人从机器学习视角

讨论了风险导向型资产配置的权重生成思路，与本文凸优化路径形成方法上的对照^[48]。这类数据驱动方法在低换手约束和样本外稳健性方面的系统检验，是与本文方法进行有意义比较的前提条件。

A. 主要指标定义汇总

表 A-13 主要指标含义

Metric	Definition and Use
Net Return	扣除交易成本后的年化收益，衡量净值增长速度
Sharpe	净年化收益除以年化波动率，衡量单位波动收益
Max DD	历史净值峰谷最大跌幅，衡量路径风险
Calmar	净年化收益除以最大回撤绝对值，强调回撤调整收益
Turnover	调仓前后权重变化绝对值之和，衡量执行强度
CVaR	给定置信水平下尾部损失均值，衡量历史尾部风险

参考文献

- [1] BRINSON G P, HOOD L R, BEEBOWER G L. Determinants of portfolio performance[J/OL]. Financial Analysts Journal, 1986, 42(4): 39-44. DOI: 10.2469/faj.v42.n4.39.
- [2] QIAN E. Risk parity portfolios: efficient portfolios through true diversification[R]. PanAgora Asset Management, 2005.
- [3] MAILLARD S, RONCALLI T, TEILETCHE J. The properties of equally weighted risk contribution portfolios[J]. The Journal of Portfolio Management, 2010, 36(4): 60-70.
- [4] MARKOWITZ H M. Portfolio selection: efficient diversification of investments [M]. New York: John Wiley & Sons, 1959.
- [5] SHARPE W F. Capital asset prices: a theory of market equilibrium under conditions of risk[J]. The Journal of Finance, 1964, 19(3): 425-442.
- [6] BLACK F, LITTERMAN R. Global portfolio optimization[J]. Financial Analysts Journal, 1992, 48(5): 28-43.
- [7] JORION P. Bayes-stein estimation for portfolio analysis[J]. Journal of Financial and Quantitative Analysis, 1986, 21(3): 279-292.
- [8] CHOPRA V K, ZIEMBA W T. The effect of errors in means, variances, and covariances on optimal portfolio choice[J]. The Journal of Portfolio Management, 1993, 19(2): 6-11.
- [9] GRINOLD R C, KAHN R N. Active portfolio management[M]. New York: McGraw-Hill, 1999.
- [10] DEMIGUEL V, GARLAPPI L, UPPAL R. Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy?[J]. The Review of Financial Studies, 2009, 22(5): 1915-1953.
- [11] MICHAUD R O. The Markowitz optimization enigma: Is ‘Optimized’ optimal? [J/OL]. Financial Analysts Journal, 1989, 45(1): 31-42. DOI: 10.2469/faj.v45.n1.31.

- [12] JAGANNATHAN R, MA T. Risk reduction in large portfolios: Why imposing the wrong constraints helps[J/OL]. *The Journal of Finance*, 2003, 58(4): 1651-1683. DOI: 10.1111/1540-6261.00580.
- [13] LALOUX L, CIZEAU P, BOUCHAUD J P, et al. Noise dressing of financial correlation matrices[J/OL]. *Physical Review Letters*, 1999, 83(7): 1467-1470. DOI: 10.1103/PhysRevLett.83.1467.
- [14] HERCULANO M C. Bayesian parametric portfolio policies[A/OL]. arXiv (2026). <https://arxiv.org/abs/2602.21173>.
- [15] HELLMUM O, JENSEN T I, KELLY B T, et al. Complex modern portfolio theory[J]. SSRN Working Paper, 2026.
- [16] RONCALLI T. Introduction to risk parity and budgeting[M]. Boca Raton: Chapman and Hall/CRC, 2013.
- [17] BRUDER B, RONCALLI T. Managing risk exposures using the risk budgeting approach[R]. Lyxor Asset Management, 2012.
- [18] ASNESS C S, FRAZZINI A, PEDERSEN L H. Leverage aversion and risk parity [J/OL]. *Financial Analysts Journal*, 2012, 68(1): 47-59. DOI: 10.2469/faj.v68.n1.1.
- [19] CHAVES D B, HSU J C, LI F, et al. Risk parity portfolio vs. other asset allocation heuristic portfolios[J]. *The Journal of Investing*, 2011, 20(1): 108-118.
- [20] 林晓明, 黄晓彬, 源洁莹. 风险平价模型的常见理解误区剖析: “风险” 的界定、度量与 “平价”、杠杆的实现[R]. 华泰证券研究所, 2020.
- [21] 张继强, 陶冶, 何颖雯. 风险平价的理念与国内实践: 资产配置方法论系列[R]. 华泰证券研究所, 2024.
- [22] GAMBETA V, KWON R. Risk return trade-off in relaxed risk parity portfolio optimization[J/OL]. *Journal of Risk and Financial Management*, 2020, 13(10): 237. DOI: 10.3390/jrfm13100237.
- [23] CETINGOZ A R, GUÉANT O. Asset and factor risk budgeting: a balanced approach[A/OL]. arXiv (2024). <https://arxiv.org/abs/2312.11132>.
- [24] BESSLER W, TAUSHANOV G, WOLFF D. Factor investing and asset allocation strategies: a comparison of factor versus sector optimization[J/OL]. *Journal of Asset Management*, 2021, 22(6): 488-506. DOI: 10.1057/s41260-021-00225-1.
- [25] ROCKAFELLAR R T, URYASEV S. Optimization of conditional value-at-risk[J].

- Journal of Risk, 2000, 2(3): 21-41.
- [26] ROCKAFELLAR R T, URYASEV S. Conditional Value-at-Risk for general loss distributions[J/OL]. Journal of Banking & Finance, 2002, 26(7): 1443-1471. DOI: 10.1016/S0378-4266(02)00271-6.
 - [27] BOYD S, VANDENBERGHE L. Convex optimization[M]. Cambridge: Cambridge University Press, 2004.
 - [28] ALMGREN R, CHRISS N. Optimal execution of portfolio transactions[J/OL]. Journal of Risk, 2001, 3(2): 5-39. DOI: 10.21314/JOR.2001.041.
 - [29] UHL M W, JURT F, WALLISER S. Can AI detect tail events? Stock performance around tail events during different sentiment regimes[J]. Journal of Behavioral Finance, 2024.
 - [30] ALOUADI A, et al. SBBTS: a unified Schrödinger–Bass framework for synthetic financial time series[A/OL]. arXiv (2026). <https://arxiv.org/abs/2604.07159>.
 - [31] LÓPEZ DE PRADO M. Building diversified portfolios that outperform out of sample[J]. The Journal of Portfolio Management, 2016, 42(4): 59-69.
 - [32] RAFFINOT T. The hierarchical equal risk contribution portfolio[J]. SSRN Electronic Journal, 2018.
 - [33] CICIRETTI V, PALLOTTA A. Network risk parity: graph theory-based portfolio construction[J/OL]. Journal of Asset Management, 2024, 25(2): 136-146. DOI: 10.1057/s41260-023-00347-8.
 - [34] LOHRE H, ROTHER C, SCHÄFER K A. Hierarchical risk parity: Accounting for tail dependencies in multi-asset multi-factor allocations[M/OL]//JURCZENKO E. Machine Learning for Asset Management: New Developments and Financial Applications. Wiley, 2020: 329-368. DOI: 10.1002/9781119751182.ch9.
 - [35] CHO Y, SONG J W. Hierarchical risk parity using security selection based on peripheral assets of correlation-based minimum spanning trees[J/OL]. Finance Research Letters, 2023, 53: 103608. DOI: 10.1016/j.frl.2022.103608.
 - [36] 林晓明, 黄晓彬, 张泽. 风险平价之标的优选与层次化风险估计[R]. 华泰证券研究所, 2021.
 - [37] 陈果, 王程畅. 大类资产配置方法在中国市场实践: 大类资产配置策略系列[R]. 中信建投证券股份有限公司, 2025.

- [38] 张继强, 陶冶, 何颖雯. 低利率环境下的绝对收益路径: 资产配置方法论系列[R]. 华泰证券研究所, 2025.
- [39] LEDOIT O, WOLF M. A well-conditioned estimator for large-dimensional covariance matrices[J]. *Journal of Multivariate Analysis*, 2004, 88(2): 365-411.
- [40] LEDOIT O, WOLF M. Quadratic shrinkage for large covariance matrices[J/OL]. *Bernoulli*, 2022, 28(3): 1519-1547. DOI: 10.3150/20-BEJ1315.
- [41] WHITE H. A reality check for data snooping[J/OL]. *Econometrica*, 2000, 68(5): 1097-1126. DOI: 10.1111/1468-0262.00152.
- [42] HARVEY C R, LIU Y. Backtesting[J/OL]. *The Journal of Portfolio Management*, 2015, 42(1): 13-28. DOI: 10.3905/jpm.2015.42.1.013.
- [43] BAILEY D H, BORWEIN J M, LÓPEZ DE PRADO M, et al. The probability of backtest overfitting[J]. *Journal of Computational Finance*, 2014, 20(4): 39-69.
- [44] BAILEY D H, LÓPEZ DE PRADO M. The deflated sharpe ratio: correcting for selection bias, backtest overfitting, and non-normality[J]. *The Journal of Portfolio Management*, 2014, 40(5): 94-107.
- [45] 华泰证券研究所. 从资产配置走向因子配置: 中国版全天候增强策略[R]. 华泰证券研究所, 2025.
- [46] MILLEA A, EDALAT A. Using deep reinforcement learning with hierarchical risk parity for portfolio optimization[J/OL]. *International Journal of Financial Studies*, 2023, 11(1): 10. DOI: 10.3390/ijfs11010010.
- [47] YANG S. Deep reinforcement learning for portfolio management[J/OL]. *Knowledge-Based Systems*, 2023, 278: 110905. DOI: 10.1016/j.knosys.2023.110905.
- [48] AGAL S, RAULJI K, ODEDRA N D. A machine learning approach to risk based asset allocation in portfolio optimization[J/OL]. *Scientific Reports*, 2025, 15: 42263. DOI: 10.1038/s41598-025-26337-x.